

Edición 2020

NOTAS DE ÁLGEBRA LINEAL NUMÉRICA

Damián Fernández

Índice general

Índice general	2
1 Introducción	5
1.1. Notación	5
1.1.1. Precaución al momento de derivar	6
1.2. Sistemas lineales	7
1.3. Matrices por bloques	8
1.4. Aritmética de punto flotante de doble precisión	9
2 Métodos directos	12
2.1. Sistema triangular	12
2.1.1. Matriz triangular inferior	12
2.1.2. Matriz triangular superior	15
2.2. Sistema definido positivo	18
2.2.1. Descomposición de Cholesky	20
2.3. Sistema indefinido	25
2.3.1. Eliminación Gaussiana	27
2.3.2. Descomposición LU	29
2.3.3. Eliminación Gaussiana con pivoteo parcial	31
2.3.4. Descomposición LU con permutaciones	33
2.4. Ejercicios	35
3 Sensibilidad de sistemas lineales	38
3.1. Normas	38
3.1.1. Normas vectoriales	39
3.1.2. Normas matriciales	43
3.2. Errores	46
3.3. Ejercicios	49
4 Residuos mínimos	51
4.1. Cuadrados mínimos	52
4.1.1. Rotaciones de Givens	52
4.1.2. Reflexiones de Householder	56
4.1.3. Ortonormalización de Gram-Schmidt	60

4.1.4.	QR con pivoteo de columnas	62
4.1.5.	Ecuación normal	65
4.2.	Minimización lineal	66
4.3.	Ejercicios	68
5	Descomposición en valores singulares	70
5.1.	Propiedades de la SVD	71
5.2.	Cuadrados mínimos y pseudoinversa	76
5.3.	Calculando la SVD	78
5.4.	Ejercicios	78
6	Autovalores y autovectores	79
6.1.	Método de Jacobi	79
6.2.	Métodos de las potencias	83
6.2.1.	Método de las potencias inversas	88
6.3.	Método de iteraciones QR	89
6.4.	Ejercicios	95
7	Métodos iterativos	97
7.1.	Métodos de separación	97
7.2.	Métodos de proyección	102
7.2.1.	Sistema definido positivo	103
7.2.2.	Sistema indefinido	115
7.3.	Ejercicios	122
8	Ecuaciones no lineales y minimización	124
8.1.	Ecuaciones no lineales	124
8.1.1.	Método de Newton	125
8.1.2.	Método de Newton truncado	128
8.1.3.	Métodos cuasi-Newton	130
8.1.4.	Cuadrados mínimos no lineales	132
8.2.	Minimización no lineal	134
8.2.1.	Condiciones de optimalidad	134
8.2.2.	Método de búsqueda lineal	136
8.3.	Ejercicios	144
	Bibliografía	145

Prólogo

Ya no sé si es hoy, ayer o mañana...

Estas notas fueron creadas para dar el curso Análisis Numérico II de la Licenciatura en Matemática en la Facultad de Matemática, Astronomía, Física y Computación de la Universidad Nacional de Córdoba.

A lo largo de los años, se han utilizado distintos lenguajes de programación para implementar los algoritmos de estas notas. Por ese motivo, en esta versión se utilizan pseudocódigos independientes de cualquier lenguaje de programación específico.

La situación sanitaria del año 2020 nos ha llevado a dar clases en modalidad virtual, haciendo que pueda darle un buen uso a la mayor parte de estas notas, que fueron escritas en $\text{\LaTeX}$ hace casi una década. Los últimos dos capítulos estaban aún en papel y relegados por otros proyectos. Este año los alumnos podrán contar con el manuscrito completo con un diseño optimizado para su lectura en dispositivos portátiles.

–Damián Fernández, *diciembre de 2020.*

Capítulo 1

Introducción

1.1. Notación

Se usará $\mathbb{R}$, $\mathbb{Z}$ y $\mathbb{N}$ para denotar el conjunto de números reales, enteros y naturales, respectivamente.

Sucesiones de escalares se denotarán con subíndices y se omitirán los límites del contador si son claros por el contexto. Por ejemplo, usaremos $\{\alpha_k\}$.

Se usará $\mathbb{R}^n$ para denotar el espacio de vectores reales n -dimensionales. Los elementos de $\mathbb{R}^n$ serán denotados con letras minúsculas y dado $x \in \mathbb{R}^n$ se denotará por x_i su i -ésima componente. Todo $x \in \mathbb{R}^n$ será considerado un vector columna, o sea, $x \in \mathbb{R}^{n \times 1}$. Por lo tanto, si $x \in \mathbb{R}^n$ entonces

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}, \quad x_i \in \mathbb{R}.$$

Se denotará por x^T al vector fila que es transpuesto de x . Con esto, el producto interno Euclídeo $\langle \cdot, \cdot \rangle : \mathbb{R}^n \times \mathbb{R}^n \mapsto \mathbb{R}$ cumple que $\langle x, y \rangle = x^T y$. Para ser coherente con lo que se verá en la Sección 3.1, la norma Euclídea se denotará por

$$\|x\|_2 = \sqrt{x^T x} = \left(\sum_{i=1}^n x_i^2 \right)^{1/2}.$$

Sucesiones de vectores se denotarán con supraíndices, o sea, $\{x^k\}$. Dados $x^1, \dots, x^l$ vectores en $\mathbb{R}^n$, se denotará por $\text{span}\{x^1, \dots, x^l\}$ al subespacio generado por esos vectores.

Se usará $\mathbb{R}^{m \times n}$ para denotar el espacio de matrices reales de m filas y n columnas. Las matrices serán denotadas con letras mayúsculas (A , B , C , etc.) y se usará su respectiva minúscula con subíndice ij para denotar el elemento (i, j) de la misma (a_{ij} , b_{ij} , c_{ij} , etc.). Por lo tanto, si $A \in \mathbb{R}^{m \times n}$ entonces

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}, \quad a_{ij} \in \mathbb{R}.$$

Se usará I para denotar la matriz identidad, la dimensión de la misma no se detallará pues siempre quedará establecida por el contexto. Se usará 0 (cero) para denotar matrices de ceros

de dimensiones acordes al contexto en el que se usa. Al usar matrices por bloques, los bloques vacíos corresponden a aquellos bloques de ceros. Por ejemplo,

$$A = \begin{bmatrix} B_{11} & I & & \\ I & B_{22} & & \\ & & & \\ & & & B_{33} \end{bmatrix}.$$

Dada una matriz $A \in \mathbb{R}^{m \times n}$ y conjuntos de índices $\mathcal{I} \subset \{1, \dots, m\}$, $\mathcal{J} \subset \{1, \dots, n\}$ se denotará por $A_{\mathcal{I}\mathcal{J}}$ a la submatriz de filas indexadas por $\mathcal{I} = \{i_1, \dots, i_r\}$ y columnas indexadas por $\mathcal{J} = \{j_1, \dots, j_s\}$, i.e.,

$$A_{\mathcal{I}\mathcal{J}} = \begin{bmatrix} a_{i_1 j_1} & a_{i_1 j_2} & \cdots & a_{i_1 j_s} \\ a_{i_2 j_1} & a_{i_2 j_2} & \cdots & a_{i_2 j_s} \\ \vdots & \vdots & & \vdots \\ a_{i_r j_1} & a_{i_r j_2} & \cdots & a_{i_r j_s} \end{bmatrix}.$$

En particular se denotará por $A_{\bullet\mathcal{J}}$ las columnas de A indexadas por $\mathcal{J}$ y por $A_{\mathcal{I}\bullet}$ las filas de A indexadas por $\mathcal{I}$. Se denotará por A^T la transpuesta de A . El espacio imagen y el núcleo de $A \in \mathbb{R}^{m \times n}$ se denotarán por $\text{Im}(A)$ y $\text{Ker}(A)$, respectivamente, i.e.,

$$\begin{aligned} \text{Im}(A) &= \{y \in \mathbb{R}^m \mid \exists x \in \mathbb{R}^n \text{ con } y = Ax\}, \\ \text{Ker}(A) &= \{x \in \mathbb{R}^n \mid Ax = 0\}. \end{aligned}$$

Sucesiones de matrices se denotarán con subíndices, o sea, $\{M_k\}$.

1.1.1. Precaución al momento de derivar

La imposición de identificar todo vector como vector columna (i.e., $\mathbb{R}^n \equiv \mathbb{R}^{n \times 1}$) nos permitirá hacer compatible la notación estándar del *Cálculo en varias variables* con la notación estándar del *Álgebra Lineal Numérica*. Esta simple identificación impacta al momento de expresar el gradiente de una función de varias variables. La derivada de una función diferenciable $f : \mathbb{R}^n \mapsto \mathbb{R}$ en un punto x es una transformación lineal $f'(x) : \mathbb{R}^n \mapsto \mathbb{R}$ tal que

$$f'(x)d = \sum_{i=1}^n \frac{\partial f}{\partial x_i}(x)d_i = \langle \nabla f(x), d \rangle,$$

donde el gradiente $\nabla f(x)$ es el representante de $f'(x)$ para el producto interno $\langle \cdot, \cdot \rangle$. En nuestro caso,

$$\nabla f(x) = \begin{bmatrix} \frac{\partial f}{\partial x_1}(x) \\ \vdots \\ \frac{\partial f}{\partial x_n}(x) \end{bmatrix} = f'(x)^T.$$

Ejemplo 1.1 Considere $A \in \mathbb{R}^{m \times n}$, $x \in \mathbb{R}^n$, $b \in \mathbb{R}^m$ y $f : \mathbb{R}^n \mapsto \mathbb{R}$ tal que

$$f(x) = \frac{1}{2} \|Ax - b\|_2^2.$$

Si se desea encontrar $\bar{x}$ solución de minimizar $f(x)$ para todo $x \in \mathbb{R}^n$, es necesario (y suficiente según Proposición 4.9) que $f'(\bar{x}) = 0$.

Para calcular esta derivada se escribe $f = h(g(x))$ con $h : \mathbb{R}^m \mapsto \mathbb{R}$ t.q. $h(y) = \frac{1}{2}\|y\|_2^2$ y $g : \mathbb{R}^n \mapsto \mathbb{R}^m$ t.q. $g(x) = Ax - b$. Usando la regla de la cadena estándar del Cálculo en varias variables se obtiene que

$$f'(x) = h'(g(x))g'(x) = g(x)^T A = (Ax - b)^T A,$$

pues $h'(y) = y^T \in \mathbb{R}^{1 \times m}$ y $g'(x) = A \in \mathbb{R}^{m \times n}$. Por lo tanto, para hallar $\bar{x}$ debemos resolver el sistema lineal

$$0 = f'(\bar{x}) = (\bar{x}^T A^T - b^T)A = \bar{x}^T \tilde{A}^T - \tilde{b}^T,$$

donde $\tilde{A} = A^T A$ y $\tilde{b} = A^T b$. Note que este es un sistema lineal de vectores fila y el producto matriz vector se realiza a izquierda.

La identificación de $\mathbb{R}^n$ con los vectores columna, nos permite obtener

$$0 = \nabla f(\bar{x}) = A^T(Ax - b) = \tilde{A}\bar{x} - \tilde{b}.$$

De esta forma se obtendrán sistemas lineales en el formato estándar de Álgebra Lineal.

En general, si $f = h(g(x))$ con $h : \mathbb{R}^m \mapsto \mathbb{R}$ y $g : \mathbb{R}^n \mapsto \mathbb{R}^m$ la regla de la cadena estándar es

$$f'(x) = h'(g(x))g'(x),$$

mientras que para el gradiente se obtiene

$$\nabla f(x) = g'(x)^T \nabla h(g(x)).$$

1.2. Sistemas lineales

A lo largo del curso se usarán de forma indistinta las equivalencias dadas en el siguiente enunciado.

Teorema 1.2 Sea $A \in \mathbb{R}^{n \times n}$. Entonces las siguientes afirmaciones son equivalentes:

1. existe A^{-1} ,
2. no existe $y \neq 0$ tal que $Ay = 0$,
3. las columnas de A son linealmente independientes,
4. las filas de A son linealmente independientes,
5. $\det(A) \neq 0$,
6. dado $b \in \mathbb{R}^n$ existe un único $x \in \mathbb{R}^n$ tal que $Ax = b$.

La demostración de este teorema puede encontrarse en libros de álgebra lineal.

El sistema de ecuaciones $Ax = b$ es llamado lineal, pues $x \mapsto Ax$ es una función lineal. El sistema $Ax = 0$ se conoce como sistema lineal homogéneo, de aquí que b recibe el nombre de término no homogéneo.

El objetivo principal de este texto es dar a conocer técnicas numéricas para resolver sistemas lineales. Por lo tanto, dada $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$, el problema de mayor interés es

$$\text{hallar } x \in \mathbb{R}^n \text{ tal que } Ax = b.$$

1.3. Matrices por bloques

Sean $A \in \mathbb{R}^{n \times m}$ y $B \in \mathbb{R}^{m \times p}$ particionadas de la siguiente forma

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}, \quad A_{ij} \in \mathbb{R}^{n_i \times m_j},$$

$$B = \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix}, \quad B_{ij} \in \mathbb{R}^{m_i \times p_j},$$

donde $n_1 + n_2 = n$, $m_1 + m_2 = m$ y $p_1 + p_2 = p$. Entonces

$$C = AB = \begin{bmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{bmatrix},$$

donde $C_{ij} = A_{i1}B_{1j} + A_{i2}B_{2j} \in \mathbb{R}^{n_i \times p_j}$.

Ejemplo 1.3 Sean

$$A = \left[\begin{array}{c|cc} 1 & 3 & 2 \\ 2 & 1 & 1 \\ \hline -1 & 0 & 1 \end{array} \right], \quad B = \left[\begin{array}{c|cc} 1 & 0 & 1 \\ 2 & 1 & 1 \\ \hline -1 & 2 & 0 \end{array} \right].$$

Entonces

$$\begin{aligned} C &= \left[\begin{array}{c|c} \left[\begin{array}{c} 1 \\ 2 \end{array} \right] 1 + \left[\begin{array}{cc} 3 & 2 \\ 1 & 1 \end{array} \right] \left[\begin{array}{c} 2 \\ -1 \end{array} \right] & \left[\begin{array}{c} 1 \\ 2 \end{array} \right] [0 \ 1] + \left[\begin{array}{cc} 3 & 2 \\ 1 & 1 \end{array} \right] \left[\begin{array}{cc} 1 & 1 \\ 2 & 0 \end{array} \right] \\ \hline (-1)1 + [0 \ 1] \left[\begin{array}{c} 2 \\ -1 \end{array} \right] & (-1)[0 \ 1] + [0 \ 1] \left[\begin{array}{cc} 1 & 1 \\ 2 & 0 \end{array} \right] \end{array} \right] \\ &= \left[\begin{array}{c|c} \left[\begin{array}{c} 1 \\ 2 \end{array} \right] + \left[\begin{array}{c} 4 \\ 1 \end{array} \right] & \left[\begin{array}{cc} 0 & 1 \\ 0 & 2 \end{array} \right] + \left[\begin{array}{cc} 7 & 3 \\ 3 & 1 \end{array} \right] \\ \hline -1 + (-1) & [0 \ -1] + [2 \ 0] \end{array} \right] = \left[\begin{array}{c|cc} 5 & 7 & 4 \\ 3 & 3 & 3 \\ \hline -2 & 2 & -1 \end{array} \right] \end{aligned}$$

Tomando lo anterior, la demostración del siguiente resultado puede ser realizada por el lector.

Teorema 1.4 Sean $A \in \mathbb{R}^{n \times m}$ y $B \in \mathbb{R}^{m \times p}$ tales que

$$A = \begin{bmatrix} A_{11} & \dots & A_{1s} \\ \vdots & \ddots & \vdots \\ A_{r1} & \dots & A_{rs} \end{bmatrix}, \quad B = \begin{bmatrix} B_{11} & \dots & B_{1t} \\ \vdots & \ddots & \vdots \\ B_{s1} & \dots & B_{st} \end{bmatrix},$$

con $A_{ij} \in \mathbb{R}^{n_i \times m_j}$ y $B_{ij} \in \mathbb{R}^{m_i \times p_j}$, donde $n_1 + \dots + n_r = n$, $m_1 + \dots + m_s = m$ y $p_1 + \dots + p_t = p$. Entonces $C = AB$ si y solo si

$$C_{ij} \in \mathbb{R}^{n_i \times p_j} \quad \text{con} \quad C_{ij} = \sum_{k=1}^s A_{ik} B_{kj}, \quad i = 1, \dots, r; \quad j = 1, \dots, t.$$

Ejemplo 1.5 Sea $A \in \mathbb{R}^{n \times m}$ y $x \in \mathbb{R}^m$. Si defino $a^j = A_{\bullet j}$ la j -ésima columna de A , entonces

$$Ax = [a^1 \ a^2 \ \dots \ a^m] \begin{bmatrix} \frac{x_1}{x_2} \\ \vdots \\ \frac{x_m}{x_m} \end{bmatrix} = \sum_{i=1}^m x_i a^i.$$

Obteniendo fácilmente que la imagen de A es un subespacio formado por la combinación lineal de las columnas de A .

Ejemplo 1.6 Sea $A \in \mathbb{R}^{n \times m}$ y $B \in \mathbb{R}^{m \times p}$. Si $C = AB$, $b^j = B_{\bullet, j}$ y $c^j = C_{\bullet, j}$, entonces

$$C = AB = A[b^1 \ b^2 \ \dots \ b^p] = [Ab^1 \ Ab^2 \ \dots \ Ab^p].$$

O sea, $c^j = Ab^j$.

Por lo tanto, si $A \in \mathbb{R}^{n \times n}$ encontrar X tal que $AX = I$ es equivalente a resolver n sistemas lineales de la forma

$$Ax^j = e^j, \quad j = 1, \dots, n,$$

donde x^j son las columnas de X y e^j el j -ésimo vector canónico.

1.4. Aritmética de punto flotante de doble precisión

Ya que los procedimientos que se verán estarán enfocados a su implementación computacional, recordaremos brevemente algunos conceptos básicos de la aritmética finita de los computadores. Para no ahondar en detalles, veremos solamente la aritmética finita más usada en la actualidad para computación científica.

En la aritmética de punto flotante de doble precisión, cada número se representa utilizando 64 bits

[illegible]

partido en 3 binarios:

- el signo s de 1 dígito,
- el exponente c , un entero con representación binaria de 11 dígitos excluyendo 00000000000 y 11111111111, y
- la mantisa f , real menor a uno con representación fraccionaria binaria de 52 dígitos.

Como el exponente c cumple

$$0 < c < \sum_{i=0}^{10} 2^i = 2^{11} - 1 = 2047,$$

para poder representar números con exponente negativo, a c se le resta 1023, obteniendo exponentes enteros en el intervalo $(-1023, 1024)$. Además, para tener siempre una mantisa

con parte entera igual a uno, sumaremos 1 a f . Con esto, los números no nulos representables en esta aritmética son

$$x = (-1)^s 2^{c-1023} (1 + f).$$

Se define al cero tomando $c = 0$ y $f = 0$, obteniendo dos representaciones: cuando $s = 0$ y cuando $s = 1$.

Ejemplo 1.7 Escribamos el número real cuya representación en 64 bits es

[illegible]

Por un lado tenemos el exponente

$$\begin{aligned} c &= 1 \cdot 2^{10} + 0 \cdot 2^9 + 0 \cdot 2^8 + 0 \cdot 2^7 + 0 \cdot 2^6 + 0 \cdot 2^5 \\ &\quad + 0 \cdot 2^4 + 0 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 1 \cdot 2^0 \\ &= 1024 + 2 + 1 = 1027. \end{aligned}$$

Por otro, la mantisa

$$\begin{aligned} f &= 1 \cdot \left(\frac{1}{2}\right)^1 + 0 \cdot \left(\frac{1}{2}\right)^2 + 1 \cdot \left(\frac{1}{2}\right)^3 + 1 \cdot \left(\frac{1}{2}\right)^4 + 1 \cdot \left(\frac{1}{2}\right)^5 + 0 \cdot \left(\frac{1}{2}\right)^6 \\ &\quad + 0 \cdot \left(\frac{1}{2}\right)^7 + 1 \cdot \left(\frac{1}{2}\right)^8 + \dots + 1 \cdot \left(\frac{1}{2}\right)^{12} + \dots + 0 \cdot \left(\frac{1}{2}\right)^{52} \\ &= \frac{1}{2} + \frac{1}{8} + \frac{1}{16} + \frac{1}{32} + \frac{1}{256} + \frac{1}{4096} \end{aligned}$$

De esto obtenemos que el número real es

$$x = \left(1 + \frac{1}{2} + \frac{1}{8} + \frac{1}{16} + \frac{1}{32} + \frac{1}{256} + \frac{1}{4096}\right) 2^4 = 27.56640625$$

Con esto, los elementos en esta aritmética pueden representarse gráficamente como una nube de puntos sobre la recta real. Para tener una mejor descripción de esta nube, destacamos algunas propiedades:

- el número positivo más pequeño se obtiene tomando $s = 0, c = 1, f = 0$ y es

$$2^{-1022} \approx 2.2251 \times 10^{-308},$$

- el número positivo más grande se obtiene tomando $s = 0, c = 2046, f = 1 - 2^{-52}$ y es

$$2^{1023}(1 + 1 - 2^{-52}) \approx 1.7977 \times 10^{308}.$$

- es simétrica en relación al cero.

Cuando el resultado de un cálculo es un número de magnitud menor a la representable, se está en presencia de un *underflow*, y cuando el resultado es un número de magnitud mayor a la representable se está en presencia de un *overflow*.

La separación de los puntos en esta aritmética dependen de un valor conocido como *épsilon de la máquina*, que suele denotarse con ϵ . Formalmente, ϵ es el número positivo más pequeño de la aritmética que satisface

$$1 + \epsilon > 1.$$

De esto se deduce que no existe ningún representante de la aritmética entre 1 y $1 + \epsilon$. En esta aritmética se sabe que $\epsilon = 2^{-52} \approx 2.2204 \times 10^{-16}$. En general se puede ver que si x es un número no nulo en esta aritmética, el siguiente punto en la aritmética estará a una distancia $|x|\epsilon$.

Toda operación se realiza solamente con elementos de la aritmética, por lo tanto a cada punto x en la recta real se le asigna un representante en la aritmética, que suele denotarse por $\text{fl}(x)$. La regla más utilizada para esta asignación es la del redondeo y consiste en definir $\text{fl}(x)$ como el punto en la aritmética más cercano a x . En el caso de existir dos posibilidades (cuando x es justo el punto medio entre dos representantes) se toma el representante de mayor magnitud.

Capítulo 2

Métodos directos

Estos procedimientos algorítmicos son capaces de resolver un sistema lineal luego de una cantidad finita de operaciones aritméticas. Las estrategias dependen de la estructura de la matriz del sistema lineal a resolver, y en estas notas las veremos ordenadas partiendo de las estructuras más simples.

2.1. Sistema triangular

Definición 2.1 Se dirá que $A \in \mathbb{R}^{n \times n}$ es triangular inferior (superior) si $a_{ij} = 0$ para $i < j$ ($i > j$).

Dada $A \in \mathbb{R}^{n \times n}$ triangular superior o inferior y $b \in \mathbb{R}^n$, se desea

$$\text{hallar } x \in \mathbb{R}^n \text{ tal que } Ax = b.$$

Proposición 2.2 Si $A \in \mathbb{R}^{n \times n}$ es triangular, el sistema $Ax = b$ tiene una única solución si y solo si $a_{ii} \neq 0$, $i = 1, \dots, n$.

Demostración. Como A es triangular, entonces $\det(A) = a_{11} \dots a_{nn}$. Por lo tanto la afirmación vale por el Teorema 1.2. ■

2.1.1. Matriz triangular inferior

Versión por filas

Considere una partición de A por filas separando los elementos diagonales:

$$A = \left[\begin{array}{c|c|c|c|c} \boxed{a_{11}} & & & & \\ \boxed{a_{21}} & \boxed{a_{22}} & & & \\ \boxed{a_{31}} & \boxed{a_{32}} & \boxed{a_{33}} & & \\ \vdots & \vdots & & \ddots & \\ \boxed{a_{n1}} & \boxed{a_{n2}} & \dots & \boxed{a_{n,n-1}} & \boxed{a_{nn}} \end{array} \right] \left[\begin{array}{c} x_1 \\ x_2 \\ \vdots \\ x_n \end{array} \right] = \left[\begin{array}{c} \boxed{b_1} \\ \boxed{b_2} \\ \vdots \\ \boxed{b_n} \end{array} \right]$$

entonces la ecuación correspondiente a la fila $i = 1$ de $Ax = b$ es $a_{11}x_1 = b_1$, por lo tanto

$$x_1 = \frac{b_1}{a_{11}}.$$

De la fila $i = 2$ se obtiene que $a_{21}x_1 + a_{22}x_2 = b_2$. Como x_1 es conocido, se obtiene que

$$x_2 = \frac{1}{a_{22}} (b_2 - a_{21}x_1).$$

De la fila $i = 3$ se obtiene que $[a_{31} \ a_{32}] \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + a_{33}x_3 = b_3$ con x_1, x_2 conocidos, entonces

$$x_3 = \frac{1}{a_{33}} \left(b_3 - [a_{31} \ a_{32}] \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \right).$$

Continuando de este modo, se obtiene que en la i -ésima fila

$$[a_{i1} \ \dots \ a_{i,i-1}] \begin{bmatrix} x_1 \\ \vdots \\ x_{i-1} \end{bmatrix} + a_{ii}x_i = b_i,$$

con $x_1, \dots, x_{i-1}$ conocidos. Pudiendo así definir

$$x_i = \frac{1}{a_{ii}} \left(b_i - [a_{i1} \ \dots \ a_{i,i-1}] \begin{bmatrix} x_1 \\ \vdots \\ x_{i-1} \end{bmatrix} \right).$$

Este proceso repetitivo es conocido como sustitución hacia adelante por filas. Podemos describirlo algorítmicamente de esta manera:

Algoritmo 1 (Sustitución hacia adelante por filas)

Entradas: $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$. *Salida:* $x \in \mathbb{R}^n$ t.q. $Ax = b$.

Paso 0: Definir $x_1 = b_1/A_{11}$, $i = 1$ e ir al paso 2.

Paso 1: Definir $\mathcal{J} = \{1, \dots, i-1\}$ y

$$x_i = (b_i - A_{i\mathcal{J}}x_{\mathcal{J}}) / A_{ii}$$

Paso 2: Si $i < n$, hacer $i \leftarrow i + 1$ e ir al paso 1.

Sino, retornar x .

Una implementación correcta de este algoritmo requiere un control *a priori* de la no nulidad de las entradas diagonales. Note que el símbolo “ $\leftarrow$ ” fue usado para redefinir una variable evitando la confusión que puede generar el uso de la igualdad algebraica ($=$).

Una forma de cuantificar el costo computacional al ejecutar un algoritmo es mediante la noción del **flop**. Un **flop** es una operación de punto flotante. Note que en cada ejecución del ciclo del Algoritmo 1, se debe realizar el producto de dos vectores de dimensión $i-1$ (el cual requiere $i-1$ productos con $i-2$ sumas), una diferencia y un cociente. Por lo tanto en cada ejecución del ciclo se necesitan realizar $2(i-1) + 1$ flops. Tomando en cuenta el cociente fuera del ciclo, se necesitan

$$1 + \sum_{i=2}^n (2(i-1) + 1) = 1 + 2 \frac{(n-1)n}{2} + n - 1 = n^2$$

flops, donde para la primer igualdad se usó que $\sum_{i=1}^k i = k(k+1)/2$. Por lo tanto, se obtiene que el Algoritmo 1 tiene un costo operacional de $O(n^2)$ flops.

Versión por columnas

Considere ahora una partición de A por separando el primer elemento diagonal para resolver

$$\left[\begin{array}{c|cccc} a_{11} & & & & \\ a_{21} & a_{22} & & & \\ a_{31} & a_{32} & a_{33} & & \\ \vdots & \vdots & \vdots & \ddots & \\ a_{n1} & a_{n2} & a_{n3} & \cdots & a_{nn} \end{array} \right] \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \\ \vdots \\ b_n \end{bmatrix}.$$

Separando la columna $j = 1$ en la ecuación $Ax = b$, se obtiene que

$$a_{11}x_1 = b_1, \quad \begin{bmatrix} a_{21} \\ \vdots \\ a_{n1} \end{bmatrix} x_1 + \begin{bmatrix} a_{22} & & \\ \vdots & \ddots & \\ a_{n2} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_2 \\ \vdots \\ b_n \end{bmatrix}.$$

Ahora se puede definir x_1 y redefinir $b_2, \dots, b_n$ de esta forma

$$x_1 = b_1/a_{11}, \quad \begin{bmatrix} b_2 \\ \vdots \\ b_n \end{bmatrix} \leftarrow \begin{bmatrix} b_2 \\ \vdots \\ b_n \end{bmatrix} - \begin{bmatrix} a_{21} \\ \vdots \\ a_{n1} \end{bmatrix} x_1,$$

donde el símbolo " $\leftarrow$ " fue usado para redefinir el vector. De esta forma, se obtiene un problema con la misma estructura del original pero con una dimensión menos:

$$\left[\begin{array}{c|ccc} a_{22} & & & \\ \vdots & \ddots & & \\ a_{n2} & \cdots & a_{nn} \end{array} \right] \begin{bmatrix} x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_2 \\ \vdots \\ b_n \end{bmatrix}.$$

Procediendo similarmente, para la j -ésima columna se puede definir x_j y redefinir $b_{j+1}, \dots, b_n$,

$$x_j = b_j/a_{jj}, \quad \begin{bmatrix} b_{j+1} \\ \vdots \\ b_n \end{bmatrix} \leftarrow \begin{bmatrix} b_{j+1} \\ \vdots \\ b_n \end{bmatrix} - \begin{bmatrix} a_{j+1,j} \\ \vdots \\ a_{nj} \end{bmatrix} x_j.$$

Siguiendo hasta $j = n - 1$, se obtiene

$$x_{n-1} = b_{n-1}/a_{n-1,n-1}, \quad b_n \leftarrow b_n - a_{n,n-1}x_{n-1}.$$

Quedando solamente la resolución de $a_{nn}x_n = b_n$, que es simplemente

$$x_n = b_n/a_{nn}.$$

El proceso repetitivo descrito es conocido como sustitución hacia adelante por columnas. Su pseudocódigo es el siguiente:

Algoritmo 2 (Sustitución hacia adelante por columnas)

Entradas: $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$. *Salida:* $x \in \mathbb{R}^n$ t.q. $Ax = b$.

Paso 0: Definir $j = 1$.

Paso 1: Definir $x_j = b_j / A_{jj}$.

Paso 2: Si $j < n$, definir $\mathcal{I} = \{j + 1, \dots, n\}$, hacer

$$b_{\mathcal{I}} \leftarrow b_{\mathcal{I}} - A_{\mathcal{I}j} x_j,$$

hacer $j \leftarrow j + 1$ e ir al paso 1.

Sino, retornar x .

Una implementación correcta de este algoritmo requiere un control *a priori* de la no nulidad de las entradas diagonales.

Para el conteo operacional de este algoritmo, note que dentro del ciclo se tiene un cociente, la diferencia de dos vectores de dimensión $n - j$ y el producto de un escalar por un vector de dimensión $n - j$. Por lo tanto, se necesitan $2(n - j) + 1$ flops en cada ejecución del ciclo. Tomando el cociente fuera del ciclo, el algoritmo necesita de una cantidad de flops igual a

$$\sum_{j=1}^{n-1} (2(n - j) + 1) + 1.$$

Sumando, se obtiene que el Algoritmo 2 tiene un costo operacional de $O(n^2)$ flops.

2.1.2. Matriz triangular superior

Versión por filas

Considere una partición de A por filas y separando sus elementos diagonales, entonces se deben hallar $x_1, \dots, x_n$ tales que

$$\left[\begin{array}{cccccc} a_{11} & a_{12} & \dots & a_{1,n-1} & a_{1n} & \\ & \ddots & & \vdots & \vdots & \\ & & a_{n-2,n-2} & a_{n-2,n-1} & a_{n-2,n} & \\ & & & a_{n-1,n-1} & a_{n-1,n} & \\ & & & & a_{nn} & \end{array} \right] \begin{bmatrix} x_1 \\ \vdots \\ x_{n-2} \\ x_{n-1} \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_{n-2} \\ b_{n-1} \\ b_n \end{bmatrix}.$$

De la ecuación correspondiente a la fila $i = n$ se obtiene que $a_{nn}x_n = b_n$ y por lo tanto

$$x_n = \frac{b_n}{a_{nn}}.$$

Para la fila $i = n - 1$ se tiene que $a_{n-1,n-1}x_{n-1} + a_{n-1,n}x_n = b_{n-1}$. Como x_n ya fue calculado en el paso anterior, se puede definir

$$x_{n-1} = \frac{1}{a_{n-1,n-1}} (b_{n-1} - a_{n-1,n}x_n).$$

Ahora, para $i = n - 2$ se obtiene que

$$a_{n-2,n-2}x_{n-2} + [a_{n-2,n-1} \ a_{n-2,n}] \begin{bmatrix} x_{n-1} \\ x_n \end{bmatrix} = b_{n-2},$$

donde x_{n-1} y x_n son conocidos. Por lo tanto se tiene que

$$x_{n-2} = \frac{1}{a_{n-2,n-2}} \left(b_{n-2} - [a_{n-2,n-1} \ a_{n-2,n}] \begin{bmatrix} x_{n-1} \\ x_n \end{bmatrix} \right).$$

Continuando de esta manera, se obtiene que para la i -ésima fila con $i \leq n - 1$ vale que

$$a_{ii}x_i + [a_{i,i+1} \ \dots \ a_{in}] \begin{bmatrix} x_{i+1} \\ \vdots \\ x_n \end{bmatrix} = b_i,$$

con $x_{i+1}, \dots, x_n$ conocidos. Pudiendo así definir

$$x_i = \frac{1}{a_{ii}} \left(b_i - [a_{i,i+1} \ \dots \ a_{in}] \begin{bmatrix} x_{i+1} \\ \vdots \\ x_n \end{bmatrix} \right).$$

El procedimiento descrito es conocido como sustitución hacia atrás por filas y su pseudo-código es el puede escribirse de esta manera:

Algoritmo 3 (Sustitución hacia atrás por filas)

Entradas: $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$. *Salida:* $x \in \mathbb{R}^n$ t.q. $Ax = b$.

Paso 0: Definir $x_n = b_n/A_{nn}$, $i = n$ e ir al paso 2.

Paso 1: Definir $\mathcal{J} = \{i + 1, \dots, n\}$ y

$$x_i = (b_i - A_{i\mathcal{J}}x_{\mathcal{J}}) / A_{ii}.$$

Paso 2: Si $i > 1$, hacer $i \leftarrow i - 1$ e ir al paso 1.

Sino, retornar x .

Recuerde que su implementación correcta debería controlar previamente la no nulidad de las entradas diagonales. Note que realizamos un cociente (1 flop) antes del ciclo y dentro del ciclo se tiene un cociente (1 flop), una diferencia (1 flop) y un producto interno de dos vectores de dimensión $n - i$ ($2(n - i) - 1$ flops). Por lo tanto procedimiento deberá realizar una cantidad de flops igual a

$$1 + \sum_{i=1}^{n-1} (2(n - i) + 1) = n^2.$$

Concluimos que el Algoritmo 3 tiene un costo operacional de $O(n^2)$ flops.

Versión por columnas

Si consideramos una partición de A separando el último elemento diagonal. El sistema a resolver sería

$$\left[\begin{array}{cccc|c} a_{11} & \cdots & a_{1,n-2} & a_{1,n-1} & a_{1n} \\ & \ddots & \vdots & \vdots & \vdots \\ & & a_{n-2,n-2} & a_{n-2,n-1} & a_{n-2,n} \\ & & & a_{n-1,n-1} & a_{n-1,n} \\ \hline & & & & a_{nn} \end{array} \right] \begin{bmatrix} x_1 \\ \vdots \\ x_{n-2} \\ x_{n-1} \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_{n-2} \\ \frac{b_{n-1}}{x_n} \\ b_n \end{bmatrix}.$$

Separando la columna $j = n$, se obtiene que

$$\begin{bmatrix} a_{11} & \cdots & a_{1,n-1} \\ & \ddots & \vdots \\ & & a_{n-1,n-1} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_{n-1} \end{bmatrix} + \begin{bmatrix} a_{1n} \\ \vdots \\ a_{n-1,n} \end{bmatrix} x_n = \begin{bmatrix} b_1 \\ \vdots \\ b_{n-1} \end{bmatrix},$$

con $a_{nn}x_n = b_n$. Por lo tanto se puede definir x_n y redefinir $b_1, \dots, b_{n-1}$ de esta forma:

$$x_n = b_n/a_{nn}, \quad \begin{bmatrix} b_1 \\ \vdots \\ b_{n-1} \end{bmatrix} \leftarrow \begin{bmatrix} b_1 \\ \vdots \\ b_{n-1} \end{bmatrix} - \begin{bmatrix} a_{1n} \\ \vdots \\ a_{n-1,n} \end{bmatrix} x_n.$$

De esta forma se obtiene un sistema lineal con la misma estructura pero con una dimensión menos,

$$\left[\begin{array}{ccc|c} a_{11} & \cdots & a_{1,n-1} & \\ & \ddots & \vdots & \\ \hline & & a_{n-1,n-1} & \end{array} \right] \begin{bmatrix} x_1 \\ \vdots \\ x_{n-1} \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_{n-1} \end{bmatrix}.$$

Repetiendo lo anterior, se puede deducir que al separar la j -ésima columna se deberá definir

$$x_j = b_j/a_{jj}, \quad \begin{bmatrix} b_1 \\ \vdots \\ b_{j-1} \end{bmatrix} \leftarrow \begin{bmatrix} b_1 \\ \vdots \\ b_{j-1} \end{bmatrix} - \begin{bmatrix} a_{1j} \\ \vdots \\ a_{j-1,j} \end{bmatrix} x_j.$$

Note que este proceso puede repetirse hasta $j = 2$, donde se podrá definir

$$x_2 = b_2/a_{22}, \quad b_1 \leftarrow b_1 - a_{12}x_2.$$

Quedando solamente hallar x_1 tal que $a_{11}x_1 = b_1$, que es

$$x_1 = b_1/a_{11}.$$

El esquema repetitivo es conocido como sustitución hacia atrás por columnas. Su pseudo-código es el siguiente:

Algoritmo 4 (Sustitución hacia atrás por columnas)

Entradas: $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$. *Salida:* $x \in \mathbb{R}^n$ t.q. $Ax = b$.

Paso 0: Definir $j = n$.

Paso 1: Definir $x_j = b_j / A_{jj}$.

Paso 2: Si $j > 1$, definir $\mathcal{I} = \{1, \dots, j-1\}$, hacer

$$b_{\mathcal{I}} \leftarrow b_{\mathcal{I}} - A_{\mathcal{I}j}x_j,$$

hacer $j \leftarrow j-1$ e ir al paso 1.

Sino, retornar x .

La no nulidad de las entradas diagonales debe ser controlada previamente.

La cantidad de operaciones que realizamos dentro del ciclo son: una división (1 flop), la resta de dos vectores de dimensión $j-1$ ($j-1$ flops) y el producto de un escalar por un vector de dimensión $j-1$ ($j-1$ flops). Tomando en cuenta la división fuera del ciclo, se tiene un total de flops igual a

$$\sum_{j=2}^n (2(j-1) + 1) + 1.$$

Sumando, se obtiene que el Algoritmo 4 tiene un costo operacional de $O(n^2)$ flops.

2.2. Sistema definido positivo

Definición 2.3 Se dirá que $A \in \mathbb{R}^{n \times n}$ es definida positiva si $x^T Ax > 0$ para todo $x \in \mathbb{R}^n$, $x \neq 0$.

Usando la definición, es fácil ver que si $A \in \mathbb{R}^{n \times n}$ es definida positiva, entonces:

1. $a_{ii} > 0$, $i = 1, \dots, n$.
2. Las submatrices principales

$$A_k = \begin{bmatrix} a_{11} & \dots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{k1} & \dots & a_{kk} \end{bmatrix},$$

son definidas positivas para $k = 1, \dots, n$.

3. Si $X \in \mathbb{R}^{n \times m}$ tiene rango m (i.e., tiene columnas linealmente independientes) entonces $B = X^T AX$ es definida positiva.

Definición 2.4 Se dirá que $A \in \mathbb{R}^{n \times n}$ es simétrica si $A^T = A$ y antisimétrica si $A^T = -A$.

Dada una matriz arbitraria $A \in \mathbb{R}^{n \times n}$, uno siempre puede realizar la siguiente descomposición

$$A = \frac{1}{2}(A + A^T) + \frac{1}{2}(A - A^T) = A_S + A_N,$$

donde A_S es la parte simétrica de A , pues $A_S^T = A_S$, y A_N es la parte antisimétrica de A , pues $A_N^T = -A_N$.

Hay que resaltar que una matriz definida positiva no debe ser necesariamente simétrica. En la literatura, algunos autores asumen que las matrices definidas positivas deben ser simétricas, la justificación para hacer tal suposición viene del siguiente resultado.

Proposición 2.5 *A es definida positiva si y solo si su parte simétrica, A_S , es definida positiva.*

Demostración. Note que

$$\begin{aligned} x^T A_S x &= \frac{1}{2} x^T (A + A^T) x = \frac{1}{2} (x^T A x + x^T A^T x) \\ &= \frac{1}{2} (x^T A x + (x^T A^T x)^T) = \frac{1}{2} (x^T A x + x^T A x) = x^T A x, \end{aligned}$$

donde usamos que la transpuesta de un escalar es él mismo. De aquí, concluimos que $x^T A x > 0$ si y solo si $x^T A_S x > 0$. ■

Una caracterización importante de este tipo de matrices viene de comparar la forma cuadrática $x^T A x$ con $x^T x$.

Teorema 2.6 *$A \in \mathbb{R}^{n \times n}$ es definida positiva si y solo si existe $\alpha > 0$ tal que*

$$x^T A x \geq \alpha \|x\|_2^2,$$

para todo $x \in \mathbb{R}^n$.

Demostración. Si A es definida positiva entonces A_S es definida positiva. Como A_S es simétrica, entonces existen $\Lambda, V \in \mathbb{R}^{n \times n}$ tales que Λ es diagonal con entradas $\lambda_1, \dots, \lambda_n$, $V^T V = I$ y $V^T A_S V = \Lambda$. Defino $\alpha = \min_{1 \leq i \leq n} \lambda_i$. Entonces existe $z \in \mathbb{R}^n$ con $\|z\|_2 = 1$ tal que $A_S z = \alpha z$ y por lo tanto $\alpha = \alpha z^T z = z^T A_S z > 0$. Además, dado $x \in \mathbb{R}^n$ existe $y \in \mathbb{R}^n$ tal que $x = Vy$. Por lo tanto

$$\begin{aligned} x^T A x &= x^T A_S x = y^T V^T A_S V y = y^T \Lambda y = \sum_{i=1}^n \lambda_i y_i^2 \\ &\geq \alpha \sum_{i=1}^n y_i^2 = \alpha y^T y = \alpha x^T x. \end{aligned}$$

Claramente, si existe $\alpha > 0$ tal que $x^T A x \geq \alpha \|x\|_2^2$ para todo x , entonces A es definida positiva. ■

Note que si A es definida positiva y $Ay = 0$, entonces $y = 0$. Por lo tanto, usando el Teorema 1.2 se obtiene que si A es definida positiva entonces el sistema $Ax = b$ tiene solución.

2.2.1. Descomposición de Cholesky

Supongamos que dados $b \in \mathbb{R}^n$ y $A \in \mathbb{R}^{n \times n}$ simétrica y definida positiva, se desea

$$\text{hallar } x \in \mathbb{R}^n \text{ tal que } Ax = b.$$

Una estrategia para resolver este sistema lineal consiste en calcular $G \in \mathbb{R}^{n \times n}$ triangular superior tal que $A = G^T G$. De esta forma, si x es solución entonces

$$b = Ax = G^T Gx = G^T y \quad \text{con} \quad y = Gx.$$

Por lo tanto, para resolver $Ax = b$, resuelvo los sistemas triangulares $G^T y = b$ y $Gx = y$. Veamos que dicha descomposición es posible.

Teorema 2.7 *Sea $A \in \mathbb{R}^{n \times n}$ simétrica y definida positiva. Entonces existe una única $G \in \mathbb{R}^{n \times n}$ triangular superior con elementos diagonales positivos tal que $A = G^T G$.*

Demostración. *Existencia.* Se usará inducción en n . Si $n = 1$, entonces $A = a_{11} > 0$. Definiendo $G = g_{11} = \sqrt{a_{11}}$, vale que $A = G^T G$.

Suponga que la descomposición vale para matrices en $\mathbb{R}^{(n-1) \times (n-1)}$. Sea $A \in \mathbb{R}^{n \times n}$. Considere la siguiente expresión por bloques:

$$A = \begin{bmatrix} a_{11} & h^T \\ h & \hat{A} \end{bmatrix}, \quad a_{11} > 0, \quad h \in \mathbb{R}^{n-1}, \quad \hat{A} \in \mathbb{R}^{(n-1) \times (n-1)}.$$

Defina $g_{11} = \sqrt{a_{11}}$, $s = \frac{1}{g_{11}}h$ y $\tilde{A} = \hat{A} - ss^T$. Entonces

$$\begin{bmatrix} g_{11} & 0 \\ s & I \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & \tilde{A} \end{bmatrix} \begin{bmatrix} g_{11} & s^T \\ 0 & I \end{bmatrix} = \begin{bmatrix} g_{11}^2 & g_{11}s^T \\ g_{11}s & \tilde{A} + ss^T \end{bmatrix} = A. \quad (2.1)$$

Claramente, la matriz $X = \begin{bmatrix} g_{11} & s^T \\ 0 & I \end{bmatrix}^{-1}$ existe. Como X es no singular, usando (2.1), se obtiene que

$$X^T A X = \begin{bmatrix} 1 & 0 \\ 0 & \tilde{A} \end{bmatrix}$$

es definida positiva. Por lo tanto, $\tilde{A}$ es definida positiva. Como $\tilde{A}$ es simétrica por construcción, usando la hipótesis inductiva se obtiene la existencia de $\tilde{G} \in \mathbb{R}^{(n-1) \times (n-1)}$ tal que $\tilde{A} = \tilde{G}^T \tilde{G}$ con $\tilde{G}$ triangular superior con elementos diagonales positivos. Reemplazando en (2.1), se tiene que

$$\begin{aligned} A &= \begin{bmatrix} g_{11} & 0 \\ s & I \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & \tilde{G}^T \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & \tilde{G} \end{bmatrix} \begin{bmatrix} g_{11} & s^T \\ 0 & I \end{bmatrix} \\ &= \begin{bmatrix} g_{11} & 0 \\ s & \tilde{G}^T \end{bmatrix} \begin{bmatrix} g_{11} & s^T \\ 0 & \tilde{G} \end{bmatrix} = G^T G, \end{aligned}$$

con $G \in \mathbb{R}^{n \times n}$ triangular superior con elementos diagonales positivos.

Unicidad. Supongamos que existen $G_1, G_2 \in \mathbb{R}^{n \times n}$ triangulares superiores con elementos diagonales positivos tales que $A = G_1^T G_1 = G_2^T G_2$. Entonces $G_2^{-T} G_1^T = G_2 G_1^{-1}$, siendo el término izquierdo triangular inferior y el derecho triangular superior. Por lo tanto existe una matriz diagonal D con $d_{ii} > 0$, $i = 1, \dots, n$, tal que $G_2^{-T} G_1^T = G_2 G_1^{-1} = D$. Como

$$D^2 = DD^T = (G_2 G_1^{-1})(G_2^{-T} G_1^T)^T = G_2 G_1^{-1} G_1 G_2^{-1} = I,$$

usando que $d_{ii} > 0$, se obtiene que $d_{ii} = 1$. Por lo tanto $D = I$ y en consecuencia $G_2 = G_1$.

La descomposición dada por el teorema se conoce como **descomposición de Cholesky** y la matriz G obtenida se conoce como el factor de Cholesky de A . Ahora que se sabe que esta descomposición puede realizarse, se verá como obtenerla algorítmicamente.

Versión producto exterior

Note que el argumento utilizado en el paso inductivo de la demostración del Teorema 2.7 puede utilizarse para calcular G . Si $i < n$, para $\mathcal{J} = \{i+1, \dots, n\}$

$$\begin{bmatrix} a_{ii} & A_{i\mathcal{J}} \\ A_{i\mathcal{J}}^T & A_{\mathcal{J}\mathcal{J}} \end{bmatrix} = \begin{bmatrix} g_{ii} & 0 \\ G_{i\mathcal{J}}^T & G_{\mathcal{J}\mathcal{J}}^T \end{bmatrix} \begin{bmatrix} g_{ii} & G_{i\mathcal{J}} \\ 0 & G_{\mathcal{J}\mathcal{J}} \end{bmatrix}.$$

Obteniendo que $a_{ii} = g_{ii}^2$, $A_{i\mathcal{J}} = g_{ii} G_{i\mathcal{J}}$ y $A_{\mathcal{J}\mathcal{J}} = (G_{i\mathcal{J}})^T G_{i\mathcal{J}} + (G_{\mathcal{J}\mathcal{J}})^T G_{\mathcal{J}\mathcal{J}}$. Pudiendo entonces definir

$$g_{ii} = \sqrt{a_{ii}}, \quad G_{i\mathcal{J}} = \frac{1}{g_{ii}} A_{i\mathcal{J}},$$

y luego realizamos la actualización

$$A_{\mathcal{J}\mathcal{J}} \leftarrow A_{\mathcal{J}\mathcal{J}} - (G_{i\mathcal{J}})^T G_{i\mathcal{J}}.$$

De esta manera, tenemos que $A_{\mathcal{J}\mathcal{J}} = (G_{\mathcal{J}\mathcal{J}})^T G_{\mathcal{J}\mathcal{J}}$ y repetimos el argumento anterior para una matriz con una dimensión menos. Claramente, para $i = n$ obtendremos $a_{nn} = g_{nn}^2$ y por lo tanto $g_{nn} = \sqrt{a_{nn}}$.

El pseudocódigo de este esquema es el siguiente:

Algoritmo 5 (Descomposición de Cholesky, producto exterior)

Entrada: $A \in \mathbb{R}^{n \times n}$. Salida: $G \in \mathbb{R}^{n \times n}$ tr. sup. t.q. $A = G^T G$.

Paso 0: Definir $i = 1$.

Paso 1: Definir $G_{ii} = \sqrt{A_{ii}}$.

Paso 2: Si $i < n$, definir $\mathcal{J} = \{i+1, \dots, n\}$,

$$G_{i\mathcal{J}} = A_{i\mathcal{J}} / G_{ii},$$

$$A_{\mathcal{J}\mathcal{J}} \leftarrow A_{\mathcal{J}\mathcal{J}} - (G_{i\mathcal{J}})^T G_{i\mathcal{J}},$$

hacer $i \leftarrow i + 1$, e ir al paso 1.

Sino, retornar G .

Versión por filas

Considere $A = G^T G$ con A simétrica y definida positiva. Escriba G^T separando los elementos diagonales:

$$\begin{bmatrix} \boxed{a_{11}} & a_{12} & \dots & a_{1n} \\ a_{12} & \boxed{a_{22}} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \\ a_{1n} & a_{2n} & \dots & \boxed{a_{nn}} \end{bmatrix} = \begin{bmatrix} \boxed{g_{11}} & & & \\ g_{12} & \boxed{g_{22}} & & \\ \vdots & \vdots & \ddots & \\ \boxed{g_{1n}} & \dots & g_{n-1,n} & \boxed{g_{nn}} \end{bmatrix} \begin{bmatrix} g_{11} & g_{12} & \dots & g_{1n} \\ & g_{22} & \dots & g_{2n} \\ & & \ddots & \vdots \\ & & & g_{nn} \end{bmatrix}.$$

La ecuación correspondiente a la fila $i = 1$ es

$$[a_{11} \ a_{12} \ \dots \ a_{1n}] = g_{11}[g_{11} \ g_{12} \ \dots \ g_{1n}],$$

por lo tanto $a_{11} = g_{11}^2 > 0$ y en consecuencia $g_{11} = \sqrt{a_{11}}$. Reemplazando en la ecuación para la fila, se obtiene que

$$[g_{11} \ g_{12} \ \dots \ g_{1n}] = \frac{1}{\sqrt{a_{11}}}[a_{11} \ a_{12} \ \dots \ a_{1n}].$$

Para la fila $i = 2$ se tiene la relación

$$[a_{22} \ \dots \ a_{2n}] = g_{12}[g_{12} \ \dots \ g_{1n}] + g_{22}[g_{22} \ \dots \ g_{2n}].$$

Defino

$$[\tilde{g}_{22} \ \dots \ \tilde{g}_{2n}] = [a_{22} \ \dots \ a_{2n}] - g_{12}[g_{12} \ \dots \ g_{1n}],$$

vector con elementos conocidos. Por lo tanto, se deberá tener $\tilde{g}_{22} = g_{22}^2 > 0$ y en consecuencia $g_{22} = \sqrt{\tilde{g}_{22}}$. Reemplazando en la ecuación para la fila, se obtiene que

$$[g_{22} \ g_{23} \ \dots \ g_{2n}] = \frac{1}{\sqrt{\tilde{g}_{22}}}[\tilde{g}_{22} \ \tilde{g}_{23} \ \dots \ \tilde{g}_{2n}].$$

Para la fila $i = 3$ se tiene la relación

$$[a_{33} \ \dots \ a_{3n}] = [g_{13} \ g_{23}] \begin{bmatrix} g_{13} & \dots & g_{1n} \\ g_{23} & \dots & g_{2n} \end{bmatrix} + g_{33}[g_{33} \ \dots \ g_{3n}].$$

Defino el vector de elementos conocidos

$$[\tilde{g}_{33} \ \dots \ \tilde{g}_{3n}] = [a_{33} \ \dots \ a_{3n}] - \begin{bmatrix} g_{13} \\ g_{23} \end{bmatrix}^T \begin{bmatrix} g_{13} & \dots & g_{1n} \\ g_{23} & \dots & g_{2n} \end{bmatrix}.$$

Por lo tanto, se deberá tener $\tilde{g}_{33} = g_{33}^2 > 0$ y en consecuencia $g_{33} = \sqrt{\tilde{g}_{33}}$. Reemplazando en la ecuación para la fila, se obtiene que

$$[g_{33} \ g_{34} \ \dots \ g_{3n}] = \frac{1}{\sqrt{\tilde{g}_{33}}}[\tilde{g}_{33} \ \tilde{g}_{34} \ \dots \ \tilde{g}_{3n}].$$

De esta forma, para cualquier fila $i > 1$ se tendrá la relación

$$[a_{ii} \dots a_{in}] = [g_{1i} \dots g_{i-1,i}] \begin{bmatrix} g_{1i} & \dots & g_{1n} \\ \vdots & \ddots & \vdots \\ g_{i-1,i} & \dots & g_{i-1,n} \end{bmatrix} + g_{ii}[g_{ii} \dots g_{in}].$$

Definiendo el vector de elementos conocidos

$$[\tilde{g}_{ii} \dots \tilde{g}_{in}] = [a_{ii} \dots a_{in}] - \begin{bmatrix} g_{1i} \\ \vdots \\ g_{i-1,i} \end{bmatrix}^T \begin{bmatrix} g_{1i} & \dots & g_{1n} \\ \vdots & \ddots & \vdots \\ g_{i-1,i} & \dots & g_{i-1,n} \end{bmatrix},$$

se tendrá $\tilde{g}_{ii} = g_{ii}^2 > 0$ y en consecuencia $g_{ii} = \sqrt{\tilde{g}_{ii}}$. Reemplazando en la ecuación para la fila, se obtendrá

$$[g_{ii} \dots g_{in}] = \frac{1}{\sqrt{\tilde{g}_{ii}}}[\tilde{g}_{ii} \dots \tilde{g}_{in}].$$

El pseudocódigo puede escribirse de esta manera:

Algoritmo 6 (Descomposición de Cholesky)

Entrada: $A \in \mathbb{R}^{n \times n}$. *Salida:* $G \in \mathbb{R}^{n \times n}$ tr. sup. t.q. $A = G^T G$.

Paso 0: Definir $i = 1$, $\mathcal{I} = \{1, \dots, n\}$ y $G_{1\mathcal{I}} = A_{1\mathcal{I}}$.

Paso 1: Si $i > 1$, definir

$$\begin{aligned} \mathcal{I} &= \{1, \dots, i-1\}, \\ \mathcal{J} &= \{i, \dots, n\}, \\ G_{i\mathcal{J}} &= A_{i\mathcal{J}} - (G_{\mathcal{I}i})^T G_{\mathcal{I}\mathcal{J}}. \end{aligned}$$

Paso 2: Definir

$$G_{i\mathcal{J}} = G_{i\mathcal{J}} / \sqrt{G_{ii}}.$$

Paso 3: Si $i < n$, hacer $i \leftarrow i + 1$ e ir al paso 1.

Sino, retornar G .

Para una correcta implementación, se debe controlar que la entrada diagonal sea positiva antes de tomar su raíz cuadrada. En caso de tener una entrada diagonal no positiva, se deberá parar la ejecución del algoritmo. Claramente, si la matriz A no es definida positiva entonces se tendrá al menos una entrada diagonal de G no positiva.

La cantidad de operaciones realizadas en el Algoritmo 6 es: si $i = 1$ se tienen n productos y una raíz cuadrada (o sea, $n + 1$ flops); para cada $i > 1$ se tienen $(n - i + 1)(i - 1)$ productos y $(n - i + 1)(i - 2)$ sumas (o sea, $2(n - i + 1)(i - 1) - (n - i + 1)$ flops) provenientes del producto de una matriz $1 \times (i - 1)$ por una $(i - 1) \times (n - i + 1)$, $n - i + 1$ sumas debido a la suma de vectores, $n - i + 1$ productos y una raíz cuadrada. Por lo tanto, se tiene un total

de flops igual a

$$\begin{aligned}
 & \sum_{i=1}^n (2(n-i+1)(i-1) + (n-i+1) + 1) \\
 &= \sum_{i=1}^n (-2(n-i+1)^2 + (2n+1)(n-i+1) + 1) \\
 &= -2 \frac{n(n+1)(2n+1)}{6} + (2n+1) \frac{n(n+1)}{2} + n \\
 &= \frac{n(n+1)(2n+1)}{6} + n \\
 &= \frac{n^3}{3} + \frac{n^2}{2} + \frac{7n}{6}.
 \end{aligned}$$

donde usamos que $\sum_{k=1}^n k^2 = n(n+1)(2n+1)/6$. Con esto, concluimos que la descomposición de Cholesky tiene un costo operacional de $O(n^3/3)$ flops.

Con lo visto hasta ahora, estamos en condiciones de resolver computacionalmente el sistema lineal $Ax = b$ con A simétrica y definida positiva. El procedimiento para hacerlo es el siguiente.

Algoritmo 7 (Resolución de sistemas definidos positivos)

Entradas: $A \in \mathbb{R}^{n \times n}$ y $b \in \mathbb{R}^n$. *Salida:* $x \in \mathbb{R}^n$ t.q. $Ax = b$.

Paso 0: Calcular G tr. sup. tal que $A = G^T G$, mediante el Algoritmo 6.

Paso 1: Hallar y solución de $G^T y = b$, mediante el Algoritmo 3 o 4.

Paso 2: Hallar x solución de $Gx = y$, mediante el Algoritmo 1 o 2.

Ejemplo 2.8 Cartera de acciones. Para una cartera de n acciones, si invierto x_i pesos en la empresa i , el retorno será

$$\sum_{i=1}^n r_i x_i,$$

donde $r_i = r_i(\omega)$ variable aleatoria. Para manejar la aleatoriedad, se trabajará con el retorno esperado

$$\mathbb{E} \left(\sum_{i=1}^n r_i x_i \right) = \sum_{i=1}^n \mathbb{E}(r_i) x_i.$$

Además, se medirá el riesgo de la inversión con su varianza

$$\mathbb{V} \left(\sum_{i=1}^n r_i x_i \right) = \sum_{i=1}^n \sum_{j=1}^n \sigma_{ij} x_i x_j,$$

donde σ_{ij} es la covarianza entre las variables aleatorias r_i y r_j . Con esto, el problema que se desea resolver es

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \quad \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \sigma_{ij} x_i x_j - \alpha \sum_{i=1}^n \mathbb{E}(r_i) x_i,$$

para $\alpha > 0$. Note que si $\alpha \approx 0$ importa el riesgo y si $\alpha \approx \infty$ importa el retorno. Para poder resolver este problema, se tomarán m muestras $r_i(\omega_l)$ con $l = 1, \dots, m$ para cada variable aleatoria con $i = 1, \dots, n$ y se aproximarán

$$\mathbb{E}(r_i) \approx \mu_i = \frac{1}{m} \sum_{l=1}^m r_i(\omega_l) \quad y \quad \sigma_{ij} \approx s_{ij} = \frac{1}{m-1} \sum_{l=1}^m (r_i(\omega_l) - \mu_i)(r_j(\omega_l) - \mu_j).$$

Por lo tanto el problema que se resolverá es

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \quad \frac{1}{2} \langle Sx, x \rangle - \alpha \langle \mu, x \rangle,$$

donde $S \in \mathbb{R}^{n \times n}$ es simétrica y, bajo ciertas hipótesis, definida positiva. La solución del problema de minimización es aquel x donde el gradiente se anula, o sea, x tal que $0 = Sx - \alpha\mu$.

2.3. Sistema indefinido

Suponga que dados $b \in \mathbb{R}^n$ y $A \in \mathbb{R}^{n \times n}$ no singular, se desea

$$\text{hallar } x \in \mathbb{R}^n \quad \text{tal que} \quad Ax = b.$$

Para resolver este tipo de sistema lineal, se usará el método de eliminación Gaussiana y la descomposición LU. Estos métodos pueden deducirse con las mismas herramientas teóricas aunque se diferencian en su implementación.

Transformaciones de Gauss. Si uno desea transformar el vector $\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$ con $x_1 \neq 0$ a un vector con $x_2 = 0$ sin modificar x_1 , una operación matemática para realizarlo sería

$$\begin{bmatrix} 1 & 0 \\ -\tau & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_1 \\ 0 \end{bmatrix},$$

donde $\tau = x_2/x_1$. En general, si deseo transformar $x \in \mathbb{R}^n$, con $x_k \neq 0$, en un vector con $x_i = 0$ para $i = k+1, \dots, n$ sin alterar x_i para $i = 1, \dots, k$, defino la transformación de Gauss

$$M_k = I - v^k (e^k)^T = I - \begin{bmatrix} 0 \\ \vdots \\ 0 \\ 0 \\ v_{k+1}^k \\ \vdots \\ v_n^k \end{bmatrix} (e^k)^T = \begin{bmatrix} 1 & & & & & \\ & \ddots & & & & \\ & & 1 & & & \\ & & & 1 & & \\ & & & -v_{k+1}^k & 1 & \\ & & & \vdots & & \ddots \\ & & & -v_n^k & & 1 \end{bmatrix},$$

donde $v_i^k = 0$ para $i = 1, \dots, k$, $v_i^k = x_i/x_k$ para $i = k+1, \dots, n$ y e^k es el k -ésimo vector canónico. Claramente,

$$M_k x = x - x_k v^k = \begin{bmatrix} x_1 \\ \vdots \\ x_k \\ x_{k+1} \\ \vdots \\ x_n \end{bmatrix} - \begin{bmatrix} 0 \\ \vdots \\ 0 \\ x_{k+1} \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} x_1 \\ \vdots \\ x_k \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Además, para cualquier $y \in \mathbb{R}^n$ con $y_k = 0$ se tendrá $M_k y = y - y_k v^k = y$.

Los métodos que se verán se basan en aplicar una sucesión de transformaciones de Gauss $M_1, \dots, M_{n-1}$ tales que

$$M_{n-1} \dots M_2 M_1 A = U,$$

con U triangular superior. Para definir estas matrices, piense en una sucesión de matrices tal que $A_0 = A$, $A_k = M_k A_{k-1}$ y $U = A_{n-1}$, con la propiedad que

$$A_k = \begin{bmatrix} U_k & V_k \\ 0 & W_k \end{bmatrix}, \quad U_k \in \mathbb{R}^{k \times k} \text{ triangular superior},$$

con $W_k \in \mathbb{R}^{(n-k) \times (n-k)}$ y $V_k \in \mathbb{R}^{k \times (n-k)}$. Que es lo mismo que decir que los elementos $a_{ij}^{(k)}$ de A_k cumplen $a_{ij}^{(k)} = 0$ si $j+1 \leq i \leq n$ y $1 \leq j \leq k$.

Ejemplo 2.9 Sea $A_0 = A = \begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 10 \end{bmatrix}$. Para generar A_1 se debe definir M_1 que anule

los elementos $a_{i1}^{(0)}$ con $i > 1$. Tomando $v^1 = [0, 2, 3]^T$, entonces

$$M_1 = I - v^1 (e^1)^T = \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ -3 & 0 & 1 \end{bmatrix} \text{ y } A_1 = M_1 A_0 = \begin{bmatrix} 1 & 4 & 7 \\ 0 & -3 & -6 \\ 0 & -6 & -11 \end{bmatrix}.$$

Como $a_{12}^{(1)} = 0$, M_2 dejará invariante la primer columna de A_1 , por lo tanto solo se debe trabajar con su segunda columna. Tomando $v^2 = [0, 0, 2]^T$, se obtiene

$$M_2 = I - v^2 (e^2)^T = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -2 & 1 \end{bmatrix} \text{ y } A_2 = M_2 A_1 = \begin{bmatrix} 1 & 4 & 7 \\ 0 & -3 & -6 \\ 0 & 0 & 1 \end{bmatrix}.$$

En general, para $k = 1, \dots, n-1$ se puede generar $A_k = M_k A_{k-1}$ con la propiedad deseada si se define M_k con v^k tal que

$$v_i^k = \begin{cases} 0, & 1 \leq i \leq k, \\ a_{ik}^{(k-1)} / a_{kk}^{(k-1)}, & k+1 \leq i \leq n. \end{cases}$$

Note que este procedimiento está bien definido solo si $a_{kk}^{(k-1)} \neq 0$ para $k = 1, \dots, n-1$. Las entradas $a_{kk}^{(k-1)}$ reciben el nombre de pivotes.

Se verá a continuación en que caso se puede afirmar que el procedimiento anterior está bien definido.

Teorema 2.10 Si $A \in \mathbb{R}^{n \times n}$ satisface

$$\det \left(\begin{bmatrix} a_{11} & \dots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{k1} & \dots & a_{kk} \end{bmatrix} \right) \neq 0, \quad (2.2)$$

para $k = 1, \dots, n-1$, entonces las transformaciones de Gauss M_k están bien definidas para $k = 1, \dots, n-1$.

Demostración. Note que usando la definición de v^k solo basta probar que $a_{kk}^{(k-1)} \neq 0$ para $k = 1, \dots, n-1$.

Usando inducción en k , si (2.2) vale para $k = 1$ entonces $a_{11}^{(0)} = a_{11} \neq 0$ y por lo tanto se puede definir M_1 . Suponga que se tienen definidas M_k para $k = 1, \dots, l-1$ y que vale (2.2) para $k = l$, entonces $\Gamma = M_{l-1} \dots M_1$ es una matriz triangular inferior con unos en la diagonal. Usando los índices $\mathcal{I} = \{1, \dots, l\}$ y $\mathcal{J} = \{l+1, \dots, n\}$, se tiene

$$A_{l-1} = \Gamma A = \begin{bmatrix} \Gamma_{\mathcal{I}\mathcal{I}} & 0 \\ \Gamma_{\mathcal{J}\mathcal{I}} & \Gamma_{\mathcal{J}\mathcal{J}} \end{bmatrix} \begin{bmatrix} A_{\mathcal{I}\mathcal{I}} & A_{\mathcal{I}\mathcal{J}} \\ A_{\mathcal{J}\mathcal{I}} & A_{\mathcal{J}\mathcal{J}} \end{bmatrix}.$$

Obteniendo que el bloque de A_{l-1} con filas y columnas indexadas por $\mathcal{I}$ es igual a $\Gamma_{\mathcal{I}\mathcal{I}} A_{\mathcal{I}\mathcal{I}}$ con $\Gamma_{\mathcal{I}\mathcal{I}}$ triangular inferior con unos en la diagonal. Entonces,

$$\det(A_{\mathcal{I}\mathcal{I}}) = \det(\Gamma_{\mathcal{I}\mathcal{I}} A_{\mathcal{I}\mathcal{I}}) = \det \left(\begin{bmatrix} a_{11}^{(l-1)} & \dots & a_{1l}^{(l-1)} \\ 0 & \ddots & \vdots \\ 0 & 0 & a_{ll}^{(l-1)} \end{bmatrix} \right) = a_{11}^{(l-1)} \dots a_{ll}^{(l-1)}.$$

Como $\det(A_{\mathcal{I}\mathcal{I}}) \neq 0$, pues vale (2.2) para $k = l$, entonces $a_{ll}^{(l-1)} \neq 0$. Por lo tanto, se puede definir M_l . ■

2.3.1. Eliminación Gaussiana

Para resolver el sistema $Ax = b$ aplicamos transformaciones de Gauss hasta obtener un sistema equivalente $Ux = y$, donde

$$y = M_{n-1} \dots M_2 M_1 b, \quad U = M_{n-1} \dots M_2 M_1 A.$$

Luego, el sistema $Ux = b$ puede resolverse usando el Algoritmo 3 o 4.

Aplicando lo visto previamente y de acuerdo al Teorema 2.10, se pueden generar $b^k = M_k b^{k-1}$ y $A_k = M_k A_{k-1}$ para $k = 1, \dots, n-1$ con $b^0 = b$ y $A_0 = A$, obteniendo $y = b^{n-1}$ y $U = A_{n-1}$. Para realizar este procedimiento optimizando el uso de la memoria del computador, se tendrán en consideración ciertos aspectos del proceso. Primero, note que para realizar la transformación solo se necesita información del paso previo, siendo

innecesario el almacenamiento de todos los pasos anteriores. Entonces, si se ha almacenado A_{k-1} en A , se tendrá

$$A = \begin{bmatrix} U & V \\ 0 & W \end{bmatrix} \quad \text{con} \quad U \in \mathbb{R}^{(k-1) \times (k-1)}.$$

Para definir v^k , se puede usar el conjunto de índices $\mathcal{I} = \{k+1, \dots, n\}$ de esta manera: $v_i^k = 0$ si $i \notin \mathcal{I}$ y $v_{\mathcal{I}}^k = \frac{1}{a_{kk}} A_{\mathcal{I}k}$. Ahora, considerando el conjunto de índices $\mathcal{J} = \{k, \dots, n\}$, se obtiene que

$$M_k A = \begin{bmatrix} I & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -v_{\mathcal{I}}^k & I \end{bmatrix} \begin{bmatrix} U & V \\ 0 & A_{k\mathcal{J}} \\ 0 & A_{\mathcal{I}\mathcal{J}} \end{bmatrix} = \begin{bmatrix} U & V \\ 0 & A_{k\mathcal{J}} \\ 0 & A_{\mathcal{I}\mathcal{J}} - v_{\mathcal{I}}^k A_{k\mathcal{J}} \end{bmatrix}.$$

Por lo tanto, solo es necesario actualizar el bloque $A_{\mathcal{I}\mathcal{J}}$ de la matriz A . Análogamente, se obtiene que solo se debe actualizar el subvector $b_{\mathcal{I}}$ de b . Con esto, una posible pseudocódigo sería el siguiente:

Algoritmo 8 (Eliminación Gaussiana)

Entradas: $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$. *Salidas:* $U \in \mathbb{R}^{n \times n}$ tr. sup., $y \in \mathbb{R}^n$ tal que $Ax = b$ y $Ux = y$ sean equivalentes.

Paso 0: Definir $k = 1$.

Paso 1: Si $k \leq n - 1$, definir

$$\begin{aligned} \mathcal{I} &= \{k+1, \dots, n\}, \\ \mathcal{J} &= \{k, \dots, n\}, \\ v_{\mathcal{I}} &= A_{\mathcal{I}k} / A_{kk}, \\ A_{\mathcal{I}\mathcal{J}} &\leftarrow A_{\mathcal{I}\mathcal{J}} - v_{\mathcal{I}} A_{k\mathcal{J}}, \\ b_{\mathcal{I}} &\leftarrow b_{\mathcal{I}} - v_{\mathcal{I}} b_k. \end{aligned}$$

Sino, retornar $U = A$, $y = b$.

Paso 2: Hacer $k \leftarrow k + 1$ e ir al paso 1.

Note que en este algoritmo la matriz U quedó almacenada en A y el vector y quedó almacenado en b . Además, una correcta implementación de este algoritmo requiere controlar la no nulidad de la entrada diagonal antes de usarla para dividir.

La cantidad de operaciones realizadas en el Algoritmo 8 para cada k es: $(n - k)$ productos al definir $v_{\mathcal{I}}$, $(n - k)(n - k + 1)$ productos y $(n - k)(n - k + 1)$ sumas al actualizar A , $n - k$

productos y $n - k$ sumas al actualizar b . Por lo tanto, se tiene un total de flops igual a

$$\begin{aligned} \sum_{k=1}^{n-1} (2(n-k)(n-k+1) + 3(n-k)) &= \sum_{i=1}^{n-1} (2(n-k)^2 + 5(n-k)) \\ &= 2 \frac{(n-1)n(2n-1)}{6} + 5 \frac{(n-1)n}{2} \\ &= (n-1)n \left(\frac{2}{3}n - \frac{1}{3} + \frac{5}{2} \right) \\ &= \frac{2}{3}n^3 + \frac{3}{2}n^2 - \frac{13}{6}n. \end{aligned}$$

Con esto, concluimos que el Algoritmo 8 tiene un costo operacional de $O(2n^3/3)$ flops.

2.3.2. Descomposición LU

Se sabe que $U = M_{n-1} \dots M_2 M_1 A$ con $M_k = I - v^k (e^k)^T$ triangular inferior con unos en la diagonal. Usando la estructura de M_k se puede probar que su inversa es triangular inferior con unos en la diagonal, más aún, se puede ver que $M_k^{-1} = I + v^k (e^k)^T$. Por lo tanto, si se define

$$L = M_1^{-1} M_2^{-1} \dots M_{n-1}^{-1},$$

se obtiene que L es triangular inferior con unos en la diagonal y $A = LU$. De esta forma, si x es solución de $Ax = b$, entonces

$$b = Ax = LUx = Ly \quad \text{con} \quad y = Ux.$$

O sea, para resolver $Ax = b$, resolvemos los sistemas triangulares $Ly = b$ y $Ux = y$. Usando el Teorema 2.10 garantizamos la existencia de una descomposición LU, veamos ahora que dicha descomposición es única.

Corolario 2.11 Si $A \in \mathbb{R}^{n \times n}$ satisface (2.2) para $k = 1, \dots, n$, entonces la descomposición LU existe y es única. Además, $\det(A) = \det(U) = u_{11} \dots u_{nn}$.

Demostración. Como (2.2) vale para $k = 1, \dots, n-1$ entonces A tiene descomposición LU. Además, como (2.2) vale para $k = n$ entonces A es no singular.

Supongamos que A tiene dos factorizaciones LU, i.e., $A = L_1 U_1 = L_2 U_2$. Como U_1 es no singular, pues $\det(U_1) = \det(L_1 U_1) = \det(A)$, entonces $L_2^{-1} L_1 = U_2 U_1^{-1}$. Obteniendo que $L_2^{-1} L_1$ es triangular superior, triangular inferior y con unos en la diagonal. Por lo tanto $L_2^{-1} L_1 = I$. Concluyendo que $L_1 = L_2$ y $U_1 = U_2$. Además,

$$\det(A) = \det(LU) = \det(U) = u_{11} \dots u_{nn}.$$

■

Si A tiene descomposición LU, entonces se puede ver que

$$L = I + \sum_{k=1}^{n-1} v^k (e^k)^T.$$

Por lo tanto, se puede almacenar la matriz $L - I$ en la parte triangular inferior de U , obteniendo una matriz tal que su k -ésima columna es de la forma

$$\begin{bmatrix} u_{1k} \\ \vdots \\ u_{kk} \\ v_{k+1}^k \\ \vdots \\ v_n^k \end{bmatrix}.$$

Para ahorrar memoria en el computador, se irán almacenando columnas de esta forma en la matriz A . Suponga que en el k -ésimo paso se tiene almacenado en A una matriz A_{k-1} cuyo elemento ij es v_i^j si $j + 1 \leq i \leq n$ y $1 \leq j \leq k$. Usando lo deducido para el método de eliminación Gaussiana, para índices $\mathcal{I} = \{k + 1, \dots, n\}$ y $\mathcal{J} = \{k\} \cup \mathcal{I}$ se debe definir $v_{\mathcal{I}}^k = \frac{1}{a_{kk}} A_{\mathcal{I}k}$ y actualizar la submatriz $A_{\mathcal{I}\mathcal{J}}$ por

$$A_{\mathcal{I}\mathcal{J}} - v_{\mathcal{I}}^k A_{k\mathcal{J}} = [A_{\mathcal{I}k} - v_{\mathcal{I}}^k a_{kk} A_{\mathcal{I}\mathcal{I}} - v_{\mathcal{I}}^k A_{k\mathcal{I}}] = [0 \ A_{\mathcal{I}\mathcal{I}} - v_{\mathcal{I}}^k A_{k\mathcal{I}}].$$

Como la primer columna tendrá solo elementos nulos, se almacenará $v_{\mathcal{I}}^k$ en esa columna. Obteniendo así que se debe almacenar $v_{\mathcal{I}}^k$ en $A_{\mathcal{I}k}$ y actualizar la submatriz $A_{\mathcal{I}\mathcal{I}}$. Un posible pseudocódigo sería el siguiente.

Algoritmo 9 (Descomposición LU)

Entrada: $A \in \mathbb{R}^{n \times n}$. *Salidas:* $L, U \in \mathbb{R}^{n \times n}$ tr. inf. y tr. sup. tal que $LU = A$.

Paso 0: Definir $k = 1$.

Paso 1: Si $k \leq n - 1$, definir

$$\begin{aligned} \mathcal{I} &= \{k + 1, \dots, n\}, \\ A_{\mathcal{I}k} &\leftarrow A_{\mathcal{I}k} / A_{kk}, \\ A_{\mathcal{I}\mathcal{I}} &\leftarrow A_{\mathcal{I}\mathcal{I}} - A_{\mathcal{I}k} A_{k\mathcal{I}}. \end{aligned}$$

Sino, retornar A .

Paso 2: Hacer $k \leftarrow k + 1$ e ir al paso 1.

Note que la matriz U quedó almacenada en la parte triangular superior de A y la matriz $L - I$ quedó almacenada en la parte triangular inferior sin la diagonal. Además, recuerde que siempre debe controlar la no nulidad de la entrada diagonal antes de usarla para dividir.

La cantidad de operaciones realizadas en el Algoritmo 9 para cada k es: $(n - k)$ productos al definir en el cociente por el elemento diagonal, $(n - k)(n - k)$ productos y $(n - k)(n - k)$

sumas al actualizar $A_{\mathcal{IL}}$. Por lo tanto, se tiene un total de flops igual a

$$\begin{aligned} \sum_{k=1}^{n-1} (2(n-k)^2 + (n-k)) &= 2 \frac{(n-1)n(2n-1)}{6} + \frac{(n-1)n}{2} \\ &= (n-1)n \left(\frac{2}{3}n - \frac{1}{3} + \frac{1}{2} \right) \\ &= \frac{2}{3}n^3 - \frac{1}{2}n^2 - \frac{1}{6}n. \end{aligned}$$

Con esto, concluimos que el Algoritmo 9 tiene un costo operacional de $O(2n^3/3)$ flops.

2.3.3. Eliminación Gaussiana con pivoteo parcial

El algoritmo de eliminación Gaussiana y el algoritmo de descomposición LU están bien definidos si en el paso k , el pivote $a_{kk}^{(k-1)}$ es no nulo. Infelizmente, esta hipótesis es muy restrictiva y puede no valer para sistemas lineales simples.

Ejemplo 2.12 Sea $A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$. Como A es no singular, por Teorema 1.2, dado b el sistema $Ax = b$ tiene una única solución. No obstante, como $a_{11} = 0$, tanto el algoritmo de eliminación Gaussiana (Algoritmo 8) como el de descomposición LU (Algoritmo 9) fallan en el paso $k = 1$.

Para evitar pivotes nulos, se permutarán las filas de la matriz. A fin de realizar los cálculos matriciales, se introducirán matrices de permutación.

Definición 2.13 Una matriz de permutación P es una matriz identidad con sus filas reordenadas.

Ejemplo 2.14 Considere A y una matriz de permutación P tales que

$$A = \begin{bmatrix} 2 & 3 & 5 \\ 4 & 9 & 25 \\ 8 & 27 & 125 \end{bmatrix}, \quad P = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}.$$

Note que P reordena las filas $(1, 2, 3)$ de la identidad en $(3, 1, 2)$ y

$$PA = \begin{bmatrix} 8 & 27 & 125 \\ 2 & 3 & 5 \\ 4 & 9 & 25 \end{bmatrix},$$

reordena las filas $(1, 2, 3)$ de A en $(3, 1, 2)$. Además, P reordena las columnas $(1, 2, 3)$ de la identidad en $(2, 3, 1)$ y

$$AP = \begin{bmatrix} 3 & 5 & 2 \\ 9 & 25 & 4 \\ 27 & 125 & 8 \end{bmatrix}.$$

En este caso, se permutarán solamente las filas (de ahí el pivoteo “parcial”) de A_{k-1} antes de definir A_k . La estrategia es permutar las filas a fin de obtener el pivot $a_{kk}^{(k-1)}$ tal que

$$|a_{kk}^{(k-1)}| \geq |a_{ik}^{(k-1)}| \quad \text{para } i = k+1, \dots, n.$$

Esta elección no solo evita pivotes no nulos, además garantiza que las transformaciones de Gauss M_k tienen entradas de módulo menor o igual a 1. Vea esto en el siguiente ejemplo.

Ejemplo 2.15 Sea

$$A = \begin{bmatrix} 3 & 17 & 10 \\ 2 & 4 & -2 \\ 6 & 18 & -12 \end{bmatrix}.$$

Como $|a_{31}| \geq |a_{i1}|$, defina una permutación E_1 , permute las filas de $A_0 = A$ y luego defina M_1 , o sea,

$$E_1 = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}, \quad E_1 A_0 = \begin{bmatrix} 6 & 18 & -12 \\ 2 & 4 & -2 \\ 3 & 17 & 10 \end{bmatrix}, \quad M_1 = \begin{bmatrix} 1 & 0 & 0 \\ -1/3 & 1 & 0 \\ -1/2 & 0 & 1 \end{bmatrix}.$$

Entonces,

$$A_1 = M_1 E_1 A_0 = \begin{bmatrix} 6 & 18 & -12 \\ 0 & -2 & 2 \\ 0 & 8 & 16 \end{bmatrix}.$$

Como $|a_{32}| > |a_{22}|$, defina una permutación E_2 , permute las filas de A_1 y luego defina M_2 , o sea,

$$E_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}, \quad E_2 A_1 = \begin{bmatrix} 6 & 18 & -12 \\ 0 & 8 & 16 \\ 0 & -2 & 2 \end{bmatrix}, \quad M_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1/4 & 1 \end{bmatrix}.$$

Por lo tanto,

$$A_2 = M_2 E_2 A_1 = \begin{bmatrix} 6 & 18 & -12 \\ 0 & 8 & 16 \\ 0 & 0 & 6 \end{bmatrix}.$$

En general, en el paso k se define E_k matriz de permutación de fila k con fila l para un l tal que

$$|a_{lk}^{(k-1)}| = \max_{k \leq j \leq n} \{|a_{jk}^{(k-1)}|\}.$$

Si el máximo entre esos elementos es cero, entonces $a_{jk}^{(k-1)} = 0$ para $j = k, \dots, n$. En este caso los elementos de la columna k por debajo de la diagonal ya son nulos, siendo innecesaria la aplicación de M_k y E_k . Matricialmente, es equivalente a suponer $M_k = E_k = I$.

Por lo tanto, el algoritmo de eliminación Gaussiana con pivoteo puede describirse como una sucesión de $n - 1$ pasos, comenzando con $A_0 = A$ y $b^0 = b$, tal que en el paso k se define

$$A_k = M_k E_k A_{k-1}, \quad b^k = M_k E_k b^{k-1}.$$

Obteniendo $y = b^{n-1}$ y $U = A_{n-1}$. Por construcción, este método está bien definido para cualquier matriz A .

Note que la única diferencia respecto del método sin pivoteo es que, en vez de definir M_k con elementos de A_{k-1} , se define M_k con elementos de $E_k A_{k-1}$. Por lo tanto, la única diferencia con el Algoritmo 8 va a ser la incorporación del intercambio de filas.

Algoritmo 10 (Eliminación Gaussiana con pivoteo parcial)

Entradas: $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$. *Salidas:* $U \in \mathbb{R}^{n \times n}$ tr. sup., $y \in \mathbb{R}^n$ tal que $Ax = b$ y $Ux = y$ sean equivalentes.

Paso 0: Definir $k = 1$.

Paso 1: Si $k \leq n - 1$, definir l t.q. $|A_{lk}| = \max_{k \leq j \leq n} \{|A_{jk}|\}$.
Sino, retornar $U = A$, $y = b$.

Paso 2: Si $A_{lk} \neq 0$,

$$A \leftarrow E_k A,$$

$$b \leftarrow E_k b,$$

donde E_k permuta las filas k y l ,

$$\mathcal{I} = \{k + 1, \dots, n\},$$

$$v_{\mathcal{I}} = A_{\mathcal{I}k} / A_{kk},$$

$$A_{\mathcal{I}k} = 0,$$

$$A_{\mathcal{I}\mathcal{I}} \leftarrow A_{\mathcal{I}\mathcal{I}} - v_{\mathcal{I}} A_{k\mathcal{I}},$$

$$b_{\mathcal{I}} \leftarrow b_{\mathcal{I}} - v_{\mathcal{I}} b_k.$$

Paso 3: Hacer $k \leftarrow k + 1$ e ir al paso 1.

Note que la función $\max$ solo realiza comparaciones y las permutaciones en A y b son simples reasignaciones de valores, o sea, no hubo operaciones en punto flotante. Por lo tanto, el costo operacional del Algoritmo 10 es de $O(2n^3/3)$ flops.

Con lo visto hasta ahora, estamos en condiciones de resolver computacionalmente el sistema lineal $Ax = b$ con A no singular. El procedimiento para hacerlo es el siguiente.

Algoritmo 11 (Resolución de sistemas no singulares)

Entradas: $A \in \mathbb{R}^{n \times n}$ y $b \in \mathbb{R}^n$. *Salida:* $x \in \mathbb{R}^n$ t.q. $Ax = b$.

Paso 0: Calcular y , U mediante el Algoritmo 10.

Paso 1: Hallar x solución de $Ux = y$, mediante el Algoritmo 3 o 4.

2.3.4. Descomposición LU con permutaciones

Anteriormente, vimos que el mismo procedimiento usado para el método de eliminación Gaussiana nos servía para deducir la descomposición LU. Si usamos el método de eliminación Gaussiana con pivoteo, en el último paso se obtendrá

$$U = M_{n-1} E_{n-1} \dots M_2 E_2 M_1 E_1 A.$$

Lo que se puede demostrar es que existe una matriz de permutación de filas P tal que $PA = LU$. La formalización de tal afirmación es la siguiente.

Teorema 2.16 Sea $A \in \mathbb{R}^{n \times n}$ y $U = M_{n-1}E_{n-1} \dots M_2E_2M_1E_1A$ con M_k y E_k generadas por el método de eliminación Gaussiana con pivoteo. Entonces

$$PA = LU,$$

donde

$$P = E_{n-1} \dots E_1, \quad L = I + \sum_{k=1}^{n-1} g^k (e^k)^T,$$

con $g^k = E_{n-1} \dots E_{k+1} v^k$.

Demostración. Usando que $E_k^2 = I$, note que

$$\begin{aligned} M_2E_2M_1E_1A &= M_2E_3E_3E_2M_1E_2E_2E_1A \\ &= M_2E_3 \dots E_{n-1}E_{n-1} \dots E_2M_1E_2 \dots E_{n-1}E_{n-1} \dots E_1A. \end{aligned}$$

Defina $P = E_{n-1} \dots E_1$, $\tilde{M}_k = E_{n-1} \dots E_{k+1}M_kE_{k+1} \dots E_{n-1}$, $k = 1, \dots, n-2$, y $\tilde{M}_{n-1} = M_{n-1}$. Entonces

$$\tilde{M}_{n-1} \dots \tilde{M}_1 PA = U.$$

Como E_i permuta la fila i con la fila l con $l \geq i$, entonces

$$E_i = \begin{bmatrix} I & 0 \\ 0 & P \end{bmatrix}, \quad I \in \mathbb{R}^{(i-1) \times (i-1)},$$

y por lo tanto $(e^k)^T E_i = (e^k)^T$ si $k \leq i-1$, o equivalentemente $k+1 \leq i$. Obteniendo así que

$$\tilde{M}_k = E_{n-1} \dots E_{k+1} \left(I - v^k (e^k)^T \right) E_{k+1} \dots E_{n-1} = I - g^k (e^k)^T,$$

donde $g^k = E_{n-1} \dots E_{k+1} v^k$. Por lo tanto

$$L = \tilde{M}_1^{-1} \dots \tilde{M}_{n-1}^{-1} = I + \sum_{k=1}^{n-1} g^k (e^k)^T.$$

Para la implementación del algoritmo, note que la matriz P es una matriz identidad con sus filas reordenadas, por lo tanto $P = I_{\mathcal{J}}$ donde $\mathcal{J}$ es un reordenamiento de $\{1, \dots, n\}$. Además, como $g^k = E_{n-1} \dots E_{k+1} v^k$, entonces $g_i^k = 0$ para $i = 1, \dots, k$. Si $\mathcal{I} = \{k+1, \dots, n\}$ y vamos almacenando $v_{\mathcal{I}}^k$ en la parte triangular inferior de A , como en el Algoritmo 9, entonces al permutar las filas A se irán obteniendo automáticamente $g_{\mathcal{I}}^k$. Un posible pseudocódigo es el siguiente.

Algoritmo 12 (Descomposición LU con permutaciones)

Entrada: $A \in \mathbb{R}^{n \times n}$. *Salidas:* $L, U, P \in \mathbb{R}^{n \times n}$ tr. inf., tr. sup. y permutación tal que $LU = PA$.

Paso 0: Definir $P = I$, $k = 1$.

Paso 1: Si $k \leq n-1$, definir l t.q. $|A_{lk}| = \max_{k \leq j \leq n} \{|A_{jk}|\}$.

Sino, retornar A y P .

Paso 2: Si $A_{lk} \neq 0$,

$$A \leftarrow E_k A,$$

$$P \leftarrow E_k P,$$

donde E_k permuta las filas k y l ,

$$\mathcal{I} = \{k + 1, \dots, n\},$$

$$A_{\mathcal{I}k} \leftarrow A_{\mathcal{I}k} / A_{kk},$$

$$A_{\mathcal{I}\mathcal{I}} \leftarrow A_{\mathcal{I}\mathcal{I}} - A_{\mathcal{I}k} A_{k\mathcal{I}}.$$

Paso 3: Hacer $k \leftarrow k + 1$ e ir al paso 1.

Al igual que la versión sin permutaciones, U quedó almacenada en la parte triangular superior de A y $L - I$ en la parte triangular inferior. Para resolver el sistema lineal $Ax = b$, tendremos $LUx = PAx = Pb$. Note que al igual que el Algoritmo 9, el costo operacional del Algoritmo 12 es de $O(2n^3/3)$ flops.

Una forma computacionalmente eficiente de calcular la inversa de una matriz $A \in \mathbb{R}^{n \times n}$ es aplicando el algoritmo anterior. Si deseo hallar $X \in \mathbb{R}^{n \times n}$ tal que $AX = I$, o sea,

$$I = AX = [Ax^1 \ Ax^2 \ \dots \ Ax^n],$$

donde x^j es la j -ésima columna de X , debo resolver los siguientes n sistemas lineales: $Ax^j = e^j$ para $j = 1, \dots, n$. Los pasos a seguir son:

1. obtener L, U y P mediante el Algoritmo 12,
2. para $j = 1, \dots, n$
 - a) obtener y t.q. $Ly = Pe^j$, usando el Algoritmo 1 o 2,
 - b) obtener x^j t.q. $Ux^j = y$, usando el Algoritmo 3 o 4.

2.4. Ejercicios

1. Considere las matrices A, B y C particionadas como se indica:

$$A = \left[\begin{array}{c|cc} 1 & 3 & 2 \\ 2 & 1 & 1 \\ \hline -1 & 0 & 1 \end{array} \right], \quad B = \left[\begin{array}{c|cc} 1 & 0 & 1 \\ 2 & 1 & 1 \\ \hline -1 & 2 & 0 \end{array} \right], \quad C = \left[\begin{array}{c|cc} 5 & 7 & 4 \\ 3 & 3 & 3 \\ \hline -2 & 2 & -1 \end{array} \right].$$

Muestre que $AB = C$ y $A_{i1}B_{1j} + A_{i2}B_{2j} = C_{ij}$, $i = 1, 2, j = 1, 2$.

2. Suponga un esquema de inversión mensual, donde la ganancia y_{m+1} del mes $m + 1$ se obtiene de un porcentaje α de la ganancia del mes m y un porcentaje β del aporte u_m que se realiza en el mes m . Matemáticamente, para N meses se obtiene que

$$y_{m+1} = \alpha y_m + \beta u_m, \quad m = 1, \dots, N.$$

Si se conocen los porcentajes α, β y se planifican ganancias $y_1, \dots, y_{N+1}$, escriba el sistema lineal que debe resolverse para obtener los aportes necesarios.

3. Demuestre que:

- Si A y B son triangulares superiores (inferiores) con elementos diagonales iguales a 1, entonces AB también es triangular superior (inferior) con elementos diagonales iguales a 1.
- Probar que si A es triangular superior (inferior) con elementos diagonales iguales a 1, entonces A^{-1} también es triangular superior (inferior) con elementos diagonales iguales a 1.

4. Pruebe que si $A \in \mathbb{R}^{n \times n}$ es simétrica, las siguientes son equivalentes:

- A es definida positiva,
- todos los autovalores de A son positivos,
- para todo conjunto de índices $\mathcal{I} \subset \{1, \dots, n\}$, las submatrices $A_{\mathcal{I}\mathcal{I}}$ son definidas positivas.

5. Sea $A \in \mathbb{R}^{n \times n}$ simétrica y definida positiva tal que

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}, \quad A_{ij} \in \mathbb{R}^{n_i \times n_j}, \quad n_1 + n_2 = n.$$

Demuestre que si A_{11} es no singular, entonces la matriz $S = A_{22} - A_{21}A_{11}^{-1}A_{12}$ (llamada complemento de Schur de A_{11} en A) es definida positiva.

6. Demuestre que:

- si $B \in \mathbb{R}^{n \times n}$ es definida positiva y $X \in \mathbb{R}^{n \times m}$ tiene rango m , entonces $A = X^T B X \in \mathbb{R}^{m \times m}$ es definida positiva.
- Si $A \in \mathbb{R}^{n \times n}$ es simétrica semidefinida positiva y con núcleo cero, entonces A es definida positiva.

7. Demuestre que si A es simétrica definida positiva, existen L triangular inferior con unos en la diagonal y D diagonal con entradas positivas tales que $A = LDL^T$.

8. Si $B = LA$, donde L es triangular inferior con unos en la diagonal, para $\mathcal{I} = \{1, \dots, k\}$ demuestre que $B_{\mathcal{I}\mathcal{I}} = L_{\mathcal{I}\mathcal{I}}A_{\mathcal{I}\mathcal{I}}$.

9. Considere las transformaciones de Gauss $M_k = I - v^k(e^k)^T$ donde $e^k \in \mathbb{R}^n$ es el k -ésimo vector canónico y $v^k \in \mathbb{R}^n$ con $v_i^k = 0$ para $i = 1, \dots, k$. Demuestre que

$$a) M_k^{-1} = I + v^k(e^k)^T,$$


$$b) L = M_1^{-1} \dots M_{n-1}^{-1} = I + \sum_{k=1}^{n-1} v^k(e^k)^T.$$

10. Sea A una matriz simétrica. Suponga que A ha sido reducida a la forma

$$\left[\begin{array}{c|ccc} a_{11} & a_{12} & \dots & a_{1n} \\ \hline 0 & & & \\ \vdots & & \hat{A} & \\ 0 & & & \end{array} \right]$$

efectuando solo operaciones elementales por filas. Demuestre que $\hat{A}$ es simétrica. ¿Qué ventajas tiene esto cuando se efectúa la eliminación Gaussiana de A ?

11. Escriba un pseudocódigo de un algoritmo de eliminación Gaussiana (sin pivoteo) adaptado a la estructura de una matriz A cuyos únicos elementos que pueden ser no nulos son a_{1n} , a_{n1} y a_{ij} con $|i - j| \leq 1$.
12. Muestre que si P es una matriz de permutación, entonces $P^T P = P P^T = I$
13. Calcule el costo computacional (en flops) para obtener la inversa de una matriz (tome en cuenta las entradas nulas de los vectores canónicos).
14. En una red en equilibrio los flujos entrantes y salientes en cada nodo deben ser iguales. Encuentre valores de flujos positivos para que la red esté en equilibrio.



¿Existe una única solución?

15. Toda circunferencia en el plano puede definirse implícitamente mediante la ecuación

$$x^2 + y^2 + ax + by + c = 0.$$

Dados tres puntos no colineales en el plano $\{(x_i, y_i)\}_{i=1}^3$, (i) escriba el sistema lineal para determinar los valores de a , b y c ; (ii) usando estos valores escriba la circunferencia en coordenadas polares.

Capítulo 3

Sensibilidad de sistemas lineales

Al momento de resolver el sistema lineal $Ax = b$ computacionalmente, por lo general lo que se termina resolviendo es $(A + \Theta)x = b + \vartheta$ donde $\Theta \in \mathbb{R}^{n \times n}$ y $\vartheta \in \mathbb{R}^n$ son pequeñas perturbaciones producidas por la aritmética finita del computador.

Para poder decir como varía la solución si variamos los datos, primero necesitamos introducir como medir las variaciones en vectores y en matrices.

3.1. Normas

Como se trabajará solamente con vectores o matrices, en lo que sigue suponga que $\mathcal{X}$ es $\mathbb{R}^n$ o $\mathbb{R}^{m \times n}$.

Definición 3.1 Una norma en $\mathcal{X}$ es una función $f : \mathcal{X} \mapsto \mathbb{R}$ tal que

1. $f(x) \geq 0$ para todo $x \in \mathcal{X}$ y $f(x) = 0$ si y solo si $x = 0$.
2. $f(x + y) \leq f(x) + f(y)$ para todo $x, y \in \mathcal{X}$ (f subaditiva).
3. $f(\alpha x) = |\alpha|f(x)$ para todo $\alpha \in \mathbb{R}$ y todo $x \in \mathcal{X}$ (f absolutamente homogénea).

Si f es una norma en $\mathcal{X}$, se usará la notación $f(x) = \|x\|$.

Proposición 3.2 Si f es una norma en $\mathcal{X}$, entonces

$$|f(y) - f(x)| \leq f(y - x),$$

para todo $x, y \in \mathcal{X}$.

Demostración. Como

$$f(x) = f(x - y + y) \leq f(x - y) + f(y)$$

y

$$f(y) = f(y - x + x) \leq f(y - x) + f(x),$$

se obtiene que

$$-f(y - x) \leq f(y) - f(x) \leq f(y - x).$$

■

3.1.1. Normas vectoriales

Considere $\mathcal{X} = \mathbb{R}^n$. Entre las normas vectoriales, la norma p es una de las más usadas y se define de esta forma: dado $x \in \mathbb{R}^n$ y $p \geq 1$

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p} \quad \text{si } p \in [1, \infty) \quad \text{y} \quad \|x\|_\infty = \max_{1 \leq i \leq n} |x_i|.$$

Veamos que es una norma vectorial.

Teorema 3.3 Si $1 \leq p \leq \infty$ entonces $\|\cdot\|_p$ es una norma.

Demostración. Claramente, si $1 \leq p \leq \infty$ entonces $\|x\|_p \geq 0$ y $\|x\|_p = 0$ si y solo si $x = 0$. Suponga primero que $p = \infty$. Si $\alpha \in \mathbb{R}$,

$$\|\alpha x\|_\infty = \max_{1 \leq i \leq n} |\alpha x_i| = \max_{1 \leq i \leq n} |\alpha| |x_i| = |\alpha| \|x\|_\infty.$$

Además, como $|x_i + y_i| \leq |x_i| + |y_i| \leq \|x\|_\infty + \|y\|_\infty$ entonces $\|x + y\|_\infty \leq \|x\|_\infty + \|y\|_\infty$.

Suponga ahora que $p \in [1, \infty)$. Para $\alpha \in \mathbb{R}$,

$$\|\alpha x\|_p = \left(\sum_{i=1}^n |\alpha x_i|^p \right)^{1/p} = |\alpha| \left(\sum_{i=1}^n |x_i|^p \right)^{1/p} = |\alpha| \|x\|_p.$$

Como la función $t \mapsto |t|^p$ es convexa, entonces para todo $\lambda \in [0, 1]$ vale que

$$|(1 - \lambda)t_0 + \lambda t_1|^p \leq (1 - \lambda)|t_0|^p + \lambda|t_1|^p.$$

Considere $\hat{x} = x/\|x\|_p$, $\hat{y} = y/\|y\|_p$ y $\lambda = \|y\|_p/(\|x\|_p + \|y\|_p)$, luego

$$\begin{aligned} \left(\frac{\|x + y\|_p}{\|x\|_p + \|y\|_p} \right)^p &= \left\| \frac{\|x\|_p}{\|x\|_p + \|y\|_p} \frac{x}{\|x\|_p} + \frac{\|y\|_p}{\|x\|_p + \|y\|_p} \frac{y}{\|y\|_p} \right\|_p^p \\ &= \|(1 - \lambda)\hat{x} + \lambda\hat{y}\|_p^p \\ &= \sum_{i=1}^n |(1 - \lambda)\hat{x}_i + \lambda\hat{y}_i|^p \\ &\leq \sum_{i=1}^n (1 - \lambda)|\hat{x}_i|^p + \lambda|\hat{y}_i|^p \\ &= (1 - \lambda)\|\hat{x}\|_p^p + \lambda\|\hat{y}\|_p^p \\ &= (1 - \lambda) + \lambda = 1. \end{aligned}$$

Obteniendo así la desigualdad¹ $\|x + y\|_p \leq \|x\|_p + \|y\|_p$. ■

Claramente, la norma Euclídea corresponde a $p = 2$. Una propiedad conocida de esta norma es la desigualdad de Cauchy-Schwarz

$$|x^T y| \leq \|x\|_2 \|y\|_2.$$

Para poder obtener una relación similar cualquier $p \geq 1$, deberemos utilizar la desigualdad de Young.

¹ conocida como desigualdad de Minkowski

Proposición 3.4 Si a y b son positivos y $p, q \in (1, \infty)$ tal que $1/p + 1/q = 1$, entonces

$$ab \leq \frac{1}{p}a^p + \frac{1}{q}b^q.$$

Demostración. Utilizando que la función exponencial es convexa, que $1 - 1/q = 1/p$ y considerando $t_0 = \log(a^p)$ y $t_1 = \log(b^q)$, obtenemos

$$\begin{aligned} ab &= (a^p)^{1/p} (b^q)^{1/q} = e^{\frac{1}{p}t_0} e^{\frac{1}{q}t_1} = e^{\left(1 - \frac{1}{q}\right)t_0 + \frac{1}{q}t_1} \\ &\leq \left(1 - \frac{1}{q}\right)e^{t_0} + \frac{1}{q}e^{t_1} = \frac{1}{p}a^p + \frac{1}{q}b^q. \end{aligned}$$

■

Con esto, podemos ver que vale la desigualdad de Hölder.

Teorema 3.5 Si $1 \leq p \leq \infty$, para todo $x, y \in \mathbb{R}^n$ vale que

$$|x^T y| \leq \|x\|_p \|y\|_q \quad \text{si} \quad \frac{1}{p} + \frac{1}{q} = 1, \quad (3.1)$$

donde $q = 1$ si $p = \infty$.

Demostración. Si $p = \infty$ y $q = 1$,

$$|x^T y| \leq \sum_{i=1}^n |x_i| |y_i| \leq \|x\|_\infty \sum_{i=1}^n |y_i| = \|x\|_\infty \|y\|_1.$$

Suponga ahora que $1 < p < \infty$. Como la desigualdad vale trivialmente para x o y nulos, considere $x \neq 0$, $y \neq 0$ y defina $\tilde{x} = x/\|x\|_p$, $\tilde{y} = y/\|y\|_q$. Utilizando la desigualdad de Young se obtiene que


$$\begin{aligned} \frac{|x^T y|}{\|x\|_p \|y\|_q} &= |\tilde{x}^T \tilde{y}| \leq \sum_{i=1}^n |\tilde{x}_i| |\tilde{y}_i| \leq \frac{1}{p} \sum_{i=1}^n |\tilde{x}_i|^p + \frac{1}{q} \sum_{i=1}^n |\tilde{y}_i|^q \\ &= \frac{1}{p} \|\tilde{x}\|_p^p + \frac{1}{q} \|\tilde{y}\|_q^q = \frac{1}{p} + \frac{1}{q} = 1. \end{aligned}$$

En consecuencia, $|x^T y| \leq \|x\|_p \|y\|_q$. ■


Los números p y q tales que $1/p + 1/q = 1$ son llamados conjugados. Para el caso particular $p = q = 2$, de la desigualdad de Hölder recobramos la desigualdad de Cauchy-Schwarz.

Ejemplo 3.6 Veamos como interpretar las normas p más usadas. Supongamos que se quiere medir la distancia entre $x = (2, 1)$ e $y = (4, 5)$.


La norma 2, conocida como norma Euclídea, mide la distancia en línea recta: $\|y - x\|_2 = \sqrt{20}$,



La norma 1, conocida como norma de Manhattan, mide la distancia en cantidad mínima de cuadras que uno debe recorrer: $\|y - x\|_1 = 6$,



La norma infinito, conocida como la norma de Chebyshev, mide la distancia en pasos mínimos que debe realizar el rey en un tablero de ajedrez: $\|y - x\|_\infty = 4$,



Veamos que las normas en $\mathbb{R}^n$ son equivalentes.

Teorema 3.7 Si f es una norma en $\mathbb{R}^n$, entonces existen $\alpha, \beta > 0$ tales que

$$\alpha\|x\|_2 \leq f(x) \leq \beta\|x\|_2,$$

para todo $x \in \mathbb{R}^n$.

Demostración. Sea $\mathcal{S} = \{x \in \mathbb{R}^n \mid \|x\|_2 = 1\}$. Veamos que existe β tal que $f(x) \leq \beta$ para todo $x \in \mathcal{S}$. Si $m = \max_{1 \leq i \leq n} f(e^i)$, entonces

$$f(x) = f\left(\sum_{i=1}^n x_i e^i\right) \leq \sum_{i=1}^n |x_i| f(e^i) \leq m \sum_{i=1}^n |x_i|.$$

Como para todo i vale que $|x_i| \leq \|x\|_2 = 1$ entonces la desigualdad vale con $\beta = mn$.

Note que f es continua en $\mathbb{R}^n$, pues combinando Proposición 3.2 y el resultado anterior, se obtiene $f(0) = 0$ y para $y \neq x$

$$|f(y) - f(x)| \leq f(y - x) = \|y - x\|_2 f\left(\frac{y - x}{\|y - x\|_2}\right) \leq \beta\|y - x\|_2.$$

Defina $\alpha = \inf_{x \in \mathcal{S}} f(x)$. Si $\alpha = 0$, por definición de ínfimo, existe $\{x^k\} \subset \mathcal{S}$ tal que $f(x^k) \leq 1/k$. Como $\mathcal{S}$ es cerrado y acotado, existe $\bar{x} \in \mathcal{S}$ y una subsucesión $\{x^{k_j}\}$ de $\{x^k\}$ tal que $\lim_{j \rightarrow \infty} x^{k_j} = \bar{x}$. Entonces

$$f(\bar{x}) = \lim_{j \rightarrow \infty} f(x^{k_j}) \leq \lim_{j \rightarrow \infty} \frac{1}{k_j} = 0.$$

Usando que f es una norma, se obtiene que $\bar{x} = 0$, contradiciendo el hecho que $\bar{x} \in \mathcal{S}$. Por lo tanto $\alpha > 0$.

Ahora, si $x \neq 0$ se tiene

$$\alpha \leq f\left(\frac{x}{\|x\|_2}\right) \leq \beta,$$

concluyendo que $\alpha\|x\|_2 \leq f(x) \leq \beta\|x\|_2$. La desigualdad es trivial para $x = 0$. ■

Corolario 3.8 Si f y g son normas en $\mathbb{R}^n$, entonces existen $\alpha_{fg}, \beta_{fg} > 0$ tales que

$$\alpha_{fg} g(x) \leq f(x) \leq \beta_{fg} g(x),$$

para todo $x \in \mathbb{R}^n$.

Demostración. Usando el Teorema 3.7, se obtiene que

$$\alpha_f\|x\|_2 \leq f(x) \leq \beta_f\|x\|_2, \quad \alpha_g\|x\|_2 \leq g(x) \leq \beta_g\|x\|_2.$$

Por lo tanto

$$\frac{\alpha_f}{\beta_g} g(x) \leq \alpha_f\|x\|_2 \leq f(x) \leq \beta_f\|x\|_2 \leq \frac{\beta_f}{\alpha_g} g(x).$$

■

Ejemplo 3.9

1. Si $A \in \mathbb{R}^{n \times n}$ es una matriz simétrica y definida positiva, entonces $\|\cdot\|_A$ tal que $\|x\|_A = \sqrt{x^T A x}$ es una norma en $\mathbb{R}^n$.
2. Si $B \in \mathbb{R}^{m \times n}$ tiene rango n (tiene columnas linealmente independientes) y $\|\cdot\|$ es una norma en $\mathbb{R}^m$, entonces $\|\cdot\|_B$ tal que $\|x\|_B = \|Bx\|$ es una norma en $\mathbb{R}^n$.
3. Sea $\mathcal{B}$ un conjunto convexo, cerrado, acotado, con interior no vacío y simétrico (i.e., $x \in \mathcal{B} \Rightarrow -x \in \mathcal{B}$), entonces el funcional de Minkowski

$$\gamma(x) = \inf \left\{ \lambda > 0 \mid \frac{x}{\lambda} \in \mathcal{B} \right\},$$

es una norma.

3.1.2. Normas matriciales

Considere $\mathcal{X} = \mathbb{R}^{m \times n}$. En algunos casos se identificará el espacio $\mathbb{R}^{m \times n}$ con $\mathbb{R}^{mn}$. Para ser mas precisos se usará la función $\text{vec}_{mn} : \mathbb{R}^{m \times n} \mapsto \mathbb{R}^{mn}$ que dada una matriz A los elementos del vector $\text{vec}_{mn}(A)$ son las entradas de A ordenadas columna a columna. Note que esta función tiene su inversa bien definida. Por lo general la dimensión de filas y columnas quedará claro por el contexto, en consecuencia usaremos $\text{vec}(A)$ en vez de $\text{vec}_{mn}(A)$.

Ejemplo 3.10 Si

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \quad \text{entonces} \quad \text{vec}(A) = \begin{bmatrix} 1 \\ 4 \\ 2 \\ 5 \\ 3 \\ 6 \end{bmatrix}.$$

Cuando se usan normas matriciales, además de las propiedades básicas existe otra propiedad que suele ser de utilidad.

Definición 3.11 Se dirá que $\|\cdot\|$, norma matricial en $\mathbb{R}^{m \times n}$, es submultiplicativa si

$$\|AB\| \leq \|A\| \|B\|.$$

Entre las normas matriciales mas usadas está la norma de Frobenius: dada $A \in \mathbb{R}^{m \times n}$

$$\|A\|_F = \sqrt{\text{tr}(A^T A)} = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}$$

Se puede ver que $\|A\|_F = \|\text{vec}(A)\|_2$.

Proposición 3.12 La norma de Frobenius, $\|\cdot\|_F$, es una norma matricial submultiplicativa.

Demostración. Note que la función vec es lineal, o sea si $\alpha \in \mathbb{R}$ y $A, B \in \mathbb{R}^{m \times n}$ entonces $\text{vec}(A + \alpha B) = \text{vec}(A) + \alpha \text{vec}(B)$. Por lo tanto, $\|A\|_F = \|\text{vec}(A)\|_2 \geq 0$ y $\|A\|_F = 0$ si y solo si $A = 0$,

$$\|\alpha A\|_F = \|\text{vec}(\alpha A)\|_2 = \|\alpha \text{vec}(A)\|_2 = |\alpha| \|\text{vec}(A)\|_2 = |\alpha| \|A\|_F$$

y

$$\begin{aligned} \|A + B\|_F &= \|\text{vec}(A + B)\|_2 = \|\text{vec}(A) + \text{vec}(B)\|_2 \\ &\leq \|\text{vec}(A)\|_2 + \|\text{vec}(B)\|_2 = \|A\|_F + \|B\|_F. \end{aligned}$$

Probando así que $\|\cdot\|_F$ es una norma matricial. Para ver que es submultiplicativa, suponga $A \in \mathbb{R}^{m \times n}$ y $B \in \mathbb{R}^{n \times p}$. Denote por $a^i \in \mathbb{R}^n$, $i = 1, \dots, m$ las columnas de A^T y por $b^j \in \mathbb{R}^n$, $j = 1, \dots, p$ las columnas de B , entonces para $C = AB$ se tiene $c_{ij} = (a^i)^T b^j$. Con esto, usando la desigualdad de Cauchy-Schwarz, se concluye que

$$\begin{aligned} \|AB\|_F^2 &= \sum_{i=1}^m \sum_{j=1}^p |(a^i)^T b^j|^2 \leq \sum_{i=1}^m \sum_{j=1}^p \|a^i\|_2^2 \|b^j\|_2^2 = \sum_{i=1}^m \|a^i\|_2^2 \sum_{j=1}^p \|b^j\|_2^2 \\ &= \|\text{vec}(A)\|_2^2 \|\text{vec}(B)\|_2^2 = \|A\|_F^2 \|B\|_F^2. \end{aligned}$$

■

Otra familia de normas matriciales muy usadas son las *normas matriciales inducidas*, esto es, dada una norma vectorial $\|\cdot\|$ (norma en $\mathbb{R}^n$ y $\mathbb{R}^m$), defino $\|\cdot\|$ para elementos en $\mathbb{R}^{m \times n}$ como

$$\|A\| = \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

Claramente, para todo $x \in \mathbb{R}^n$ se tendrá que $\|Ax\| \leq \|A\| \|x\|$. Es un buen ejercicio demostrar que efectivamente $\|\cdot\|$ es una norma matricial, que es submultiplicativa y que puede definirse como $\|A\| = \max_{\|x\|=1} \|Ax\|$.

En particular, se verá como expresar las normas matriciales inducidas por $\|\cdot\|_1$, $\|\cdot\|_\infty$ y $\|\cdot\|_2$. Para ello se necesita la siguiente definición.

Definición 3.13 Dada $A \in \mathbb{R}^{n \times n}$, se dirá que el radio espectral de A es el valor máximo de los módulos de los autovalores $\lambda \in \mathbb{C}$ de A . O sea

$$\rho(A) = \max\{|\lambda| \mid \det(A - \lambda I) = 0\}.$$

Proposición 3.14 Si $A \in \mathbb{R}^{m \times n}$, entonces

- $\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|.$
- $\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|.$

$$\blacksquare \|A\|_2 = \sqrt{\rho(A^T A)}.$$

Demostración. Para $\|\cdot\|_1$, tome $x \in \mathbb{R}^n$, entonces

$$\begin{aligned} \|Ax\|_1 &= \sum_{i=1}^m \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \sum_{j=1}^n \sum_{i=1}^m |a_{ij}| |x_j| \\ &\leq \left(\max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| \right) \sum_{j=1}^n |x_j| = \left(\max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| \right) \|x\|_1. \end{aligned}$$

Como x era arbitrario, dividiendo por $\|x\|_1$ y tomando supremo, obtengo que $\|A\|_1 \leq \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$. Para ver que la desigualdad opuesta vale, tome l tal que $\sum_{i=1}^m |a_{il}| = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$. Usando que el vector canónico e^l cumple $\|e^l\|_1 = 1$, se obtiene

$$\max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| = \sum_{i=1}^m |a_{il}| = \|Ae^l\|_1 \leq \sup_{x \neq 0} \frac{\|Ax\|_1}{\|x\|_1} = \|A\|_1.$$

Para $\|\cdot\|_\infty$, tome $x \in \mathbb{R}^n$, entonces

$$\begin{aligned} \|Ax\|_\infty &= \max_{1 \leq i \leq m} \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}| |x_j| \\ &\leq \left(\max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}| \right) \|x\|_\infty. \end{aligned}$$

Como x era arbitrario, dividiendo por $\|x\|_\infty$ y tomando supremo, obtengo que $\|A\|_\infty \leq \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$. Para ver que la desigualdad opuesta vale, tome l tal que $\sum_{j=1}^n |a_{lj}| = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$. Defino $\hat{x}$ tal que $\hat{x}_j = 1$ si $a_{lj} \geq 0$ y $\hat{x}_j = -1$ si $a_{lj} < 0$. Como $|\hat{x}_j| = 1$,

$$\left| \sum_{j=1}^n a_{lj} \hat{x}_j \right| \leq \sum_{j=1}^n |a_{lj}| \leq \sum_{j=1}^n |a_{lj}| = \sum_{j=1}^n a_{lj} \hat{x}_j = \left| \sum_{j=1}^n a_{lj} \hat{x}_j \right|.$$

Entonces, tomando máximo, concluimos que $\|A\hat{x}\|_\infty = \sum_{j=1}^n |a_{lj}|$. Usando que $\|\hat{x}\|_\infty = 1$, se obtiene

$$\max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}| = \sum_{j=1}^n |a_{lj}| = \|A\hat{x}\|_\infty \leq \sup_{x \neq 0} \frac{\|Ax\|_\infty}{\|x\|_\infty} = \|A\|_\infty.$$

Para $\|\cdot\|_2$, como $A^T A$ es simétrica se obtiene que sus autovalores son reales y dado un autovalor λ existe $v \in \mathbb{R}^n$, $v \neq 0$, tal que $A^T A v = \lambda v$, entonces

$$\lambda \|v\|_2^2 = v^T (\lambda v) = v^T A^T A v = \|Av\|_2^2.$$

Por lo tanto $\lambda \geq 0$ y

$$\sqrt{\lambda} = \frac{\|Av\|_2}{\|v\|_2} \leq \sup_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \|A\|_2.$$

Concluyendo que $\sqrt{\rho(A^T A)} \leq \|A\|_2$. Para probar la desigualdad contraria se usará que $\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2$, que es lo mismo que decir que la función

$$f(x) = \frac{\|Ax\|_2^2}{\|x\|_2^2}$$

alcanza su valor máximo en un $\hat{x}$ tal que $\|\hat{x}\|_2 = 1$ y, en consecuencia, $\|A\hat{x}\|_2^2 = f(\hat{x}) = \|A\|_2^2$. Además, se debe cumplir que $\nabla f(\hat{x}) = 0$. Para calcular el gradiente de f note que: si $h(x) = \|x\|_2^2$ entonces $\nabla h(x) = 2x$ y si $g(x) = h(Ax)$ entonces $\nabla g(x) = A^T \nabla h(Ax) = 2A^T Ax$. Por lo tanto,

$$\nabla f(x) = \frac{2\|x\|_2^2 A^T Ax - 2\|Ax\|_2^2 x}{\|x\|_2^4} \quad \text{y} \quad 0 = \nabla f(\hat{x}) = 2A^T A\hat{x} - 2\|A\|_2^2 \hat{x}.$$

Obteniendo que $A^T A\hat{x} = \|A\|_2^2 \hat{x}$, o sea, $\|A\|_2^2$ es un autovalor de $A^T A$. Entonces $\|A\|_2^2 \leq \rho(A^T A)$, esto es, $\|A\|_2 \leq \sqrt{\rho(A^T A)}$. ■

Como el espacio de matrices $\mathbb{R}^{m \times n}$ puede identificarse con $\mathbb{R}^{mn}$, se obtiene que las normas matriciales son equivalentes.

3.2. Errores

Como las normas vectoriales son equivalentes al igual que las normas matriciales, se puede medir la sensibilidad de los sistemas lineales usando una norma genérica $\|\cdot\|$. Para evitar ambigüedades, la norma matricial $\|\cdot\|$ será aquella inducida por la norma vectorial $\|\cdot\|$.

Definición 3.15 Si $\hat{x} \in \mathbb{R}^n$ es una aproximación de $x \in \mathbb{R}^n$ y $\|\cdot\|$ es una norma en $\mathbb{R}^n$, se dirá que:

- $\|\hat{x} - x\|$ es el error absoluto de $\hat{x}$,
- $\frac{\|\hat{x} - x\|}{\|x\|}$ es el error relativo de $\hat{x}$.

Por ejemplo, si $\alpha \in \mathbb{R}$ y $\beta = \alpha \pm 0.1\alpha$, entonces β tiene un error relativo de 0.1, o sea, del 10 % de α . Si se desea resolver $Ax = b$ y se perturba A o b , la perturbación que se obtendrá en la solución dependerá del condicionamiento de la matriz:

Definición 3.16 Si $A \in \mathbb{R}^{n \times n}$ y $\|\cdot\|$ es una norma matricial, el número de condición de A , $\kappa(A)$, es dado por

$$\kappa(A) = \|A\| \|A^{-1}\|$$

si A es no singular y $\kappa(A) = \infty$ si A es singular.

Ya que el número de condición depende de la norma usada, se denotará por κ_F cuando se use la norma de Frobenius y por κ_p cuando se use una norma p .

Interpretando $\kappa(A)$. Si $\|\cdot\|$ es una norma matricial y A es no singular, note que

$$\|A^{-1}\| = \sup_{y \neq 0} \frac{\|A^{-1}y\|}{\|y\|} = \sup_{x \neq 0} \frac{\|x\|}{\|Ax\|} = \frac{1}{\inf_{x \neq 0} \frac{\|Ax\|}{\|x\|}} = \frac{1}{\min_{\|x\|=1} \|Ax\|}.$$

Entonces,

$$\kappa(A) = \frac{\sup_{x \neq 0} \frac{\|Ax\|}{\|x\|}}{\inf_{x \neq 0} \frac{\|Ax\|}{\|x\|}} = \frac{\max_{\|x\|=1} \|Ax\|}{\min_{\|x\|=1} \|Ax\|}.$$

Ejemplo 3.17 Sea $A = \begin{bmatrix} 1000 & 999 \\ 999 & 998 \end{bmatrix}$, entonces $A^{-1} = \begin{bmatrix} -998 & 999 \\ 999 & -1000 \end{bmatrix}$. Además, $\|A\|_{\infty} = 1999$ y $\|A^{-1}\|_{\infty} = 1999$. Sean

$$\hat{x} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \tilde{y} = \frac{1}{1999} A \hat{x} = \frac{1}{1999} \begin{bmatrix} 1999 \\ 1997 \end{bmatrix}.$$

Entonces $\|\hat{x}\|_{\infty} = 1$ y $\|A\hat{x}\|_{\infty} = 1999 = \|A\|_{\infty}$. Por lo tanto, $\hat{x}$ es la dirección de máxima magnificación de A en $\|\cdot\|_{\infty}$. Además, $\|\tilde{y}\|_{\infty} = 1$ y $\|A^{-1}\tilde{y}\|_{\infty} = \frac{1}{1999} = \frac{1}{\|A\|_{\infty}} = \min_{\|y\|_{\infty}=1} \|A^{-1}y\|_{\infty}$. Por lo tanto, $\tilde{y}$ es la dirección de mínima magnificación de A^{-1} en $\|\cdot\|_{\infty}$. Sean

$$\hat{y} = \begin{bmatrix} -1 \\ 1 \end{bmatrix}, \quad \tilde{x} = \frac{1}{1999} A^{-1} \hat{y} = \frac{1}{1999} \begin{bmatrix} 1997 \\ -1999 \end{bmatrix}.$$

Entonces $\|\hat{y}\|_{\infty} = 1$ y $\|A^{-1}\hat{y}\|_{\infty} = 1999 = \|A^{-1}\|_{\infty}$. Por lo tanto, $\hat{y}$ es la dirección de máxima magnificación de A^{-1} en $\|\cdot\|_{\infty}$. Además, $\|\tilde{x}\|_{\infty} = 1$ y $\|A\tilde{x}\|_{\infty} = \frac{1}{1999} = \frac{1}{\|A^{-1}\|_{\infty}} = \min_{\|x\|_{\infty}=1} \|Ax\|_{\infty}$. Por lo tanto, $\tilde{x}$ es la dirección de mínima magnificación de A en $\|\cdot\|_{\infty}$. En consecuencia,

$$\kappa_{\infty}(A) = \frac{\|A\hat{x}\|_{\infty}}{\|A\tilde{x}\|_{\infty}} = \frac{\|A^{-1}\hat{y}\|_{\infty}}{\|A^{-1}\tilde{y}\|_{\infty}}.$$

Ejemplo 3.18 Para cualquier matriz A ,

$$\kappa_2(A) = \frac{\max_{\|x\|_2=1} \sqrt{x^T A^T A x}}{\min_{\|x\|_2=1} \sqrt{x^T A^T A x}} = \frac{\sqrt{\lambda_{\max}(A^T A)}}{\sqrt{\lambda_{\min}(A^T A)}},$$

donde $\lambda_{\max}(A^T A)$ y $\lambda_{\min}(A^T A)$ denotan los autovalores máximo y mínimo de $A^T A$.

El siguiente resultado muestra que si perturbamos solamente el término no homogéneo, el error relativo de la solución del problema perturbado es proporcional al error relativo del término no homogéneo.

Teorema 3.19 Sea $A \in \mathbb{R}^{n \times n}$ no singular y $b \in \mathbb{R}^n$ no nulo. Si $Ax = b$ y $A\hat{x} = b + \vartheta$, entonces

$$\frac{\|\hat{x} - x\|}{\|x\|} \leq \kappa(A) \frac{\|\vartheta\|}{\|b\|}.$$

Demostración. Sea $\zeta = \hat{x} - x$, luego $b + \vartheta = A(x + \zeta) = Ax + A\zeta = b + A\zeta$. Entonces $A\zeta = \vartheta$, o equivalentemente, $\zeta = A^{-1}\vartheta$. Obteniendo que $\|\zeta\| \leq \|A^{-1}\|\|\vartheta\|$.

Por otro lado, $b = Ax$ implica que $\|b\| \leq \|A\|\|x\|$ y por lo tanto $\frac{1}{\|x\|} \leq \|A\|\frac{1}{\|b\|}$. Combinando esto con la desigualdad anterior, concluimos que

$$\frac{\|\zeta\|}{\|x\|} \leq \|A\|\|A^{-1}\|\frac{\|\vartheta\|}{\|b\|}.$$

■

Definición 3.20 El residuo de una aproximación $\hat{x}$ de la solución de $Ax = b$ es el número $\|b - A\hat{x}\|$ y llamaremos vector residuo a $b - A\hat{x}$.

Por lo tanto, dado $\hat{x}$ se obtiene $A\hat{x} = b + A\hat{x} - b = b + \vartheta$ con $\vartheta = -(b - A\hat{x})$. Usando el resultado anterior,

$$\frac{\|x - \hat{x}\|}{\|x\|} \leq \kappa(A) \frac{\|b - A\hat{x}\|}{\|b\|}.$$

De esta forma, se puede controlar el error relativo de la solución del problema mediante la disminución del residuo.

Si se tiene perturbación en la matriz, es importante garantizar que el sistema perturbado pueda resolverse. El siguiente resultado garantiza que para pequeñas perturbaciones la no singularidad se preserva.

Teorema 3.21 Si $A \in \mathbb{R}^{n \times n}$ es no singular y

$$\frac{\|\Theta\|}{\|A\|} < \frac{1}{\kappa(A)}$$

entonces $A + \Theta$ es no singular.

Demostración. Suponga que $A + \Theta$ es singular, o sea, existe $y \neq 0$ tal que $(A + \Theta)y = 0$. Como A es no singular, se obtiene que $y = -A^{-1}\Theta y$. Entonces $\|y\| \leq \|A^{-1}\|\|\Theta\|\|y\|$ y por lo tanto $1 \leq \|A^{-1}\|\|\Theta\|$. En consecuencia

$$\frac{1}{\kappa(A)} \leq \frac{\|A^{-1}\|\|\Theta\|}{\kappa(A)} = \frac{\|A^{-1}\|\|\Theta\|}{\|A\|\|A^{-1}\|} = \frac{\|\Theta\|}{\|A\|}.$$

■

Ahora, veamos que sucede si resolvemos el sistema linear con la matriz y el término no homogéneo perturbados.

Teorema 3.22 Sea $A \in \mathbb{R}^{n \times n}$ no singular, $\frac{\|\Theta\|}{\|A\|} < \frac{1}{\kappa(A)}$ y $b \in \mathbb{R}^n$ no nulo. Si $Ax = b$ y $(A + \Theta)\hat{x} = b + \vartheta$, entonces

$$\frac{\|\hat{x} - x\|}{\|x\|} \leq \frac{\kappa(A) \left(\frac{\|\Theta\|}{\|A\|} + \frac{\|\vartheta\|}{\|b\|} \right)}{1 - \kappa(A) \frac{\|\Theta\|}{\|A\|}}.$$

Demostración. Sea $\zeta = \hat{x} - x$, luego $b + \vartheta = (A + \Theta)(x + \zeta) = Ax + A\zeta + \Theta x + \Theta\zeta$, entonces $\zeta = A^{-1}(\vartheta - \Theta x - \Theta\zeta)$. Tomando norma en ambos miembros, se obtiene que $\|\zeta\| \leq \|A^{-1}\|(\|\vartheta\| + \|\Theta\|\|x\| + \|\Theta\|\|\zeta\|)$. Por lo tanto

$$\begin{aligned} (1 - \|A^{-1}\|\|\Theta\|)\|\zeta\| &\leq \|A^{-1}\|(\|\Theta\|\|x\| + \|\vartheta\|) \\ &= \kappa(A) \left(\frac{\|\Theta\|}{\|A\|} + \frac{\|\vartheta\|}{\|A\|\|x\|} \right) \|x\|. \end{aligned}$$

Como $\|b\| = \|Ax\| \leq \|A\|\|x\|$ entonces $\frac{1}{\|A\|\|x\|} \leq \frac{1}{\|b\|}$. Obteniendo así que

$$\left(1 - \kappa(A) \frac{\|\Theta\|}{\|A\|}\right) \frac{\|\zeta\|}{\|x\|} \leq \kappa(A) \left(\frac{\|\Theta\|}{\|A\|} + \frac{\|\vartheta\|}{\|b\|} \right)$$

■

3.3. Ejercicios

1. Demuestre que $\|x\|_2 \leq \|x\|_1 \leq \sqrt{n}\|x\|_2$.
2. Demuestre que para $p \geq 1$ y $x \in \mathbb{R}^n$ vale $\|x\|_p \leq \|x\|_1$. Concluya que
 - a) $\|x\|_\infty \leq \|x\|_p$.
 - b) $\|x\|_p \leq n^{1/p}\|x\|_\infty$.
 - c) $\lim_{p \rightarrow \infty} \|x\|_p = \|x\|_\infty$.
3. Grafique la bola unidad $\mathcal{B} = \{x \in \mathbb{R}^2 \mid \|x\| \leq 1\}$ para $\|\cdot\| = \|\cdot\|_1$, $\|\cdot\|_2$ y $\|\cdot\|_\infty$.
4. a) Dada una norma vectorial $\|\cdot\|$ en $\mathbb{R}^n$, ¿qué condiciones debe cumplir una matriz $A \in \mathbb{R}^{m \times n}$ para que la función $\|\cdot\|_A$ definida por $\|x\|_A = \|Ax\|$, $\forall x \in \mathbb{R}^n$ sea una norma vectorial?

b) Para $A \in \mathbb{R}^{n \times n}$ simétrica y definida positiva, se define $\|x\|_A = \sqrt{x^T A x}$. Demuestre que $\|\cdot\|_A$ es una norma vectorial en $\mathbb{R}^n$ y que $\sqrt{\lambda_{\min}(A)}\|x\|_2 \leq \|x\|_A \leq \sqrt{\lambda_{\max}(A)}\|x\|_2$, con $\lambda_{\min}(A)$, $\lambda_{\max}(A)$ el mínimo y máximo autovalor de A . ¿Qué ocurre si $A = I$?
5. La distancia Euclídea de un punto $x \in \mathbb{R}^n$ al conjunto $C = \{x \in \mathbb{R}^n \mid x_i \leq 0, i = 1, \dots, n\}$ puede definirse como

$$d(x) = \|\max\{0, x\}\|_2,$$

donde el máximo es tomado coordenada a coordenada.

- a) Demuestre que d cumple la desigualdad triangular.
- b) Encuentre una norma $\|\cdot\|$, tal que al cambiar $\|\cdot\|_2$ por $\|\cdot\|$, d no cumpla la desigualdad triangular.
6. Sea $\|\cdot\|$ una norma vectorial y sean $A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{n \times p}$. Pruebe que la norma matricial inducida por $\|\cdot\|$ satisface que:

a) es efectivamente una norma matricial.

b) $\|Ax\| \leq \|A\|\|x\|, \forall x \in \mathbb{R}^n$.

c) $\exists x \in \mathbb{R}^n, x \neq 0$ tal que $\|Ax\| = \|A\|\|x\|$.

d) $\|AB\| \leq \|A\|\|B\|$ (submultiplicatividad).

e) Si $A \in \mathbb{R}^{n \times n}$ es no singular, entonces $\|A\|\|A^{-1}\| \geq 1$.

f) $\rho(A) \leq \|A\|, \forall A \in \mathbb{R}^{n \times n}$, donde $\rho(A) = \max\{|\lambda| \mid \det(A - \lambda I) = 0\}$.

7. Si $A \in \mathbb{R}^{n \times n}$, entonces $\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2 = \max_{\|x\|_2=1, \|y\|_2=1} y^T Ax$.

8. Demuestre que $\|A\|_{\max} = \max_{1 \leq i \leq m, 1 \leq j \leq n} |a_{ij}|$ es una norma matricial en $\mathbb{R}^{m \times n}$, pero no es submultiplicativa.

9. Si $A \in \mathbb{R}^{m \times n}$, demuestre que:

a) $\|A\|_{\max} \leq \|A\|_2 \leq \|A\|_F \leq \sqrt{mn}\|A\|_{\max}$.

b) $\frac{1}{\sqrt{n}}\|A\|_{\infty} \leq \|A\|_2 \leq \sqrt{m}\|A\|_{\infty}$.

c) $\frac{1}{\sqrt{m}}\|A\|_1 \leq \|A\|_2 \leq \sqrt{n}\|A\|_1$.

10. Pruebe las siguientes afirmaciones:

a) $\kappa(A) = \kappa(A^{-1})$,

b) $\kappa(AB) \leq \kappa(A)\kappa(B)$, para toda $A, B \in \mathbb{R}^{n \times n}$ y $\|\cdot\|$ submultiplicativa,

c) Si A es una matriz ortogonal, entonces $\kappa_2(A) = 1$.

11. Considere el sistema

$$\begin{bmatrix} 1000 & 999 \\ 999 & 998 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1999 \\ 1997 \end{bmatrix}.$$

El vector $\hat{x} = [20.97, -18.99]^T$ es una mala aproximación de la solución. Pruebe que los residuos $r_1(\hat{x})$, $r_2(\hat{x})$ y $r_{\infty}(\hat{x})$ son sin embargo pequeños.

12. Sea $A = \begin{bmatrix} 375 & 374 \\ 752 & 750 \end{bmatrix}$.

a) Calcule A^{-1} y $\kappa_{\infty}(A)$.

b) Encuentre $b, \delta b, x$ y δx tales que $Ax = b$, $A(x + \delta x) = b + \delta b$, $\frac{\|\delta b\|_{\infty}}{\|b\|_{\infty}}$ sea pequeño y $\frac{\|\delta x\|_{\infty}}{\|x\|_{\infty}}$ sea grande.

c) Encuentre $b, \delta b, x$ y δx tales que $Ax = b$, $A(x + \delta x) = b + \delta b$, $\frac{\|\delta x\|_{\infty}}{\|x\|_{\infty}}$ sea pequeño y $\frac{\|\delta b\|_{\infty}}{\|b\|_{\infty}}$ sea grande.

Capítulo 4

Residuos mínimos

Muchas veces el sistema lineal $Ax = b$, con $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$, no posee solución. Una buena opción es hacer el residuo, lo más pequeño posible. En este caso, el problema matemático sería

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \|Ax - b\|,$$

donde $\|\cdot\|$ es una norma en $\mathbb{R}^m$. Claramente, el problema a resolver dependerá de la norma usada.

Ejemplo 4.1 Suponga que se tienen los pares ordenados $\{(t_i, b_i)\}_{i=1}^m$ para m grande y se quiere aproximar estos datos por una función f , o sea, $f(t_i) \approx b_i$. Para resolver este problema computacionalmente, asumimos que f pertenece a un espacio de funciones generado por una base finita $\{\phi_1, \dots, \phi_n\}$, de esta manera existen $x_j \in \mathbb{R}$ tales que $f(t) = \sum_{j=1}^n x_j \phi_j(t)$ para todo t . Con esto, lo que deseamos es encontrar x_j , $j = 1, \dots, n$ tales que

$$\sum_{j=1}^n x_j \phi_j(t_i) \approx b_i, \quad i = 1, \dots, m.$$

Matricialmente, se quiere que $Ax - b$ sea lo más próximo a cero, donde

$$A = \begin{bmatrix} \phi_1(t_1) & \phi_2(t_1) & \dots & \phi_n(t_1) \\ \phi_1(t_2) & \phi_2(t_2) & \dots & \phi_n(t_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_1(t_m) & \phi_2(t_m) & \dots & \phi_n(t_m) \end{bmatrix}.$$

Por ejemplo, si f es un polinomio de grado a lo sumo $n-1$ se puede tomar la base de monomios,

$$\phi_j(t) = t^{j-1}.$$

Si f es periódica en $[-\pi, \pi]$ y $t_1 = -\pi$, $t_m = \pi$ entonces se puede considerar la base

$$\phi_0(t) = \frac{1}{2} \quad \text{y para } j \geq 1 \quad \phi_j(t) = \begin{cases} \cos\left(\frac{j}{2}t\right), & \text{si } j \text{ es par,} \\ \sin\left(\frac{j+1}{2}t\right), & \text{si } j \text{ es impar.} \end{cases}$$

En este capítulo, se verá cómo minimizar $\|Ax - b\|_2$, $\|Ax - b\|_1$ y $\|Ax - b\|_\infty$.

4.1. Cuadrados mínimos

Suponga que se desea minimizar $\|Ax - b\|_2$. La solución $\bar{x} \in \mathbb{R}^n$ que minimiza $\|Ax - b\|_2$ es igual a la que minimiza $\|Ax - b\|_2^2$, con el agregado que esta última es diferenciable como función de x . Por lo tanto, esta sección se basará en

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \|Ax - b\|_2^2.$$

De aquí que el problema de residuo mínimo en $\|\cdot\|_2$ recibe el nombre de *cuadrados mínimos*. Las técnicas usadas para resolver este problema de manera directa están relacionadas al proceso de ortogonalización.

Definición 4.2 Un conjunto de vectores $\{x^1, \dots, x^p\}$ en $\mathbb{R}^m$ se dice *ortogonal* si $(x^i)^T x^j = 0$ para $i \neq j$ y *ortonormal* si además vale $(x^i)^T x^i = 1$.

El complemento ortogonal de un subespacio $\mathcal{K} \subseteq \mathbb{R}^m$ es

$$\mathcal{K}^\perp = \{y \in \mathbb{R}^m \mid y^T x = 0, \quad \forall x \in \mathcal{K}\}.$$

Una matriz $Q \in \mathbb{R}^{m \times m}$ se dice *ortogonal* si $Q^T = Q^{-1}$, o sea $Q^T Q = Q Q^T = I$, por lo tanto $Q = [q^1 \dots q^m]$ es ortogonal si y solo si sus columnas forman una base ortonormal de $\mathbb{R}^m$.

Note que si $Q \in \mathbb{R}^{m \times n}$, con $m \geq n$, tiene sus columnas ortonormales se obtiene que $Q^T Q = I$ y por lo tanto $(Qy)^T Qx = y^T x$ para todo $x, y \in \mathbb{R}^n$. Concluyendo que las matrices con columnas ortonormales preservan $\|\cdot\|_2$, i.e., para cualquier $x \in \mathbb{R}^n$,

$$\|Qx\|_2 = \|x\|_2.$$

Hay que resaltar que si $m > n$ entonces $Q Q^T \neq I$ y por lo tanto no se puede intercambiar Q por Q^T en la ecuación anterior.

Ya que nuestra finalidad es minimizar $\|Ax - b\|_2$ y

$$\|Ax - b\|_2 = \|Q^T(Ax - b)\|_2 = \|Q^T Ax - Q^T b\|_2,$$

para $Q^T \in \mathbb{R}^{p \times m}$ con columnas ortonormales, las técnicas siguientes se basan en construir Q ortogonal tal que $Q^T A$ sea triangular superior con elementos diagonales no negativos. Al igual que el proceso de triangularización usando transformaciones de Gauss, se procederá aplicando transformaciones ortogonales actuando columna a columna de manera de obtener ceros en los elementos por debajo de la diagonal.

Si $R = Q^T A$ con $Q \in \mathbb{R}^{m \times m}$ ortogonal se obtiene que $A = QR$. Este tipo de proceso se conoce como descomposición QR. Se verán dos técnicas para construir la matriz ortogonal Q , usando rotaciones y usando reflexiones.

4.1.1. Rotaciones de Givens

En esta técnica se irán rotando los elementos de dos en dos, siendo uno de ellos el elemento diagonal de la columna y el otro un elemento por debajo de la diagonal. Por lo tanto, se tiene

$$Q = \begin{bmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{bmatrix}$$

y se desea encontrar $c = \cos(\theta)$, $s = \sin(\theta)$ tales que

$$\begin{bmatrix} y \\ 0 \end{bmatrix} = Q \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} cx_1 - sx_2 \\ sx_1 + cx_2 \end{bmatrix}.$$

Como $c^2 + s^2 = 1$ y utilizando que $sx_1 = -cx_2$ por la segunda ecuación, entonces se obtiene

$$x_1^2 = (c^2 + s^2)x_1^2 = c^2x_1^2 + s^2x_1^2 = c^2x_1^2 + c^2x_2^2 = c^2(x_1^2 + x_2^2).$$

Por lo tanto, si

$$c = \frac{x_1}{\sqrt{x_1^2 + x_2^2}}, \quad s = \frac{-x_2}{\sqrt{x_1^2 + x_2^2}},$$

entonces $y = cx_1 - sx_2 = \sqrt{x_1^2 + x_2^2}$. En caso de tener $x_1 = x_2 = 0$, definimos $c = 1$ y $s = 0$.

Intentando disminuir errores numéricos, este procedimiento puede escribirse con el siguiente pseudocódigo:

Algoritmo 13 (rotacion de Givens)

Entradas: $x_1, x_2 \in \mathbb{R}$. *Salidas:* $c, s \in \mathbb{R}$.

Paso 0: Si $|x_1| + |x_2| = 0$, definir $c = 1$, $s = 0$ e ir al paso 2.

Paso 1: Si $|x_2| > |x_1|$, definir

$$\begin{aligned} \tau &= -x_1/x_2, \\ s &= -\text{sign}(x_2)/\sqrt{1 + \tau^2}, \\ c &= s\tau, \end{aligned}$$

Sino, definir

$$\begin{aligned} \tau &= -x_2/x_1, \\ c &= \text{sign}(x_1)/\sqrt{1 + \tau^2}, \\ s &= c\tau. \end{aligned}$$

Paso 2: Retornar c y s .

Este procedimiento tiene un costo operacional máximo de 6 flops.

En general, si $x \in \mathbb{R}^m$ defino $G_{ki} \in \mathbb{R}^{m \times m}$ matriz de rotación de las coordenadas k e i , i.e.,

$$G_{ki} = \left[\begin{array}{c|cc|c} I & & & \\ \hline & c & -s & \\ & & I & \\ & s & c & \\ \hline & & & I \end{array} \right] \begin{array}{l} \rightarrow (i) \\ \rightarrow (k) \end{array},$$

donde c y s son obtenidos aplicando el Algoritmo 13 al par (x_i, x_k) . De aquí, si $y = G_{ki}x$ entonces $y_i = cx_i - sx_k = \sqrt{x_i^2 + x_k^2}$, $y_k = sx_i + cx_k = 0$ y $y_j = x_j$ para $j \neq i, k$.

Suponga $A \in \mathbb{R}^{m \times n}$ y que se han aplicado rotaciones de Givens hasta obtener

$$G_{m,j-1} \dots G_{31} G_{21} A = \begin{bmatrix} \tilde{a}_{11} & \dots & \tilde{a}_{1,j-1} & \tilde{a}_{1j} & \dots & \tilde{a}_{1n} \\ 0 & \ddots & \vdots & \vdots & \dots & \vdots \\ \vdots & & \tilde{a}_{j-1,j-1} & \tilde{a}_{j-1,j} & \dots & \tilde{a}_{j-1,n} \\ \vdots & & 0 & \tilde{a}_{jj} & \dots & \tilde{a}_{jn} \\ \vdots & & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & \tilde{a}_{mj} & \dots & \tilde{a}_{mn} \end{bmatrix}.$$

Para obtener ceros en los elementos por debajo de la diagonal en la columna j , se deberá multiplicar por $G_{mj} \dots G_{j+1,j}$, donde G_{kj} hace cero el elemento $\tilde{a}_{kj}$ y se define tomando c y s dados por el Algoritmo 13 aplicado a $(\tilde{a}_{jj}, \tilde{a}_{kj})$. En este caso, el nuevo elemento $\tilde{a}_{jj}$ será $\sqrt{\tilde{a}_{jj}^2 + \tilde{a}_{kj}^2}$.

Note que para obtener una matriz triangular superior con elementos diagonales no negativos, solo se necesitan generar ceros por debajo de la diagonal y entradas diagonales no negativas en las primeras $m - 1$ columnas si $m \leq n$ y en las n columnas si $m > n$. Además, para $m \leq n$ se deberá aplicar una matriz, denotada por $G_{m+1,m}$, igual a la identidad si $\tilde{a}_{mm} \geq 0$ o la identidad cambiando su última entrada diagonal por -1 si $\tilde{a}_{mm} < 0$. Este procedimiento nos garantiza el siguiente resultado.

Teorema 4.3 Si $A \in \mathbb{R}^{m \times n}$, entonces existe $Q \in \mathbb{R}^{m \times m}$ ortogonal y $R \in \mathbb{R}^{m \times n}$ triangular superior con elementos diagonales no negativos tal que $A = QR$.

Demostración. Por construcción $G_{ij} \in \mathbb{R}^{m \times m}$ es ortogonal y al aplicarla en $\tilde{A}$ hace $\tilde{a}_{ij} = 0$. Por lo tanto, si $m \leq n$,

$$\begin{aligned} R &= G_{m+1,m} G_{m,m-1} \dots G_{32} G_{m1} \dots G_{31} G_{21} A, \\ Q &= G_{21}^T G_{31}^T \dots G_{m1}^T G_{32}^T \dots G_{m,m-1}^T G_{m+1,m}^T, \end{aligned}$$

si $m > n$

$$\begin{aligned} R &= G_{m,n} \dots G_{n+1,n} \dots G_{32} G_{m1} \dots G_{31} G_{21} A, \\ Q &= G_{21}^T G_{31}^T \dots G_{m1}^T G_{32}^T \dots G_{n+1,n}^T \dots G_{m,n}^T. \end{aligned}$$

Entonces $r_{ij} = 0$ para $j = 1, \dots, \min\{m-1, n\}$, $i = j+1, \dots, m$ con $r_{jj} \geq 0$. Además, se obtiene que $A = QR$. ■

Para construir el algoritmo de descomposición QR usando rotaciones de Givens, note que las primeras $j - 1$ columnas quedarán invariantes al aplicar G_{kj} y que, por la forma de esta matriz, solamente se verán afectadas las componentes de las filas j y k . Por lo tanto, si $\tilde{a}_{kj} \neq 0$, solo se actualizarán los elementos de las filas j y k desde la columna j a la n . Un posible pseudocódigo sería el siguiente:

Algoritmo 14 (QR con rotaciones de Givens)

Entrada: $A \in \mathbb{R}^{m \times n}$. *Salidas:* $Q \in \mathbb{R}^{m \times m}$ ortogonal y $R \in \mathbb{R}^{m \times n}$ tr. sup. t.q. $A = QR$.

Paso 0: Definir $Q = I \in \mathbb{R}^{m \times m}$, $p = \min\{m-1, n\}$, $j = 1$, $i = 1$.

Paso 1: Si $j > p$ ir al paso 6. Sino, definir $i = j + 1$.

Paso 2: Si $i > m$ ir al paso 5.

Paso 3: Si $A_{ij} = 0$ ir al paso 4. Sino, definir $\mathcal{I} = \{j, i\}$, $\mathcal{J} = \{j, \dots, n\}$,

$$G = \begin{bmatrix} c & -s \\ s & c \end{bmatrix} \text{ aplicando Algoritmo 13 a } (A_{jj}, A_{ij}),$$

$$A_{\mathcal{I}\mathcal{J}} \leftarrow GA_{\mathcal{I}\mathcal{J}},$$

$$Q_{\bullet\mathcal{I}} \leftarrow Q_{\bullet\mathcal{I}}G^T.$$

Paso 4: Hacer $i \leftarrow i + 1$ e ir al paso 2.

Paso 5: Hacer $j \leftarrow j + 1$ e ir al paso 1.

Paso 6: Si $m \leq n$ y $A_{mm} < 0$, definir $\mathcal{J} = \{m, \dots, n\}$,

$$A_{m\mathcal{J}} \leftarrow -A_{m\mathcal{J}},$$

$$Q_{\bullet m} \leftarrow -Q_{\bullet m}.$$

Paso 7: Retornar Q y $R = A$.

La cantidad de operaciones realizadas en el Algoritmo 14 para cada (i, j) es: 6 flops del Algoritmo 13, $6(n-j+1)$ flops de los 4 productos y 2 sumas en cada una de las $n-j+1$ columnas al actualizar A y $6m$ flops de los 4 productos y 2 sumas por m filas al actualizar Q . El cambio de signo en el paso 6 no realiza operaciones. Por lo tanto, separando el costo para obtener R y Q , como máximo se tiene un total de flops igual a

$$\begin{aligned} & \sum_{j=1}^p \sum_{i=j+1}^m (6 + 6(n-j+1)) + \sum_{j=1}^p \sum_{i=j+1}^m 6m \\ &= \sum_{j=1}^p 6(n-j+2)(m-j) + \sum_{j=1}^p 6m(m-j) \\ &= 3p^2(m+n-\frac{4}{3}p) + 6p(m-p-1)(n-p) + 9p(m-p) + 3pn - 5p \\ & \quad + 6mp(m-\frac{1}{2}p) - 3mp \\ &= O(3p^2(m+n-\frac{4}{3}p)) + O(6mp(m-\frac{1}{2}p)). \end{aligned}$$

Con esto, concluimos que el Algoritmo 14 tiene un costo operacional de $O(3n^2(m-n/3)) + O(6mn(m-n/2))$ flops si $m > n$ y de $O(3m^2(n-m/3)) + O(3m^3)$ si $m \leq n$. El costo de calcular Q puede eliminarse con una estrategia descrita en [2, Subsección 5.1.11 y 5.2.3]

que consiste en almacenar valores para luego obtener la función $x \mapsto Q^T x$ sin construir la matriz Q .

4.1.2. Reflexiones de Householder

En esta técnica se realizarán reflexiones a través de cierto hiperplano que garantice que el vector columna reflejado tenga elementos nulos debajo de la diagonal.

Dado $u \in \mathbb{R}^n$, se considera el hiperplano $\mathcal{H} = u^\perp = \{v \in \mathbb{R}^n \mid u^T v = 0\}$ y se define $Q \in \mathbb{R}^{n \times n}$ como la reflexión de $\mathbb{R}^n$ a través de $\mathcal{H}$. Como $x \in \mathbb{R}^n$ puede escribirse como $x = \alpha u + \beta v$ para algún $v \in \mathcal{H}$ y $\alpha, \beta \in \mathbb{R}$, se obtendrá que $Q(\alpha u + \beta v) = -\alpha u + \beta v$, esto es equivalente a tener

$$Qu = -u, \quad Qv = v \quad \text{para todo } v \in \mathcal{H}.$$

Veamos que existe dicha reflexión Q .

Proposición 4.4 Sea $u \in \mathbb{R}^n$ con $u \neq 0$. Si $Q = I - \frac{2}{\|u\|_2^2} uu^T$, entonces

1. $Qu = -u$,
2. $Qv = v$ si $u^T v = 0$,
3. $Q = Q^T$,
4. $Q = Q^{-1}$.

Demostración. Calculando directamente se obtiene que

$$Qu = \left(I - \frac{2}{\|u\|_2^2} uu^T \right) u = u - 2u = -u.$$

Si $u^T v = 0$ entonces

$$Qv = \left(I - \frac{2}{\|u\|_2^2} uu^T \right) v = v.$$

Transponiendo,

$$Q^T = \left(I - \frac{2}{\|u\|_2^2} uu^T \right)^T = \left(I - \frac{2}{\|u\|_2^2} uu^T \right) = Q.$$

Multiplicando por Q ,

$$\begin{aligned} QQ &= \left(I - \frac{2}{\|u\|_2^2} uu^T \right) \left(I - \frac{2}{\|u\|_2^2} uu^T \right) \\ &= I - \frac{2}{\|u\|_2^2} uu^T - \frac{2}{\|u\|_2^2} uu^T + \frac{4}{\|u\|_2^4} \|u\|_2^2 uu^T = I. \end{aligned}$$

La matriz $I - \frac{2}{\|u\|_2^2} uu^T$ con $u \neq 0$ es llamada reflexión de Householder.

Si se quiere aplicar reflexiones de Householder para obtener una descomposición QR de una matriz, se puede comenzar suponiendo que dado $x \in \mathbb{R}^n$, se desea hallar una reflexión de

Householder Q tal que $Qx = \alpha e^1$. Como Q preserva la norma 2 y los elementos diagonales de la matriz triangular superior deben ser no negativos, el problema se reduce a hallar Q tal que $Qx = \|x\|_2 e^1$, o sea

$$\|x\|_2 e^1 = \left(I - \frac{2}{\|u\|_2^2} uu^T \right) x = x - \frac{2}{\|u\|_2^2} (u^T x) u.$$

Note que por definición de Q , al cambiar u por cu para alguna constante $c \neq 0$, la matriz no se altera. Entonces, se puede redefinir u por $\frac{2}{\|u\|_2^2} (u^T x) u$, obteniendo así que $u = x - \|x\|_2 e^1$.

Claramente u difiere de x en su primera componente que es $u_1 = x_1 - \|x\|_2$. Si $x_1 > 0$ se puede evitar el error numérico escribiendo

$$u_1 = x_1 - \|x\|_2 = \frac{x_1^2 - \|x\|_2^2}{x_1 + \|x\|_2} = -\frac{x_2^2 + \dots + x_n^2}{x_1 + \|x\|_2}.$$

Por motivos numéricos, y ya que cualquier múltiplo de u genera la misma Q , el vector u se escala para obtener $u_1 = 1$, o sea,

$$u = \begin{bmatrix} 1 \\ x_2/\gamma \\ \vdots \\ x_n/\gamma \end{bmatrix} \quad \text{donde} \quad \gamma = \begin{cases} x_1 - \sqrt{x_1^2 + \sigma} & \text{si } x_1 \leq 0 \\ -\frac{\sigma}{x_1 + \sqrt{x_1^2 + \sigma}} & \text{si } x_1 > 0 \end{cases},$$

con $\sigma = x_2^2 + \dots + x_n^2$ y $\sigma = 0$ si x es de dimensión $n = 1$. Note que $\gamma = 0$ si y solo si $\sigma = 0$ y $x_1 \geq 0$. En este caso $x = \|x\|_2 e^1$. Si se tiene $\gamma \neq 0$ se obtiene que $\|u\|_2^2 = 1 + \frac{\sigma}{\gamma^2}$. Por lo tanto, se puede tomar $Q = I - \rho uu^T$ donde

$$\rho = \begin{cases} 0 & \text{si } \sigma = 0 \text{ y } x_1 \geq 0, \\ 2\gamma^2/(\gamma^2 + \sigma) & \text{caso contrario.} \end{cases}$$

Con esto, un posible pseudocódigo para calcular esta matriz de Householder sería el siguiente:

Algoritmo 15 (reflexión de Householder)

Entrada: $x \in \mathbb{R}^n$. *Salidas:* $u \in \mathbb{R}^n$, $\rho \in \mathbb{R}$ tal que $(I - \rho uu^T)x = \|x\|_2 e^1$.

Paso 0: Si $n = 1$, definir $\sigma = 0$. Sino, definir $\sigma = x_2^2 + \dots + x_n^2$.

Paso 1: Si $\sigma = 0$ y $x_1 \geq 0$, definir $\rho = 0$, $u = x$, $u_1 = 1$ e ir al paso 5.

Paso 2: Definir $\mu = \sqrt{x_1^2 + \sigma}$.

Paso 3: Si $x_1 \leq 0$, definir $\gamma = x_1 - \mu$. Sino, definir $\gamma = -\sigma/(x_1 + \mu)$.

Paso 4: Definir $\rho = 2\gamma^2/(\gamma^2 + \sigma)$, $u = x/\gamma$ y $u_1 = 1$.

Paso 5: Retornar u y ρ .

Se puede ver que el costo operacional de este algoritmo es de $O(3n)$ flops.

Ahora, dada $A \in \mathbb{R}^{m \times n}$ se puede realizar una descomposición QR aplicando reflexiones de Householder por columnas. Dado $\mathcal{I} = \{j, \dots, m\}$, para el vector

$$x = A_{\mathcal{I}j} = \begin{bmatrix} a_{jj} \\ \vdots \\ a_{mj} \end{bmatrix},$$

se construye $Q_j \in \mathbb{R}^{(m-j+1) \times (m-j+1)}$ tal que $Q_j = I - \rho uu^T$ con u y ρ dados por el Algoritmo 15. Definiendo $\tilde{Q}_j \in \mathbb{R}^{m \times m}$ tal que

$$\tilde{Q}_j = I - \rho \tilde{u} \tilde{u}^T \quad \text{con} \quad \tilde{u} = \begin{bmatrix} 0 \\ u \end{bmatrix} \in \mathbb{R}^m,$$

se obtiene $\tilde{Q}_j$ ortogonal con la propiedad que

$$R = \tilde{Q}_p \dots \tilde{Q}_1 A, \quad p = \min\{m, n\},$$

es triangular superior con elementos diagonales no negativos y por lo tanto

$$Q = \tilde{Q}_1 \dots \tilde{Q}_p.$$

Para obtener Q y A podemos comenzar con $Q = I$ y realizar las actualizaciones

$$\begin{aligned} Q &\leftarrow Q \tilde{Q}_j = Q - [0 \ \rho Q_{\bullet \mathcal{I} j} u u^T], \\ A &\leftarrow \tilde{Q}_j A = A - \begin{bmatrix} 0 \\ \rho u u^T A_{\mathcal{I} \bullet} \end{bmatrix} = A - \begin{bmatrix} 0 & 0 \\ 0 & \rho u u^T A_{\mathcal{I} \mathcal{J}} \end{bmatrix}, \end{aligned}$$

para $\mathcal{J} = \{j, \dots, n\}$, donde utilizamos que las primeras $j - 1$ columnas de A tienen ceros debajo de la diagonal. El siguiente es un posible pseudocódigo para este procedimiento.

Algoritmo 16 (QR con reflexiones de Householder)

Entrada: $A \in \mathbb{R}^{m \times n}$. *Salidas:* $Q \in \mathbb{R}^{m \times m}$ ortogonal y $R \in \mathbb{R}^{m \times n}$ tr. sup. t.q. $A = QR$.

Paso 0: Definir $Q = I \in \mathbb{R}^{m \times m}$, $p = \min\{m, n\}$, $j = 1$.

Paso 1: Si $j > p$ ir al paso 3. Sino, definir $\mathcal{I} = \{j, \dots, m\}$, $\mathcal{J} = \{j, \dots, n\}$

u, ρ aplicando Algoritmo 15 a $A_{\mathcal{I}j}$,

$w = \rho u$,

$A_{\mathcal{I} \mathcal{J}} \leftarrow A_{\mathcal{I} \mathcal{J}} - w (u^T A_{\mathcal{I} \mathcal{J}})$,

$Q_{\bullet \mathcal{I}} \leftarrow Q_{\bullet \mathcal{I}} - Q_{\bullet \mathcal{I} j} w u^T$.

Paso 2: Hacer $j \leftarrow j + 1$ e ir al paso 1.

Paso 3: Retornar Q y $R = A$.

Note que las paréntesis en los productos del paso 1 no alteran el resultado final, pero si el costo computacional. Generalmente los productos matriciales se realizan de izquierda a derecha, por lo tanto para $x, y, z \in \mathbb{R}^n$ la operación $xy^T z$ se obtiene calculando $(xy^T)z$ y tiene un costo de $O(3n^2)$ flops, o también puede obtenerse calculando $x(y^T z)$ con un costo de $O(3n)$ flops.

Este algoritmo de descomposición QR utiliza en el j -ésimo paso: $3(m - j + 1)$ flops del Algoritmo 15, $m - j + 1$ flops para w , $(m - j + 1)(n - j + 1)$ productos con $(m - j)(n - j + 1)$ sumas para calcular $u^T A_{\mathcal{I}J}$, $(m - j + 1)(n - j + 1)$ productos al multiplicar por w y $(m - j + 1)(n - j + 1)$ sumas al actualizar A . Para actualizar Q tenemos $2m(m - j + 1) - m$ flops de $Q_{\bullet \mathcal{I}J} w$, más $m(m - j + 1)$ del producto con u^T y luego $m(m - j + 1)$ flops de la diferencia de matrices. Separando los costos de R y Q obtenemos

$$\begin{aligned} & \sum_{j=1}^p 4(m - j + 1) + 4(m - j + 1)(n - j + 1) - (n - j + 1) \\ & + \sum_{j=1}^p 4m(m - j + 1) - m \\ & = 2p^2 \left(m + n - \frac{4}{3}p \right) + 4p(m - p)(n - p) + 2p \left(3m + \frac{1}{2}n - \frac{25}{12}p + \frac{17}{12} \right) \\ & + 4mp \left(m - \frac{1}{2}p \right) + mp \\ & = O \left(2p^2 \left(m + n - \frac{4}{3}p \right) \right) + O \left(4mp \left(m - \frac{1}{2}p \right) \right) \end{aligned}$$

Por lo tanto, el Algoritmo 16 tiene un costo operacional de $O(2n^2(m - n/3)) + O(4mn(m - n/2))$ flops si $m > n$ y de $O(2m^2(n - m/3)) + O(2m^3)$ si $m \leq n$. Hay que resaltar que la técnica utilizada para calcular Q no es la mejor en términos de cantidad de flops. Para técnicas más eficientes se recomienda ver [2, Subsección 5.1.6 y 5.1.7].

Por lo visto anteriormente, podemos garantizar la factorización de una matriz como un producto de Q por R . Veamos ahora algunas propiedades de la matriz Q .

Teorema 4.5 Si $A = QR$ es una descomposición QR de $A \in \mathbb{R}^{m \times n}$ de rango n y $A = [a^1 \dots a^n]$, $a^j \in \mathbb{R}^m$, $Q = [q^1 \dots q^m]$, $q^j \in \mathbb{R}^m$, entonces

$$\text{span}\{a^1, \dots, a^k\} = \text{span}\{q^1, \dots, q^k\},$$

para $k = 1, \dots, n$. En particular si $Q = [Q_1 \ Q_2]$, $Q_1 \in \mathbb{R}^{m \times n}$, entonces $\text{Im}(A) = \text{Im}(Q_1)$, $\text{Im}(A)^\perp = \text{Im}(Q_2)$ y tomando $R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix}$, $R_1 \in \mathbb{R}^{n \times n}$, se obtiene que $A = Q_1 R_1$.

Demostración. Comparando las columnas de $A = QR$ se obtiene que si $1 \leq k \leq n$ entonces

$$a^k = \sum_{j=1}^k r_{jk} q^j \in \text{span}\{q^1, \dots, q^k\}.$$

Obteniendo que $\text{span}\{a^1, \dots, a^k\} \subset \text{span}\{q^1, \dots, q^k\}$. Como A tiene rango n , los vectores $a^1, \dots, a^k$ son linealmente independientes y por lo tanto generan el mismo espacio que

$q^1, \dots, q^k$. Por otro lado,

$$A = QR = [Q_1 \ Q_2] \begin{bmatrix} R_1 \\ 0 \end{bmatrix} = Q_1 R_1.$$

Entonces $\text{Im}(A) = \text{Im}(Q_1)$ pues R_1 es de rango n . Además, $A^T Q_2 = R_1^T Q_1^T Q_2 = 0$ implica que $\text{Im}(Q_2) = \text{Ker}(A^T) = \text{Im}(A)^\perp$. ■

Se dirá que $A = Q_1 R_1$ es la factorización QR reducida de A . Bajo ciertas hipótesis esta factorización es única.

Teorema 4.6 Sea $A \in \mathbb{R}^{m \times n}$ de rango n , entonces la factorización QR reducida $A = Q_1 R_1$ es única si $Q_1 \in \mathbb{R}^{m \times n}$ tiene columnas ortonormales y R_1 es triangular superior con elementos diagonales positivos. Más aún, R_1 es el factor de Cholesky de $A^T A$.

Demostración. Como $A^T A = R_1^T Q_1^T Q_1 R_1 = R_1^T R_1$ con R_1 triangular superior con elementos diagonales positivos. Entonces, por la unicidad de la descomposición de Cholesky, se obtiene que R_1 es el factor de Cholesky de $A^T A$. Además, $Q_1 = A R_1^{-1}$ también es única. ■

Por lo tanto, para resolver el problema de cuadrados mínimos realizamos una descomposición QR de $A \in \mathbb{R}^{m \times n}$. Si A tiene rango n , entonces se obtendrá

$$Q^T A = \begin{bmatrix} R_1 \\ 0 \end{bmatrix}, \quad Q^T b = \begin{bmatrix} Q_1^T b \\ Q_2^T b \end{bmatrix} = \begin{bmatrix} c \\ d \end{bmatrix},$$

donde $R_1 \in \mathbb{R}^{n \times n}$ es triangular superior con elementos diagonales positivos, $c \in \mathbb{R}^n$ y $d \in \mathbb{R}^{m-n}$. Entonces,

$$\|Ax - b\|_2^2 = \|Q^T Ax - Q^T b\|_2^2 = \left\| \begin{bmatrix} R_1 x - c \\ -d \end{bmatrix} \right\|_2^2 = \|R_1 x - c\|_2^2 + \|d\|_2^2.$$

De esta manera, si $R_1 \hat{x} = c$ entonces $\hat{x}$ es solución de minimizar $\|Ax - b\|_2$ y el residuo mínimo es $\|A\hat{x} - b\|_2 = \|d\|_2$.

4.1.3. Ortonormalización de Gram-Schmidt

Otra forma de calcular la descomposición QR de una matriz es usando la clásica ortonormalización de Gram-Schmidt: dados $a^1, \dots, a^n$ linealmente independientes con $a^j \in \mathbb{R}^m$, construyo $q^1, \dots, q^n$ ortonormales tales que $r_{11} = \|a^1\|_2$, $q^1 = \frac{1}{r_{11}} a^1$ y para $j = 2, \dots, n$ defino

$$\begin{aligned} r_{ij} &= (q^i)^T a^j \quad \text{para } i = 1, \dots, j-1, \\ \tilde{q}^j &= a^j - \sum_{i=1}^{j-1} r_{ij} q^i, \\ r_{jj} &= \|\tilde{q}^j\|_2, \\ q^j &= \frac{1}{r_{jj}} \tilde{q}^j. \end{aligned}$$

Note que si $A = [a^1 \dots a^n]$, $Q = [q^1 \dots q^n]$ entonces

$$a^j = \sum_{i=1}^j r_{ij} q^i = Q \begin{bmatrix} r_{1j} \\ \vdots \\ r_{jj} \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Por lo tanto $A = QR$ con $R \in \mathbb{R}^{n \times n}$ triangular superior con elementos diagonales positivos. Un pseudocódigo para este procedimiento es el siguiente:

Algoritmo 17 (QR con ortonormalización de Gram-Schmidt)

Entrada: $A \in \mathbb{R}^{m \times n}$. *Salidas:* $Q \in \mathbb{R}^{m \times n}$ ortogonal y $R \in \mathbb{R}^{n \times n}$ tr. sup. t.q. $A = QR$.

Paso 0: Definir $R_{11} = \|A_{\bullet 1}\|_2$, $Q_{\bullet 1} = A_{\bullet 1}/R_{11}$, $j = 2$.

Paso 1: Si $j > n$, ir al paso 3. Sino, definir $\mathcal{I} = \{1, \dots, j-1\}$,

$$\begin{aligned} R_{\mathcal{I}j} &= (Q_{\bullet \mathcal{I}})^T A_{\bullet j}, \\ q &= A_{\bullet j} - Q_{\bullet \mathcal{I}} R_{\mathcal{I}j}, \\ R_{jj} &= \|q\|_2, \\ Q_{\bullet j} &= q/R_{jj}. \end{aligned}$$

Paso 2: Hacer $j \leftarrow j + 1$ e ir al paso 1.

Paso 3: Retornar Q y R .

Este algoritmo de descomposición QR utiliza en el paso 0: $2m$ flops para la norma y m flops para el cociente; en el paso 1, para cada j : $(2m-1)(j-1)$ para $R_{\mathcal{I}j}$, $(2(j-1)-1)m + m$ para q , $2m$ para R_{jj} y m del cociente. Obteniendo una cantidad de flops igual a:

$$\begin{aligned} \sum_{j=1}^n ((4m-1)(j-1) + 3m) &= (4m-1) \frac{(n-1)n}{2} + 3mn \\ &= 2mn^2 + mn - \frac{1}{2}n^2 + \frac{1}{2}n. \end{aligned}$$

Por lo tanto, el Algoritmo 17 tiene un costo operacional de $O(2mn^2)$ flops. Debido a errores de redondeo, este procedimiento sufre pérdida de ortogonalidad de los vectores q^j . Se recomienda verificar este hecho realizando experimentos numéricos.

Gram-Schmidt modificado. Para disminuir errores numéricos se calcularán Q y R de una manera alternativa. Suponga que se tiene la descomposición QR de A y considere las siguientes particiones de las matrices:

$$A = [a^1 \hat{A}], \quad Q = [q^1 \hat{Q}], \quad R = \begin{bmatrix} r_{11} & r^T \\ 0 & \hat{R} \end{bmatrix}.$$

Como $A = QR$, se obtiene que $a^1 = r_{11}q^1$ y $\hat{A} = q^1r^T + \hat{Q}\hat{R}$. Usando que Q es ortogonal en las relaciones anteriores se pueden definir

$$r_{11} = \|a^1\|_2, \quad q^1 = \frac{1}{r_{11}}a^1 \quad \text{y} \quad r^T = (q^1)^T \hat{A}.$$

Además, $\hat{A} - q^1r^T = \hat{Q}\hat{R}$. Actualizando $\hat{A}$ por $\hat{A} - q^1r^T$ se obtiene una descomposición QR de la matriz $\hat{A}$ que posee una columna menos que A . Por lo tanto, se puede repetir el argumento anterior reduciendo en cada paso la cantidad de columnas. Al llegar a la última columna se deberá definir solamente r_{nn} y q^n .

Un pseudocódigo para esta alternativa es el siguiente:

Algoritmo 18 (QR con Gram-Schmidt modificado)

Entrada: $A \in \mathbb{R}^{m \times n}$. *Salidas:* $Q \in \mathbb{R}^{m \times n}$ ortogonal y $R \in \mathbb{R}^{n \times n}$ tr. sup. t.q. $A = QR$.

Paso 0: Definir $j = 1$

Paso 1: Si $j > n - 1$ ir al paso 3. Sino, definir $\mathcal{J} = \{j + 1, \dots, n\}$,

$$\begin{aligned} R_{jj} &= \|A_{\bullet j}\|_2, \\ Q_{\bullet j} &= A_{\bullet j} / R_{jj}, \\ R_{j\mathcal{J}} &= (Q_{\bullet j})^T A_{\bullet \mathcal{J}}, \\ A_{\bullet \mathcal{J}} &\leftarrow A_{\bullet \mathcal{J}} - Q_{\bullet j} R_{j\mathcal{J}}. \end{aligned}$$

Paso 2: Hacer $j \leftarrow j + 1$ e ir al paso 1.

Paso 3: Definir $R_{nn} = \|A_{\bullet n}\|_2$, $Q_{\bullet n} = A_{\bullet n} / R_{nn}$ y retornar Q y R .

4.1.4. QR con pivoteo de columnas

Si $A \in \mathbb{R}^{m \times n}$ tiene rango $p < n$, la descomposición QR podría generar R con $r_{jj} = 0$ para algún j con $1 \leq j \leq p$. Esto sucede cuando las primeras p columnas de A son linealmente dependientes.

Ejemplo 4.7 Considere reflexiones de Householder para realizar la descomposición QR de

$$A = \begin{bmatrix} 2 & 2 & 3 \\ 2 & 2 & 0 \\ 1 & 1 & 0 \end{bmatrix}.$$

En el primer paso defina $Q = I - \rho uu^T$ con $u = (1, -2, -1)^T$, $\rho = 1/3$. Aplicándola en A se obtiene

$$Q^T A = \begin{bmatrix} 3 & 3 & 2 \\ 0 & 0 & 2 \\ 0 & 0 & 1 \end{bmatrix}.$$

Obteniendo así una descomposición QR de A con $r_{22} = 0$.

Para evitar esto, se permutarán las columnas a fin de obtener $r_{jj} > 0$ para $1 \leq j \leq p$. Ya sea usando rotaciones de Givens o reflexiones de Householder, se pueden modificar los métodos para obtener $P \in \mathbb{R}^{n \times n}$ matriz de permutación tal que

$$Q^T AP = \begin{bmatrix} R_{11} & R_{12} \\ 0 & 0 \end{bmatrix},$$

con $R_{11} \in \mathbb{R}^{p \times p}$ y $R_{12} \in \mathbb{R}^{p \times (n-p)}$.

Para realizar esta modificación, suponga que luego del paso $j - 1$ se obtiene la matriz

$$\begin{bmatrix} R & V \\ 0 & W \end{bmatrix},$$

con $R \in \mathbb{R}^{(j-1) \times (j-1)}$ y $W \in \mathbb{R}^{(m-j+1) \times (n-j+1)}$. Considere la partición por columnas $W = [w^j \dots w^n]$ y tome el índice l tal que

$$\|w^l\|_2^2 = \max_{j \leq k \leq n} \|w^k\|_2^2.$$

Si $\|w^l\|_2 = 0$, entonces se finaliza el procedimiento, pues $W = 0$ y en este caso se obtendrá que A tiene rango $j - 1$. Si $\|w^l\|_2 > 0$, se define $P_j \in \mathbb{R}^{n \times n}$ matriz de permutación de columnas j y l . Luego, se procede de manera normal con el paso j del método de descomposición QR elegido aplicado a la matriz

$$\begin{bmatrix} R & V \\ 0 & W \end{bmatrix} P_j.$$

De esta forma se obtendrá la descomposición deseada con $P = P_1 \dots P_r$. Claramente, $AP = QR$.

Ejemplo 4.8 *Apliquemos permutación de columnas al ejemplo anterior. Tenemos*

$$A = \begin{bmatrix} 2 & 2 & 3 \\ 2 & 2 & 0 \\ 1 & 1 & 0 \end{bmatrix}.$$

Como la primera columna tiene norma máxima, definimos $P_1 = I$. Luego $Q_1 = I - \rho_1 u_1 u_1^T$ con $u_1 = (1, -2, -1)^T$, $\rho_1 = 1/3$ y

$$Q_1^T AP_1 = \begin{bmatrix} 3 & 3 & 2 \\ 0 & 0 & 2 \\ 0 & 0 & 1 \end{bmatrix}.$$

Mirando la norma de las columnas de la submatriz con filas y columnas indexadas por $\{2, 3\}$, obtenemos que hay que permutar las columnas 2 y 3. Luego de la permutación obtenemos que $Q_2 = I - \rho_2 u_2 u_2^T$ con $u_2 = (0, 1, 1/(2 - \sqrt{5}))^T$, $\rho_2 = (2 - \sqrt{5})^2 / (5 - 2\sqrt{5})$ y

$$Q_2^T Q_1^T AP_1 P_2 = \begin{bmatrix} 3 & 2 & 3 \\ 0 & \sqrt{5} & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

Obteniendo así una descomposición QR de A con r_{11} y r_{22} positivos.

Para reducir el costo computacional del cálculo de las normas de las columnas en cada iteración, note que si

$$Q^T z = \begin{bmatrix} \alpha \\ w \end{bmatrix},$$

con $\alpha \in \mathbb{R}$ y Q ortogonal, entonces $\|z\|_2^2 = \|Q^T z\|_2^2 = \alpha^2 + \|w\|_2^2$. Por lo tanto se pueden calcular las normas de las columnas usando la información de la norma del paso anterior, definiendo $\|w\|_2^2 = \|z\|_2^2 - \alpha^2$.

Aplicando esta modificación en el Algoritmo 16 se obtiene el siguiente.

Algoritmo 19 (QR con reflexiones y permutaciones)

Entrada: $A \in \mathbb{R}^{m \times n}$. *Salidas:* $Q \in \mathbb{R}^{m \times m}$ ortogonal, $R \in \mathbb{R}^{m \times n}$ tr. sup. y P matriz de permutación t.q. $AP = QR$.

Paso 0: Definir $Q = I \in \mathbb{R}^{m \times m}$, $P = I \in \mathbb{R}^{n \times n}$, $c \in \mathbb{R}^{1 \times n}$ t.q. $c_j = \|A_{\bullet j}\|_2^2$, $p = \min\{m, n\}$ y $j = 1$.

Paso 1: Si $j > p$, ir al paso 4. Sino, definir $\mathcal{J} = \{j, \dots, n\}$ y l t.q. $c_l = \max_{j \in \mathcal{J}} c_j$.

Paso 2: Si $c_l = 0$, ir al paso 4. Sino, definir P_j permutación de columnas j y l , $\mathcal{I} = \{j, \dots, m\}$,

$$\begin{aligned} A &\leftarrow AP_j, \\ P &\leftarrow PP_j, \\ c &\leftarrow cP_j, \\ u, \rho &\text{ aplicando Algoritmo 15 a } A_{\mathcal{I}j}, \\ w &= \rho u, \\ A_{\mathcal{I}\mathcal{J}} &\leftarrow A_{\mathcal{I}\mathcal{J}} - w (u^T A_{\mathcal{I}\mathcal{J}}), \\ Q_{\bullet \mathcal{I}} &\leftarrow Q_{\bullet \mathcal{I}} - Q_{\bullet \mathcal{I}} w u^T, \\ c_{\mathcal{J}} &\leftarrow c_{\mathcal{J}} - A_{j\mathcal{J}} \circ A_{j\mathcal{J}}. \end{aligned}$$

Paso 3: Hacer $j \leftarrow j + 1$ e ir al paso 1.

Paso 4: Retornar Q , $R = A$ y P .

Donde se utilizó el producto de Hadamard $\circ : \mathbb{R}^n \times \mathbb{R}^n \mapsto \mathbb{R}^n$ tal que $(x \circ y)_i = x_i y_i$.

Por lo tanto, para resolver el problema de cuadrados mínimos con $A \in \mathbb{R}^{m \times n}$ de rango $p < n$, se usa el Algoritmo 19 para obtener

$$Q^T AP = \begin{bmatrix} R_{11} & R_{12} \\ 0 & 0 \end{bmatrix}, \quad Q^T b = \begin{bmatrix} c \\ d \end{bmatrix},$$

donde $R_{11} \in \mathbb{R}^{p \times p}$ es triangular superior con elementos diagonales positivos, $R_{12} \in \mathbb{R}^{p \times (n-p)}$, $c \in \mathbb{R}^p$, $d \in \mathbb{R}^{m-p}$ y los bloques de ceros son de dimensión $(m-p) \times p$ y $(m-p) \times (n-p)$, pudiendo no existir alguno de ellos si $p = m$ o $p = n$. Como $PP^T = I$,

particionando $P^T x$ en $y^1 \in \mathbb{R}^p$ y $y^2 \in \mathbb{R}^{n-p}$ se tiene que

$$\|Q^T A P P^T x - Q^T b\|_2^2 = \left\| \begin{bmatrix} R_{11}y^1 + R_{12}y^2 - c \\ -d \end{bmatrix} \right\|_2^2 = \|R_{11}y^1 + R_{12}y^2 - c\|_2^2 + \|d\|_2^2.$$

De esta manera, si $\hat{y}^2 = 0$ y $R_{11}\hat{y}^1 = c$ entonces $\hat{x} = P \begin{bmatrix} \hat{y}^1 \\ \hat{y}^2 \end{bmatrix}$ es solución de minimizar $\|Ax - b\|_2$ y el residuo mínimo es $\|A\hat{x} - b\|_2 = \|d\|_2$.

En resumen, para resolver el problema de cuadrados mínimos para A y b los pasos a seguir son:

1. calcular Q , R y P dados por el Algoritmo 19. Definir $q = Q^T b$.
2. Obtener p , el rango de R , como el mayor entero tal que $r_{ii} > 0$ para $i = 1, \dots, p$. Definir $\mathcal{I} = \{1, \dots, p\}$.
3. Hallar $y_{\mathcal{I}}$ solución de $R_{\mathcal{I}\mathcal{I}}y_{\mathcal{I}} = q_{\mathcal{I}}$, mediante el Algoritmo 3 o 4, y definir $y_i = 0$ para $i = p + 1, \dots, n$.
4. Definir $x = Py$.

Un posible pseudocódigo es el siguiente.

Algoritmo 20 (Cuadrados mínimos)

Entrada: $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$. *Salidas:* $x \in \mathbb{R}^n$ y el residuo mínimo r_2 .

Paso 0: Definir Q , R y P aplicando Algoritmo 19 a A .

Paso 1: Definir

$$\begin{aligned} q &= Q^T b, \\ p &= \max\{i \mid r_{ii} > 0\}, \\ \mathcal{I} &= \{1, \dots, p\}, \\ \mathcal{J} &= \{1, \dots, n\} \setminus \mathcal{I}, \\ y_{\mathcal{I}} &\text{ aplicando Algoritmo 3 a } (R_{\mathcal{I}\mathcal{I}}, q_{\mathcal{I}}), \\ y_{\mathcal{J}} &= 0. \end{aligned}$$

Paso 2: Retornar $x = Py$, $r_2 = \|q_{\mathcal{J}}\|_2$.

4.1.5. Ecuación normal

El problema de cuadrados mínimos también puede resolverse sin realizar una descomposición QR. Considere el problema

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} f(x),$$

donde $f : \mathbb{R}^n \mapsto \mathbb{R}$ se define como $f(x) = \frac{1}{2}\|Ax - b\|_2^2$. Usando QR con permutación de columnas puede demostrarse que independientemente de la estructura de A este problema

siempre tiene una solución $\bar{x}$. Por otro lado, se sabe que si $\bar{x}$ es un minimizador de f entonces $0 = \nabla f(\bar{x})$. Como $\nabla f(x) = A^T(Ax - b)$ entonces el minimizador $\bar{x}$ tiene que ser solución del sistema lineal

$$A^T Ax = A^T b.$$

Este sistema de ecuaciones lineales es conocido como *ecuación normal*. En este caso particular la recíproca también vale, i.e., si $\nabla f(\bar{x}) = 0$ entonces $\bar{x}$ es solución del problema de minimización. Cabe aclarar que esta afirmación no siempre es cierta, pues $\nabla f(\bar{x}) = 0$ también vale si $\bar{x}$ es un maximizador o un punto de ensilladura.

Proposición 4.9 Para cualquier $A \in \mathbb{R}^{m \times n}$, $\bar{x}$ es solución de

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \quad \frac{1}{2} \|Ax - b\|_2^2$$

si y solo si

$$A^T A\bar{x} = A^T b.$$

Demostración. Por el comentario previo, si $\bar{x}$ es solución del problema de minimización entonces $A^T A\bar{x} = A^T b$.

Suponga ahora que $A^T A\bar{x} = A^T b$ y tome $x \in \mathbb{R}^n$ arbitrario. Entonces

$$\begin{aligned} \|Ax - b\|_2^2 &= \|A(x - \bar{x}) + A\bar{x} - b\|_2^2 \\ &= \|A(x - \bar{x})\|_2^2 + 2(x - \bar{x})^T A^T(A\bar{x} - b) + \|A\bar{x} - b\|_2^2 \\ &\geq \|A\bar{x} - b\|_2^2, \end{aligned}$$

donde se usó que $\|A(x - \bar{x})\|_2^2 \geq 0$ y $A^T(A\bar{x} - b) = A^T A\bar{x} - A^T b = 0$. Por lo tanto $\bar{x}$ es solución del problema de minimización. ■

Si $A \in \mathbb{R}^{m \times n}$, entonces $A^T A$ es una matriz simétrica y semidefinida positiva, por lo tanto se puede hallar $\bar{x}$ resolviendo la ecuación normal mediante una descomposición de Cholesky si A tiene rango completo o una versión con permutaciones en caso que A tenga rango deficiente, tal variante puede verse en [2, Subsección 4.2.9]. Lamentablemente el número de condición de $A^T A$ puede ser muy grande comparado con el de A , mientras que el número de condición de R_1 (donde $A = Q_1 R_1$) es igual al de A . Por lo tanto, la ecuación normal es importante desde el punto de vista analítico del problema de cuadrados mínimos, pero no se recomienda utilizarlo como herramienta numérica para resolver el problema.

4.2. Minimización lineal

Para minimizar $\|Ax - b\|_1$ o $\|Ax - b\|_\infty$ se resolverá un problema de optimización lineal. En general, un problema de optimización lineal puede escribirse como

$$\begin{aligned} &\text{minimizar} && c^T w \\ &\text{sujeto a} && Mw \leq d, \end{aligned}$$

donde $c \in \mathbb{R}^p$, $d \in \mathbb{R}^q$, $M \in \mathbb{R}^{q \times p}$ y la desigualdad es tomada componente a componente. Los métodos para resolver problemas de optimización lineal (también conocidos como problemas

de programación lineal) están más allá del alcance de estas notas. Para resolver el problema de optimización lineal se puede utilizar el método Simplex, detallado en [4, Sección 4.10].

Se dice que w es factible para el problema de optimización lineal si $Mw \leq d$. Por lo tanto, si $\bar{w}$ es solución del problema entonces debe ser factible y cumplir que $c^T \bar{w} \leq c^T w$ para todo w factible. Tomando esto en cuenta se obtiene lo siguiente.

Teorema 4.10 Si $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$, entonces $\bar{x} \in \mathbb{R}^n$ es solución de

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \|Ax - b\|_1, \quad (4.1)$$

si y solo si $(\bar{x}, \bar{y}) \in \mathbb{R}^n \times \mathbb{R}^m$ es solución de

$$\begin{aligned} & \underset{(x,y)}{\text{minimizar}} \quad e^T y \\ & \text{sueto a} \quad \begin{bmatrix} A & -I \\ -A & -I \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} \leq \begin{bmatrix} b \\ -b \end{bmatrix}, \end{aligned} \quad (4.2)$$

donde $e = (1, \dots, 1)^T \in \mathbb{R}^m$.

Demostración. Considere la partición por columnas $A^T = [a^1 \dots a^m]$. Note que (x, y) es factible para (4.2) si y solo si $-y \leq Ax - b \leq y$, que es equivalente a $|(a^i)^T x - b_i| \leq y_i$ para $i = 1, \dots, m$.

Con esto, si $\bar{x}$ solución de (4.1), definiendo $\bar{y}_i = |(a^i)^T \bar{x} - b_i|$ se obtiene que $(\bar{x}, \bar{y})$ es factible para (4.2). Además, para cualquier (x, y) factible para el problema (4.2),

$$\begin{aligned} e^T \bar{y} &= \sum_{i=1}^m \bar{y}_i = \sum_{i=1}^m |(a^i)^T \bar{x} - b_i| \\ &= \|A\bar{x} - b\|_1 \\ &\leq \|Ax - b\|_1 = \sum_{i=1}^m |(a^i)^T x - b_i| \leq \sum_{i=1}^m y_i \\ &= e^T y. \end{aligned}$$

Obteniendo que $(\bar{x}, \bar{y})$ es solución de (4.2).

Consideremos ahora que $(\bar{x}, \bar{y})$ es solución de (4.2) y $x \in \mathbb{R}^n$ arbitrario. Definiendo $y_i = |(a^i)^T x - b_i|$, se obtiene que (x, y) es factible para el problema (4.2), y

$$\|A\bar{x} - b\|_1 \leq e^T \bar{y} \leq e^T y = \|Ax - b\|_1,$$

donde la primera desigualdad vale porque $(\bar{x}, \bar{y})$ es factible para (4.2) y la segunda vale por ser solución. Concluyendo que $\bar{x}$ es solución de (4.1). ■

Si usamos $\|\cdot\|_\infty$ en vez de $\|\cdot\|_1$ se obtiene lo siguiente.

Teorema 4.11 Si $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$, entonces $\bar{x} \in \mathbb{R}^n$ es solución de

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \|Ax - b\|_\infty, \quad (4.3)$$

si y solo si $(\bar{x}, \bar{t}) \in \mathbb{R}^n \times \mathbb{R}$ es solución de

$$\begin{aligned} & \underset{(x,t)}{\text{minimizar}} \quad t \\ & \text{sueto a} \quad \begin{bmatrix} A & -e \\ -A & -e \end{bmatrix} \begin{bmatrix} x \\ t \end{bmatrix} \leq \begin{bmatrix} b \\ -b \end{bmatrix}, \end{aligned} \quad (4.4)$$

donde $e = (1, \dots, 1)^T \in \mathbb{R}^m$.

Demostración. Considere $A^T = [a^1 \dots a^m]$. Note que (x, t) es factible para el problema (4.4) si y solo si $-te \leq Ax - b \leq te$, que es equivalente a $|(a^i)^T x - b_i| \leq t$ para todo i y esta última equivalente a $\|Ax - b\|_\infty \leq t$.

Ahora, si $\bar{x}$ solución de (4.3) y definimos $\bar{t} = \|A\bar{x} - b\|_\infty$, obtenemos que $(\bar{x}, \bar{t})$ es factible para (4.4). Para (x, t) arbitrario factible para (4.4) se tiene que

$$\bar{t} = \|A\bar{x} - b\|_\infty \leq \|Ax - b\|_\infty \leq t.$$

Por lo tanto $(\bar{x}, \bar{t})$ es solución de (4.4).

Si $(\bar{x}, \bar{t})$ es solución de (4.4), para $x \in \mathbb{R}^n$ arbitrario defina $t = \|Ax - b\|_\infty$. Como (x, t) es factible para (4.4) se obtiene

$$\|A\bar{x} - b\|_\infty \leq \bar{t} \leq t = \|Ax - b\|_\infty.$$

Concluyendo que $\bar{x}$ es solución de (4.3). ■

4.3. Ejercicios

1. Resuelva el siguiente sistema lineal usando rotaciones de Givens y reflexiones de Householder

$$\begin{bmatrix} 2 & 3 \\ 5 & 7 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 12 \\ 29 \end{bmatrix}.$$

2. Encuentre una reflexión Q tal que $Qx = y$ para vectores $x, y \in \mathbb{R}^n$ con $\|x\|_2 = \|y\|_2 = 1$.
3. Demuestre que si $R \in \mathbb{R}^{(n-1) \times (n-1)}$, $w \in \mathbb{R}^{n-1}$, $v \in \mathbb{R}^{m-n+1}$, $c \in \mathbb{R}^{n-1}$, $d \in \mathbb{R}^{m-n+1}$ tales que

$$A = \begin{bmatrix} R & w \\ 0 & v \end{bmatrix}, \quad b = \begin{bmatrix} c \\ d \end{bmatrix},$$

con A de rango completo, entonces $\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2 = \|d\|_2^2 - (v^T d / \|v\|_2)^2$

4. Se desea hallar la recta $y = c_1 + c_2 x$ que ajuste los datos $(x_i, y_i) = (i, i)$ para $i = 1, \dots, 9$ y $(x_{10}, y_{10}) = (10, 0)$.


- a) Encuentre c solución de minimizar $\|Ac - b\|_2^2$.
- b) Encuentre c solución de minimizar $\|Ac - b\|_1$.

- c) Encuentre c solución de minimizar $\|Ac - b\|_\infty$.
 - d) Grafique simultáneamente las tres rectas y los datos.
5. Se desea contar con un modelo para pronosticar el comportamiento de un sistema desconocido. Para ello, contamos con valores de entrada $u(t)$ y de salida $y(t)$ para tiempos $t = 0, \dots, N$. Una estrategia, consiste en suponer que la salida depende de las últimas $\tau + 1$ entradas, o sea,

$$y(t) \approx h_0 u(t) + h_1 u(t-1) + \dots + h_\tau u(t-\tau), \quad \text{para } t = \tau, \dots, N.$$

Descargue el archivo `dryer2.dat` (datos de una secadora industrial obtenidos de DaISy) donde los datos t , $u(t)$, $y(t)$ están en las columnas 1, 2 y 5, respectivamente.

- a) Grafique conjuntamente $u(t)$ e $y(t)$.
 - b) Entrene su modelo con $\tau = 100$ y $N = 500$.
 - c) Grafique su estimación $y_{\text{est}}(t)$ junto a $y(t)$ para $t > N$.
6. Se desea detectar la posición en tres dimensiones de una masa no uniforme. Se cuenta con información de la imagen de dos cámaras posicionadas como indica la figura. Tomando como unidad 1 m, las cámaras están situadas a 0.5 de la pared lateral, 2 de la pared del frente y 1.5 de altura. Tomando la esquina como el origen de coordenadas, desde la cámara 1 el centro de la masa está en la posición $(0.35, 1.43)$ y desde la cámara 2 en la posición $(-0.28, 1.55)$. Note que desde la cámara 2 el eje x tiene orientación negativa.



Escriba un sistema de cuatro ecuaciones y tres incógnitas para determinar la posición espacial de la masa.

Capítulo 5

Descomposición en valores singulares

Ejemplo 5.1 Calificando exámenes. Suponga que se debe calificar un examen en el que se presentaron $m = 11$ alumnos y el cual contaba con $n = 5$ ejercicios que se corrigieron asignando valores entre 0 y 10. Con esto, se puede construir $A \in \mathbb{R}^{11 \times 5}$ tal que $A_{i \bullet}$ contiene el puntaje que el i -ésimo alumno obtuvo en los 5 ejercicios.

Recuerde que para una variable aleatoria discreta $x : \{1, \dots, m\} \mapsto \mathbb{R}$, o sea $x \in \mathbb{R}^m$, se define la esperanza de x como

$$\mathbb{E}(x) = \frac{1}{m} \sum_{i=1}^m x_i = \frac{1}{m} e^T x,$$

donde $e = (1, \dots, 1)^T \in \mathbb{R}^m$. Si y es otra variable aleatoria, la covarianza entre x e y es

$$\begin{aligned} \text{Cov}(x, y) &= \frac{1}{m} \sum_{i=1}^m (x_i - \mathbb{E}(x))(y_i - \mathbb{E}(y)) = \frac{1}{m} (x - \mathbb{E}(x)e)^T (y - \mathbb{E}(y)e) \\ &= \frac{1}{m} x^T (I - \frac{1}{m} ee^T)^T (I - \frac{1}{m} ee^T) y = x^T C y, \end{aligned}$$

para $C = \frac{1}{m} (I - \frac{1}{m} ee^T)^T (I - \frac{1}{m} ee^T)$. La varianza y desviación estándar de x se definen como

$$\mathbb{V}\text{ar}(x) = \text{Cov}(x, x) = x^T C x, \quad \sigma(x) = \sqrt{\mathbb{V}\text{ar}(x)}.$$

Las notas del examen se calculan asignando un peso w_j al j -ésimo ejercicio. Por lo tanto, dado un peso $w \in \mathbb{R}^n$, la nota del i -ésimo alumno será $A_{i \bullet} w$, concluyendo que Aw es el vector con la nota de todos los alumnos. Un buen peso para diferenciar los alumnos que estudiaron de los que no, es aquel que dé la mayor variabilidad de notas, i.e., $w \in \mathbb{R}^n$ solución de

$$\underset{\|w\|_2=1}{\text{maximizar}} \sigma(Aw),$$

donde $\sigma(Aw) = (w^T A^T C A w)^{1/2}$. Si se toma $B = m^{-1/2} (I - \frac{1}{m} ee^T) A$, entonces $B^T B = A^T C A$ es la matriz de covarianzas para las variables aleatorias $A_{\bullet j}$. Con esto, nuestro problema se reduce a encontrar w tal que $\|w\|_2 = 1$ y $\|Bw\|_2 = \|B\|_2 = \sqrt{\rho(B^T B)}$, o sea, w autovector asociado al máximo autovalor de $B^T B$.

Si se desea que las notas de los alumnos sean cercanas a la media entonces w deberá ser solución de

$$\underset{\|w\|_2=1}{\text{minimizar}} \sigma(Aw).$$

En este caso la solución es el autovector asociado al mínimo autovalor de $B^T B$. El análisis de los pesos asociados a los autovalores de $B^T B$ se conoce como análisis de componentes principales (PCA, por sus siglas en inglés).

Definición 5.2 Dada $A \in \mathbb{R}^{n \times n}$, se llamarán valores singulares de A a las raíces cuadradas de los autovalores de $A^T A$, i.e., σ es un valor singular de A si $\sigma = \sqrt{\lambda}$ con λ autovalor de $A^T A$.

A continuación se verá que toda matriz A puede escribirse como $A = U\Sigma V^T$ con U y V ortogonales y Σ conteniendo los valores singulares de A en su diagonal. Esta última se conoce como descomposición en valores singulares (SVD, por sus siglas en inglés).

5.1. Propiedades de la SVD

Veamos que cualquier matriz posee una descomposición en valores singulares.

Teorema 5.3 Sea $A \in \mathbb{R}^{m \times n}$ de rango r , entonces existen matrices $U \in \mathbb{R}^{m \times m}$, $V \in \mathbb{R}^{n \times n}$ ortogonales y

$$\Sigma = \begin{bmatrix} \sigma_1 & & & & & \\ & \ddots & & & & \\ & & \sigma_r & & & \\ & & & 0 & & \\ & & & & \ddots & \\ & & & & & 0 \end{bmatrix} \in \mathbb{R}^{m \times n},$$

con $\sigma_1 \geq \dots \geq \sigma_r > 0$ tales que $A = U\Sigma V^T$.

Demostración. Veamos primero que si U y V son ortogonales entonces $\|A\|_2 = \|U^T A V\|_2$, pues usando la ortogonalidad de U y V , se tiene que

$$\begin{aligned} \|A\|_2 &= \sup_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \sup_{x \neq 0} \frac{\|U^T A V V^T x\|_2}{\|V^T x\|_2} \\ &= \sup_{y \neq 0} \frac{\|U^T A V y\|_2}{\|y\|_2} = \|U^T A V\|_2. \end{aligned}$$

Además, si

$$U^T A V = \begin{bmatrix} \beta & z^T \\ 0 & B \end{bmatrix},$$

con $\beta = \|A\|_2$, entonces $z = 0$. Pues, como

$$\left\| U^T A V \begin{bmatrix} \beta \\ z \end{bmatrix} \right\|_2^2 = (\beta^2 + \|z\|_2^2)^2 + \|Bz\|_2^2 \geq (\beta^2 + \|z\|_2^2)^2,$$

se obtiene que $\beta^2 + \|z\|_2^2 \leq \|U^T AV\|_2^2 = \|A\|_2^2 = \beta^2$, concluyendo que $z = 0$.

Procedamos a probar el Teorema usando inducción en el rango de A . Si $r = 1$, tome $\sigma_1 = \|A\|_2$. Entonces existe $v^1 \in \mathbb{R}^n$ tal que $\|v^1\|_2 = 1$ y $\|Av^1\|_2 = \sigma_1$. Defina $u^1 = \frac{1}{\sigma_1} Av^1$, entonces $u^1 \in \mathbb{R}^m$ y $\|u^1\|_2 = 1$. Como $r = 1$, se tiene que $\text{Im}(A) = \text{span}\{u^1\}$. Genere $U_1 = [u^1 \dots u^m]$ y $V_1 = [v^1 \dots v^n]$ tales que $U = [u^1 U_1]$ y $V = [v^1 V_1]$ sean matrices ortogonales. Entonces

$$U^T AV = \begin{bmatrix} (u^1)^T \\ U_1^T \end{bmatrix} [Av^1 AV_1] = \begin{bmatrix} (u^1)^T \\ U_1^T \end{bmatrix} [\sigma_1 u^1 AV_1] = \begin{bmatrix} \sigma_1 & z^T \\ 0 & 0 \end{bmatrix},$$

donde se usó que $Av^j \in \text{span}\{u^1\}$. Como $\sigma_1 = \|A\|_2$, se tiene que $z = 0$. Por lo tanto, definiendo

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 \\ 0 & 0 \end{bmatrix},$$

queda demostrado el Teorema para $r = 1$.

Ahora, supongamos que el enunciado vale para matrices de rango $r - 1$. Si A tiene rango $r \geq 2$, tome $\sigma_1 = \|A\|_2$ y $v^1 \in \mathbb{R}^n$ tal que $\|v^1\|_2 = 1$ y $\|Av^1\|_2 = \sigma_1$. Defina $u^1 = \frac{1}{\sigma_1} Av^1$ y genere $U_1 = [u^1 \dots u^m]$ y $V_1 = [v^1 \dots v^n]$ tales que $\tilde{U} = [u^1 U_1]$ y $\tilde{V} = [v^1 V_1]$ sean matrices ortogonales. Entonces

$$\tilde{U}^T A \tilde{V} = \begin{bmatrix} (u^1)^T \\ U_1^T \end{bmatrix} [Av^1 AV_1] = \begin{bmatrix} (u^1)^T \\ U_1^T \end{bmatrix} [\sigma_1 u^1 AV_1] = \begin{bmatrix} \sigma_1 & z^T \\ 0 & \hat{A} \end{bmatrix}.$$

Por lo visto anteriormente se obtiene que $z = 0$ y usando la hipótesis inductiva se obtiene que $\hat{A} = \hat{U} \hat{\Sigma} \hat{V}^T$ con $\hat{U}, \hat{V}$ ortogonales y

$$\hat{\Sigma} = \begin{bmatrix} \sigma_2 & & & & \\ & \ddots & & & \\ & & \sigma_r & & \\ & & & 0 & \\ & & & & \ddots \\ & & & & & 0 \end{bmatrix} \in \mathbb{R}^{(m-1) \times (n-1)},$$

con $\sigma_2 \geq \dots \geq \sigma_r > 0$. Definiendo

$$U = \tilde{U} \begin{bmatrix} 1 & 0 \\ 0 & \hat{U} \end{bmatrix}, \quad V = \tilde{V} \begin{bmatrix} 1 & 0 \\ 0 & \hat{V} \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \sigma_1 & 0 \\ 0 & \hat{\Sigma} \end{bmatrix},$$

se obtienen $U \in \mathbb{R}^{m \times m}$ y $V \in \mathbb{R}^{n \times n}$ ortogonales tales que $U^T AV = \Sigma$. Solo falta probar que $\sigma_1 \geq \sigma_2$. Tomando $e^2 \in \mathbb{R}^n$, segundo vector de la base canónica, se tiene que

$$\sigma_1 = \|A\|_2 = \|U^T AV\|_2 = \|\Sigma\|_2 \geq \|\Sigma e^2\|_2 = \sigma_2.$$

■

Usando la descomposición SVD se puede interpretar cómo la aplicación de A deforma el espacio. Usando que $A = U \Sigma V^T$, el vector Ax se consigue aplicando primero una transformación ortogonal (rotaciones y/o reflexiones) a x , o sea, $V^T x$, luego un escalado en las




Figura 5.1: Deformación de la esfera unidad en norma 2

direcciones coordenadas $\Sigma V^T x$ y por último otra transformación ortogonal $U \Sigma V^T x$. En la Figura 5.1 se puede ver como la matriz $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ deforma $S = \{x \in \mathbb{R}^2 \mid \|x\|_2 = 1\}$, la esfera unidad en norma 2.

La descomposición SVD nos provee gran cantidad de información de la matriz. Algunas se presentan en el siguiente resultado.

Corolario 5.4 Sea $A \in \mathbb{R}^{m \times n}$ de rango r . Si $U = [u^1 \dots u^m] \in \mathbb{R}^{m \times m}$, $V = [v^1 \dots v^n] \in \mathbb{R}^{n \times n}$ y Σ diagonal con entradas $\sigma_1 \geq \dots \geq \sigma_r > 0$ corresponden a la descomposición SVD de A , entonces

$$Av^i = \begin{cases} \sigma_i u^i, & 1 \leq i \leq r \\ 0, & r+1 \leq i \leq n \end{cases}, \quad A^T u^i = \begin{cases} \sigma_i v^i, & 1 \leq i \leq r \\ 0, & r+1 \leq i \leq m \end{cases}.$$

Por lo tanto, $\text{Im}(A) = \text{span}\{u^1, \dots, u^r\}$ y $\text{Ker}(A) = \text{span}\{v^{r+1}, \dots, v^n\}$.

Demostración. Como $A = U \Sigma V^T$, entonces $AV = U \Sigma$ y $A^T U = V \Sigma^T$. Mirando las columnas de AV se obtiene que $Av^i = \sigma_i u^i$ si $1 \leq i \leq r$ y $Av^i = 0$ si $r+1 \leq i \leq n$. Mirando las columnas de $A^T U$ se obtiene que $A^T u^i = \sigma_i v^i$ si $1 \leq i \leq r$ y $A^T u^i = 0$ si $r+1 \leq i \leq m$. ■

Se deduce fácilmente que $\sigma_1, \dots, \sigma_r$ son los valores singulares de A . Además, el vector v^i es llamado el i -ésimo vector singular a derecha y u^i el i -ésimo vector singular a izquierda.

Veamos que la norma de Frobenius y la norma 2 pueden expresarse en términos de los valores singulares de A .

Proposición 5.5 Sea $A \in \mathbb{R}^{m \times n}$ de rango r y $A = U \Sigma V^T$ su descomposición SVD, entonces

1. $\|A\|_2 = \sigma_1$,

$$2. \|A\|_F = \sqrt{\sigma_1^2 + \dots + \sigma_r^2}.$$

Demostración. Como $\|\Sigma\|_2 = \sigma_1$, entonces

$$\|A\|_2 = \|U^T A V\|_2 = \|\Sigma\|_2 = \sigma_1.$$

Por otro lado, como

$$\Sigma = \begin{bmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{bmatrix} \quad \text{con} \quad \hat{\Sigma} = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix},$$

entonces

$$\begin{aligned} \|A\|_F^2 &= \text{tr}(A^T A) = \text{tr}(V \Sigma^T U^T U \Sigma V^T) = \text{tr}(V \Sigma^T \Sigma V^T) = \text{tr}(\Sigma^T \Sigma V^T V) \\ &= \text{tr}(\Sigma^T \Sigma) = \text{tr}(\hat{\Sigma}^T \hat{\Sigma}) = \sigma_1^2 + \dots + \sigma_r^2, \end{aligned}$$

donde usamos que $\text{tr}(M_1 M_2) = \text{tr}(M_2 M_1)$. ■

En general, dada $A \in \mathbb{R}^{m \times n}$ de rango r se obtiene que

$$A = U \Sigma V^T = [u^1 \dots u^m] \begin{bmatrix} \sigma_1 (v^1)^T \\ \vdots \\ \sigma_r (v^r)^T \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \sum_{i=1}^r \sigma_i u^i (v^i)^T.$$

Como $\|u^i (v^i)^T\|_2 = \|u^i\|_2 \|v^i\|_2 = 1$, se obtiene una descomposición de A como combinación lineal de matrices de norma 1, donde los escalares son los valores singulares. Si los valores singulares fueran pequeños a partir de σ_k , con $k < r$, uno podría truncar la sumatoria y obtener una aproximación de A . Veamos que esa aproximación es la mejor en norma 2.

Teorema 5.6 Sea $A \in \mathbb{R}^{m \times n}$ de rango r y $A = U \Sigma V^T$ su descomposición SVD. Si para $k < r$,

$$A_k = \sum_{i=1}^k \sigma_i u^i (v^i)^T,$$

entonces A_k tiene rango k y

$$\min\{\|B - A\|_2 \mid B \in \mathbb{R}^{m \times n} \text{ de rango } \leq k\} = \|A_k - A\|_2 = \sigma_{k+1}.$$

Demostración. Como $(v^i)^T v^j = 0$ si $i \neq j$ e igual a 1 si $i = j$, entonces

$$U^T A_k V = \begin{bmatrix} (u^1)^T \\ \vdots \\ (u^m)^T \end{bmatrix} [\sigma_1 u^1 \dots \sigma_k u^k \ 0 \dots 0] = \begin{bmatrix} \Sigma_k & 0 \\ 0 & 0 \end{bmatrix},$$

donde

$$\Sigma_k = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_k \end{bmatrix}.$$

Obteniendo así que A_k tiene rango k . Sea $B \in \mathbb{R}^{m \times n}$ arbitraria con rango $\leq k$. Como $n = \dim(\text{Im}(B)) + \dim(\text{Ker}(B))$, entonces $\dim(\text{Ker}(B)) \geq n - k$. Obteniendo que $\dim(\text{Ker}(B)) + \dim(\text{span}\{v^1, \dots, v^{k+1}\}) \geq n + 1$. Garantizando por lo tanto la existencia de $z \in \text{Ker}(B) \cap \text{span}\{v^1, \dots, v^{k+1}\}$ con $\|z\|_2 = 1$. Entonces,

$$1 = \|z\|_2^2 = \|V^T z\|_2^2 = \sum_{i=1}^{k+1} ((v^i)^T z)^2,$$

pues $(v^i)^T z = 0$ si $i > k + 1$. Usando que $Bz = 0$ se obtiene

$$\begin{aligned} \|B - A\|_2^2 &\geq \|(B - A)z\|_2^2 = \|Az\|_2^2 = \|U\Sigma V^T z\|_2^2 = \|\Sigma V^T z\|_2^2 \\ &= \sum_{i=1}^{k+1} \sigma_i^2 ((v^i)^T z)^2 \geq \sigma_{k+1}^2 \sum_{i=1}^{k+1} ((v^i)^T z)^2 = \sigma_{k+1}^2. \end{aligned}$$

Veamos que la cota inferior se alcanza si $B = A_k$. Como

$$U^T(A_k - A)V = U^T A_k V - U^T A V = \begin{bmatrix} 0 & 0 & 0 \\ 0 & -\tilde{\Sigma}_k & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

con

$$\tilde{\Sigma}_k = \begin{bmatrix} \sigma_{k+1} & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}.$$

entonces $\|A_k - A\|_2 = \|U^T(A_k - A)V\|_2 = \sigma_{k+1}$. ■

Como ya vimos en el Teorema 3.21, cuando se tiene una matriz cuadrada no singular A toda matriz cuadrada B que satisfice

$$\|B - A\| < \frac{\|A\|}{\kappa(A)} = \frac{1}{\|A^{-1}\|},$$

también debe ser no singular.

Cuando la matriz es rectangular, se puede generalizar este resultado para norma 2 aplicando el Teorema anterior. La demostración del mismo es un buen ejercicio para el lector.

Corolario 5.7 Suponga $A \in \mathbb{R}^{m \times n}$ de rango $r = \min\{m, n\}$ con valores singulares $\sigma_1 \geq \dots \geq \sigma_r > 0$. Si $B \in \mathbb{R}^{m \times n}$ satisface $\|B - A\|_2 < \sigma_r$ entonces B tiene rango r .

5.2. Cuadrados mínimos y pseudoinversa

Para resolver el problema de cuadrados mínimos, una de las estrategias usadas fue la de realizar una descomposición QR con pivoteo de columnas. De esta forma se obtuvo que $Q^T AP = R$ con Q ortogonal y P permutación (también ortogonal). Ya que con la descomposición SVD se obtiene $U^T AV = \Sigma$, se pueden usar las ideas anteriores para resolver el problema de cuadrados mínimos.

Teorema 5.8 Sea $A \in \mathbb{R}^{m \times n}$ de rango r y $A = U\Sigma V^T$ su descomposición SVD. Si $b \in \mathbb{R}^m$ entonces

$$\bar{x} = \sum_{i=1}^r \frac{(u^i)^T b}{\sigma_i} v^i = \left(\sum_{i=1}^r \frac{1}{\sigma_i} v^i (u^i)^T \right) b$$

es solución de minimizar $\|Ax - b\|_2^2$ y el mínimo es $\|A\bar{x} - b\|_2^2 = \sum_{i=r+1}^m ((u^i)^T b)^2$. Además, si $\hat{x}$ es otra solución, entonces $\|\bar{x}\|_2 \leq \|\hat{x}\|_2$.

Demostración. Note que

$$\begin{aligned} \|Ax - b\|_2^2 &= \|U^T(Ax - b)\|_2^2 = \|U^T AV V^T x - U^T b\|_2^2 \\ &= \|\Sigma z - U^T b\|_2^2 = \sum_{i=1}^r (\sigma_i z_i - (u^i)^T b)^2 + \sum_{i=r+1}^m ((u^i)^T b)^2, \end{aligned}$$

donde $z = V^T x$. Claramente el mínimo se alcanza haciendo la primera sumatoria igual a cero, o sea, si $\hat{x}$ es solución y $\hat{z} = V^T \hat{x}$ entonces $\hat{z}_i = (u^i)^T b / \sigma_i$ para $i = 1, \dots, r$.

Defina $\bar{z}$ tomando $\bar{z}_i = (u^i)^T b / \sigma_i$ para $i = 1, \dots, r$ y $\bar{z}_i = 0$ para $i = r+1, \dots, n$. Entonces $\bar{x} = V\bar{z} = \sum_{i=1}^r \bar{z}_i v^i$ es minimizador y por lo tanto cumple que $\|A\bar{x} - b\|_2^2 = \sum_{i=r+1}^m ((u^i)^T b)^2$. Además, para cualquier solución $\hat{x}$,

$$\|\bar{x}\|_2^2 = \|\bar{z}\|_2^2 = \sum_{i=1}^r \bar{z}_i^2 = \sum_{i=1}^r \hat{z}_i^2 \leq \sum_{i=1}^n \hat{z}_i^2 = \|\hat{z}\|_2^2 = \|\hat{x}\|_2^2.$$

■

Si se desea resolver el problema de cuadrados mínimos con A invertible, entonces la solución de minimizar $\|Ax - b\|_2^2$ es $\bar{x} = A^{-1}b$. Usando la descomposición SVD para $A \in \mathbb{R}^{n \times n}$ de rango n , se obtiene que

$$A^{-1} = V\Sigma^{-1}U^T = V \begin{bmatrix} 1/\sigma_1 & & \\ & \ddots & \\ & & 1/\sigma_n \end{bmatrix} U^T.$$

Si se desea resolver el problema de cuadrados mínimos con $A \in \mathbb{R}^{m \times n}$ de rango n (implicando que $m \geq n$), se puede usar que la solución $\bar{x}$ debe resolver la ecuación normal $A^T A \bar{x} = A^T b$. Como $A^T A \in \mathbb{R}^{n \times n}$ es invertible, se obtiene que $\bar{x} = (A^T A)^{-1} A^T b$. De la descomposición SVD de A se obtiene que

$$\Sigma = \begin{bmatrix} \hat{\Sigma} \\ 0 \end{bmatrix} \in \mathbb{R}^{m \times n}, \quad \hat{\Sigma} = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix} \in \mathbb{R}^{n \times n}$$

y por lo tanto

$$A^T A = V \Sigma^T U^T U \Sigma V^T = V \Sigma^T \Sigma V^T = V \hat{\Sigma}^T \hat{\Sigma} V^T = V \hat{\Sigma}^2 V^T$$

y

$$(A^T A)^{-1} A^T = V \hat{\Sigma}^{-2} V^T V \Sigma^T U^T = V \hat{\Sigma}^{-2} [\hat{\Sigma} \ 0] U^T = V [\hat{\Sigma}^{-1} \ 0] U^T.$$

Esto puede generalizarse con la siguiente definición.

Definición 5.9 Dada $A \in \mathbb{R}^{m \times n}$ de rango r y su descomposición SVD

$$A = U \begin{bmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{bmatrix} V^T, \quad \hat{\Sigma} = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} \in \mathbb{R}^{r \times r}$$

se define su pseudoinversa como

$$A^\dagger = V \begin{bmatrix} \hat{\Sigma}^{-1} & 0 \\ 0 & 0 \end{bmatrix} U^T$$

Ahora, si $A \in \mathbb{R}^{m \times n}$ tiene rango r y se toma $b \in \mathbb{R}^m$,

$$A^\dagger b = V \begin{bmatrix} \hat{\Sigma}^{-1} & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} (u^1)^T b \\ \vdots \\ (u^r)^T b \\ 0 \\ \vdots \\ 0 \end{bmatrix} = V \begin{bmatrix} (u^1)^T b / \sigma_1 \\ \vdots \\ (u^r)^T b / \sigma_r \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \sum_{i=1}^r \frac{(u^i)^T b}{\sigma_i} v^i.$$

Por el Teorema 5.8 se sabe que $\bar{x} = A^\dagger b$ es la solución de norma 2 mínima del problema de cuadrados mínimos.

Note que si $A \in \mathbb{R}^{n \times n}$ tiene rango n entonces

$$A^\dagger = V \hat{\Sigma}^{-1} U^T = A^{-1}.$$

Además, si $A \in \mathbb{R}^{m \times n}$ tiene rango n entonces

$$A^\dagger = V [\hat{\Sigma}^{-1} \ 0] U^T = (A^T A)^{-1} A^T.$$

Por lo tanto, para cualquier $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$ una solución de

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \|Ax - b\|_2^2$$

es $\bar{x} = A^\dagger b$.

5.3. Calculando la SVD

Un algoritmo eficiente para obtener la descomposición SVD de una matriz A puede encontrarse en [2, Subsección 8.6.2]. Otra manera, no tan eficiente pero más didáctica, consiste en los siguientes pasos:

1. Hallar los autovalores y autovectores de $C = A^T A$, o sea, W ortogonal y D diagonal tal que $W^T C W = D$.
2. Realizar una descomposición QR con permutación de columnas a la matriz AW , o sea, obtener Q ortogonal, R triangular superior y P permutación tal que $Q^T (AW) P = R$.
3. Definir $U = Q$, $V = WP$ y $\Sigma = R$.

Para ver que efectivamente esto nos genera una descomposición SVD, note primero que como C es simétrica y semidefinida positiva, entonces diagonaliza en base ortonormal y D tiene entradas diagonales no negativas. Como P es ortogonal, se tiene que $V = WP$ es ortogonal. De la descomposición QR con permutaciones obtenemos que las entradas diagonales de R son no negativas y decrecientes. Además

$$R^T R = (U^T A V)^T U^T A V = V^T C V = P^T W^T C W P = P^T D P.$$

Como $P^T D P$ es una matriz diagonal, se puede ver que R debe ser una matriz diagonal. Para ello, separando la primera entrada diagonal de R tenemos

$$R^T R = \begin{bmatrix} r_{11} & 0 \\ s & \hat{R}^T \end{bmatrix} \begin{bmatrix} r_{11} & s^T \\ 0 & \hat{R} \end{bmatrix} = \begin{bmatrix} r_{11}^2 & r_{11} s^T \\ r_{11} s & s s^T + \hat{R}^T \hat{R} \end{bmatrix}.$$

Por lo tanto $s = 0$ y $\hat{R}^T \hat{R}$ debe ser diagonal. Repitiendo este argumento se obtiene que R es una matriz diagonal.

Los métodos para realizar el paso 1 del procedimiento anterior se estudiarán en el siguiente capítulo.

5.4. Ejercicios

1. Demuestre que si $A \in \mathbb{R}^{m \times n}$ tiene valores singulares $\sigma_1 \geq \dots \geq \sigma_n > 0$, entonces $\|(A^T A)^{-1}\|_2 = \sigma_n^{-2}$, $\|(A^T A)^{-1} A^T\|_2 = \sigma_n^{-1}$, $\|A(A^T A)^{-1}\|_2 = \sigma_n^{-1}$ y $\|A(A^T A)^{-1} A^T\|_2 = 1$.
2. Si $A \in \mathbb{R}^{n \times n}$ tiene valores singulares $\sigma_1 \geq \dots \geq \sigma_n > 0$, demuestre que $\kappa_2(A) = \frac{\sigma_1}{\sigma_n}$.
3. Demuestre que dados $\varepsilon > 0$ y $A \in \mathbb{R}^{m \times n}$ de rango $r < \min\{m, n\}$, existe $A_\varepsilon \in \mathbb{R}^{m \times n}$ de rango $\min\{m, n\}$ tal que $\|A - A_\varepsilon\| < \varepsilon$.
4. Dada $A \in \mathbb{R}^{m \times n}$, defina $B(\lambda) = (A^T A + \lambda I)^{-1} A^T$ con $\lambda > 0$. Demuestre que si $p = \min\{m, n\}$, $\sigma_1 \geq \dots \geq \sigma_r > \sigma_{r+1} = \dots = \sigma_p = 0$ son los valores singulares de A y $A^\dagger$ es su pseudoinversa, entonces

$$\|B(\lambda) - A^\dagger\|_2 = \frac{\lambda}{\sigma_r(\sigma_r^2 + \lambda)}.$$

Concluya que $B(\lambda) \rightarrow A^\dagger$ si $\lambda \rightarrow 0^+$.

Capítulo 6

Autovalores y autovectores

En este capítulo, se asume que A es una matriz cuadrada. Ya que una matriz con coeficientes reales puede tener autovalores complejos, se deberá trabajar con elementos en $\mathbb{C}$, $\mathbb{C}^n$ y $\mathbb{C}^{n \times n}$. En este caso para $z \in \mathbb{C}$ con $z = x + iy$ se tendrá $|z| = \sqrt{x^2 + y^2}$ y para $A \in \mathbb{C}^{m \times n}$ se denotará por A^* a la matriz transpuesta y conjugada de A . De esta forma todas las normas vectoriales y matriciales previamente definidas para arreglos con coeficientes reales se extienden de manera natural al tener coeficientes complejos.

6.1. Método de Jacobi

Si se desea encontrar los autovalores y autovectores de $A \in \mathbb{R}^{2 \times 2}$ simétrica, uno puede hacerlo de manera directa, o sea, existen fórmulas cerradas para los autovalores λ_i y autovectores q^i tales que $Aq^i = \lambda_i q^i$, $i = 1, 2$. Veamos como deducir dichas fórmulas. Suponga que $Q = [q^1 \ q^2] \in \mathbb{R}^{2 \times 2}$ es una matriz de rotación, entonces

$$\begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} = Q^T A Q = \begin{bmatrix} c & s \\ -s & c \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} \\ a_{12} & a_{22} \end{bmatrix} \begin{bmatrix} c & -s \\ s & c \end{bmatrix}$$

$$= \begin{bmatrix} a_{11}c^2 + 2a_{12}cs + a_{22}s^2 & (a_{22} - a_{11})cs + a_{12}(c^2 - s^2) \\ (a_{22} - a_{11})cs + a_{12}(c^2 - s^2) & a_{11}s^2 - 2a_{12}cs + a_{22}c^2 \end{bmatrix},$$

donde $c = \cos(\theta)$ y $s = \sin(\theta)$ para algún θ . Claramente, si $a_{12} = 0$ entonces la matriz es diagonal y basta tomar $c = 1$ y $s = 0$ (i.e., $\theta = 0$). Si $a_{12} \neq 0$, entonces $c \neq 0$ (pues si $c = 0$ entonces $s = 1$). Tome

$$\tau = \frac{a_{22} - a_{11}}{2a_{12}}, \quad t = \frac{s}{c}.$$

Por lo tanto

$$0 = \frac{1}{c^2 a_{12}} ((a_{22} - a_{11})cs + a_{12}(c^2 - s^2)) = 2\tau t + 1 - t^2,$$

obteniendo $t = \tau \pm \sqrt{\tau^2 + 1}$. Para evitar errores numéricos, considere la raíz con menor valor absoluto. Con esto,

$$t = \tau - \sqrt{\tau^2 + 1} = -\frac{1}{\tau + \sqrt{\tau^2 + 1}}, \text{ si } \tau \geq 0,$$

$$t = \tau + \sqrt{\tau^2 + 1} = \frac{1}{-\tau + \sqrt{\tau^2 + 1}}, \text{ si } \tau < 0.$$

Como $t^2 = s^2/c^2 = (1 - c^2)/c^2 = 1/c^2 - 1$, se puede definir

$$c = \frac{1}{\sqrt{1+t^2}} \quad \text{y} \quad s = tc.$$

Claramente, una vez calculados c y s obtenemos que

$$\lambda_1 = a_{11}c^2 + 2a_{12}cs + a_{22}s^2,$$

$$\lambda_2 = a_{11}s^2 - 2a_{12}cs + a_{22}c^2.$$

Un pseudocódigo para este procedimiento es el siguiente:

Algoritmo 21 (*diagonalización de $A \in \mathbb{R}^{2 \times 2}$ simétrica*)

Entrada: $A \in \mathbb{R}^{2 \times 2}$. *Salidas:* $c, s \in \mathbb{R}$.

Paso 0: Si $A_{12} = 0$, definir $c = 1$ y $s = 0$ e ir al paso 2.

Paso 1: Definir

$$\begin{aligned} \tau &= (A_{22} - A_{11})/(2A_{12}), \\ t &= \begin{cases} -1/(\tau + \sqrt{\tau^2 + 1}), & \text{si } \tau \geq 0, \\ 1/(-\tau + \sqrt{\tau^2 + 1}), & \text{si } \tau < 0. \end{cases} \\ c &= 1/\sqrt{1+t^2}, \\ s &= tc. \end{aligned}$$

Paso 2: Retornar c y s

En general, para matrices simétricas de dimensiones mayores a 2, uno puede ir aplicando el procedimiento anterior en submatrices de dimensión 2.

El algoritmo de Jacobi para hallar autovalores consiste en definir en cada iteración una matriz A_k semejante a A_{k-1} con el siguiente procedimiento: en el paso k elegir los índices i, j tales que $|a_{ij}^{(k-1)}| = \max_{r \neq s} |a_{rs}^{(k-1)}|$ y definir $A_k = Q_k^T A_{k-1} Q_k$ donde

$$Q_k = \left[\begin{array}{c|cc|c} I & & & \\ \hline & c & -s & \\ & & I & \\ \hline & s & c & \\ & & & I \end{array} \right] \begin{array}{l} \rightarrow (i) \\ \rightarrow (j) \end{array}.$$

Obteniendo así A_k con $a_{ij}^{(k)} = 0$ y con los mismos autovalores de A_{k-1} .

Para analizar que este método iterativo converge a una matriz diagonal semejante a A se usará la función $\text{off} : \mathbb{R}^{n \times n} \mapsto \mathbb{R}$ dada por

$$\text{off}(A) = \sqrt{\sum_{i=1}^n \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij}^2}.$$

Claramente, $\text{off}(A) = 0$ si y solo si A es diagonal. Matemáticamente, $\text{off}(A)$ es la distancia en norma de Frobenius de A al conjunto de matrices diagonales.

Note que si A es simétrica, Q es la matriz de rotación de las coordenadas ij y $B = Q^T A Q$ entonces

$$\begin{bmatrix} b_{ii} & b_{ij} \\ b_{ji} & b_{jj} \end{bmatrix} = \begin{bmatrix} c & s \\ -s & c \end{bmatrix} \begin{bmatrix} a_{ii} & a_{ij} \\ a_{ij} & a_{jj} \end{bmatrix} \begin{bmatrix} c & -s \\ s & c \end{bmatrix},$$

donde c y s fueron escogidos de manera que $b_{ij} = b_{ji} = 0$. Como estas matrices 2×2 son semejantes, entonces poseen igual norma de Frobenius. Tomando norma de Frobenius al cuadrado se obtiene que

$$b_{ii}^2 + b_{jj}^2 = a_{ii}^2 + 2a_{ij}^2 + a_{jj}^2.$$

Además, $b_{ll} = a_{ll}$ para todo $l \neq i, j$. Usando nuevamente que matrices semejantes poseen igual norma de Frobenius, se concluye que

$$\begin{aligned} \text{off}(B)^2 &= \|B\|_F^2 - \sum_{l=1}^n b_{ll}^2 \\ &= \|A\|_F^2 - \sum_{\substack{l=1 \\ l \neq i, j}}^n a_{ll}^2 - (b_{ii}^2 + b_{jj}^2) \\ &= \|A\|_F^2 - \sum_{l=1}^n a_{ll}^2 - 2a_{ij}^2 \\ &= \text{off}(A)^2 - 2a_{ij}^2. \end{aligned}$$

Con esto, se puede establecer la convergencia del método de Jacobi.

Teorema 6.1 Sea $A \in \mathbb{R}^{n \times n}$ simétrica y considere $\{A_k\}$ generada por el método de Jacobi. Entonces

$$\lim_{k \rightarrow \infty} \text{off}(A_k) = 0.$$

Demostración. Como $\{A_k\}$ es generada por el método de Jacobi, $A_k = Q_k^T A_{k-1} Q_k$ y por lo visto anteriormente $\text{off}(A_k)^2 = \text{off}(A_{k-1})^2 - 2 \left(a_{ij}^{(k-1)} \right)^2$. Por otro lado, como $|a_{ij}^{(k-1)}| = \max_{r \neq s} |a_{rs}^{(k-1)}|$, se tiene que

$$\begin{aligned} \text{off}(A_{k-1})^2 &= \sum_{r=1}^n \sum_{\substack{s=1 \\ r \neq s}}^n \left(a_{rs}^{(k-1)} \right)^2 \\ &\leq (n^2 - n) \left(a_{ij}^{(k-1)} \right)^2 = 2N \left(a_{ij}^{(k-1)} \right)^2, \end{aligned}$$

donde $N = n(n-1)/2$. Por lo tanto $-2 \left(a_{ij}^{(k-1)} \right)^2 \leq -\frac{1}{N} \text{off}(A_{k-1})^2$ y

$$\text{off}(A_k)^2 \leq \left(1 - \frac{1}{N} \right) \text{off}(A_{k-1})^2 \leq \dots \leq \left(1 - \frac{1}{N} \right)^k \text{off}(A_0)^2.$$

Concluyendo que $\lim_{k \rightarrow \infty} \text{off}(A_k)^2 = 0$. ■

Un pseudocódigo para el método de Jacobi para diagonalizar matrices simétricas sería el siguiente:

Algoritmo 22 (método de Jacobi para diagonalización)

Entrada: $A \in \mathbb{R}^{n \times n}$ simétrica y $\epsilon > 0$. *Salidas:* $B, Q \in \mathbb{R}^{n \times n}$ t.q. $B = Q^T A Q$ con $\text{off}(B) \leq \epsilon$.

Paso 0: Definir $Q = I$.

Paso 1: Si $\text{off}(A) \leq \epsilon$ ir al paso 3.

Paso 2: Definir $\mathcal{I} = \{i, j\}$ t.q. $|A_{ij}| = \max_{r \neq s} |A_{rs}|$,

$$J = \begin{bmatrix} c & -s \\ s & c \end{bmatrix} \text{ aplicando Algoritmo 21 a } A_{\mathcal{II}},$$

$$A_{\mathcal{I}\bullet} \leftarrow J^T A_{\mathcal{I}\bullet},$$

$$A_{\bullet\mathcal{I}} \leftarrow A_{\bullet\mathcal{I}} J,$$

$$Q_{\bullet\mathcal{I}} \leftarrow Q_{\bullet\mathcal{I}} J.$$

Ir al paso 1.

Paso 3: Retornar $B = A$ y Q .

Una implementación correcta debería adicionar un criterio de parada por número de iteraciones máximas alcanzadas. Por otro lado, para simplificar cálculos puede usar que A es simétrica y por lo tanto

$$\text{off}(A) = \sqrt{2 \sum_{i=2}^n \sum_{j=1}^{i-1} a_{ij}^2}.$$

El procedimiento anterior debe comparar los valores de la matriz fuera de la diagonal en cada iteración. Para disminuir este costo, existen versiones donde en cada iteración todas las entradas de la parte triangular inferior (o superior) son visitadas.

Claramente, si $\epsilon = 0$ entonces el método finalizará con una matriz B diagonal cuyas entradas son los autovalores de A . Cuando $\epsilon > 0$, la matriz B puede no ser diagonal y sus entradas diagonales no son necesariamente los autovalores. El siguiente resultado nos provee una estimación del error cometido.

Teorema 6.2 (Discos de Gershgorin) Si $X^{-1}AX = D + F$ con D diagonal y F con ceros en la diagonal, entonces cada autovalor λ de A satisface

$$\lambda \in \bigcup_{i=1}^n D_i,$$

donde $D_i = \{z \in \mathbb{C} \mid |z - d_i| \leq \sum_{j=1}^n |f_{ij}|\}$.

Demostración. Sea λ un autovalor de A . Si $\lambda = d_i$ para algún i , el resultado es trivial. Suponga que $\lambda \neq d_i$ para todo i . Como λ es también autovalor de $X^{-1}AX$, entonces $D + F - \lambda I$ es singular. Luego $I + \Theta$ es singular para $\Theta = (D - \lambda I)^{-1}F$.

Si $\|\Theta\|_\infty < 1$, entonces

$$\frac{\|\Theta\|_\infty}{\|I\|_\infty} = \|\Theta\|_\infty < 1 = \frac{1}{\kappa_\infty(I)},$$

luego, por Teorema 3.21, $I + \Theta$ debe ser no singular. Por lo tanto

$$1 \leq \|\Theta\|_\infty = \|(D - \lambda I)^{-1}F\|_\infty = \sum_{j=1}^n \frac{|f_{ij}|}{|d_i - \lambda|}$$

para algún i . ■

En particular, si $X = I$ los discos de Gershgorin quedan

$$D_i = \left\{ z \in \mathbb{C} \mid |z - a_{ii}| \leq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \right\}.$$

O sea, el resultado anterior nos dice que los autovalores van a distar de los elementos diagonales como máximo la suma de los elementos de la fila en valor absoluto y sin la diagonal.

6.2. Métodos de las potencias

Supongamos que $A \in \mathbb{R}^{n \times n}$ es diagonalizable con $V = [v^1 \ \dots \ v^n] \in \mathbb{C}^{n \times n}$ tal que

$$V^{-1}AV = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix},$$

con $\lambda_i \in \mathbb{C}$ y $|\lambda_1| \geq \dots \geq |\lambda_n|$.

Definición 6.3 Se dirá que λ_1 es un autovalor dominante de A si $|\lambda_1| > |\lambda_2|$. En este caso, v^1 será llamado el autovector dominante de A .

Es sabido que si A tiene coeficientes reales y $\lambda \in \mathbb{C}$ es un autovalor de A , entonces $\bar{\lambda} \in \mathbb{C}$ también es un autovalor de A . Claramente $|\lambda| = |\bar{\lambda}|$. Con esto se concluye fácilmente que si $A \in \mathbb{R}^{n \times n}$ tiene un autovalor dominante λ_1 entonces $\lambda_1 \in \mathbb{R}$, más aún, $v^1 \in \mathbb{R}^n$.

Para deducir el método de las potencias, supongamos que $A \in \mathbb{R}^{n \times n}$ es diagonalizable y que tiene un autovalor dominante. Tome $q \in \mathbb{R}^n$ arbitrario. Como las columnas de V generan $\mathbb{C}^n$ entonces existen $c_1, \dots, c_n$ tales que $q = \sum_{i=1}^n c_i v^i$. Por lo tanto

$$Aq = \sum_{i=1}^n c_i A v^i = \sum_{i=1}^n c_i \lambda_i v^i.$$

Aplicando A reiteradas veces, se obtiene que

$$A^k q = \sum_{i=1}^n c_i \lambda_i^k v^i = \lambda_1^k \left(c_1 v^1 + \sum_{i=2}^n c_i \left(\frac{\lambda_i}{\lambda_1} \right)^k v^i \right).$$

Este producto matriz vector puede ser definido iterativamente como $q^0 = q$, $q^k = Aq^{k-1}$ para $k \geq 1$. Claramente,

$$q^k = Aq^{k-1} = A^2 q^{k-2} = \dots = A^k q.$$

Como $\lim_{k \rightarrow \infty} \left(\frac{\lambda_i}{\lambda_1} \right)^k = 0$ para $i \geq 2$, entonces si $c_1 \neq 0$ se obtendrá

$$\lim_{k \rightarrow \infty} \|q^k\| = \begin{cases} +\infty & \text{si } |\lambda_1| > 1, \\ |c_1| \|v^1\| & \text{si } |\lambda_1| = 1, \\ 0 & \text{si } |\lambda_1| < 1. \end{cases}$$

Para evitar que q^k sea muy grande o muy pequeño en norma, habrá que escalarlo. Por ejemplo, defina

$$q^k = \frac{1}{\lambda_1} Aq^{k-1}, \quad q^0 = q.$$

Como $Aq^0 = \lambda_1(c_1 v^1 + \sum_{i=2}^n c_i (\lambda_i/\lambda_1) v^i)$ se tendrá $q^1 = c_1 v^1 + \sum_{i=2}^n c_i (\lambda_i/\lambda_1) v^i$. Siguiendo el proceso de multiplicar por A y dividir por λ_1 se obtiene que

$$q^k = c_1 v^1 + \sum_{i=2}^n c_i \left(\frac{\lambda_i}{\lambda_1} \right)^k v^i.$$

Por lo tanto $\lim_{k \rightarrow \infty} q^k = c_1 v^1$. Obteniendo una sucesión que converge a un autovector dominante.

Lamentablemente, λ_1 es también una incógnita de nuestro problema y por lo tanto el escalado escogido es generalmente impracticable. Una opción fácilmente computable es la siguiente:

$$q^k = \frac{1}{\sigma_{k-1}} Aq^{k-1}, \quad q^0 = q,$$

donde σ_{k-1} garantiza que $\|q^k\| = 1$ para alguna norma.

Teorema 6.4 Sea $A \in \mathbb{R}^{n \times n}$ diagonalizable con λ_1 autovalor dominante y $V = [v^1 \dots v^n] \in \mathbb{C}^{n \times n}$ autovectores. Suponga que las sucesiones $\{q^k\}$ y $\{\rho_k\}$ fueron generadas por

$$q^{k+1} = \frac{1}{[Aq^k]_{j_k}} Aq^k, \quad \rho_{k+1} = [Aq^{k+1}]_{j_k},$$

donde $[Aq^k]_{j_k} = \|Aq^k\|_\infty$. Si $q^0 \in \mathbb{R}^n$ con $q^0 = \sum_{i=1}^n c_i v^i$ y $c_1 \neq 0$, entonces $\{\rho_k\}$ converge a λ_1 y los puntos límite de $\{q^k\}$ son $v^1/\|v^1\|_\infty$ y $-v^1/\|v^1\|_\infty$.

Demostración. Tome $\sigma_k = [Aq^k]_{j_k}$, $\eta_0 = 1$ y $\eta_{k+1} = \eta_k \frac{\sigma_k}{\lambda_1}$. Por lo tanto

$$\begin{aligned}\eta_k q^k &= \eta_{k-1} \frac{\sigma_{k-1}}{\lambda_1} q^k = \eta_{k-1} \frac{1}{\lambda_1} Aq^{k-1} = \frac{1}{\lambda_1} A \left(\eta_{k-1} q^{k-1} \right) \\ &= \frac{1}{\lambda_1^k} A^k q^0 \\ &= c_1 v^1 + \sum_{i=2}^n c_i \left(\frac{\lambda_i}{\lambda_1} \right)^k v^i.\end{aligned}$$

Como λ_1 es dominante, se tiene que

$$\lim_{k \rightarrow \infty} \eta_k q^k = c_1 v^1. \quad (6.1)$$

Como $\|q^k\|_\infty = 1$ y $\eta_k \neq 0$ (pues $c_1 \neq 0$), entonces $\lim_{k \rightarrow \infty} |\eta_k| = \|c_1 v^1\|_\infty$.

O sea, $\{\eta_k\}$ tiene a lo sumo dos puntos límite, $\|c_1 v^1\|_\infty$ y $-\|c_1 v^1\|_\infty$. De esto se deduce que $q^k = \eta_k^{-1} \eta_k q^k$ tiene a lo sumo dos puntos límite, $v^1/\|v^1\|_\infty$ y $-v^1/\|v^1\|_\infty$.

Por otro lado, como para todo k vale que $q_{j_{k-1}}^k = 1$, entonces

$$\rho_k = [Aq^k]_{j_{k-1}} = \sigma_k q_{j_{k-1}}^{k+1} = \lambda_1 \frac{\eta_{k+1}}{\eta_k} q_{j_{k-1}}^{k+1} = \lambda_1 \frac{[\eta_{k+1} q^{k+1}]_{j_{k-1}}}{[\eta_k q^k]_{j_{k-1}}}.$$

Además, como la sucesión $\{j_{k-1}\}$ es un conjunto infinito contenido en $\{1, \dots, n\}$, debe existir algún $l \in \{1, \dots, n\}$ tal que $j_{k-1} = l$ para infinitos k . Defina $\mathcal{K}_l = \{k \mid j_{k-1} = l\}$ y tome l tal que $\mathcal{K}_l$ sea infinito, entonces usando (6.1) se obtiene

$$\lim_{\substack{k \rightarrow \infty \\ k \in \mathcal{K}_l}} \rho_k = \lim_{\substack{k \rightarrow \infty \\ k \in \mathcal{K}_l}} \lambda_1 \frac{[\eta_{k+1} q^{k+1}]_l}{[\eta_k q^k]_l} = \lambda_1 \frac{c_1 v_l^1}{c_1 v_l^1} = \lambda_1.$$

Como el límite es independiente del l escogido, se obtiene que λ_1 es el límite de $\{\rho_k\}$. ■

Un pseudocódigo para el procedimiento del Teorema es el siguiente:

Algoritmo 23 (método de las potencias en norma infinito)

Entrada: $A \in \mathbb{R}^{n \times n}$, $q^0 \in \mathbb{R}^n$ y $\epsilon > 0$. *Salidas:* $q \in \mathbb{R}^n$ y $\rho \in \mathbb{R}$.

Paso 0: Definir $\hat{q} = Aq^0$ y $\hat{\rho} = \infty$.

Paso 1: Definir j t.q. $|\hat{q}_j| = \|\hat{q}\|_\infty$,

$$q = \hat{q}/\hat{q}_j,$$

$$\hat{q} = Aq,$$

$$\rho = \hat{q}_j.$$

Paso 2: Si $|\rho - \hat{\rho}| \leq \epsilon$, parar y retornar q y ρ .

Sino, definir $\hat{\rho} = \rho$ e ir al paso 1.

Una implementación correcta debería adicionar un criterio de parada por número de iteraciones máximas alcanzadas.

Veamos un resultado análogo usando $\|\cdot\|_2$.

Teorema 6.5 Sea $A \in \mathbb{R}^{n \times n}$ diagonalizable con λ_1 autovalor dominante y $V = [v^1 \dots v^n] \in \mathbb{C}^{n \times n}$ autovectores. Suponga que las sucesiones $\{q^k\}$ y $\{\rho_k\}$ fueron generadas por

$$q^{k+1} = \frac{1}{\|Aq^k\|_2} Aq^k, \quad \rho_{k+1} = (q^{k+1})^T Aq^{k+1}.$$

Si $q^0 \in \mathbb{R}^n$ con $q^0 = \sum_{i=1}^n c_i v^i$ y $c_1 \neq 0$, entonces $\{\rho_k\}$ converge a λ_1 y los puntos límite de $\{q^k\}$ son $v^1/\|v^1\|_2$ y $-v^1/\|v^1\|_2$.

Demostración. Defina $\sigma_k = \|Aq^k\|_2$, $\eta_0 = 1$ y $\eta_{k+1} = \eta_k \frac{\sigma_k}{\lambda_1}$. Por lo tanto

$$\begin{aligned} \eta_k q^k &= \eta_{k-1} \frac{\sigma_{k-1}}{\lambda_1} q^k = \eta_{k-1} \frac{1}{\lambda_1} Aq^{k-1} = \frac{1}{\lambda_1} A \left(\eta_{k-1} q^{k-1} \right) \\ &= \frac{1}{\lambda_1^k} A^k q^0 \\ &= c_1 v^1 + \sum_{i=2}^n c_i \left(\frac{\lambda_i}{\lambda_1} \right)^k v^i. \end{aligned}$$

Como λ_1 es dominante, se tiene que $\lim_{k \rightarrow \infty} \eta_k q^k = c_1 v^1$.

Por otro lado, como $\|q^k\|_2 = 1$ y $\eta_k \neq 0$ (pues $c_1 \neq 0$), entonces $\lim_{k \rightarrow \infty} |\eta_k| = \|c_1 v^1\|_2$. Por lo tanto $\{\eta_k\}$ tiene a lo sumo dos puntos límite, $\|c_1 v^1\|_2$ y $-\|c_1 v^1\|_2$.

Combinando estos límites, se obtiene que $q^k = \eta_k^{-1} \eta_k q^k$ tiene a lo sumo dos puntos límite, $v^1/\|v^1\|_2$ y $-v^1/\|v^1\|_2$.

Veamos ahora que la sucesión $\{\rho_k\}$ converge a λ_1 . Note que

$$\begin{aligned} \rho_k &= (q^k)^T Aq^k = \sigma_k (q^k)^T q^{k+1} = \lambda_1 \frac{\eta_{k+1}}{\eta_k} (q^k)^T q^{k+1} \\ &= \lambda_1 \frac{1}{\eta_k^2} (\eta_k q^k)^T (\eta_{k+1} q^{k+1}). \end{aligned}$$

Usando los límites anteriores se obtiene que

$$\lim_{k \rightarrow \infty} \rho_k = \lambda_1 \frac{1}{\|c_1 v^1\|_2^2} (c_1 v^1)^T (c_1 v^1) = \lambda_1.$$

Podemos describir este procedimiento en el siguiente pseudocódigo:

Algoritmo 24 (método de las potencias en norma 2)

Entrada: $A \in \mathbb{R}^{n \times n}$, $q^0 \in \mathbb{R}^n$ y $\epsilon > 0$. *Salidas:* $q \in \mathbb{R}^n$ y $\rho \in \mathbb{R}$.

Paso 0: Definir $\hat{q} = Aq^0$ y $\hat{\rho} = (q^0)^T \hat{q} / \|q^0\|_2^2$.

Paso 1: Definir

$$q = \hat{q} / \|\hat{q}\|_2,$$

$$\hat{q} = Aq,$$

$$\rho = q^T \hat{q}.$$

Paso 2: Si $|\rho - \hat{\rho}| \leq \epsilon$, parar y retornar q y ρ .

Sino, definir $\hat{\rho} = \rho$ e ir al paso 1.

Note que la aproximación inicial al autovalor fue definida como $\rho_0 = \frac{(q^0)^T A q^0}{\|q^0\|_2^2}$.

La forma de aproximar el autovalor en el resultado anterior es una expresión conocida.

Definición 6.6 El cociente de Rayleigh de $q \in \mathbb{C}^n$ con respecto a $A \in \mathbb{C}^{n \times n}$ es el valor

$$\rho = \frac{q^* A q}{q^* q}.$$

Veamos que el cociente de Rayleigh aproxima al autovalor.

Teorema 6.7 Sea $A \in \mathbb{C}^{n \times n}$ tal que $Av = \lambda v$ con $\|v\|_2 = 1$ y sea $\rho = q^* A q$ con $q^* q = \|q\|_2^2 = 1$. Entonces $|\lambda - \rho| \leq 2\|A\|_2\|v - q\|_2$.

Demostración. Como $v^* Av = \lambda\|v\|_2^2 = \lambda$, entonces

$$\lambda - \rho = v^* Av - q^* A q = v^* A(v - q) + (v - q)^* A q.$$

Por lo tanto,

$$|\lambda - \rho| \leq \|v\|_2 \|A\|_2 \|v - q\|_2 + \|v - q\|_2 \|A\|_2 \|q\|_2 = 2\|A\|_2 \|v - q\|_2.$$

Si A tiene autovalores $\lambda_1, \dots, \lambda_n$ con

$$|\lambda_1| > |\lambda_2| > \dots > |\lambda_n|,$$

entonces la matriz $A - \rho I$ tiene autovalores $\lambda_1 - \rho, \dots, \lambda_n - \rho$ con

$$|\lambda_{i_1} - \rho| > |\lambda_{i_2} - \rho| > \dots > |\lambda_{i_n} - \rho|.$$

Por lo tanto, si aplicamos el método de las potencias a la matriz $A - \rho I$ se obtendrá como resultado $\tilde{\lambda} = \lambda_{i_1} - \rho$. Concluyendo que $\lambda_{i_1} = \tilde{\lambda} + \rho$. De esta manera, al variar ρ se podrían calcular todos los autovalores de A . Esta variante es conocida como método de las potencias con desplazamientos.

En el caso particular de tener A simétrica, se obtiene que

$$A = V \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} V^T = \sum_{i=1}^n \lambda_i v^i (v^i)^T.$$

Entonces se pueden calcular los primeros k autovalores de A de la siguiente manera: tome $A_0 = A$ e $i = 1$.

1. Obtenga λ_i, v^i aplicando el método de las potencias en norma 2 a $\tilde{A}_{i-1}$.
2. Defina $\tilde{A}_i = \tilde{A}_{i-1} - \lambda_i v^i (v^i)^T$.
3. Si $i = k$, parar. Sino hacer $i \leftarrow i + 1$ e ir al paso 1.

6.2.1. Método de las potencias inversas

Como es sabido, si λ es un autovalor de una matriz no singular A , entonces $1/\lambda$ es un autovalor de A^{-1} . Usando esta propiedad se obtiene que si $\lambda_1, \dots, \lambda_n$ son autovalores de A y ρ es una aproximación de λ_i tal que $|\lambda_i - \rho| < |\lambda_j - \rho|$ para todo $j \neq i$ entonces

$$\frac{1}{|\lambda_i - \rho|} > \frac{1}{|\lambda_j - \rho|}$$

para todo $j \neq i$. O sea, $1/(\lambda_i - \rho)$ es un autovalor dominante de $(A - \rho I)^{-1}$.

Aplicando el método de las potencias se genera $\{q^k\}$, con

$$q^{k+1} = \frac{1}{\sigma_k} (A - \rho I)^{-1} q^k.$$

Computacionalmente, se debe hallar z^k tal que $(A - \rho I)z^k = q^k$ y luego definir $q^{k+1} = \frac{1}{\sigma_k} z^k$. Este procedimiento obtendrá $\tilde{\lambda} = 1/(\lambda_i - \rho)$ y por lo tanto $\lambda_i = 1/\tilde{\lambda} + \rho$.

Una de las mayores deficiencias de esta técnica es el hecho de tener un desplazamiento ρ adecuado. Una de las opciones más viables es ir actualizando el valor de ρ en cada iteración de manera que vaya aproximando a algún autovalor. Si dicha aproximación se realiza usando el cociente de Rayleigh se obtiene lo siguiente: dado q^0 con $\|q^0\|_2 = 1$ y $k = 0$,

1. definir $\rho_k = (q^k)^T A q^k$,
2. hallar z^k tal que $(A - \rho_k I)z^k = q^k$,
3. definir $q^{k+1} = z^k / \|z^k\|_2$, hacer $k \leftarrow k + 1$ y regresar al paso 1.

Este procedimiento recibe el nombre de iteración del cociente de Rayleigh. Note que

$$\rho_{k+1} = (q^{k+1})^T A q^{k+1} = (q^{k+1})^T (A - \rho_k I) q^{k+1} + \rho_k = \frac{(q^{k+1})^T q^k}{\|z^k\|_2} + \rho_k.$$

Tomando esto en cuenta, obtenemos el siguiente pseudocódigo:

Algoritmo 25 (iteración del cociente de Rayleigh)

Entrada: $A \in \mathbb{R}^{n \times n}$, $q^0 \in \mathbb{R}^n$ y $\epsilon > 0$. *Salidas:* $q \in \mathbb{R}^n$ y $\rho \in \mathbb{R}$.

Paso 0: Definir $q = q^0 / \|q^0\|_2$, $\hat{q} = q$ y $\rho = q^T A q$.

Paso 1: Definir z tal que $(A - \rho I)z = \hat{q}$,

$$\sigma = \|z\|_2,$$

$$q = z/\sigma,$$

$$\theta = q^T \hat{q} / \sigma.$$

Paso 2: Si $|\theta| \leq \epsilon$, parar y retornar q y $\rho + \theta$.

Sino, definir $\hat{q} = q$, hacer $\rho \leftarrow \rho + \theta$ e ir al paso 1.

6.3. Método de iteraciones QR

El método de las potencias puede usarse para ir calculando los autovalores y autovectores de uno en uno, siempre y cuando uno inicie el proceso iterativo con un q^0 con coordenada no nula en la dirección del autovector dominante. Una propiedad difícil de verificar en la práctica.

Si $Q \in \mathbb{R}^{n \times n}$ es una matriz ortogonal, entonces sus columnas generan $\mathbb{R}^n$ y por lo tanto alguno de estos vectores columna es el q^0 necesario para la convergencia del método de las potencias. Una opción podría ser ejecutar el método de las potencias para cada una de las n columnas de Q , otra opción podría ser realizar una versión matricial del método de las potencias. Considere esta segunda opción.

El método de las potencias se compone de dos partes: la potencia ($z^k = Aq^{k-1}$) y el escalado ($q^k = z^k / \sigma_k$). Para realizar la parte de la potencia de manera matricial se puede considerar $Z_k = AQ_{k-1}$ donde Q_0 es una matriz ortogonal. En el proceso de escalado se deberá encontrar una matriz ortogonal Q_k que preserve el espacio generado por las columnas de Z_k , o sea $\text{Im}(Z_k)$. Esto se puede obtener realizando una descomposición QR de Z_k , obteniendo Q_k ortogonal y R_k tal que $Q_k R_k = Z_k$.

El procedimiento anterior es conocido como método de iteraciones ortogonales y su esquema iterativo es el siguiente: dada Q_0 ortogonal y $k = 0$,

1. definir $Z_k = AQ_{k-1}$,
2. obtener Q_k, R_k tal que $Q_k R_k = Z_k$ con la descomposición QR de Z_k ,
3. hacer $k = k + 1$ y regresar al paso 1.

Este método, genera sucesiones de matrices $\{Q_k\}$ ortogonales y $\{R_k\}$ triangulares superiores tales que

$$R_k = Q_k^T Z_k = Q_k^T A Q_{k-1}.$$

Como $\|Q_k\|_2 = 1$ para todo k , tomando subsucesiones se obtiene que R_k converge a $Q^T A \hat{Q}$ triangular superior, donde Q y $\hat{Q}$ son puntos límite de Q_k y Q_{k-1} , respectivamente.

Si en el método de iteraciones ortogonales se van definiendo matrices $T_k = Q_k^T A Q_k$, tomando límite se obtendría $T = Q^T A Q$ con Q ortogonal. Si T fuera triangular superior se tendrían los autovalores de A en la diagonal de T . Infelizmente, todas las matrices anteriores tienen coeficientes reales y no toda matriz $A \in \mathbb{R}^{n \times n}$ tiene todos sus autovalores reales. Se verá que para matrices con coeficientes complejos siempre se puede encontrar una matriz semejante a A triangular superior. Más aún, si se realiza el método de las iteraciones ortogonales con matrices $Q_k \in \mathbb{C}^{n \times n}$ unitarias entonces la sucesión $\{T_k\}$ converge a una matriz triangular superior semejante a A .

En lo que sigue, se trabajará con matrices de coeficientes complejos y luego se adaptarán las ideas para matrices con coeficientes reales.

Veamos primero que toda matriz $A \in \mathbb{C}^{n \times n}$ es semejante a una triangular superior.

Teorema 6.8 (Descomposición de Schur) Si $A \in \mathbb{C}^{n \times n}$, entonces existe $Q \in \mathbb{C}^{n \times n}$ unitaria tal que $T = Q^* A Q$ es triangular superior.

Demostración. Se demostrará realizando inducción en n . Si $n = 1$ entonces $A = a \in \mathbb{C}$. Tomando $Q = 1$ se obtiene $Q^* A Q = a = T$.

Suponga que el teorema vale para matrices de dimensión $n - 1$. Sea $\lambda \in \mathbb{C}$ tal que $Av = \lambda v$ con $\|v\|_2 = 1$. Usando Gram-Schmidt genero $U = [v \ V] \in \mathbb{C}^{n \times n}$ unitaria. Como

$$U^* A U = \begin{bmatrix} v^* \\ V^* \end{bmatrix} [Av \ AV] = \begin{bmatrix} \lambda & w^* \\ 0 & B \end{bmatrix},$$

con $w^* = v^* A V$ y $B = V^* A V$. Por hipótesis inductiva, existe $\tilde{U} \in \mathbb{C}^{(n-1) \times (n-1)}$ unitaria tal que $\tilde{U}^* B \tilde{U} = \tilde{T}$ es triangular superior. Sea

$$Q = U \begin{bmatrix} 1 & 0 \\ 0 & \tilde{U} \end{bmatrix}.$$

Entonces

$$Q^* A Q = \begin{bmatrix} 1 & 0 \\ 0 & \tilde{U}^* \end{bmatrix} \begin{bmatrix} \lambda & w^* \\ 0 & B \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & \tilde{U} \end{bmatrix} = \begin{bmatrix} \lambda & w^* \tilde{U} \\ 0 & \tilde{T} \end{bmatrix} = T.$$

Que es una matriz triangular superior. ■

Claramente, la matriz triangular superior T es la suma de una matriz diagonal mas una nilpotente. Tal resultado suele encontrarse también en libros de álgebra lineal.

Veamos como generar iterativamente $T_k = Q_k^* A Q_k$ donde Q_k es unitaria y generada por el método de iteraciones ortogonales, o sea, $Q_k R_k = Z_k$ descomposición QR de Z_k con $Z_k = A Q_{k-1}$, donde Q_0 es unitaria. Por un lado

$$T_{k-1} = Q_{k-1}^* A Q_{k-1} = Q_{k-1}^* Z_k = Q_{k-1}^* Q_k R_k,$$

donde $Q_{k-1}^* Q_k$ es una matriz unitaria. Por otro lado

$$T_k = Q_k^* A Q_k = Q_k^* A Q_{k-1} Q_{k-1}^* Q_k = Q_k^* Z_k Q_{k-1}^* Q_k = R_k Q_{k-1}^* Q_k.$$

Por lo tanto, si se define U_k y R_k mediante la descomposición QR de T_{k-1} , o sea $T_{k-1} = U_k R_k$, se puede definir $T_k = R_k U_k$. Este procedimiento es conocido como *método de iteraciones QR* y su esquema iterativo es el siguiente: dada U_0 unitaria

1. definir $T_0 = U_0^* A U_0$ y $k = 1$,
2. obtener U_k, R_k tal que $U_k R_k = T_{k-1}$ con la descomposición QR de T_{k-1} ,
3. definir $T_k = R_k U_k$,
4. hacer $k = k + 1$ y regresar al paso 2.

Como

$$T_k = R_k U_k = U_k^* T_{k-1} U_k = \dots = U_k^* \dots U_1^* T_0 U_1 \dots U_k = Q_k^* A Q_k,$$

donde $Q_k = U_0 U_1 \dots U_k$, entonces, tomando subsucesiones si fuera necesario, $\{T_k\}$ converge a T semejante a A . Además, si $|\lambda_1| > \dots > |\lambda_n|$ se puede afirmar que T es triangular superior. La demostración de esa afirmación puede obtenerse usando [2, Teorema 7.3.1] o [5, Teorema 6.2.3].

Ahora estamos en condiciones de adaptar el método de iteraciones QR para matrices con coeficientes reales. Veamos en primer lugar la descomposición de Schur.

Teorema 6.9 (Descomposición de Schur en $\mathbb{R}$) Si $A \in \mathbb{R}^{n \times n}$, entonces existe $Q \in \mathbb{R}^{n \times n}$ ortogonal tal que

$$Q^T A Q = \begin{bmatrix} R_{11} & R_{12} & \dots & R_{1s} \\ & R_{22} & & \vdots \\ & & \ddots & \vdots \\ & & & R_{ss} \end{bmatrix},$$

donde $R_{ll} \in \mathbb{R}^{2 \times 2}$ con autovalores complejos conjugados ó $R_{ll} \in \mathbb{R}^{1 \times 1}$.

Demostración. Como $p(x) = \det(A - xI)$ tiene coeficientes reales, si $p(\lambda) = 0$ con $\lambda \in \mathbb{C}$ entonces $p(\bar{\lambda}) = 0$. Sea k el número de pares $(\lambda, \bar{\lambda})$ de autovalores complejos de A . La demostración se realizará mediante inducción en k .

Si $k = 0$ entonces se puede usar el mismo argumento usado para demostrar el Teorema 6.8, obteniendo que $R_{ll} \in \mathbb{R}^{1 \times 1}$ para todo l .

Suponga que A tiene $k \geq 1$ pares de autovalores complejos $(\lambda, \bar{\lambda})$ y que el Teorema vale para $k - 1$. Si $\lambda = \gamma + i\mu \in \mathbb{C}$, con $\mu \neq 0$, es un autovalor de A , entonces existen $y, z \in \mathbb{R}^n$ tales que $y + iz \neq 0$ y

$$A(y + iz) = (\gamma + i\mu)(y + iz) = \gamma y - \mu z + i(\mu y + \gamma z).$$

Agrupando parte real y parte imaginaria, se obtiene que

$$A[y \ z] = [y \ z] \begin{bmatrix} \gamma & \mu \\ -\mu & \gamma \end{bmatrix} = [y \ z] S \quad \text{con} \quad [y \ z] \in \mathbb{R}^{n \times 2}, \quad S = \begin{bmatrix} \gamma & \mu \\ -\mu & \gamma \end{bmatrix}.$$

Veamos que y, z son vectores linealmente independientes. Si $y = cz$ para $c \in \mathbb{R}$ entonces

$$Az = \frac{1}{c+i} A(y + iz) = \frac{1}{c+i} (\gamma + i\mu)(y + iz) = (\gamma + i\mu)z.$$

Contradiciendo que $Az \in \mathbb{R}^n$.

Usando que y, z son linealmente independientes, la descomposición QR nos garantiza la existencia de $\hat{R} \in \mathbb{R}^{2 \times 2}$ triangular superior no singular y $\hat{Q} \in \mathbb{R}^{n \times n}$ ortogonal tales que

$$[y \ z] = \hat{Q} \begin{bmatrix} \hat{R} \\ 0 \end{bmatrix}.$$

Considere la siguiente matriz partida por bloques

$$\hat{Q}^T A \hat{Q} = \begin{bmatrix} \hat{R}_{11} & \hat{R}_{12} \\ \hat{R}_{21} & \hat{R}_{22} \end{bmatrix},$$

con $\hat{R}_{11} \in \mathbb{R}^{2 \times 2}$. Entonces

$$\begin{aligned} \begin{bmatrix} \hat{R}_{11} \hat{R} \\ \hat{R}_{21} \hat{R} \end{bmatrix} &= \begin{bmatrix} \hat{R}_{11} & \hat{R}_{12} \\ \hat{R}_{21} & \hat{R}_{22} \end{bmatrix} \begin{bmatrix} \hat{R} \\ 0 \end{bmatrix} = \hat{Q}^T A \hat{Q} \begin{bmatrix} \hat{R} \\ 0 \end{bmatrix} \\ &= \hat{Q}^T A [y \ z] = \hat{Q}^T [y \ z] S \\ &= \begin{bmatrix} \hat{R} \\ 0 \end{bmatrix} S = \begin{bmatrix} \hat{R} S \\ 0 \end{bmatrix}. \end{aligned}$$

Como $\hat{R}$ es no singular, se concluye que $\hat{R}_{21} = 0$ y $S = \hat{R}^{-1} \hat{R}_{11} \hat{R}$. Por lo tanto los autovalores de $\hat{R}_{11}$ coinciden con los de S y son $\gamma + i\mu$ y $\gamma - i\mu$. Además, la matriz $\hat{R}_{22}$ debe tener los restantes autovalores de A y por lo tanto a lo sumo $k - 1$ pares de autovalores complejos $(\lambda, \bar{\lambda})$. Por hipótesis inductiva, existe $\tilde{Q} \in \mathbb{R}^{(n-2) \times (n-2)}$ ortogonal tal que $\tilde{Q}^T \hat{R}_{22} \tilde{Q} = R_{22}$ cumple con el resultado del Teorema. Defina

$$Q = \hat{Q} \begin{bmatrix} I & 0 \\ 0 & \tilde{Q} \end{bmatrix}, \quad I \in \mathbb{R}^{2 \times 2}.$$

Entonces

$$Q^T A Q = \begin{bmatrix} I & 0 \\ 0 & \tilde{Q}^T \end{bmatrix} \begin{bmatrix} \hat{R}_{11} & \hat{R}_{12} \\ 0 & \hat{R}_{22} \end{bmatrix} \begin{bmatrix} I & 0 \\ 0 & \tilde{Q} \end{bmatrix} = \begin{bmatrix} \hat{R}_{11} & \hat{R}_{12} \tilde{Q} \\ 0 & R_{22} \end{bmatrix}$$

cumple lo enunciado en el Teorema. ■

La matriz semejante a A del resultado anterior corresponde a una familia de matrices conocidas.

Definición 6.10 Se dice que H es una matriz Hessenberg superior si $h_{ij} = 0$ para $i > j + 1$.

Una matriz Hessenberg superior 5×5 tiene la siguiente estructura:

$$H = \begin{bmatrix} h_{11} & h_{12} & h_{13} & h_{14} & h_{15} \\ h_{21} & h_{22} & h_{23} & h_{24} & h_{25} \\ 0 & h_{32} & h_{33} & h_{34} & h_{35} \\ 0 & 0 & h_{43} & h_{44} & h_{45} \\ 0 & 0 & 0 & h_{54} & h_{55} \end{bmatrix}$$

El método de iteraciones QR preserva la estructura Hessenberg superior de las matrices.

Teorema 6.11 Si $H \in \mathbb{R}^{n \times n}$ es Hessenberg superior y no singular con $H = QR$ su descomposición QR, entonces RQ es Hessenberg superior.

Demostración. Como H es no singular, entonces R es triangular superior y no singular, por lo tanto $r_{ii} \neq 0$ para todo i . Veamos primero que Q es Hessenberg superior. Analizando las columnas de $H = QR$, se ve que la j -ésima columna es

$$\begin{bmatrix} h_{1j} \\ \vdots \\ h_{j+1,j} \\ 0 \\ \vdots \\ 0 \end{bmatrix} = Q \begin{bmatrix} r_{1j} \\ \vdots \\ r_{jj} \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \sum_{l=1}^j r_{lj} \begin{bmatrix} q_{1l} \\ \vdots \\ q_{l+1,l} \\ q_{l+2,l} \\ \vdots \\ q_{nl} \end{bmatrix}.$$

Para $j = 1$ se obtiene que $q_{i1} = 0$ para $i = 3, \dots, n$. Usando lo anterior, si $j = 2$ entonces $q_{i2} = 0$ para $i = 4, \dots, n$. Siguiendo de esta manera hasta $j = n$ se obtiene que $q_{ij} = 0$ para $i \geq j + 2$, concluyendo que Q es Hessenberg superior.

Ahora, analizando las columnas de $\tilde{H} = RQ$ se obtiene que la j -ésima columna es igual a

$$\begin{bmatrix} \tilde{h}_{1j} \\ \vdots \\ \tilde{h}_{j+1,j} \\ \tilde{h}_{j+2,j} \\ \vdots \\ \tilde{h}_{nj} \end{bmatrix} = R \begin{bmatrix} q_{1j} \\ \vdots \\ q_{j+1,j} \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \sum_{l=1}^{j+1} q_{lj} \begin{bmatrix} r_{1l} \\ \vdots \\ r_{ll} \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Por lo tanto $\tilde{h}_{ij} = 0$ para $i \geq j + 2$, o sea, $\tilde{H}$ es Hessenberg superior. ■

Usando esta propiedad, si iniciamos el método de iteraciones QR con una matriz ortogonal Q_0 tal que $H_0 = Q_0^T A Q_0$ sea Hessenberg superior entonces para todo k , $H_k = R_k Q_k$ es Hessenberg superior, donde $Q_k R_k = H_{k-1}$ es la descomposición QR de H_{k-1} .

Una de las maneras de reducir A en un Hessenberg superior, es ir aplicando matrices ortogonales para poner ceros debajo de la primera subdiagonal. Este procedimiento puede realizarse aplicando rotaciones de Givens o reflexiones de Householder. Por simplicidad, veamos cómo hacerlo mediante reflexiones.

Defina $V_j = I - (2/\|u^j\|_2^2)u^j(u^j)^T$ que transforme la j -ésima columna de A haciendo $a_{ij} = 0$ para $i = j + 2, \dots, n$. O sea,

$$V_j^T \begin{bmatrix} a_{1j} \\ \vdots \\ a_{j+1,j} \\ a_{j+2,j} \\ \vdots \\ a_{nj} \end{bmatrix} = \begin{bmatrix} a_{1j} \\ \vdots \\ \tilde{a}_{j+1,j} \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Como los primeros j elementos quedan invariantes, se obtendrá

$$V_1^T A V_1 = \begin{bmatrix} * & * & * & * & * & * \\ * & * & * & * & * & * \\ 0 & * & * & * & * & * \\ 0 & * & * & * & * & * \\ 0 & * & * & * & * & * \\ 0 & * & * & * & * & * \end{bmatrix}, \quad V_2^T V_1^T A V_1 V_2 = \begin{bmatrix} * & * & * & * & * & * \\ * & * & * & * & * & * \\ 0 & * & * & * & * & * \\ 0 & 0 & * & * & * & * \\ 0 & 0 & * & * & * & * \\ 0 & 0 & * & * & * & * \end{bmatrix},$$

$$V_{n-2}^T \dots V_2^T V_1^T A V_1 V_2 \dots V_{n-2} = \begin{bmatrix} * & * & * & * & * & * \\ * & * & * & * & * & * \\ 0 & * & * & * & * & * \\ 0 & 0 & * & * & * & * \\ 0 & 0 & 0 & * & * & * \\ 0 & 0 & 0 & 0 & * & * \end{bmatrix}.$$

Entonces $H_0 = Q_0^T A Q_0$, donde $Q_0 = V_1 V_2 \dots V_{n-2}$.

Un pseudocódigo para este procedimiento sería el siguiente:

Algoritmo 26 (reducción a Hessenberg usando Householder)

Entrada: $A \in \mathbb{R}^{n \times n}$. *Salidas:* $H, Q \in \mathbb{R}^{n \times n}$ t.q. $H = Q^T A Q$.

Paso 0: Definir $Q = I$ y $j = 1$.

Paso 1: Si $j > n - 2$ ir al paso 3. Sino, definir $\mathcal{I} = \{j + 1, \dots, n\}$, $\mathcal{J} = \{j, \dots, n\}$,

u, ρ aplicando Algoritmo 15 a $A_{\mathcal{I}\mathcal{J}}$,

$w = \rho u$,

$A_{\mathcal{I}\mathcal{J}} \leftarrow A_{\mathcal{I}\mathcal{J}} - w (u^T A_{\mathcal{I}\mathcal{J}})$,

$A_{\bullet\mathcal{I}} \leftarrow A_{\bullet\mathcal{I}} - A_{\bullet\mathcal{I}} w u^T$,

$Q_{\bullet\mathcal{I}} \leftarrow Q_{\bullet\mathcal{I}} - Q_{\bullet\mathcal{I}} w u^T$,

Paso 2: Hacer $j \leftarrow j + 1$ e ir al paso 1.

Paso 3: Retornar $H = A$ y Q

Un procedimiento similar puede realizarse utilizando rotaciones de Givens.

Note que si H_{k-1} es Hessenberg superior uno puede realizar su descomposición QR aplicando solamente una rotación de Givens $G_{j+1,j}$ para la columna j . Por lo tanto se puede obtener la descomposición QR de H_{k-1} haciendo

$$R_k = G_{n,n-1} \dots G_{32} G_{21} H_{k-1},$$

y luego obtener $H_k = R_k Q_k$ haciendo

$$H_k = R_k G_{21}^T G_{32}^T \dots G_{n,n-1}^T,$$

donde $Q_k = G_{21}^T G_{32}^T \dots G_{n,n-1}^T$.

Usando lo anterior, se puede implementar el método de iteraciones QR para obtener una sucesión de matrices $\{H_k\}$ que va a converger a una matriz H Hessenberg superior con bloques diagonales 1×1 o 2×2 , correspondiente a la descomposición de Schur en $\mathbb{R}$ de A .

Una implementación práctica de este método incorpora desplazamientos y reducción de dimensiones, entre otras cosas, y puede encontrarse en [2, Sección 7.5].

El siguiente pseudocódigo se incorpora con fines didácticos.

Algoritmo 27 (método de iteraciones QR)

Entradas: $A \in \mathbb{R}^{n \times n}$ y $k_{\max}$ (máximo de iteraciones). *Salidas:* $H, Q \in \mathbb{R}^{n \times n}$ t.q. $H = Q^T A Q$ es la descomposición de Schur.

Paso 0: Obtener H y Q aplicando el Algoritmo 26 a A y definir $k = 0, j = 1, l = 1$.

Paso 1: Si $j > n - 1$ ir al paso 3. Sino, definir $\mathcal{I} = \{j, j + 1\}, \mathcal{J} = \{j, \dots, n\}$,

$$G_j = \begin{bmatrix} c & -s \\ s & c \end{bmatrix} \text{ aplicando Algoritmo 13 a } (H_{jj}, H_{j+1,j}),$$

$$H_{\mathcal{I}\mathcal{J}} \leftarrow G_j H_{\mathcal{I}\mathcal{J}}.$$

Paso 2: Hacer $j \leftarrow j + 1$ e ir al paso 1.

Paso 3: Si $l > n - 1$ ir al paso 5. Sino, definir $\mathcal{I} = \{l, l + 1\}$,

$$H_{\bullet\mathcal{I}} \leftarrow H_{\bullet\mathcal{I}} G_l^T,$$

$$Q_{\bullet\mathcal{I}} \leftarrow Q_{\bullet\mathcal{I}} G_l^T.$$

Paso 4: Hacer $l \leftarrow l + 1$ e ir al paso 3.

Paso 5: Si $k > k_{\max}$, parar y retornar H y Q .

Sino, hacer $k \leftarrow k + 1, j = 1, l = 1$ e ir al paso 1.

6.4. Ejercicios

1. Demuestre que si A es simétrica y $Av^1 = \lambda_1 v^1$ entonces $\check{A} = A - \lambda_1 v^1 (v^1)^T$ es simétrica y tiene los mismos autovalores de A salvo λ_1 .
2. **Dinámica Poblacional.** Sea n_i^t la cantidad de individuos en la faja etaria i al final del año t , s_i la porción de individuos de la faja i que pasan anualmente a la faja $i + 1$ y f_i la tasa de fecundidad per cápita de la faja i . Entonces la dinámica de la población cumple con las siguientes ecuaciones:

$$n_1^{t+1} = f_1 n_1^t + \dots + f_p n_p^t$$

$$n_i^{t+1} = s_i n_{i-1}^t \quad \text{para } i = 2, \dots, p.$$

De manera vectorial esta dinámica puede escribirse como $n^{t+1} = L n^t$ donde L es llamada matriz de Leslie. Con el autovalor dominante λ_1 de esta matriz se obtiene

que si $\lambda_1 < 1$ la población decrece exponencialmente, $\lambda_1 > 1$ la población crece exponencialmente y $\lambda_1 = 1$ la población es estable e igual al autovector asociado.

Determine el comportamiento de la población de esta especie:

edad	0-2	2-4	4-6	6-8	8-10	10-12	12-14
f_i	0.0	0.2	0.9	0.9	0.9	0.8	0.3
s_i	0.3	0.7	0.9	0.9	0.9	0.6	0.0
n_i^0	10	2	8	5	12	0	1

3. Sea p un polinomio tal que $p(x) = x^n + a_{n-1}x^{n-1} + \dots + a_1x + a_0$. Demuestre que las raíces de p son los autovalores de la matriz

$$A = \begin{bmatrix} -a_{n-1} & -a_{n-2} & \cdots & -a_1 & -a_0 \\ 1 & & & & \\ & 1 & & & \\ & & \ddots & & \\ & & & 1 & \end{bmatrix}.$$

4. Sea H Hessenberg superior tal que $H = Q^T A Q$. Demuestre que si A es simétrica entonces H es tridiagonal.
5. Demostrar que si $T \in \mathbb{R}^{n \times n}$ es tridiagonal, simétrica y no singular con $T = QR$ su descomposición QR, entonces RQ es tridiagonal y simétrica.
6. Para una matriz $H_0 \in \mathbb{R}^{n \times n}$ Hessenberg superior, cada iteración del método QR con desplazamientos está dada por: $H_{k-1} - \mu_k I = Q_k R_k$ (descomposición QR) con $\mu_k = h_{nn}^{k-1}$, y $H_k = R_k Q_k + \mu_k I$. Pruebe que H_k es semejante a H_0 .

Capítulo 7

Métodos iterativos

Para resolver sistemas lineales con matrices de gran porte o ralas (que poseen pocos elementos no nulos), los métodos directos pueden no ser tan prácticos. Una descomposición (Cholesky o LU) implicaría almacenar en la memoria al menos dos matrices y en la mayoría de los casos densas (que poseen pocos elementos nulos). Perdiendo así la estructura de la matriz y aumentando el costo computacional.

Los métodos que se presentarán en este capítulo se basarán en generar una sucesión $\{x^k\}$ de aproximaciones a la solución x^* del sistema lineal $Ax = b$ con $A \in \mathbb{R}^{n \times n}$.

7.1. Métodos de separación

Para resolver el sistema lineal $Ax = b$ se considera $A = M - N$. Por lo tanto nuestro problema es hallar $x^* \in \mathbb{R}^n$ tal que $Mx^* = Nx^* + b$. Por lo tanto se generará una sucesión $\{x^k\}$ tal que

$$Mx^{k+1} = Nx^k + b. \quad (7.1)$$

Por un lado, para que este procedimiento sea práctico se debe escoger M de manera que el sistema lineal sea de fácil resolución. Por otro lado, hay que escoger M y N adecuadamente para que la sucesión $\{x^k\}$ converja a x^* .

Para analizar la convergencia de estos métodos, note que tomando $G : \mathbb{R}^n \mapsto \mathbb{R}^n$ tal que $G(x) = M^{-1}Nx + M^{-1}b$, se tiene que

$$x^{k+1} = G(x^k) \quad \text{y} \quad x^* = G(x^*).$$

Por lo tanto el problema se reduce a hallar un punto fijo de G .

Teorema 7.1 (Punto fijo) *Sea $\|\cdot\|$ una norma en $\mathbb{R}^n$, $F : \mathbb{R}^n \mapsto \mathbb{R}^n$ y suponga que existe $\tau \in [0, 1)$ tal que $\|F(y) - F(x)\| \leq \tau\|y - x\|$ para todo $x, y \in \mathbb{R}^n$. Entonces existe x^* tal que $x^* = F(x^*)$ y dicho punto es único. Más aún, para cualquier $x^0 \in \mathbb{R}^n$ la sucesión $\{x^k\}$ generada por $x^{k+1} = F(x^k)$ converge a x^* .*

Demostración. Sea x^0 arbitrario y $x^{k+1} = F(x^k)$ para $k \geq 0$. Como

$$\|x^{k+1} - x^k\| = \|F(x^k) - F(x^{k-1})\| \leq \tau\|x^k - x^{k-1}\| \leq \dots \leq \tau^k\|x^1 - x^0\|,$$

para $k \geq 1$. Suponiendo $m > l$ se deduce que

$$\begin{aligned} \|x^m - x^l\| &= \left\| \sum_{k=0}^{m-l-1} x^{l+k+1} - x^{l+k} \right\| \leq \sum_{k=0}^{m-l-1} \|x^{l+k+1} - x^{l+k}\| \\ &\leq \sum_{k=0}^{m-l-1} \tau^{l+k} \|x^1 - x^0\| \leq \tau^l \|x^1 - x^0\| \sum_{k=0}^{\infty} \tau^k \\ &= \frac{\tau^l}{1 - \tau} \|x^1 - x^0\|. \end{aligned}$$

Entonces $\{x^k\}$ es una sucesión de Cauchy y por lo tanto es convergente, o sea, existe x^* tal que $\lim_{k \rightarrow \infty} x^k = x^*$. Como F es continua, se obtiene que

$$x^* = \lim_{k \rightarrow \infty} x^{k+1} = \lim_{k \rightarrow \infty} F(x^k) = F(x^*).$$

Para demostrar la unicidad, note que si $F(\hat{x}) = \hat{x}$ para algún $\hat{x}$ entonces

$$\|\hat{x} - x^*\| = \|F(\hat{x}) - F(x^*)\| \leq \tau \|\hat{x} - x^*\|.$$

Por lo tanto $(1 - \tau)\|\hat{x} - x^*\| \leq 0$ con $1 - \tau > 0$. Concluyendo que $\hat{x} = x^*$. ■

Una condición suficiente para garantizar la convergencia de los métodos de separación es dada por el siguiente corolario.

Corolario 7.2 Sea $\{x^k\}$ generada por (7.1). Si M es no singular y para alguna norma matricial inducida vale que $\|M^{-1}N\| < 1$, entonces $\{x^k\}$ converge a x^* con $Ax^* = b$. Además, vale que

$$\|x^{k+1} - x^*\| \leq \frac{\|M^{-1}N\|}{1 - \|M^{-1}N\|} \|x^{k+1} - x^k\|.$$

Demostración. Como la sucesión cumple que $x^{k+1} = G(x^k)$ con $G(x) = M^{-1}Nx + M^{-1}b$, si $\tau = \|M^{-1}N\| < 1$ entonces

$$\|G(y) - G(x)\| = \|M^{-1}N(y - x)\| \leq \tau \|y - x\|.$$

El Teorema 7.1 garantiza que $\lim_{k \rightarrow \infty} x^k = x^*$ con $Ax^* = b$.

Como x^* es un punto fijo de G ,

$$\begin{aligned} \|x^{k+1} - x^*\| &= \|G(x^k) - G(x^*)\| \leq \tau \|x^k - x^*\| \\ &\leq \tau \|x^{k+1} - x^k\| + \tau \|x^{k+1} - x^*\|. \end{aligned}$$

Usando que $\tau < 1$, despejamos $\|x^{k+1} - x^*\|$ y obtenemos lo deseado. ■

Note que $\|M^{-1}N\| < 1$ es una condición suficiente para la convergencia, pero no es necesaria. O sea, pueden existir sucesiones convergentes a x^* teniendo $\|M^{-1}N\| \geq 1$.

Veamos en qué casos podemos garantizar la convergencia de la iteración (7.1).

Definición 7.3 Se dice que A es una matriz diagonalmente dominante en sentido estricto si

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|, \quad \text{para } i = 1, \dots, n,$$

Considere $A \in \mathbb{R}^{n \times n}$ con $A = L + D + U$, donde D , L y U contienen las entradas diagonales, subdiagonales y supradiagonales de A , respectivamente. Con esto, podemos definir tres tipos de iteraciones.

Iteración de Jacobi. Tome $M_J = D$ y $N_J = -L - U$, o sea,

$$M_J = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix}, \quad N_J = - \begin{bmatrix} 0 & a_{12} & \dots & a_{1n} \\ a_{21} & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & a_{n-1,n} \\ a_{n1} & \dots & a_{n,n-1} & 0 \end{bmatrix}.$$

La iteración de Jacobi es:

$$M_J x^{k+1} = N_J x^k + b.$$

Escribiendo las componentes de esta ecuación, se tiene que

$$x_i^{k+1} = \frac{1}{a_{ii}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} x_j^k \right), \quad i = 1, \dots, n.$$

La convergencia de $\{x^k\}$ a x^* para cualquier x^0 , queda garantizada por el Corolario 7.2 y lo siguiente.

Proposición 7.4 Si $A \in \mathbb{R}^{n \times n}$ es diagonalmente dominante en sentido estricto entonces

$$\|M_J^{-1} N_J\|_\infty < 1.$$

Demostración. Por definición de M_J , N_J , $\|\cdot\|_\infty$ y la hipótesis sobre A , se tiene que

$$\|M_J^{-1} N_J\|_\infty = \max_{1 \leq i \leq n} \sum_{\substack{j=1 \\ j \neq i}}^n \left| \frac{a_{ij}}{a_{ii}} \right| < 1.$$

Como las entradas diagonales son no nulas si A es diagonalmente dominante, se puede reducir el costo computacional realizando el cociente por las entradas diagonales al inicio de la iteración.

Un posible pseudocódigo sería el siguiente.

Algoritmo 28 (iteración de Jacobi)

Entradas: $A \in \mathbb{R}^{n \times n}$, $b, x \in \mathbb{R}^n$, $\epsilon > 0$ y $k_{\max} \in \mathbb{N}$. **Salida:** x^+ aproximación de x^* .

Paso 0: Si $A_{ii} = 0$ para algún i , parar y retornar un error.

Sino, hacer $b \leftarrow D^{-1}b$, $A \leftarrow D^{-1}(L + U)$ y $k = 0$.

Paso 1: Si $k > k_{\max}$ ir al paso 3. Sino, definir

$$x^+ = b - Ax.$$

Paso 2: Si $\|x^+ - x\|_\infty \leq \epsilon$ ir al paso 3.

Sino, hacer $x = x^+$, $k \leftarrow k + 1$ e ir al paso 1.

Paso 3: Retornar x^+ .

Iteración de Gauss-Seidel. Tome $M_{GS} = L + D$ y $N_{GS} = -U$, o sea,

$$M_{GS} = \begin{bmatrix} a_{11} & 0 & \dots & 0 \\ a_{21} & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ a_{n1} & \dots & a_{n,n-1} & a_{nn} \end{bmatrix}, \quad N_{GS} = - \begin{bmatrix} 0 & a_{12} & \dots & a_{1n} \\ 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & a_{n-1,n} \\ 0 & \dots & 0 & 0 \end{bmatrix}.$$

La iteración de Gauss-Seidel es:

$$M_{GS}x^{k+1} = N_{GS}x^k + b.$$

Escribiendo las componentes de esta ecuación, se tiene que

$$x_i^{k+1} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{k+1} - \sum_{j=i+1}^n a_{ij}x_j^k \right), \quad i = 1, \dots, n.$$

El siguiente resultado junto al Corolario 7.2 garantizan la convergencia de $\{x^k\}$ a x^* para cualquier x^0 .

Proposición 7.5 Si $A \in \mathbb{R}^{n \times n}$ es diagonalmente dominante en sentido estricto entonces

$$\|M_{GS}^{-1}N_{GS}\|_\infty < 1.$$

Demostración. Por definición de norma matricial, existe x tal que $\|x\|_\infty = 1$ y $\|M_{GS}^{-1}N_{GS}\|_\infty = \|M_{GS}^{-1}N_{GS}x\|_\infty$. Sea $y = M_{GS}^{-1}N_{GS}x$, por lo tanto hay que demostrar que $\|y\|_\infty < 1$.

Tome l tal que $|y_l| = \|y\|_\infty$. Como $M_{GS}y = N_{GS}x$, la coordenada l de esta ecuación es

$$\sum_{j=1}^{l-1} a_{lj}y_j + a_{ll}y_l = - \sum_{j=l+1}^n a_{lj}x_j.$$

Por la condición en A , se obtiene que

$$|a_{ll}| - s_L - s_U > 0,$$

donde $s_L = \sum_{j=1}^{l-1} |a_{lj}|$ y $s_U = \sum_{j=l+1}^n |a_{lj}|$. Como

$$\left| \sum_{j=1}^{l-1} a_{lj} y_j \right| \leq s_L \|y\|_\infty,$$

entonces

$$|a_{ll} y_l| - \left| \sum_{j=1}^{l-1} a_{lj} y_j \right| \geq (|a_{ll}| - s_L) \|y\|_\infty > 0,$$

donde se usó que $|a_{ll} y_l| = |a_{ll}| \|y\|_\infty$. Además, como $|x_j| \leq \|x\|_\infty = 1$, se tiene

$$\begin{aligned} s_U &\geq \left| \sum_{j=l+1}^n a_{lj} x_j \right| = \left| \sum_{j=1}^{l-1} a_{lj} y_j + a_{ll} y_l \right| \\ &\geq \left| |a_{ll} y_l| - \left| \sum_{j=1}^{l-1} a_{lj} y_j \right| \right| \geq (|a_{ll}| - s_L) \|y\|_\infty. \end{aligned}$$

Por lo tanto

$$\|y\|_\infty \leq \frac{s_U}{|a_{ll}| - s_L} = \frac{s_U}{s_U + (|a_{ll}| - s_L - s_U)} < 1.$$

■

Dividiendo los elementos diagonales al inicio, se obtiene el siguiente pseudocódigo.

Algoritmo 29 (iteración de Gauss-Seidel)

Entradas: $A \in \mathbb{R}^{n \times n}$, $b, x \in \mathbb{R}^n$, $\epsilon > 0$ y $k_{\max} \in \mathbb{N}$. *Salida:* x^+ aproximación de x^* .

Paso 0: Si $A_{ii} = 0$ para algún i , parar y retornar un error.

Sino, hacer $b \leftarrow D^{-1}b$, $A \leftarrow D^{-1}(L + U)$, $x^+ = x$ y $k = 0$.

Paso 1: Si $k > k_{\max}$ ir al paso 5. Sino, definir $i = 1$.

Paso 2: Si $i > n$ ir al paso 4. Sino, definir

$$x_i^+ \leftarrow b_i - A_{i\bullet} x^+.$$

Paso 3: Hacer $i \leftarrow i + 1$ e ir al paso 2.

Paso 4: Si $\|x^+ - x\|_\infty \leq \epsilon$ ir al paso 5.

Sino, hacer $x = x^+$, $k \leftarrow k + 1$ e ir al paso 1.

Paso 5: Retornar x^+ .

Iteración SOR. La iteración de sobrerelajación sucesiva (SOR, Successive Over Relaxation) requiere un parámetro de relajación $\omega > 0$ y considera $M_{SOR} = \frac{1}{\omega}D + L$ y $N_{SOR} = (\frac{1}{\omega} - 1)D - U$, o sea,

$$M_{SOR} = \begin{bmatrix} \frac{1}{\omega}a_{11} & 0 & \dots & 0 \\ a_{21} & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ a_{n1} & \dots & a_{n,n-1} & \frac{1}{\omega}a_{nn} \end{bmatrix},$$

$$N_{SOR} = - \begin{bmatrix} (1 - \frac{1}{\omega})a_{11} & a_{12} & \dots & a_{1n} \\ 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & a_{n-1,n} \\ 0 & \dots & 0 & (1 - \frac{1}{\omega})a_{nn} \end{bmatrix}.$$

Note que la iteración de Gauss-Seidel es un caso particular con $\omega = 1$. Se puede demostrar (ver [4, Teorema 8.3.7]) que si A es simétrica definida positiva y $0 < \omega < 2$ entonces $\|M_{SOR}^{-1}N_{SOR}\| < 1$ para cierta norma $\|\cdot\|$.

7.2. Métodos de proyección

En esta sección se presentarán métodos iterativos que, para hallar x^* tal que $Ax^* = b$, generan una sucesión $\{x^k\}$ mediante la proyección (en una norma adecuada) de x^* en un conjunto $\mathcal{M}_k \subseteq \mathbb{R}^n$. Por lo tanto, para alguna norma $\|\cdot\|$, x^k cumple que $\|x^k - x^*\| \leq \|x - x^*\|$ para todo $x \in \mathcal{M}_k$.

Note que carece de sentido práctico definir x^k en términos de x^* , ya que x^* es lo que se desea hallar. La elección de una función f apropiada a minimizar evitará este inconveniente. En los métodos a estudiar utilizaremos $f: \mathbb{R}^n \mapsto \mathbb{R}$ tal que

$$f(x) = \frac{1}{2}x^T Qx + x^T q + c,$$

con $Q \in \mathbb{R}^{n \times n}$ simétrica semidefinida positiva, $q \in \mathbb{R}^n$ y $c \in \mathbb{R}$.

Los conjuntos $\mathcal{M}$ sobre los cuales se realiza la proyección serán subespacios desplazados del origen, los cuales se denotarán por

$$z + \mathcal{K} = \{z + v \mid v \in \mathcal{K}\},$$

donde $\mathcal{K} \subseteq \mathbb{R}^n$ es un subespacio y $z \in \mathbb{R}^n$.

El siguiente resultado da condiciones necesarias y suficientes para las soluciones de este tipo de problemas de minimización.

Teorema 7.6 Sea $z \in \mathbb{R}^n$, $\mathcal{K} \subseteq \mathbb{R}^n$ un subespacio, y f una función tal que $f(x) = \frac{1}{2}x^T Qx + x^T q + c$, con $Q \in \mathbb{R}^{n \times n}$ simétrica semidefinida positiva, $q \in \mathbb{R}^n$ y $c \in \mathbb{R}$. Entonces $\bar{x}$ es solución de

$$\underset{x \in z + \mathcal{K}}{\text{minimizar}} f(x),$$

si y solo si $\bar{x} \in z + \mathcal{K}$ y $\nabla f(\bar{x})^T v = 0$ para todo $v \in \mathcal{K}$.

Demostración. Sea $\bar{x}$ solución del problema de minimización. Entonces existe $\bar{v} \in \mathcal{K}$ tal que $\bar{x} = z + \bar{v}$. Tome $v \in \mathcal{K}$ arbitrario. Como $\mathcal{K}$ es un subespacio, para cualquier $t \in \mathbb{R}$ vale que $\bar{x} + tv = z + \bar{v} + tv \in z + \mathcal{K}$. Entonces

$$f(\bar{x}) \leq f(\bar{x} + tv), \quad \text{para todo } t \in \mathbb{R}.$$

Usando que $0 \leq (f(\bar{x} + tv) - f(\bar{x}))/t$ para $t > 0$ y que f es diferenciable, se tiene

$$0 \leq \lim_{t \rightarrow 0^+} \frac{f(\bar{x} + tv) - f(\bar{x})}{t} = \nabla f(\bar{x})^T v.$$

Repitiendo el argumento anterior para $-v \in \mathcal{K}$ se obtiene que $\nabla f(\bar{x})^T v \leq 0$. Por lo tanto $\nabla f(\bar{x})^T v = 0$ para todo $v \in \mathcal{K}$.

Sea $\bar{x} \in z + \mathcal{K}$ tal que $\nabla f(\bar{x})^T v = 0$ para todo $v \in \mathcal{K}$. Entonces $\bar{x} = z + \bar{v}$ para algún $\bar{v} \in \mathcal{K}$. Tome $x \in z + \mathcal{K}$ arbitrario, entonces existe $v \in \mathcal{K}$ tal que $x = z + v$. Como $v - \bar{v} \in \mathcal{K}$ entonces $\nabla f(\bar{x})^T (v - \bar{v}) = 0$. Usando que $\nabla^2 f(x) = Q$ es semidefinida positiva, que las derivadas de f de orden superior son cero y que $x - \bar{x} = v - \bar{v}$, se obtiene

$$\begin{aligned} f(x) &= f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) + \frac{1}{2} (x - \bar{x})^T \nabla^2 f(\bar{x}) (x - \bar{x}) \\ &= f(\bar{x}) + \nabla f(\bar{x})^T (v - \bar{v}) + \frac{1}{2} (v - \bar{v})^T Q (v - \bar{v}) \\ &\geq f(\bar{x}). \end{aligned}$$

Obteniendo así que $\bar{x}$ minimiza f en $z + \mathcal{K}$. ■

Como la proyección de x^* en $\mathcal{M}_k = \mathbb{R}^n$ en cualquier norma es x^* , del Teorema anterior obtenemos que $\nabla f(x^*)$ es ortogonal a todo $v \in \mathbb{R}^n$. Por lo tanto, el proceso iterativo deberá detenerse en la k -ésima iteración si $\|\nabla f(x^k)\| = 0$. Con esto, el esquema iterativo de los métodos de proyección es el siguiente: dado x^0 y $k = 0$,

1. si $\|\nabla f(x^k)\| = 0$ detener el proceso,
2. obtener x^{k+1} solución de minimizar $f(x)$,
 $$x \in \mathcal{M}_k$$
3. definir $\mathcal{M}_{k+1}$,
4. hacer $k = k + 1$ y regresar al paso 1.

7.2.1. Sistema definido positivo

Si $A \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva, considere $\|\cdot\|_A$ tal que $\|x\|_A = \sqrt{x^T A x}$. Usando que $Ax^* = b$, se obtiene

$$\begin{aligned} \|x - x^*\|_A^2 &= (x - x^*)^T A (x - x^*) = (x - A^{-1}b)^T (Ax - b) \\ &= x^T A x - 2x^T b + b^T A^{-1}b. \end{aligned} \tag{7.2}$$

Defina $f : \mathbb{R}^n \mapsto \mathbb{R}$ tal que

$$f(x) = \frac{1}{2} x^T A x - x^T b.$$

Note que de (7.2) se obtiene que $f(x) = \frac{1}{2}\|x - x^*\|_A^2 - \frac{1}{2}b^T A^{-1}b$. Por lo tanto se puede concluir que $\|x^k - x^*\|_A \leq \|x - x^*\|_A$ para todo $x \in \mathcal{M}_k$ si y solo si $f(x^k) \leq f(x)$ para todo $x \in \mathcal{M}_k$.

De esta forma podemos definir x^k como el minimizador de f sobre $\mathcal{M}_k$ sin necesidad de conocer *a priori* x^* .

Veamos las condiciones para la minimización de esta función particular.

Corolario 7.7 Sea $A \in \mathbb{R}^{n \times n}$ simétrica definida positiva, $b \in \mathbb{R}^n$, $V \in \mathbb{R}^{n \times p}$ de rango p y $z \in \mathbb{R}^n$. Entonces $\bar{x}$ es solución de

$$\underset{x \in z + \text{Im}(V)}{\text{minimizar}} \quad \frac{1}{2}x^T A x - x^T b,$$

si y solo si $\bar{x} = z + V\bar{\alpha}$ tal que $\bar{\alpha} = (V^T A V)^{-1} V^T r$ con $r = b - Az$.

Más aún, si $Ax^* = b$ entonces $\bar{x}$ es la proyección de x^* sobre $z + \text{Im}(V)$ en la norma $\|\cdot\|_A$.

Demostración. El resultado sale del Teorema 7.6 tomando $Q = A$, $q = -b$, $c = 0$ y notando que, como $\mathcal{K} = \text{Im}(V) = \{V\alpha \mid \alpha \in \mathbb{R}^p\}$, entonces $\bar{x} = z + V\bar{\alpha}$ para algún $\bar{\alpha} \in \mathbb{R}^p$ y $\nabla f(\bar{x})^T V\alpha = 0$ para todo $\alpha \in \mathbb{R}^p$, siendo esta última afirmación equivalente a que $V^T \nabla f(\bar{x}) = 0$.

Solo basta hallar una expresión para $\bar{\alpha}$. Como $\nabla f(x) = Ax - b$ entonces

$$0 = V^T \nabla f(\bar{x}) = V^T (A(z + V\bar{\alpha}) - b) = V^T A V \bar{\alpha} - V^T r,$$

donde $r = b - Az$. Como A es definida positiva y V tiene columnas linealmente independientes, entonces $V^T A V$ es no singular y por lo tanto

$$\bar{\alpha} = (V^T A V)^{-1} V^T r.$$

Además, de (7.2) se obtiene la última afirmación. ■

Note que al variar V se cambia el subespacio donde se desea proyectar, por lo tanto dependiendo de cómo se escoge se obtendrán distintos métodos iterativos. Para una clara presentación se separarán los métodos en dos grupos, dependiendo si el rango de la matriz V es 1 o mayor a 1.

Métodos de proyección unidimensional

Considere $\{x^k\}$ generada tomando $x^0 \in \mathbb{R}^n$ y definiendo x^{k+1} como solución de

$$\underset{x \in x^k + \text{span}\{d^k\}}{\text{minimizar}} \quad f(x).$$

El Corolario 7.7 con $z = x^k$ y $V = d^k$ nos garantiza que

$$x^{k+1} = x^k + \alpha_k d^k, \quad \alpha_k = \frac{(r^k)^T d^k}{(d^k)^T A d^k}, \quad (7.3)$$

donde $r^k = b - Ax^k$. El siguiente resultado da una estimativa del error en iteraciones sucesivas.

Proposición 7.8 Sea A simétrica definida positiva y x^{k+1} solución de

$$\underset{x \in x^k + \text{span}\{d^k\}}{\text{minimizar}} \quad \frac{1}{2}x^T A x - x^T b,$$

entonces

$$\|x^{k+1} - x^*\|_A^2 = \left(1 - \frac{(r^k)^T d^k}{(d^k)^T A d^k} \frac{(r^k)^T d^k}{(r^k)^T A^{-1} r^k}\right) \|x^k - x^*\|_A^2 \quad (7.4)$$

para x^* tal que $Ax^* = b$.

Demostración. Para simplificar notación se denotarán x^{k+1} por x^+ y x^k por x , análogamente para r^k y α_k . Por lo tanto, del Corolario 7.7 se obtiene que $x^+ = x + \alpha d$ con $\alpha = r^T d / (d^T A d)$ y $r = b - Ax$. Entonces se cumplen las siguientes relaciones,

$$\begin{aligned} A^{-1}r &= A^{-1}(b - Ax) = x^* - x \\ r^+ &= b - Ax^+ = b - A(x + \alpha d) = r - \alpha A d \\ (r^+)^T d &= r^T d - \alpha (A d)^T d = 0, \end{aligned}$$

donde en la última ecuación se usó la definición de α . Usando estas relaciones se puede ver que

$$\begin{aligned} \|x^+ - x^*\|_A^2 &= (x^+ - x^*)^T A (x^+ - x^*) = (A^{-1}r^+)^T A A^{-1}r^+ \\ &= (r^+)^T A^{-1}r^+ = (r - \alpha A d)^T A^{-1}r^+ \\ &= r^T A^{-1}r^+ - \alpha d^T r^+ = r^T A^{-1}r^+ \\ &= r^T A^{-1}(r - \alpha A d) = r^T A^{-1}r - \alpha r^T d \\ &= r^T A^{-1}r \left(1 - \alpha \frac{r^T d}{r^T A^{-1}r}\right) \\ &= \left(1 - \frac{r^T d}{d^T A d} \frac{r^T d}{r^T A^{-1}r}\right) \|x - x^*\|_A^2. \end{aligned}$$

Claramente, para que la sucesión generada converja a x^* , solución de $Ax = b$, la elección de d^k es importante. Un hecho conocido del cálculo de funciones en varias variables nos dice que el vector $\nabla f(x^k)$ apunta en la dirección del máximo crecimiento de f a partir de x^k . Ya que nuestra meta es minimizar f , una dirección d^k razonable para disminuir el valor de f sería tomar d^k opuesta a $\nabla f(x^k)$.

Formalmente, para alguna norma $\|\cdot\|$ se tomará d^k como la solución de

$$\underset{\|d\| \leq 1}{\text{minimizar}} \quad \nabla f(x^k)^T d.$$

Método de Cauchy. Considere $d^k \in \mathbb{R}^n$ solución de minimizar $\nabla f(x^k)^T d$.

Note que si $\|d\|_2 \leq 1$, por la desigualdad de Cauchy-Schwarz, $|\nabla f(x^k)^T d| \leq \|\nabla f(x^k)\|_2$ y por lo tanto $\nabla f(x^k)^T d \geq -\|\nabla f(x^k)\|_2$ para todo d con $\|d\|_2 \leq 1$. De aquí se deduce fácilmente que

$$d^k = -\frac{\nabla f(x^k)}{\|\nabla f(x^k)\|_2},$$

ya que $\|d^k\|_2 = 1$ y $\nabla f(x^k)^T d^k = -\|\nabla f(x^k)\|_2$. O sea, d^k es la dirección de máximo descenso en $\|\cdot\|_2$ para f a partir de x^k . Como $\nabla f(x) = Ax - b$, entonces $r^k = b - Ax^k = -\nabla f(x^k)$ y por lo tanto

$$d^k = \frac{r^k}{\|r^k\|_2}.$$

Usando (7.3) se obtiene que

$$x^{k+1} = x^k + \alpha_k d^k = x^k + \frac{\|r^k\|_2^2}{(r^k)^T A r^k} r^k,$$

además,

$$r^{k+1} = r^k - \alpha_k A d^k = r^k - \frac{\|r^k\|_2^2}{(r^k)^T A r^k} A r^k.$$

De esta forma, el esquema iterativo del método de Cauchy se resume en el siguiente pseudocódigo.

Algoritmo 30 (método de Cauchy)

Entradas: $A \in \mathbb{R}^{n \times n}$, $b, x \in \mathbb{R}^n$, $\epsilon > 0$ y $k_{\max} \in \mathbb{N}$. *Salida:* x^+ aproximación de x^* .

Paso 0: Definir $r = b - Ax$, $\sigma = \|r\|_2$ y $k = 0$.

Paso 1: Si $k > k_{\max}$ o $\sigma \leq \epsilon$ ir al paso 3. Sino, definir

$$\begin{aligned} v &= Ar, \\ t &= \sigma^2 / r^T v, \\ x &\leftarrow x + tr, \\ r &\leftarrow r - tv. \end{aligned}$$

Paso 2: Definir $\sigma = \|r\|_2$, hacer $k \leftarrow k + 1$ e ir al paso 1.

Paso 3: Retornar $x^+ = x$.

Note que se realiza un solo producto matriz-vector por iteración. Para demostrar que este método converge se necesitará el siguiente resultado auxiliar.

Lema 7.9 (Desigualdad de Kantorovich) Sea $A \in \mathbb{R}^{n \times n}$ simétrica definida positiva con autovalores $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0$. Entonces

$$\frac{(x^T A x)(x^T A^{-1} x)}{(x^T x)^2} \leq \frac{(\lambda_1 + \lambda_n)^2}{4\lambda_1 \lambda_n} \quad \forall x \neq 0. \quad (7.5)$$

Demostración. Como A es simétrica, existen V ortogonal y D diagonal con $d_{ii} = \lambda_i$ tales que $A = V^T D V$. Tome $x \neq 0$, entonces

$$\frac{x^T A x}{x^T x} \frac{x^T A^{-1} x}{x^T x} = \frac{x^T V^T D V x}{\|x\|_2^2} \frac{x^T V^T D^{-1} V x}{\|x\|_2^2} = (y^T D y)(y^T D^{-1} y),$$

donde $y = Vx/\|x\|_2$. Note que $\sum_{i=1}^n y_i^2 = \|y\|_2^2 = \|Vx\|_2^2/\|x\|_2^2 = 1$. Defina

$$\lambda = y^T D y = \sum_{i=1}^n \lambda_i y_i^2, \quad \nu = y^T D^{-1} y = \sum_{i=1}^n \frac{1}{\lambda_i} y_i^2.$$

Como la función $\phi(x) = \frac{1}{x}$ es convexa y $s(x) = \frac{1}{\lambda_1} + \frac{1}{\lambda_n} - \frac{x}{\lambda_1 \lambda_n}$ es la recta secante a ϕ en λ_n y λ_1 , entonces $\phi(x) \leq s(x)$ para todo $x \in [\lambda_n, \lambda_1]$. Por lo tanto

$$\nu = \sum_{i=1}^n \phi(\lambda_i) y_i^2 \leq \sum_{i=1}^n s(\lambda_i) y_i^2 = \frac{1}{\lambda_1} + \frac{1}{\lambda_n} - \frac{\lambda}{\lambda_1 \lambda_n}.$$

Por otro lado, para $a > 0$ la función $x \mapsto bx - \frac{1}{a}x^2$ alcanza su máximo en $x = \frac{1}{2}ab$, y por lo tanto $bx - \frac{1}{a}x^2 \leq \frac{1}{4}ab^2$ para todo x . Entonces

$$\begin{aligned} (y^T D y)(y^T D^{-1} y) &= \lambda \nu \leq \left(\frac{1}{\lambda_1} + \frac{1}{\lambda_n} \right) \lambda - \frac{\lambda^2}{\lambda_1 \lambda_n} \\ &\leq \frac{\lambda_1 \lambda_n}{4} \left(\frac{1}{\lambda_1} + \frac{1}{\lambda_n} \right)^2 = \frac{(\lambda_1 + \lambda_n)^2}{4 \lambda_1 \lambda_n}. \end{aligned}$$

■

Con esto, se puede garantizar la convergencia con tasa lineal del método.

Teorema 7.10 Si $A \in \mathbb{R}^{n \times n}$ es simétrica definida positiva y dado x^0 se genera $\{x^k\}$ por el método de Cauchy, entonces

$$\|x^{k+1} - x^*\|_A \leq \frac{\kappa_2(A) - 1}{\kappa_2(A) + 1} \|x^k - x^*\|_A, \quad (7.6)$$

donde $Ax^* = b$. En particular $x^k \rightarrow x^*$.

Demostración. Usando la Proposición 7.8 con $d^k = r^k/\|r^k\|_2$, la estimación (7.4) puede escribirse como

$$\|x^{k+1} - x^*\|_A^2 = \left(1 - \frac{\|r^k\|_2^2}{(r^k)^T A r^k} \frac{\|r^k\|_2^2}{(r^k)^T A^{-1} r^k} \right) \|x^k - x^*\|_A^2.$$

Ahora, por Lema 7.9, se obtiene que

$$\begin{aligned} 1 - \frac{\|r^k\|_2^2}{(r^k)^T A r^k} \frac{\|r^k\|_2^2}{(r^k)^T A^{-1} r^k} &\leq 1 - \frac{4\lambda_1 \lambda_n}{(\lambda_1 + \lambda_n)^2} \\ &= \frac{(\lambda_1 - \lambda_n)^2}{(\lambda_1 + \lambda_n)^2} = \frac{(\kappa_2(A) - 1)^2}{(\kappa_2(A) + 1)^2}. \end{aligned}$$

Por lo tanto, tomando $c = (\kappa_2(A) - 1)/(\kappa_2(A) + 1)$,

$$\begin{aligned} \|x^{k+1} - x^*\|_A &\leq c \|x^k - x^*\|_A \\ &\leq c^2 \|x^{k-1} - x^*\|_A \leq \dots \leq c^{k+1} \|x^0 - x^*\|_A. \end{aligned}$$

Como $c < 1$ se obtiene que $x^k \rightarrow x^*$.

■

Método de Gauss-Seidel óptimo. Tome d^k solución de minimizar $\nabla f(x^k)^T d$ $\|d\|_1 \leq 1$.

Note que si $\|d\|_1 \leq 1$, por la desigualdad de Hölder (3.1), $|\nabla f(x^k)^T d| \leq \|\nabla f(x^k)\|_\infty$ y por lo tanto $\nabla f(x^k)^T d \geq -\|\nabla f(x^k)\|_\infty$ para todo d con $\|d\|_1 \leq 1$. De aquí se deduce que si i_k satisface $\|\nabla f(x^k)\|_\infty = |[\nabla f(x^k)]_{i_k}|$ entonces

$$d_i^k = \begin{cases} 0, & \text{si } i \neq i_k, \\ -[\nabla f(x^k)]_{i_k} / \|\nabla f(x^k)\|_\infty & \text{si } i = i_k, \end{cases}$$

pues $\|d^k\|_1 = 1$ y $\nabla f(x^k)^T d^k = -\|\nabla f(x^k)\|_\infty$. O sea, d^k es la dirección de máximo descenso en $\|\cdot\|_1$ para f a partir de x^k . Como $r^k = b - Ax^k = -\nabla f(x^k)$, entonces

$$d^k = \frac{r_{i_k}^k}{\|r^k\|_\infty} e^{i_k},$$

donde i_k satisface $|r_{i_k}^k| = \|r^k\|_\infty$ y e^i es el i -ésimo vector canónico. Por lo tanto, de (7.3) se tiene

$$x^{k+1} = x^k + \alpha_k d^k = x^k + \frac{r_{i_k}^k}{a_{i_k i_k}} e^{i_k}.$$

Analizando cada componente se obtiene que $x_i^{k+1} = x_i^k$ si $i \neq i_k$ y

$$\begin{aligned} x_{i_k}^{k+1} &= x_{i_k}^k + \frac{1}{a_{i_k i_k}} \left(b_{i_k} - \sum_{j=1}^n a_{i_k j} x_j^k \right) \\ &= \frac{1}{a_{i_k i_k}} \left(b_{i_k} - \sum_{j=1}^{i_k-1} a_{i_k j} x_j^k - \sum_{j=i_k+1}^n a_{i_k j} x_j^k \right). \end{aligned}$$

Note que este procedimiento equivale a actualizar solo una componente por iteración en el método de Gauss-Seidel (o de Jacobi). De esta manera se puede afirmar que cuando A es simétrica y definida positiva solo basta actualizar una componente por iteración.

El esquema iterativo es similar al del método de Cauchy y por lo tanto también su implementación computacional. La convergencia del método se deduce fácilmente usando la Proposición 7.8. El enunciado sería el siguiente.

Teorema 7.11 Si $A \in \mathbb{R}^{n \times n}$ es simétrica definida positiva y dado x^0 se genera $\{x^k\}$ por el método de Gauss-Seidel óptimo, entonces

$$\|x^{k+1} - x^*\|_A \leq \left(1 - \frac{1}{n\kappa_2(A)} \right)^{1/2} \|x^k - x^*\|_A, \quad (7.7)$$

donde $Ax^* = b$. En particular $x^k \rightarrow x^*$.

Método de Gastinel. Considere $d^k \in \mathbb{R}^n$ solución de minimizar $\nabla f(x^k)^T d$.
 $\|d\|_\infty \leq 1$

Con un argumento similar al usado anteriormente, se puede demostrar que

$$d_i^k = \begin{cases} \frac{r_i^k}{|r_i^k|} & \text{si } r_i^k \neq 0, \\ 0 & \text{si } r_i^k = 0. \end{cases}$$

Además, queda como ejercicio al lector probar que la iteración generada por este método verifica (7.7).

Métodos de proyección multidimensional

Considere $\{x^k\}$ generada tomando $x^0 \in \mathbb{R}^n$ y definiendo x^{k+1} como solución de

$$\underset{x \in x^0 + \text{Im}(V_k)}{\text{minimizar}} f(x),$$

En algunos casos, se puede fijar la dimensión de V_k e ir actualizando sus columnas manteniendo un rango constante a lo largo de las iteraciones. Ya que las columnas de V_k son linealmente independientes, cuando las columnas de V_k generen $\mathbb{R}^n$ se estará resolviendo el problema de minimizar f en todo $\mathbb{R}^n$, cuya solución es x^* . Entre todos los posibles métodos nos concentraremos uno donde V_k de rango $k+1$.

El Corolario 7.7 con $z = x^0$ y $V = V_k \in \mathbb{R}^{n \times (k+1)}$ nos garantiza que

$$x^{k+1} = x^0 + V_k \alpha^k, \quad \alpha^k = (V_k^T A V_k)^{-1} V_k^T r^0, \quad (7.8)$$

donde $r^0 = b - Ax^0$. Claramente el costo computacional de hallar α^k va a depender de la estructura de la matriz $V_k^T A V_k$. Considere $V = [v^1 \dots v^p] \in \mathbb{R}^{n \times p}$, entonces

$$V^T A V = \begin{bmatrix} (v^1)^T A v^1 & \dots & (v^1)^T A v^p \\ \vdots & \ddots & \vdots \\ (v^p)^T A v^1 & \dots & (v^p)^T A v^p \end{bmatrix},$$

pudiendo obtener una matriz diagonal si $(v^i)^T A v^j = 0$ para $i \neq j$.

Definición 7.12 Para $A \in \mathbb{R}^{n \times n}$ simétrica definida positiva, se dirá que v y w son direcciones A -conjugadas si $v^T A w = 0$.

Note que en el caso de tener A simétrica definida positiva se puede considerar el producto interno $\langle \cdot, \cdot \rangle_A : \mathbb{R}^n \times \mathbb{R}^n \mapsto \mathbb{R}$ tal que $\langle x, y \rangle_A = x^T A y$ para todo $x, y \in \mathbb{R}^n$. En este caso las direcciones A -conjugadas son simplemente las direcciones ortogonales en el producto interno $\langle \cdot, \cdot \rangle_A$.

Método del gradiente conjugado. Considere que en cada iteración se tiene $V_k = [d^0 \dots d^k]$ con $d^0, \dots, d^k$ generadas a partir de $r^0, \dots, r^k$ mediante ortogonalización de Gram-Schmidt en el producto interno $\langle \cdot, \cdot \rangle_A$. O sea, $d^0 = r^0$ y para $i \geq 1$

$$d^i = r^i - \sum_{j=0}^{i-1} \beta_{ij} d^j \quad \text{con} \quad \beta_{ij} = \frac{(d^j)^T A r^i}{(d^j)^T A d^j}. \quad (7.9)$$

Con esta elección, note que las componentes de $\alpha^k = (V_k^T A V_k)^{-1} V_k^T r^0$ son

$$\alpha_{i+1}^k = \frac{(d^i)^T r^0}{(d^i)^T A d^i}, \quad i = 0, \dots, k.$$

Ya que α_{i+1}^k puede definirse en la iteración i y es constante para todo $k \geq i$, no hay ambigüedad alguna en definir $t_i = \alpha_{i+1}^k$.

Las ventajas de elegir las direcciones de esta manera es que se podrá escribir la iteración definida en (7.8) en términos solamente de la iteración anterior.

Proposición 7.13 *Las sucesiones $\{x^k\}$, $\{r^k\}$ y $\{d^k\}$ generadas por el método del gradiente conjugado satisfacen*

$$x^{k+1} = x^k + t_k d^k, \quad r^{k+1} = r^k - t_k A d^k, \quad d^{k+1} = r^{k+1} + s_k d^k,$$

con

$$t_k = \frac{\|r^k\|_2^2}{(d^k)^T A d^k}, \quad s_k = \frac{\|r^{k+1}\|_2^2}{\|r^k\|_2^2}.$$

Demostración. Como $t_i = \alpha_{i+1}^k$, se obtiene que

$$\begin{aligned} x^1 &= x^0 + V_0 \alpha^0 = x^0 + t_0 d^0, \\ x^2 &= x^0 + V_1 \alpha^1 = x^0 + t_0 d^0 + t_1 d^1 = x^1 + t_1 d^1, \\ &\vdots \end{aligned}$$

$$x^{k+1} = x^0 + V_k \alpha^k = x^0 + \sum_{i=0}^k t_i d^i = x^k + t_k d^k. \quad (7.10)$$

Claramente, $r^{k+1} = b - A x^{k+1} = r^k - t_k A d^k$. Además,

$$r^{k+1} = b - A x^{k+1} = b - A \left(x^0 + \sum_{i=0}^k t_i d^i \right) = r^0 - \sum_{i=0}^k t_i A d^i. \quad (7.11)$$

De la definición de α^k y (7.11),

$$0 = V_k^T (r^0 - A V_k \alpha^k) = V_k^T \left(r^0 - \sum_{i=0}^k t_i A d^i \right) = V_k^T r^{k+1}.$$

Por lo tanto $(d^j)^T r^{k+1} = 0$ para $j = 0, \dots, k$. Con esto, para $i \leq k$ se obtiene que

$$0 = (r^{k+1})^T d^i = (r^{k+1})^T \left(r^i - \sum_{j=0}^{i-1} \beta_{ij} d^j \right) = (r^{k+1})^T r^i. \quad (7.12)$$

Para expresar t_k independiente de r^0 , se puede ver por un lado que

$$(r^k)^T d^k = (r^k)^T \left(r^k - \sum_{j=0}^{k-1} \beta_{kj} d^j \right) = \|r^k\|_2^2, \quad (7.13)$$

donde se usó que $(d^j)^T r^k = 0$ para $j \leq k-1$. Por otro lado, como $(d^i)^T Ad^j = 0$ para $i \neq j$, se obtiene

$$(d^k)^T r^k = (d^k)^T \left(r^0 - \sum_{i=0}^{k-1} t_i Ad^i \right) = (d^k)^T r^0.$$

Por lo tanto

$$t_k = \alpha_{k+1}^k = \frac{(d^k)^T r^0}{(d^k)^T Ad^k} = \frac{\|r^k\|_2^2}{(d^k)^T Ad^k}.$$

Para ver que $\beta_{k+1,j} = 0$ para $j = 0, \dots, k-1$. Tomando $j \leq k-1$ y usando (7.12),

$$0 = (r^{k+1})^T r^{j+1} = (r^{k+1})^T (r^j - t_j Ad^j) = -t_j (r^{k+1})^T Ad^j.$$

Por lo tanto, como $t_j > 0$,

$$\beta_{k+1,j} = \frac{(d^j)^T Ar^{k+1}}{(d^j)^T Ad^j} = 0, \quad j = 0, \dots, k-1.$$

Ahora, usando (7.12) y la expresión para t_k ,

$$\begin{aligned} \|r^{k+1}\|_2^2 &= (r^{k+1})^T r^{k+1} = (r^{k+1})^T (r^k - t_k Ad^k) \\ &= -t_k (r^{k+1})^T Ad^k = -\frac{\|r^k\|_2^2}{(d^k)^T Ad^k} (r^{k+1})^T Ad^k. \end{aligned}$$

Por lo tanto,

$$s_k = -\beta_{k+1,k} = -\frac{(d^k)^T Ar^{k+1}}{(d^k)^T Ad^k} = \frac{\|r^{k+1}\|_2^2}{\|r^k\|_2^2}.$$

■

De esta forma, el esquema iterativo del método del gradiente conjugado se resume en el siguiente pseudocódigo.

Algoritmo 31 (método del gradiente conjugado)

Entradas: $A \in \mathbb{R}^{n \times n}$, $b, x \in \mathbb{R}^n$, $\epsilon > 0$ y $k_{\max} \in \mathbb{N}$. *Salida:* x^+ aproximación de x^* .

Paso 0: Definir $r = b - Ax$, $\sigma = \|r\|_2$, $d = r$ y $k = 0$.

Paso 1: Si $k > k_{\max}$ o $\sigma \leq \epsilon$ ir al paso 3. Sino, definir

$$\begin{aligned} v &= Ad, \\ t &= \sigma^2 / d^T v, \\ x &\leftarrow x + td, \\ r &\leftarrow r - tv, \\ \sigma_+ &= \|r\|_2, \\ s &= \sigma_+^2 / \sigma^2, \\ d &\leftarrow r + sd. \end{aligned}$$

Paso 2: Hacer $\sigma = \sigma_+$, $k \leftarrow k + 1$ e ir al paso 1.

Paso 3: Retornar $x^+ = x$.

Es importante notar que un solo producto matriz-vector es realizado en cada iteración.

Ya que en cada iteración el espacio en el cual se minimiza aumenta su dimensión, en el peor caso la solución del sistema lineal se hallará cuando $\text{Im}(V_k) = \mathbb{R}^n$. Esta idea se formaliza con el siguiente resultado.

Teorema 7.14 Si $A \in \mathbb{R}^{n \times n}$ es simétrica definida positiva y dado x^0 se genera $\{x^k\}$ por el método del gradiente conjugado, entonces $Ax^k = b$ para algún $k \leq n$.

Demostración. Como A es no singular, existe un único $x^* \in \mathbb{R}^n$ tal que $Ax^* = b$. Si $\|r^k\| = 0$ entonces $x^k = x^*$. Por lo tanto, suponga que $r^k \neq 0$ para $k \leq n-1$. Como $d^0, \dots, d^{n-1}$ están bien definidas y son n vectores linealmente independientes, existen $\gamma_0, \dots, \gamma_{n-1}$ tales que

$$x^* - x^0 = \sum_{i=0}^{n-1} \gamma_i d^i.$$

Por la A -conjugación de las direcciones, para $0 \leq k \leq n-1$ vale

$$\begin{aligned} (d^k)^T r^0 &= (d^k)^T (b - Ax^0) = (d^k)^T A(x^* - x^0) \\ &= (d^k)^T A \left(\sum_{i=0}^{n-1} \gamma_i d^i \right) \\ &= \gamma_k (d^k)^T A d^k. \end{aligned}$$

Entonces

$$\gamma_k = \frac{(d^k)^T r^0}{(d^k)^T A d^k} = t_k,$$

por lo tanto, por (7.10),

$$x^* = x^0 + \sum_{i=0}^{n-1} \gamma_i d^i = x^0 + \sum_{i=0}^{n-1} t_i d^i = x^n.$$

■

El análisis de la velocidad de convergencia del método se suele realizar mediante el uso del siguiente subespacio.

Definición 7.15 El subespacio de Krylov asociado a $A \in \mathbb{R}^{n \times n}$, $v \in \mathbb{R}^n$ y $j \in \mathbb{N}$ es

$$K_j(A, v) = \text{span}\{v, Av, A^2v, \dots, A^{j-1}v\}.$$

Ahora se puede afirmar la siguiente relación.

Teorema 7.16 Suponga que en el método del gradiente conjugado $r^k \neq 0$ para $k = 0, \dots, m$. Entonces

$$\text{Im}(V_m) = \text{span}\{r^0, \dots, r^m\} = K_{m+1}(A, r^0).$$

Demostración. Procediendo por inducción, note que

$$\text{Im}(V_0) = \text{span}\{d^0\} = \text{span}\{r^0\} = K_1(A, r^0).$$

Suponga que el resultado vale para espacios de dimensión m . Usando que $d^{m-1} \in \text{span}\{r^0, \dots, r^{m-1}\}$ y $d^m = r^m + s_{m-1}d^{m-1}$, se obtiene

$$\text{Im}(V_m) = \text{span}\{d^0, \dots, d^m\} \subset \text{span}\{r^0, \dots, r^m\}.$$

Además, como $d^{m-1} \in K_m(A, r^0)$ entonces

$$Ad^{m-1} \in \text{span}\{Ar^0, \dots, A^m r^0\} \subset K_{m+1}(A, r^0).$$

Usando que $r^m = r^{m-1} - t_{m-1}Ad^{m-1}$ con $r^{m-1} \in K_m(A, r^0) \subset K_{m+1}(A, r^0)$, se tiene

$$\text{span}\{r^0, \dots, r^m\} \subset K_{m+1}(A, r^0).$$

Como $d^0, \dots, d^m$ son linealmente independientes entonces $\text{Im}(V_m)$ tiene dimensión $m+1$ y por lo tanto debe coincidir con $K_{m+1}(A, r^0)$. ■

Velocidad de convergencia del método del gradiente conjugado*

Para obtener una estimativa similar a la obtenida en (7.6) se usarán propiedades del subespacio de Krylov. Dado $x^0 \in \mathbb{R}^n$ y usando que $\text{Im}(V_k) = K_{k+1}(A, r^0)$, la sucesión $\{x^k\}$ generada por el método del gradiente conjugado puede entenderse como x^{k+1} solución de

$$\underset{x \in x^0 + K_{k+1}(A, r^0)}{\text{minimizar}} \|x - x^*\|_A^2.$$

Note que si $x \in x^0 + K_{k+1}(A, r^0)$ entonces, usando que $r^0 = -A(x^0 - x^*)$,

$$\begin{aligned} x - x^* &= x^0 - x^* + c_1 r^0 + c_2 A r^0 + \dots + c_{k+1} A^k r^0 \\ &= x^0 - x^* - c_1 A(x^0 - x^*) - \dots - c_{k+1} A^{k+1}(x^0 - x^*) \\ &= p(A)(x^0 - x^*), \end{aligned}$$

donde $p(t) = 1 - c_1 t - \dots - c_{k+1} t^{k+1}$. Considere Π_k como el conjunto de polinomios p de grado menor o igual a k con coeficientes en $\mathbb{R}$ tales que $p(0) = 1$. De la ecuación anterior se deduce que $x \in x^0 + K_{k+1}(A, r^0)$ si y solo si $x - x^* = p(A)(x^0 - x^*)$ para algún $p \in \Pi_{k+1}$. Por lo tanto

$$\|x^{k+1} - x^*\|_A = \min_{x \in x^0 + K_{k+1}(A, r^0)} \|x - x^*\|_A = \min_{p \in \Pi_{k+1}} \|p(A)(x^0 - x^*)\|_A.$$

Por otro lado, como la matriz A es simétrica definida positiva entonces $A = Q\Lambda Q^T$ donde Q es ortogonal y Λ diagonal con elementos $\lambda_1 \geq \dots \geq \lambda_n > 0$. Con esto, se puede verificar que para cualquier polinomio p vale que $Q^T p(A)Q = p(\Lambda)$. Además, de la ortogonalidad de Q se obtiene la existencia de un vector ξ tal que $x^0 - x^* = Q\xi$. Por lo tanto

$$\|x^0 - x^*\|_A^2 = \|Q\xi\|_A^2 = \xi^T Q^T A Q \xi = \xi^T \Lambda \xi = \sum_{i=1}^n \lambda_i \xi_i^2.$$

Entonces,

$$\begin{aligned}
 \|p(A)(x^0 - x^*)\|_A^2 &= \|p(A)Q\xi\|_A^2 = \xi^T Q^T p(A) A p(A) Q \xi \\
 &= \xi^T Q^T p(A) Q \Lambda Q^T p(A) Q \xi = \xi^T p(\Lambda) \Lambda p(\Lambda) \xi \\
 &= \sum_{i=1}^n p(\lambda_i)^2 \lambda_i \xi_i^2 \\
 &\leq \left(\max_{1 \leq i \leq n} p(\lambda_i)^2 \right) \|x^0 - x^*\|_A^2.
 \end{aligned}$$

Concluyendo que

$$\frac{\|x^{k+1} - x^*\|_A}{\|x^0 - x^*\|_A} \leq \min_{p \in \Pi_{k+1}} \max_{1 \leq i \leq n} |p(\lambda_i)| \leq \min_{p \in \Pi_{k+1}} \max_{\lambda \in [\lambda_1, \lambda_n]} |p(\lambda)|.$$

Ahora solo basta hallar $p \in \Pi_{k+1}$ apropiado que dé una cota ajustada de el último mínimo. Tal polinomio se construye usando los polinomios ortogonales de Chebyshev. El polinomio de Chebyshev de grado k se define como

$$C_k(t) = \begin{cases} (-1)^k \cosh(k \operatorname{arccosh}(-t)), & \text{si } t < -1, \\ \cos(k \arccos(t)), & \text{si } -1 \leq t \leq 1, \\ \cosh(k \operatorname{arccosh}(t)), & \text{si } t > 1. \end{cases}$$

Se puede comprobar de manera directa que éste es un polinomio usando que $C_0(t) = 1$, $C_1(t) = t$ y $C_{k+1}(t) = 2tC_k(t) - C_{k-1}(t)$ para $k \geq 2$. Defina

$$\hat{p}(\lambda) = \frac{C_{k+1}(\varphi(\lambda))}{C_{k+1}(\varphi(0))}, \quad \text{donde} \quad \varphi(\lambda) = \frac{\lambda_1 + \lambda_n - 2\lambda}{\lambda_1 - \lambda_n}.$$

Note que $\hat{p} \in \Pi_{k+1}$ pues es un polinomio de grado menor o igual a $k+1$ y $\hat{p}(0) = 1$. Además, como φ lleva el intervalo $[\lambda_1, \lambda_n]$ al $[-1, 1]$, entonces para $\lambda \in [\lambda_1, \lambda_n]$ vale que $|C_{k+1}(\varphi(\lambda))| = |\cos((k+1) \arccos(\varphi(\lambda)))| \leq 1$. Por otro lado,

$$\varphi(0) = \frac{\lambda_1 + \lambda_n}{\lambda_1 - \lambda_n} = \frac{\kappa_2(A) + 1}{\kappa_2(A) - 1} = \frac{1}{2}(c + c^{-1}), \quad \text{donde} \quad c = \frac{\sqrt{\kappa_2(A)} - 1}{\sqrt{\kappa_2(A)} + 1}.$$

Tomando $w = \log(c)$ (bien definido pues $c > 0$) se obtiene que $\cosh(w) = (e^w + e^{-w})/2 = (c + c^{-1})/2 = \varphi(0)$. Como $\varphi(0) > 1$,

$$C_{k+1}(\varphi(0)) = \cosh((k+1)w) = \frac{e^{(k+1)w} + e^{-(k+1)w}}{2} = \frac{c^{k+1} + c^{-(k+1)}}{2}.$$

Por lo tanto,

$$\begin{aligned}
 \frac{\|x^{k+1} - x^*\|_A}{\|x^0 - x^*\|_A} &\leq \max_{\lambda \in [\lambda_1, \lambda_n]} |\hat{p}(\lambda)| \leq \frac{1}{C_{k+1}(\varphi(0))} < 2c^{k+1} \\
 &= 2 \left(\frac{\sqrt{\kappa_2(A)} - 1}{\sqrt{\kappa_2(A)} + 1} \right)^{k+1}.
 \end{aligned}$$

El lector puede verificar que para matrices con número de condición elevado, la cota del error del método del gradiente conjugado es considerablemente menor al error del método de Cauchy.

7.2.2. Sistema indefinido

Cuando la matriz del sistema lineal a resolver no es necesariamente simétrica ni definida positiva, la función a minimizar es diferente a la definida anteriormente.

Si $A \in \mathbb{R}^{m \times n}$ tiene columnas linealmente independientes, entonces $A^T A$ es simétrica y definida positiva. Considerando la norma $\|\cdot\|_{A^T A}$ y usando que $Ax^* = b$, se obtiene

$$\begin{aligned} \|x - x^*\|_{A^T A}^2 &= (x - x^*)^T A^T A (x - x^*) = (Ax - b)^T (Ax - b) \\ &= \|Ax - b\|_2^2 = \|Ax\|_2^2 - 2(Ax)^T b + \|b\|_2^2 \\ &= x^T A^T A x - 2x^T A^T b + \|b\|_2^2. \end{aligned} \quad (7.14)$$

Defina $f : \mathbb{R}^n \mapsto \mathbb{R}$ tal que

$$f(x) = \frac{1}{2} x^T A^T A x - x^T A^T b.$$

Ahora, de (7.14) se tiene que $f(x) = \frac{1}{2} \|x - x^*\|_{A^T A}^2 - \frac{1}{2} \|b\|_2^2$. Por lo tanto, se puede concluir que $\|x^k - x^*\|_{A^T A} \leq \|x - x^*\|_{A^T A}$ para todo $x \in \mathcal{M}_k$ si y solo si $f(x^k) \leq f(x)$ para todo $x \in \mathcal{M}_k$. Nuevamente, definiendo x^k como el minimizador de f sobre $\mathcal{M}_k$ sin necesidad de conocer *a priori* x^* .

Note que si A es una matriz general, entonces minimizar f equivale a resolver el problema de cuadrados mínimos. Veamos las condiciones que se obtienen de la minimización de esta función.

Corolario 7.17 Sea $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$, $V \in \mathbb{R}^{n \times p}$ de rango p y $z \in \mathbb{R}^n$. Entonces $\bar{x}$ es solución de

$$\text{minimizar}_{x \in z + \text{Im}(V)} \frac{1}{2} x^T A^T A x - x^T A^T b,$$

si y solo si $\bar{x} = z + V\bar{\alpha}$ tal que $V^T A^T A V\bar{\alpha} = V^T A^T r$ con $r = b - Az$. Más aún, $\bar{x}$ es solución de minimizar $\|Ax - b\|_2$.

Si además A tiene columnas linealmente independientes y $Ax^* = b$, entonces $\bar{x}$ es la proyección de x^* sobre $z + \text{Im}(V)$ en la norma $\|\cdot\|_{A^T A}$.

Demostración. El resultado sale del Teorema 7.6 tomando $Q = A^T A$, $q = -A^T b$, $c = 0$ y notando que $A^T A$ es simétrica semidefinida positiva. Como $\mathcal{K} = \text{Im}(V) = \{V\alpha \mid \alpha \in \mathbb{R}^p\}$, entonces $\bar{x} = z + V\bar{\alpha}$ para algún $\bar{\alpha} \in \mathbb{R}^p$ y $V^T \nabla f(\bar{x}) = 0$.

Como $\nabla f(x) = A^T A x - A^T b$ entonces

$$\begin{aligned} 0 &= V^T \nabla f(\bar{x}) = V^T (A^T A (z + V\bar{\alpha}) - A^T b) \\ &= V^T A^T A V\bar{\alpha} - V^T A^T r, \end{aligned}$$

donde $r = b - Az$.

Además, por (7.14), se tiene que el minimizador de $\frac{1}{2} x^T A^T A x - x^T A^T b$ es minimizador de $\|Ax - b\|_2$. Si el núcleo de A es cero, entonces $A^T A$ es simétrica definida positiva y vale que

$$\|x - x^*\|_{A^T A}^2 = \|Ax - b\|_2^2.$$

De manera similar a los métodos anteriores, separaremos los métodos considerando V con una o varias columnas.

Métodos de proyección unidimensional

Considere $\{x^k\}$ generada tomando $x^0 \in \mathbb{R}^n$ y definiendo x^{k+1} como solución de

$$\underset{x \in x^k + \text{span}\{d^k\}}{\text{minimizar}} \quad f(x).$$

Si $Ad^k \neq 0$ el Corolario 7.17 con $z = x^k$ y $V = d^k$ nos garantiza que

$$x^{k+1} = x^k + \alpha_k d^k, \quad \alpha_k = \frac{(r^k)^T Ad^k}{\|Ad^k\|_2^2}, \quad (7.15)$$

donde $r^k = b - Ax^k$. El siguiente resultado da una estimativa para el residuo.

Proposición 7.18 Si $Ad^k \neq 0$ y x^{k+1} es solución de

$$\underset{x \in x^k + \text{span}\{d^k\}}{\text{minimizar}} \quad \frac{1}{2}x^T A^T Ax - x^T A^T b,$$

entonces

$$\|r^{k+1}\|_2^2 = \left(1 - \frac{(r^k)^T Ad^k}{\|Ad^k\|_2^2} \frac{(r^k)^T Ad^k}{\|r^k\|_2^2}\right) \|r^k\|_2^2. \quad (7.16)$$

Demostración. Para simplificar notación se denotarán x^{k+1} por x^+ y x^k por x , análogamente para r^k y α_k . Por lo tanto, del Corolario 7.17 se obtiene que $x^+ = x + \alpha d$ con $\alpha = r^T Ad / \|Ad\|_2^2$ y $r = b - Ax$. Entonces se cumplen las siguientes relaciones,

$$\begin{aligned} r^+ &= b - Ax^+ = b - A(x + \alpha d) = r - \alpha Ad \\ (r^+)^T Ad &= r^T Ad - \alpha (Ad)^T Ad = 0, \end{aligned}$$

donde en la última ecuación se usó la definición de α . Usando estas relaciones se puede ver que

$$\begin{aligned} \|r^+\|_2^2 &= (r^+)^T r^+ = (r - \alpha Ad)^T r^+ \\ &= r^T r^+ = r^T r - \alpha r^T Ad \\ &= r^T r \left(1 - \alpha \frac{r^T Ad}{r^T r}\right) \\ &= \left(1 - \frac{r^T Ad}{\|Ad\|_2^2} \frac{r^T Ad}{\|r\|_2^2}\right) \|r\|_2^2. \end{aligned}$$

■

Usando que $\nabla f(x) = A^T(Ax - b)$ se pueden construir métodos análogos a los vistos anteriormente. Por ejemplo, para el método de Cauchy se sabe que $d^k = -\nabla f(x^k) / \|\nabla f(x^k)\|_2$ y por lo tanto

$$d^k = \frac{A^T r^k}{\|A^T r^k\|_2}.$$

Usando (7.15),

$$x^{k+1} = x^k + \frac{\|A^T r^k\|_2^2}{\|AA^T r^k\|_2^2} A^T r^k.$$

La realización de al menos dos productos matriz-vector por iteración es inevitable. En relación a la convergencia del mismo, la Proposición 7.18 nos garantiza que

$$\|r^{k+1}\|_2^2 = \left(1 - \frac{\|A^T r^k\|_2^2}{\|A A^T r^k\|_2^2} \frac{\|A^T r^k\|_2^2}{\|r^k\|_2^2}\right) \|r^k\|_2^2$$

Tomando $v^k = A^T r^k$ y usando la desigualdad de Kantorovich (7.5), se obtiene

$$\begin{aligned} 1 - \frac{\|v^k\|_2^2}{(v^k)^T A^T A v^k} \frac{\|v^k\|_2^2}{(v^k)^T (A^T A)^{-1} v^k} &\leq 1 - \frac{4\sigma_1^2 \sigma_n^2}{(\sigma_1^2 + \sigma_n^2)^2} \\ &= \frac{(\sigma_1^2 - \sigma_n^2)^2}{(\sigma_1^2 + \sigma_n^2)^2} = \frac{(\kappa_2(A^T A) - 1)^2}{(\kappa_2(A^T A) + 1)^2}, \end{aligned}$$

donde σ_1 y σ_n son el máximo y mínimo valor singular de A (raíz cuadrada de autovalores de $A^T A$). Infelizmente este método no es usado debido a su poca velocidad de convergencia y elevado costo computacional en cada iteración.

Con una propiedad adicional en A se puede usar el siguiente.

Método del residuo mínimo. Suponga A definida positiva (no necesariamente simétrica) y considere $d^k = r^k$. Entonces

$$\nabla f(x^k)^T d^k = \left(A^T (Ax^k - b)\right)^T r^k = -(r^k)^T A r^k < 0$$

y por lo tanto d^k es una dirección de descenso para f en x^k . Por (7.15) se obtiene que

$$x^{k+1} = x^k + \frac{(r^k)^T A r^k}{\|A r^k\|_2^2} r^k, \quad r^{k+1} = r^k - \frac{(r^k)^T A r^k}{\|A r^k\|_2^2} A r^k.$$

Por lo tanto solo un producto matriz-vector es necesario por iteración. Note que si A no es definida positiva pero vale que $(r^k)^T A r^k > 0$ de todas maneras se obtiene que $f(x^{k+1}) < f(x^k)$. Tomando en cuenta este comentario, el esquema iterativo del método del residuo mínimo se resume en el siguiente pseudocódigo.

Algoritmo 32 (método del residuo mínimo)

Entradas: $A \in \mathbb{R}^{n \times n}$, $b, x \in \mathbb{R}^n$, $\epsilon > 0$ y $k_{\max} \in \mathbb{N}$. *Salida:* x^+ aproximación de x^* .

Paso 0: Definir $r = b - Ax$, $\sigma = \|r\|_2$ y $k = 0$.

Paso 1: Si $k > k_{\max}$ o $\sigma \leq \epsilon$ ir al paso 4. Sino, definir

$$\begin{aligned} v &= Ar, \\ t &= r^T v / \|v\|_2^2. \end{aligned}$$

Paso 2: Si $t \leq 0$, imprimir un alerta e ir al paso 4. Sino, definir

$$\begin{aligned} x &\leftarrow x + tr, \\ r &\leftarrow r - tv. \end{aligned}$$

Paso 3: Definir $\sigma = \|r\|_2$, hacer $k \leftarrow k + 1$ e ir al paso 1.

Paso 4: Retornar $x^+ = x$.

Note que si obtenemos x^+ por la salida en el paso 2 se debe a no haber conseguido una dirección para seguir disminuyendo el residuo.

La convergencia de este método se formaliza de la siguiente manera.

Teorema 7.19 Sea $A \in \mathbb{R}^{n \times n}$ definida positiva, $\sigma = \|A\|_2$ y μ el mínimo autovalor de $\frac{1}{2}(A + A^T)$. Si dado x^0 se genera $\{x^k\}$ por el método del residuo mínimo, entonces

$$\|r^{k+1}\|_2 \leq \left(1 - \frac{\mu^2}{\sigma^2}\right)^{1/2} \|r^k\|_2. \quad (7.17)$$

En particular $x^k \rightarrow x^*$ con $Ax^* = b$.

Demostración. Usando la Proposición 7.18 con $d^k = r^k$, la estimación (7.16) puede escribirse como

$$\|r^{k+1}\|_2^2 = \left(1 - \frac{(r^k)^T A r^k}{\|A r^k\|_2^2} \frac{(r^k)^T A r^k}{\|r^k\|_2^2}\right) \|r^k\|_2^2.$$

Por un lado, para $A_S = \frac{1}{2}(A + A^T)$ y para todo $x \in \mathbb{R}^n$

$$\mu \|x\|_2^2 \leq x^T A_S x = x^T A x \leq \|A x\|_2 \|x\|_2 \leq \sigma \|x\|_2^2,$$

obteniendo que $0 < \mu \leq \sigma$ y además

$$\mu \leq \frac{(r^k)^T A r^k}{\|r^k\|_2^2}, \quad \|A r^k\|_2 \leq \sigma \|r^k\|_2.$$

Por lo tanto

$$\frac{\mu^2}{\sigma^2} \leq \left(\frac{(r^k)^T A r^k}{\|r^k\|_2^2} \frac{\|r^k\|_2}{\|A r^k\|_2}\right)^2 = \frac{(r^k)^T A r^k}{\|A r^k\|_2^2} \frac{(r^k)^T A r^k}{\|r^k\|_2^2}.$$

Entonces, para $c = 1 - \mu^2/\sigma^2$,

$$\|r^{k+1}\|_2 \leq c^{1/2} \|r^k\|_2 \leq \dots \leq c^{(k+1)/2} \|r^0\|_2,$$

concluyendo que $r^k \rightarrow 0$ pues $0 < c < 1$. En consecuencia $x^k \rightarrow x^*$. ■

Note que si A no es definida positiva pero vale que $(r^k)^T A r^k > 0$ entonces reemplazando μ por $\mu_k = (r^k)^T A r^k / \|r^k\|_2^2$ en la demostración anterior se consigue que $\|r^{k+1}\|_2 < \|r^k\|_2$.

Métodos de proyección multidimensional

Considere $\{x^k\}$ generada tomando $x^0 \in \mathbb{R}^n$ y definiendo x^{k+1} como solución de

$$\underset{x \in x^0 + \text{Im}(V_k)}{\text{minimizar}} f(x).$$

Entre los posibles métodos, detallaremos uno donde V_k tiene de rango fijo para todo k .

El Corolario 7.17 con $z = x^0$ y $V = V_k \in \mathbb{R}^{n \times p_k}$ nos garantiza que si α_k satisface $V_k^T A^T A V_k \alpha_k = V_k^T A^T r^k$ con $r^k = b - Ax^k$, entonces $x^{k+1} = x^0 + V_k \alpha^k$ es solución de

$$\underset{x \in x^0 + \text{Im}(V_k)}{\text{minimizar}} \|Ax - b\|_2.$$

Para resolver este problema se deberá escoger V_k de manera conveniente.

Para el método del gradiente conjugado se utilizó V_k tal que $V_k^T A V_k$ es diagonal. Cuando la matriz $A \in \mathbb{R}^{n \times n}$ no es simétrica lo más próximo sería la descomposición de Schur de A , o sea, $V_k^T A V_k$ es Hessenberg superior.

Para construir $V = [v^1 \dots v^p] \in \mathbb{R}^{n \times p}$ con columnas ortogonales de manera iterativa y que cumpla que $H = V^T A V$ sea Hessenberg superior, consideremos el problema de hallar H y V satisfaciendo $AV = VH$. Si analizamos la j -ésima columna de esta ecuación, se obtiene

$$Av^j = \sum_{i=1}^{j+1} h_{ij} v^i,$$

concluyendo que

$$h_{lj} = (v^l)^T Av^j, \quad h_{j+1,j} v^{j+1} = Av^j - \sum_{i=1}^j h_{ij} v^i,$$

donde para la primera relación se utilizó que las columnas de V son ortogonales.

Este procedimiento se conoce como el método de Arnoldi y propone generar H y V de la siguiente manera: dado $v \in \mathbb{R}^n$ definir $v^1 = v/\|v\|_2$ y para $j = 1, \dots, n$ defina

$$\begin{aligned} h_{ij} &= (v^i)^T Av^j \quad \text{para } i = 1, \dots, j, \\ \tilde{v}^j &= Av^j - \sum_{i=1}^j h_{ij} v^i, \\ h_{j+1,j} &= \|\tilde{v}^j\|_2, \\ v^{j+1} &= \frac{1}{h_{j+1,j}} \tilde{v}^j \quad \text{si } h_{j+1,j} \neq 0. \end{aligned}$$

Note que esta construcción tiene muchas semejanzas con la ortogonalización de Gram-Schmidt. El procedimiento se detiene si $h_{p+1,p} = 0$ para algún $p \leq n$. En este caso $\tilde{v}^p = 0$ y por lo tanto

$$A[v^1 \dots v^p] = [v^1 \dots v^p] \begin{bmatrix} h_{11} & \dots & h_{1,p-1} & h_{1p} \\ h_{21} & h_{22} & \dots & h_{2p} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \dots & h_{p,p-1} & h_{pp} \end{bmatrix}.$$

Obteniendo que A deja invariante $\text{span}\{v^1, \dots, v^p\}$. Además, tenemos la siguiente propiedad.

Teorema 7.20 Sea $A \in \mathbb{R}^{n \times n}$ y suponga que el método de Arnoldi no se detiene antes del paso m con $m < n$, entonces $\{v^1, \dots, v^m\}$ es una base ortonormal del espacio de Krylov $K_m(A, v)$.

Demostración. Los vectores $v^1, \dots, v^m$ son ortonormales por construcción y generan un espacio de dimensión m . Veamos por inducción que está contenido en $K_r(A, v)$. Claramente $v^1 = p_0(A)v$ con p_0 polinomio de grado cero. Supongamos que $v^i = p_{i-1}(A)v$ con p_{i-1} polinomio de grado $i-1$ para todo $i \leq j$. Como

$$\begin{aligned} h_{j+1,j}v^{j+1} &= Av^j - \sum_{i=1}^j h_{ij}v^i \\ &= Ap_{j-1}(A)v - \sum_{i=1}^j h_{ij}p_{i-1}(A)v \\ &= p_j(A)v, \end{aligned}$$

usando que $h_{j+1,j} \neq 0$, concluimos que $v^{j+1} = p_j(A)v$.

Por lo tanto $\text{span}\{v^1, \dots, v^m\} = \text{span}\{v, Av, \dots, A^{m-1}v\} = K_m(A, v)$ ■

Como ya se mencionó, este procedimiento tiene muchas semejanzas con la ortonormalización de Gram-Schmidt. Lamentablemente, al igual que en el método de Gram-Schmidt, sufre de pérdida de ortogonalidad numérica de los vectores v^j . En este caso el error numérico también puede disminuirse con un procedimiento similar al Gram-Schmidt modificado visto anteriormente. Para ello en vez de definir

$$h_{ij} = (v^i)^T Av^j \quad \text{para } i = 1, \dots, j,$$

se tomará $\tilde{v} = Av^j$ y se lo actualizará de la siguiente manera

$$h_{ij} = (v^i)^T \tilde{v}, \quad \tilde{v} \leftarrow \tilde{v} - h_{ij}v^i,$$

para $i = 1, \dots, j$.

Tomando en cuenta tal modificación, un posible pseudocódigo sería:

Algoritmo 33 (método de Arnoldi)

Entradas: $A \in \mathbb{R}^{n \times n}$, $v \in \mathbb{R}^n$ y $m \leq n$. *Salidas:* $\bar{H} \in \mathbb{R}^{(r+1) \times r}$, $V \in \mathbb{R}^{n \times r}$, $\bar{H}$ Hessenberg superior y V con columnas ortogonales t.q. $AV = [V \ v^{r+1}]\bar{H}$.

Paso 0: Definir $j = 1$.

Paso 1: Si $j > m$ ir al paso 6. Sino, definir $i = 1$,

$$\begin{aligned} V_{\bullet j} &= v / \|v\|_2, \\ v &= AV_{\bullet j}. \end{aligned}$$

Paso 2: Si $i > j$ ir al paso 4. Sino, definir

$$\begin{aligned} H_{ij} &= v^T V_{\bullet i}, \\ v &\leftarrow v - H_{ij}V_{\bullet i}. \end{aligned}$$

Paso 3: Hacer $i \leftarrow i + 1$ e ir al paso 2.

Paso 4: Si $\|v\|_2 = 0$, ir al paso 6. Sino, definir

$$H_{j+1,j} = \|v\|_2$$

Paso 5: Hacer $j \leftarrow j + 1$ e ir al paso 1.

Paso 6: Retornar $\bar{H}$ y V .

Desde el punto de vista matricial, obtenemos lo siguiente.

Proposición 7.21 Sea $A \in \mathbb{R}^{n \times n}$ y suponga que el método de Arnoldi realiza m pasos para $m \leq n$ y sea $\bar{H}_m \in \mathbb{R}^{(m+1) \times m}$ la matriz Hessenberg superior generada. Si $H_m \in \mathbb{R}^{m \times m}$ se obtiene eliminando la última fila de $\bar{H}_m$ y consideramos $V_j = [v^1 \dots v^j]$, entonces

$$AV_m = V_m H_m + h_{m+1,m} v^{m+1} (e^m)^T = V_{m+1} \bar{H}_m.$$

Concluyendo que $V_m^T AV_m = H_m$.

Demostración. La j -ésima columna de AV_m es Av^j y la de $V_{m+1} \bar{H}_m$ es $\sum_{i=1}^{j+1} h_{ij} v^i$. Por construcción se tiene

$$Av^j = \sum_{i=1}^{j+1} h_{ij} v^i.$$

Obteniendo que $AV_m = V_{m+1} \bar{H}_m$. Ahora, note que

$$\bar{H}_m = \begin{bmatrix} H_m \\ h_{m+1,m} (e^m)^T \end{bmatrix},$$

como $V_{m+1} = [V_m \ v^{m+1}]$ al multiplicar se obtiene

$$V_{m+1} \bar{H}_m = V_m H_m + h_{m+1,m} v^{m+1} (e^m)^T.$$

■

Método del residuo mínimo generalizado. Más conocido por GMRES (Generalized Minimum Residual), este método se basa en considerar un número $m < n$ fijo y en cada iteración tomar $V_k = [v^1 \dots v^m]$ generada por el método de Arnoldi a partir de $v = r^k$. Veamos cómo se relaciona esto con el método de proyección.

Teorema 7.22 Para $A \in \mathbb{R}^{n \times n}$, $\bar{x}$ es solución de

$$\underset{x \in x^0 + K_m(A, r^0)}{\text{minimizar}} \|Ax - b\|_2,$$

si y solo si $\bar{x} = x^0 + V_m \bar{\alpha}$ con $\bar{\alpha}$ solución de

$$\underset{\alpha \in \mathbb{R}^m}{\text{minimizar}} \|\bar{H}_m \alpha - \sigma e^1\|_2,$$

donde $\sigma = \|r^0\|_2$ y $\bar{H}_m, V_m$ generadas por el método de Arnoldi a partir de $v = r^0$.

Demostración. Como $K_m(A, r^0) = \text{Im}(V_m)$, entonces $x \in x^0 + K_m(A, r^0)$ si y solo si $x = x^0 + V_m \alpha$ con $\alpha \in \mathbb{R}^m$. Luego

$$\begin{aligned} Ax - b &= A(x^0 + V_m \alpha) - b = AV_m \alpha - r^0 \\ &= V_{m+1} \bar{H}_m \alpha - \sigma v^1 = V_{m+1}(\bar{H}_m \alpha - \sigma e^1). \end{aligned}$$

Como $V_{m+1}^T V_{m+1} = I$ entonces $\|Ax - b\|_2 = \|\bar{H}_m \alpha - \sigma e^1\|_2$.

Por lo tanto, $\bar{x}$ minimiza $\|Ax - b\|_2$ si y solo si, para $\bar{\alpha}$ tal que $\bar{x} = x^0 + V_m \bar{\alpha}$, $\bar{\alpha}$ minimiza $\|\bar{H}_m \alpha - \sigma e^1\|_2$. ■

El esquema iterativo del método GMRES (con recomienzos) sería el siguiente: dada una dimensión m para la variedad afín, x^0 y $k = 0$,

1. Definir $r^k = b - Ax^k$.
2. Generar $\bar{H}_m$ y V_m por el método de Arnoldi a partir de $v = r^k$.
3. Calcular α^m que minimiza $\|\bar{H}_m \alpha - \sigma e^1\|_2$.
4. Si $\|\bar{H}_m \alpha^m - \sigma e^1\|_2 = 0$, parar.
Sino definir $x^{k+1} = x^k + V_m \alpha^m$, $k \leftarrow k + 1$ e ir al paso 1.

Un pseudocódigo, usando m para la dimensión de la variedad afín, sería el siguiente.

Algoritmo 34 (método GMRES)

Entradas: $A \in \mathbb{R}^{n \times n}$, $b, x \in \mathbb{R}^n$, $\epsilon > 0$, $k_{\text{máx}} \in \mathbb{N}$ y $m \ll n$. *Salida:* x^+ aprox. de x^* .

Paso 0: Definir $x = x^0$, $\sigma_+ = \|b - Ax\|_2$ y $k = 0$.

Paso 1: Si $k > k_{\text{máx}}$ o $\sigma_+ \leq \epsilon$, retornar $x^+ = x$. Sino, definir $\sigma = \sigma_+$,

$$\begin{aligned} r &= b - Ax, \\ \bar{H}, V &\text{ aplicando Algoritmo 33 a } (A, r, m_A), \\ \alpha, \sigma_+ &\text{ aplicando Algoritmo 20 a } (\bar{H}, \sigma e^1), \\ x &\leftarrow x + V\alpha. \end{aligned}$$

Paso 2: Hacer $k \leftarrow k + 1$ e ir al paso 1.

Para más detalles sobre la convergencia e implementación eficiente de este método, puede consultar [3, Sección 6.5]

7.3. Ejercicios

1. Para $A \in \mathbb{R}^{n \times n}$ simétrica definida positiva, $\|x\|_A = \sqrt{x^T A x}$ y $x^* = A^{-1}b$, sean

$$f_1(x) = \frac{1}{2} \|x - x^*\|_A^2, \quad f_2(x) = \frac{1}{2} \|Ax - b\|_{A^{-1}}^2, \quad f_3(x) = \frac{1}{2} x^T A x - x^T b.$$

Calcule el gradiente de cada función. Concluya que estas funciones difieren en a lo sumo una constante.

2. Sea $A \in \mathbb{R}^{n \times n}$ simétrica definida positiva $\{x^k\}$ generada por el método de Gastinel a partir de un x^0 . Demuestre que

$$\|x^{k+1} - x^*\|_A \leq \left(1 - \frac{1}{n\kappa_2(A)}\right)^{1/2} \|x^k - x^*\|_A,$$

donde $Ax^* = b$. En particular $x^k \rightarrow x^*$.

3. Para resolver $Ax = b$ con $A \in \mathbb{R}^{n \times n}$ simétrica definida positiva, considere el siguiente método iterativo: dado x^k defina $x^{k+1} = x^k + d^k$ donde d_i^k es solución de

$$\underset{d \in \mathbb{R}}{\text{minimizar}} \quad f(x^k + de^i),$$

con $f(x) = \frac{1}{2}x^T Ax - b^T x$ y e^i el i -ésimo vector canónico. Demuestre que la sucesión generada $\{x^k\}$ coincide con la generada por el método de Jacobi.

4. Sea A simétrica definida positiva. Demuestre que las direcciones A -conjugadas (o A -ortogonales) son linealmente independientes.
5. Se desea resolver $Ax = b$ con $A \in \mathbb{R}^{n \times n}$ simétrica definida positiva y se propone el siguiente método iterativo: definir x^{k+1} como solución de $\underset{x \in x^k + \mathcal{K}_k}{\text{minimizar}} \|x - x^*\|_A$, donde $\mathcal{K}_k = \text{span}\{r^k, Ar^k\}$ con $r^k = b - Ax^k$ y $Ax^* = b$.

- a) Use Gram-Schmidt con el producto interno inducido por A para determinar p^k tal que $(p^k)^T Ar^k = 0$ y $\mathcal{K}_k = \text{span}\{r^k, p^k\}$. Dé una fórmula para calcular p^k .
- b) Escriba un pseudocódigo para el método iterativo propuesto.

6. Para $A \in \mathbb{R}^{n \times n}$ con $Ax^* = b$, sean

$$g_1(x) = \frac{1}{2}\|x - x^*\|_{A^T A}^2, \quad g_2(x) = \frac{1}{2}\|Ax - b\|_2^2, \quad g_3(x) = \frac{1}{2}x^T A^T Ax - x^T A^T b.$$

Calcule el gradiente de cada función. Concluya que estas funciones difieren en a lo sumo una constante.

Capítulo 8

Ecuaciones no lineales y minimización

Aunque los problemas que trataremos en este capítulo son no lineales, los métodos que abordaremos para hallar una solución se basan en resolver una sucesión de subproblemas lineales. Estos subproblemas corresponden a aproximaciones del problema no lineal.

Para trabajar con aproximaciones consideraremos una norma vectorial arbitraria $\|\cdot\|$ y utilizaremos la notación $\mathcal{B}(x^*, \rho) = \{x \mid \|x - x^*\| \leq \rho\}$. Además utilizaremos la notación O y o , que se leen “o grande” y “o pequeña”.

Definición 8.1 Para cualquier función $\Phi : (0, +\infty) \mapsto \mathbb{R}^n$ y $\ell \in [0, +\infty]$ diremos que

- $\Phi(t) = O(t)$ en un entorno de ℓ si

$$\limsup_{t \rightarrow \ell} \frac{\|\Phi(t)\|}{t} < +\infty.$$

- $\Phi(t) = o(t)$ en un entorno de ℓ si

$$\lim_{t \rightarrow \ell} \frac{\|\Phi(t)\|}{t} = 0.$$

8.1. Ecuaciones no lineales

En los capítulos anteriores se vieron métodos para resolver $Ax = b$, que es equivalente a resolver $F(x) = 0$ donde $F(x) = b - Ax$. En esta sección nos centraremos en

$$\text{hallar } x^* \in \mathbb{R}^n \text{ tal que } F(x^*) = 0,$$

donde $F : \mathbb{R}^n \mapsto \mathbb{R}^m$ no es necesariamente afín.

Ejemplo 8.2 Transferencia de calor. Un intercambiador de calor a partir de fluidos puede modelarse considerando un fluido caliente y uno frío, como lo indica la Figura 8.2.

El fluido caliente ingresa al intercambiador con una temperatura t_{ce} y un flujo q_c , saliendo con una temperatura t_{cs} . El fluido frío ingresa al intercambiador con una temperatura t_{fe} y un flujo q_f , saliendo con una temperatura t_{fs} . Considerando una constante de transferencia de




Figura 8.1: Transferencia de calor

calor κ y constantes α_c, α_f de proporcionalidad del flujo del fluido caliente y frío, se obtiene el siguiente sistema de ecuaciones no lineales:

$$\begin{aligned}\alpha_c q_c (t_{ce} - t_{cs}) &= \alpha_f q_f (t_{fs} - t_{fe}) \\ \alpha_c q_c (t_{ce} - t_{cs}) &= \kappa \frac{(t_{ce} - t_{fs}) - (t_{cs} - t_{fe})}{\log(t_{ce} - t_{fs}) - \log(t_{cs} - t_{fe})}\end{aligned}$$

Suponga que tanto κ como los flujos y temperaturas de los fluidos entrantes son conocidos. Luego de regular los flujos entrantes escogiendo α_c y α_f , se desea establecer las temperaturas de salida t_{cs} y t_{fs} .

En este caso, tomando $x = (t_{cs}, t_{fs})$ hay que encontrar un cero de $F : \mathbb{R}^2 \mapsto \mathbb{R}^2$ tal que

$$F(x) = \begin{bmatrix} \alpha_c q_c (t_{ce} - x_1) - \alpha_f q_f (x_2 - t_{fe}) \\ \alpha_c q_c (t_{ce} - x_1) - \kappa \frac{(t_{ce} - x_2) - (x_1 - t_{fe})}{\log(t_{ce} - x_2) - \log(x_1 - t_{fe})} \end{bmatrix}$$

Uno de los métodos más conocidos para resolver este tipo de problema es el siguiente.

8.1.1. Método de Newton

Cuando la función es diferenciable, la mejor aproximación involucrará su derivada. Recuerde que $F : \mathbb{R}^n \mapsto \mathbb{R}^m$ es diferenciable en $\bar{x}$ si existe $M \in \mathbb{R}^{m \times n}$ tal que

$$F(x) = F(\bar{x}) + M(x - \bar{x}) + o(\|x - \bar{x}\|).$$

En tal caso M es única, se le llama derivada de F en $\bar{x}$ y se denota por $F'(\bar{x})$.

Método de Newton. Si $F : \mathbb{R}^n \mapsto \mathbb{R}^n$ es diferenciable en x^k , para todo x en un entorno de x^k podremos aproximar $F(x)$ por $F(x^k) + F'(x^k)(x - x^k)$. De esta manera, dado x^k definiremos x^{k+1} como la solución de

$$F(x^k) + F'(x^k)(x - x^k) = 0.$$

Equivalentemente, $x^{k+1} = x^k + d^k$ donde d^k es solución del sistema lineal

$$F(x^k) + F'(x^k)d = 0.$$

Un posible pseudocódigo utilizando eliminación Gaussiana con pivoteo es el siguiente.

Algoritmo 35 (método de Newton)

Entradas: $F : \mathbb{R}^n \mapsto \mathbb{R}^n$, $x^0 \in \mathbb{R}^n$, $\epsilon > 0$ y $k_{\text{máx}} \in \mathbb{N}$. *Salida:* x^+ aprox. de x^* .

Paso 0: Definir $x = x^0$, $k = 0$ y obtener $r = F(x)$, $M = F'(x)$.


Paso 1: Si $k > k_{\text{máx}}$ o $\|r\| \leq \epsilon$, retornar $x^+ = x$. Sino, definir

$$d \text{ t.q. } r + Md = 0 \text{ aplicando el Algoritmo 11 a } (M, -r), \\ x \leftarrow x + d.$$

Paso 2: Obtener $r = F(x)$, $M = F'(x)$, hacer $k \leftarrow k + 1$, e ir al paso 1.

Note que en cada iteración se debe resolver un sistema lineal con un método apropiado para la estructura del mismo. Por otro lado, en cada iteración se deben evaluar F y F' en x , donde para la primera se deben evaluar n funciones y para la segunda n^2 funciones. Dependiendo de la complejidad de las funciones no lineales involucradas, por lo general el costo computacional de evaluación de las funciones es superior al costo computacional de resolución del sistema lineal.

Una manera eficiente de evaluar funciones no lineales consiste en escribirlas como composición de funciones, de esta manera se reduce el costo de cómputo de las derivadas gracias a la regla de la cadena. Por lo tanto, en general se implementa solamente una función para calcular $F(x)$ y $F'(x)$.



Ejemplo 8.3 Modelo de caja negra para una función no lineal. Tomemos como ejemplo la función del Ejemplo 8.2, o sea

$$F_1(x) = \alpha_c q_c(t_{ce} - x_1) - \alpha_f q_f(x_2 - t_{fe}) \\ F_2(x) = \alpha_c q_c(t_{ce} - x_1) - \kappa(x_1 - t_{fe}) \frac{\frac{t_{ce} - x_2}{x_1 - t_{fe}} - 1}{\log\left(\frac{t_{ce} - x_2}{x_1 - t_{fe}}\right)}$$

Para un x dado, definimos $c_1 = \alpha_c q_c$, $c_2 = \alpha_f q_f$,

$$\begin{array}{lll} y_1 = c_1(t_{ce} - x_1), & y_2 = c_2(x_2 - t_{fe}), & y_3 = t_{ce} - x_2, \\ y_4 = x_1 - t_{fe}, & y_5 = y_3/y_4, & y_6 = y_5 - 1, \\ y_7 = \log(y_5), & y_8 = y_6/y_7, & y_9 = \kappa y_4 y_8. \end{array}$$

Utilizando regla de la cadena y la notación y_{ik} para $\partial_{x_k} y_i$, como $y_{21} = y_{31} = y_{12} = y_{42} = 0$,

$$\begin{aligned} y_{11} &= -c_1, & y_{41} &= 1, & y_{51} &= -y_3 y_{41} / y_4^2, \\ y_{61} &= y_{51}, & y_{71} &= y_{51} / y_5, & y_{81} &= (y_{61} y_7 - y_6 y_{71}) / y_7^2, \\ y_{91} &= \kappa(y_{41} y_8 + y_4 y_{81}), & y_{22} &= c_2, & y_{32} &= -1, \\ y_{52} &= y_{32} / y_4, & y_{62} &= y_{52}, & y_{72} &= y_{52} / y_5, \\ y_{82} &= (y_{62} y_7 - y_6 y_{72}) / y_7^2, & y_{92} &= \kappa y_4 y_{82}. \end{aligned}$$

De esta manera

$$F(x) = \begin{bmatrix} y_1 - y_2 \\ y_1 - y_9 \end{bmatrix}, \quad F'(x) = \begin{bmatrix} y_{11} & -y_{22} \\ y_{11} - y_{91} & -y_{92} \end{bmatrix}.$$

Con el fin de analizar la convergencia de este método, formalizaremos la noción de velocidad de convergencia.

Definición 8.4 Diremos que una sucesión $\{x^k\}$ converge a x^* con tasa

- *lineal* si $\limsup_{k \rightarrow \infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} < 1$,
- *superlineal* si $\|x^{k+1} - x^*\| = o(\|x^k - x^*\|)$,
- *cuadrática* si $\|x^{k+1} - x^*\| = O(\|x^k - x^*\|^2)$.

La convergencia del método de Newton se resume en el siguiente resultado.

Teorema 8.5 Sea $F : \mathbb{R}^n \mapsto \mathbb{R}^n$ continuamente diferenciable en un entorno de x^* , con $F(x^*) = 0$ y $F'(x^*)$ no singular. Entonces existe $\varepsilon > 0$ tal que si $\|x^0 - x^*\| \leq \varepsilon$, la sucesión $\{x^k\}$ generada por el método de Newton converge superlinealmente a x^* .

Si además, $\|F'(\tilde{x}) - F'(x)\| \leq \ell \|\tilde{x} - x\|$ para todo $\tilde{x}, x$ en un entorno de x^* , entonces $\{x^k\}$ converge cuadráticamente a x^* .

Demostración. Tome $\varepsilon > 0$ tal que $F'(x)^{-1}$ exista si $x \in \mathcal{B}(x^*, \varepsilon)$. Sea ρ tal que $\|F'(x)^{-1}\| \leq \rho$ para todo $x \in \mathcal{B}(x^*, \varepsilon)$.

Suponga que para algún k , $x^k \in \mathcal{B}(x^*, \varepsilon)$ y defina $\phi(t) = F(x^* + t(x^k - x^*))$. Luego, como $\phi'(t) = F'(x^* + t(x^k - x^*))(x^k - x^*)$,

$$\begin{aligned} F(x^k) + F'(x^k)(x^* - x^k) &= F(x^k) - F(x^*) - F'(x^k)(x^k - x^*) \\ &= \phi(1) - \phi(0) - \phi'(1) \\ &= \int_0^1 (\phi'(t) - \phi'(1)) dt \\ &= \left(\int_0^1 (F'(x^* + t(x^k - x^*)) - F'(x^k)) dt \right) (x^k - x^*). \end{aligned}$$

Por otro lado,

$$\begin{aligned} x^{k+1} - x^* &= F'(x^k)^{-1} \left(F(x^k) + F'(x^k)(x^{k+1} - x^*) - F(x^k) \right) \\ &= F'(x^k)^{-1} \left(F(x^k) + F'(x^k)(x^{k+1} - x^k) - (F(x^k) + F'(x^k)(x^* - x^k)) \right). \end{aligned}$$

Como $F(x^k) + F'(x^k)(x^{k+1} - x^k) = 0$, tomando norma obtenemos que

$$\|x^{k+1} - x^*\| \leq \rho \left(\int_0^1 \|F'(x^* + t(x^k - x^*)) - F'(x^k)\| dt \right) \|x^k - x^*\|.$$

Como F' es continua, tomando $\tau < 1$ fijo y haciendo ε suficientemente pequeño se obtiene que $\|F'(\tilde{x}) - F'(x)\| \leq \tau/\rho$ para todo $\tilde{x}, x \in \mathcal{B}(x^*, \varepsilon)$.

De esta manera, si $x^0 \in \mathcal{B}(x^*, \varepsilon)$ obtendremos que $\{x^k\} \subset \mathcal{B}(x^*, \varepsilon)$. Además

$$\|x^{k+1} - x^*\| \leq \tau \|x^k - x^*\| \leq \dots \leq \tau^{k+1} \|x^0 - x^*\|.$$

Por lo tanto $x^k \rightarrow x^*$. Más aún

$$\frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} \leq \rho \left(\int_0^1 \|F'(x^* + t(x^k - x^*)) - F'(x^k)\| dt \right) \rightarrow 0.$$

Si además $\|F'(x^* + t(x^k - x^*)) - F'(x^k)\| \leq \ell \|(t-1)(x^k - x^*)\|$, entonces

$$\frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|^2} \leq \rho \ell \int_0^1 (1-t) dt = \frac{\rho \ell}{2}.$$

■

8.1.2. Método de Newton truncado

Al implementar el método de Newton, en cada iteración se debe resolver un sistema lineal. Desde el punto de vista teórico el sistema debe resolverse de manera exacta, algo que no sucede si el sistema lineal se resuelve utilizando algún método iterativo. En esta variante, permitiremos una resolución inexacta del sistema lineal con una tolerancia del error controlada.

Para una sucesión $\{\eta_k\}$ tal que $\eta_k \rightarrow 0^+$, dado x^k definiremos x^{k+1} como aquel que cumple

$$\|F(x^k) + F'(x^k)(x^{k+1} - x^k)\| \leq \eta_k \|F(x^k)\|.$$

Equivalentemente, $x^{k+1} = x^k + d^k$ donde d^k satisface

$$\|F(x^k) + F'(x^k)d^k\| \leq \eta_k \|F(x^k)\|.$$

La “sucesión forzante” $\{\eta_k\}$ puede definirse tomando $\gamma, \delta \in (0, 1)$ y $\eta_k = \min\{\gamma, \|F(x^k)\|^\delta\}$. Una implementación utilizando GMRES es la siguiente.

Algoritmo 36 (método de Newton truncado)

Entradas: $F : \mathbb{R}^n \mapsto \mathbb{R}^n$, $x^0 \in \mathbb{R}^n$, $\epsilon > 0$ y $k_{\max} \in \mathbb{N}$. *Salida:* x^+ aprox. de x^* .

Paso 0: Definir $x = x^0$, $\gamma, \delta \in (0, 1)$ y obtener $r = F(x)$, $M = F'(x)$.

Hacer $\sigma = \|r\|_2$ y $k = 0$.

Paso 1: Si $k > k_{\max}$ o $\sigma \leq \epsilon$, retornar $x^+ = x$. Sino, definir

$$\eta = \min\{\gamma, \sigma^\delta\},$$

d aplicando el Algoritmo 34 a $(M, -r, 0, \eta\sigma)$,

$$x \leftarrow x + d.$$

Paso 2: Obtener $r = F(x)$, $M = F'(x)$, hacer $\sigma = \|r\|_2$, $k \leftarrow k + 1$, e ir al paso 1.

Claramente la implementación es similar a la del método de Newton al igual que su análisis de convergencia.

Teorema 8.6 Sea $F : \mathbb{R}^n \mapsto \mathbb{R}^n$ continuamente diferenciable en un entorno de x^* , con $F(x^*) = 0$ y $F'(x^*)$ no singular. Entonces existen $\varepsilon > 0$ y $\delta > 0$ tal que si $\|x^0 - x^*\| \leq \varepsilon$ y $\eta_0 \leq \delta$, la sucesión $\{x^k\}$ generada por el método de Newton truncado con $\eta_k \leq \eta_0$, converge linealmente a x^* . Si además, $\eta_k \rightarrow 0^+$ entonces $\{x^k\}$ converge superlinealmente a x^* .

Demostración. La demostración es similar a la del Teorema 8.5. Por un lado

$$\begin{aligned} F(x^k) + F'(x^k)(x^* - x^k) &= F(x^k) - F(x^*) - F'(x^k)(x^k - x^*) \\ &= \left(\int_0^1 \left(F'(x^* + t(x^k - x^*)) - F'(x^k) \right) dt \right) (x^k - x^*). \end{aligned}$$

Por otro lado,

$$\begin{aligned} x^{k+1} - x^* &= F'(x^k)^{-1} \left(F(x^k) + F'(x^k)(x^{k+1} - x^*) - F(x^k) \right) \\ &= F'(x^k)^{-1} \left(F(x^k) + F'(x^k)(x^{k+1} - x^k) - (F(x^k) + F'(x^k)(x^* - x^k)) \right). \end{aligned}$$

Ahora, tomando norma y utilizando que

$$\begin{aligned} \|F(x^k) + F'(x^k)(x^{k+1} - x^k)\| &\leq \eta_k \|F(x^k)\| \\ &\leq \eta_k \|F(x^k) + F'(x^k)(x^* - x^k)\| + \eta_k \|F'(x^k)(x^k - x^*)\|, \end{aligned}$$

se obtiene la desigualdad

$$\begin{aligned} \|x^{k+1} - x^*\| &\leq \rho(\eta_k + 1) \left(\int_0^1 \|F'(x^* + t(x^k - x^*)) - F'(x^k)\| dt \right) \|x^k - x^*\| \\ &\quad + \rho\eta_k \|F'(x^k)\| \|x^k - x^*\|. \end{aligned}$$

Por la continuidad de F' , dado $\tau < 1$ se garantiza la existencia de $\varepsilon > 0$ y $\delta > 0$ tal que si $x^0 \in \mathcal{B}(x^*, \varepsilon)$ y $\eta_0 \leq \delta$ entonces $\|x^{k+1} - x^*\| \leq \tau \|x^k - x^*\|$. Obteniendo la convergencia con tasa lineal. Si además $\eta_k \rightarrow 0$, entonces

$$\frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} \rightarrow 0.$$

8.1.3. Métodos cuasi-Newton

El costo computacional de evaluar la matriz Jacobiana de $F : \mathbb{R}^n \mapsto \mathbb{R}^n$ puede reducirse utilizando una aproximación M_k de la misma. Todos estos métodos donde no se utiliza la derivada exacta son llamados métodos cuasi-Newton. En este caso, dado x^k definiremos x^{k+1} como la solución de

$$F(x^k) + M_k(x - x^k) = 0.$$

Equivalentemente, $x^{k+1} = x^k + d^k$ donde d^k es solución del sistema lineal

$$F(x^k) + M_k d = 0.$$

La implementación es similar a la del método de Newton, cambiando la evaluación de $F'(x^k)$ por el cálculo de M_k . La convergencia de los métodos cuasi-Newton se resume en el siguiente resultado.

Teorema 8.7 Sea $F : \mathbb{R}^n \mapsto \mathbb{R}^n$ continuamente diferenciable en un entorno de x^* , con $F(x^*) = 0$ y $F'(x^*)$ no singular. Entonces existen $\varepsilon > 0$ y $\delta > 0$ tal que si $\|x^0 - x^*\| \leq \varepsilon$ y $\|M_k - F'(x^k)\| \leq \delta$ para todo k , la sucesión $\{x^k\}$ generada por el método cuasi-Newton converge linealmente a x^* . Si además,

$$(M_k - F'(x^*))(x^k - x^*) = o(\|x^k - x^*\|),$$

entonces $\{x^k\}$ converge superlinealmente a x^* .

Demostración. La demostración es similar a la del Teorema 8.5. Por un lado

$$\begin{aligned} F(x^k) + F'(x^k)(x^* - x^k) &= F(x^k) - F(x^*) - F'(x^k)(x^k - x^*) \\ &= \left(\int_0^1 \left(F'(x^* + t(x^k - x^*)) - F'(x^k) \right) dt \right) (x^k - x^*). \end{aligned}$$

Por otro lado,

$$\begin{aligned} x^{k+1} - x^* &= M_k^{-1} \left(F(x^k) + M_k(x^{k+1} - x^*) - F(x^k) \right) \\ &= M_k^{-1} \left(F(x^k) + M_k(x^{k+1} - x^k) - (F(x^k) + M_k(x^* - x^k)) \right). \end{aligned}$$

Como $F(x^k) + M_k(x^{k+1} - x^k) = 0$, tomando norma y utilizando que

$$F(x^k) + M_k(x^* - x^k) = F(x^k) + F'(x^k)(x^* - x^k) + (M_k - F'(x^k))(x^* - x^k),$$

se obtiene la desigualdad

$$\begin{aligned} \|x^{k+1} - x^*\| &\leq \rho \left(\int_0^1 \|F'(x^* + t(x^k - x^*)) - F'(x^k)\| dt \right) \|x^k - x^*\| \\ &\quad + \rho \|(M_k - F'(x^k))(x^* - x^k)\|. \end{aligned}$$

Por la continuidad de F' , dado $\tau < 1$ se garantiza la existencia de $\varepsilon > 0$ y $\delta > 0$ tal que si $x^0 \in \mathcal{B}(x^*, \varepsilon)$ y $\|M_k - F'(x^k)\| \leq \delta$ entonces $\|x^{k+1} - x^*\| \leq \tau \|x^k - x^*\|$. Obteniendo la convergencia con tasa lineal. Si además $(M_k - F'(x^*))(x^k - x^*) = o(\|x^k - x^*\|)$, entonces

$$\frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} \leq \rho \left(\int_0^1 \|F'(x^* + t(x^k - x^*)) - F'(x^k)\| dt \right) + \rho \|F'(x^*) - F'(x^k)\| + \frac{o(\|x^k - x^*\|)}{\|x^k - x^*\|}.$$

Obteniendo así la convergencia superlineal. ■

Veamos algunas opciones de elección de matrices M_k para el método cuasi-Newton.

Diferencias finitas. Una manera de aproximar $F'(x)$ es tomando aproximaciones de las derivadas en las direcciones canónicas. En este caso dado h suficientemente pequeño, se define M de manera que

$$M_{\bullet j} = \frac{1}{h} (F(x + he^j) - F(x)).$$

Como $M_{\bullet j} = F'(x)e^j + o(h)$, entonces $M = F'(x) + o(h)$. Computacionalmente se suele tomar $h = \sqrt{\epsilon}\|x\|$ donde ϵ es el épsilon de la máquina.

Actualización secante. Las actualizaciones secantes de cambio mínimo, nos permiten obtener M_{k+1} a partir de M_k y la información en x^{k+1} y x^k . Como

$$F(x^{k+1}) - F(x^k) = F'(x^k)(x^{k+1} - x^k) + o(\|x^{k+1} - x^k\|),$$

pediremos que M_{k+1} cumpla la ecuación secante

$$F(x^{k+1}) - F(x^k) = M_{k+1}(x^{k+1} - x^k).$$

Note que M_0 puede no cumplir con la ecuación secante y deberá ser un parámetro de entrada del algoritmo. Algunas opciones pueden ser $M_0 = \rho I$ o, de ser posible, $M_0 = F'(x^0)$.

Claramente si $n = 1$ existe una única matriz que satisface la ecuación secante, pero si $n > 1$ existen infinitas opciones. Dependiendo de la estructura de la matriz, mencionaremos las actualizaciones más conocidas. Para simplificar notación, usaremos $y^k = F(x^{k+1}) - F(x^k)$, $d^k = x^{k+1} - x^k$.

- **Broyden:** actualización de rango 1 para matrices generales

$$M_{k+1} = M_k + \frac{(y^k - M_k d^k)(d^k)^T}{\|d^k\|_2^2}.$$

- **PSB:** actualización Powell-Symmetric-Broyden, de rango 2 para matrices simétricas

$$M_{k+1} = M_k + \frac{(y^k - M_k d^k)(d^k)^T + d^k(y^k - M_k d^k)^T}{\|d^k\|_2^2} - \frac{(d^k)^T(y^k - M_k d^k)}{\|d^k\|_2^4} d^k (d^k)^T.$$

- **BFGS:** actualización Broyden-Fletcher-Goldfarb-Shanno, de rango 2 para matrices simétricas definidas positivas

$$M_{k+1} = M_k - \frac{M_k d^k (d^k)^T M_k}{(d^k)^T M_k d^k} + \frac{y^k (y^k)^T}{(y^k)^T d^k}.$$

Gracias a la estructura de estas matrices, el costo de calcular estas aproximaciones es significativamente menor que las anteriormente vistas. Más aún, para resolver el sistema lineal $F(x^k) + M_k d = 0$ se puede calcular la inversa utilizando la fórmula de Sherman-Morrison-Woodbury.

Proposición 8.8 Sea $A \in \mathbb{R}^{n \times n}$ invertible y $V, U \in \mathbb{R}^{n \times p}$ tales que $I + V^T A^{-1} U$ es invertible. Entonces, para $B = A + UV^T$ su inversa es

$$B^{-1} = A^{-1} - A^{-1} U (I + V^T A^{-1} U)^{-1} V^T A^{-1}.$$

Para las matrices anteriores, $I + V^T A^{-1} U$ va a ser una matriz 1×1 o 2×2 . De esta manera se pueden ir actualizando las inversas con fórmulas similares a las anteriores.

Por ejemplo, tomando $W_k = M_k^{-1}$, para la actualización de Broyden se obtiene

$$W_{k+1} = W_k + \frac{(d^k - W_k y^k)(d^k)^T W_k}{(d^k)^T W_k y^k}.$$

Un pseudocódigo utilizando esta actualización es la siguiente.

Algoritmo 37 (método de Broyden)

Entradas: $F : \mathbb{R}^n \mapsto \mathbb{R}^n$, $x^0 \in \mathbb{R}^n$, $\epsilon > 0$ y $k_{\text{máx}} \in \mathbb{N}$. *Salida:* x^+ aprox. de x^* .

Paso 0: Definir $x = x^0$, obtener $r = F(x)$, $W = I$.

Paso 1: Si $k > k_{\text{máx}}$ o $\|r\| \leq \epsilon$, retornar $x^+ = x$. Sino, definir

$$\begin{aligned} d &= -Wr, \\ x &\leftarrow x + d, \\ r^+ &= F(x), \\ y &= r^+ - r, \\ v &= Wy, \\ W &\leftarrow W + (d - v)^T (d^T W) / d^T v, \\ r &= r^+. \end{aligned}$$

Paso 2: Hacer $k \leftarrow k + 1$, e ir al paso 1.

8.1.4. Cuadrados mínimos no lineales

Considere un sistema de ecuaciones no lineales dado por $F : \mathbb{R}^n \mapsto \mathbb{R}^m$. De manera similar a lo visto para sistemas lineales el problema a resolver será

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \|F(x)\|,$$

donde $\|\cdot\|$ es una norma en $\mathbb{R}^m$.

Este tipo de problema se utiliza cuando la cantidad de incógnitas y ecuaciones no son iguales o son iguales pero la matriz Jacobiana es singular. Además, note que la convergencia de los métodos tipo Newton fue garantizada de manera local, o sea si $x^0 \in \mathcal{B}(x^*, \varepsilon)$. La técnica de globalización más común se basa en tomar $x^0 \in \mathbb{R}^n$ e ir resolviendo el problema de minimización anterior de manera que cerca de x^* la iteración generada coincida con la de un método tipo Newton.

El problema de minimizar una función no lineal general no puede resolverse con un método directo y los métodos iterativos para resolver este tipo de problemas los veremos a continuación.

Como el estudio de métodos de minimización para funciones no diferenciables está fuera del alcance de estas notas, consideraremos solamente la minimización en norma 2. Algunos métodos prácticos para minimización no diferenciable pueden verse en [1].

Considere entonces el problema de

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|F(x)\|_2^2.$$

Tomando $f(x) = \frac{1}{2} \|F(x)\|_2^2$ obtenemos que esta función es diferenciable si F es diferenciable. Además

$$\begin{aligned} f(x+h) &= \frac{1}{2} \|F(x+h)\|_2^2 \\ &= \frac{1}{2} \|F(x) + F'(x)h + o(\|h\|)\|_2^2 \\ &= \frac{1}{2} (\|F(x)\|_2^2 + 2F(x)^T F'(x)h + \|F'(x)h\|_2^2 + o(\|h\|)) \\ &= f(x) + (F'(x)^T F(x))^T h + o(\|h\|). \end{aligned}$$

Demostrando que $\nabla f(x) = F'(x)^T F(x)$. Una de las desventajas de reformular el problema de ecuaciones no lineales a minimización, es que f puede tener minimizadores locales donde F no se anule. Por ello es importante contar con la siguiente caracterización de la solución del sistema lineal en términos de puntos estacionarios de f .

Proposición 8.9 Sea $F : \mathbb{R}^n \mapsto \mathbb{R}^m$ diferenciable y $f(x) = \frac{1}{2} \|F(x)\|_2^2$. Entonces

$$F(x^*) = 0,$$

si y solo si

$$\nabla f(x^*) = 0 \text{ y existe } d \text{ t.q. } F(x^*) + F'(x^*)d = 0.$$

Demostración. Si $F(x^*) = 0$ entonces $\nabla f(x^*) = 0$ y para $d = 0$ vale que $F(x^*) + F'(x^*)d = 0$.

Supongamos ahora que $0 = \nabla f(x^*) = F'(x^*)^T F(x^*)$ y $F(x^*) + F'(x^*)d = 0$ para algún d . Luego

$$\begin{aligned} 0 &= F(x^*)^T (F(x^*) + F'(x^*)d) \\ &= \|F(x^*)\|_2^2 + (F'(x^*)^T F(x^*))^T d \\ &= \|F(x^*)\|_2^2. \end{aligned}$$

Sólo nos resta ver cómo resolver el problema de minimización. ■

8.2. Minimización no lineal

En esta sección daremos una introducción a los problemas de minimización no lineal. Considere una función $f : \mathbb{R}^n \mapsto \mathbb{R}$ diferenciable y un conjunto de restricciones $\mathcal{D} \subset \mathbb{R}^n$. Con esto, se desea hallar x^* solución de

$$\underset{x \in \mathcal{D}}{\text{minimizar}} \quad f(x). \quad (8.1)$$

Para poder analizar este problema será conveniente introducir una terminología adecuada.

Definición 8.10 Diremos que f es la función objetivo del problema 8.1.

Diremos que $\mathcal{D}$ es el conjunto factible del problema 8.1.

Diremos que $v_* \in [-\infty, +\infty]$ es el valor mínimo del problema 8.1 si $v_* = \inf_{x \in \mathcal{D}} f(x)$.

Diremos que $x^* \in \mathcal{D}$ es un

- minimizador global de 8.1 si $f(x^*) \leq f(x)$ para todo $x \in \mathcal{D}$,
- minimizador local de 8.1 si existe $\varepsilon > 0$ tal que $f(x^*) \leq f(x)$ para todo $x \in \mathcal{D} \cap \mathcal{B}(x^*, \varepsilon)$.

Claramente, si x^* es un minimizador global entonces también es un minimizador local y $v_* = f(x^*)$.

No es cierto que todo problema de minimización tiene solución, considere por ejemplo $f : \mathbb{R} \mapsto \mathbb{R}$ tal que $f(x) = \exp(x)$ con $\mathcal{D} = \mathbb{R}$. Se puede ver que $v_* = 0$, pero por más que f sea convexa no existe un minimizador del problema. El estudio de existencia de solución de problemas de minimización, tales como el Teorema de Weierstrass, no será tratado en estas notas pues nos enfocaremos en aspectos numéricos.

En la sección 7.2 de estas notas, se estudiaron métodos iterativos para minimizar una función con una estructura muy particular, donde el criterio para detener el método era la nulidad del residuo. O sea, se contaba con una condición computacionalmente verificable para determinar el hallazgo de la solución del problema.

Para obtener condiciones computacionalmente verificables para la solución del problema 8.1, se debe estudiar distintos casos dependiendo de la estructura del conjunto $\mathcal{D}$.

Dado el carácter introductorio de estas notas, solamente se estudiarán problemas de minimización sin restricciones, o sea, cuando $\mathcal{D} = \mathbb{R}^n$. Puede encontrar métodos para minimización con restricciones en [1].

Por lo tanto, se desea hallar x^* solución de

$$\underset{x \in \mathbb{R}^n}{\text{minimizar}} \quad f(x).$$

8.2.1. Condiciones de optimalidad

Veamos algunas condiciones que debe verificar x^* .

Teorema 8.11 (Condiciones necesarias de optimalidad) Suponga que x^* es un minimizador local de f en $\mathbb{R}^n$.

1. Si f es diferenciable en x^* , entonces $\nabla f(x^*) = 0$.

2. Si f es dos veces diferenciable en x^* , entonces $\nabla^2 f(x^*)$ es semidefinida positiva.

Demostración. En el ítem 1, como f es diferenciable en x^* entonces

$$f(x) = f(x^*) + \nabla f(x^*)^T(x - x^*) + o(\|x - x^*\|).$$

Tome $d \in \mathbb{R}^n$. Como x^* es minimizador local, para $t > 0$ suficientemente pequeño vale que

$$f(x^*) \leq f(x^* + td) = f(x^*) + t\nabla f(x^*)^T d + o(t).$$

Dividiendo por t y tomando límite para $t \rightarrow 0^+$, se obtiene que $0 \leq \nabla f(x^*)^T d$ para todo $d \in \mathbb{R}^n$. En particular, si $d = -\nabla f(x^*)$ obtenemos que $\|\nabla f(x^*)\|_2^2 \leq 0$.

Para demostrar el ítem 2, , como f es dos veces diferenciable en x^* entonces

$$f(x) = f(x^*) + \nabla f(x^*)^T(x - x^*) + \frac{1}{2}(x - x^*)^T \nabla^2 f(x^*)(x - x^*) + o(\|x - x^*\|^2).$$

Tome $d \in \mathbb{R}^n$. Como x^* es minimizador local, entonces $\nabla f(x^*) = 0$ y para $t > 0$ suficientemente pequeño vale que

$$f(x^*) \leq f(x^* + td) = f(x^*) + \frac{1}{2}t^2 d^T \nabla^2 f(x^*)d + o(t^2).$$

Dividiendo por $\frac{1}{2}t^2$ y tomando límite para $t \rightarrow 0^+$, se obtiene que $0 \leq d^T \nabla^2 f(x^*)d$ para todo $d \in \mathbb{R}^n$. ■

Las condiciones de los ítems 1 y 2 son conocidas como condiciones necesarias de optimalidad de primer y segundo orden. Computacionalmente podemos verificar que $\nabla f(x^*) = 0$ tomando norma y que $\nabla^2 f(x^*)$ es semidefinida positiva mediante una descomposición de Cholesky con permutaciones. Más aún, la ecuación $\nabla f(x^*) = 0$ también es conocida como condición de Fermat y con la siguiente definición.

Definición 8.12 Diremos que x^* es un punto estacionario del problema de minimizar f en $\mathbb{R}^n$ si $\nabla f(x^*) = 0$.

De esta manera, detendremos nuestro proceso iterativo cuando el gradiente de la función se anule. Lamentablemente, los maximizadores o puntos de ensilladura de f también son puntos estacionarios, con lo cual necesitamos otra condición para verificar que estamos en un minimizador.

Teorema 8.13 (Condición suficiente de optimalidad) Suponga que f es dos veces diferenciable en x^* , con $\nabla f(x^*) = 0$ y $\nabla^2 f(x^*)$ definida positiva. Entonces x^* es un minimizador local de f en $\mathbb{R}^n$. Más aún, existen $\varepsilon > 0$ y $\gamma > 0$ tales que

$$f(x) \geq f(x^*) + \frac{\gamma}{2}\|x - x^*\|^2 \quad \forall x \in \mathcal{B}(x^*, \varepsilon). \quad (8.2)$$

Demostración. Suponga que (8.2) no vale, o sea, dado $k \in \mathbb{N}$ existe $x^k \in \mathcal{B}(x^*, \frac{1}{k})$ tal que

$$f(x^k) < f(x^*) + \frac{1}{2k}\|x^k - x^*\|^2.$$

Luego,

$$\begin{aligned} \frac{1}{2k} \|x^k - x^*\|^2 &> f(x^k) - f(x^*) \\ &= \nabla f(x^*)^T (x^k - x^*) + \frac{1}{2} (x^k - x^*)^T \nabla^2 f(x^*) (x^k - x^*) + o(\|x^k - x^*\|^2) \\ &= \frac{1}{2} (x^k - x^*)^T \nabla^2 f(x^*) (x^k - x^*) + o(\|x^k - x^*\|^2). \end{aligned}$$

Defina $d^k = (x^k - x^*) / \|x^k - x^*\|$. Como $\{d^k\} \subset \mathcal{S} = \{x \in \mathbb{R}^n \mid \|x\| = 1\}$ y $\mathcal{S}$ es cerrado y acotado, entonces existe $\hat{d} \in \mathcal{S}$ y una subsucesión $\{d^{k_j}\}$ que converge a $\hat{d}$. Entonces, de la desigualdad anterior se tiene

$$\frac{1}{k_j} > (d^{k_j})^T \nabla^2 f(x^*) d^{k_j} + \frac{o(\|x^{k_j} - x^*\|^2)}{\|x^{k_j} - x^*\|^2}.$$

Como $\|x^{k_j} - x^*\| \leq 1/k_j$, tomando límite para $j \rightarrow \infty$ se deduce que $0 \geq \hat{d}^T \nabla^2 f(x^*) \hat{d}$ con $\hat{d} \neq 0$. Contradiciendo la hipótesis que $\nabla^2 f(x^*)$ es definida positiva.

Claramente, si vale (8.2) entonces x^* es un minimizador local de f en $\mathbb{R}^n$. ■

8.2.2. Método de búsqueda lineal

Ahora estamos en condiciones de presentar el esquema general de un método de búsqueda lineal: dado x^0 y $k = 0$,

1. si $\|\nabla f(x^k)\| = 0$ detener el proceso,
2. obtener una dirección d^k tal que $\nabla f(x^k)^T d^k < 0$,
3. obtener un paso $\alpha_k > 0$ tal que $f(x^k + \alpha_k d^k) < f(x^k)$,
4. definir $x^{k+1} = x^k + \alpha_k d^k$, hacer $k = k + 1$ y regresar al paso 1.

Al finalizar se debe verificar si la matriz Hessiana de f en el punto obtenido es definida positiva.

Para obtener métodos específicos deberemos detallar cómo obtener la dirección en 2 y el paso en 3.

Elección del paso en la búsqueda lineal

Luego de haber escogido una dirección d^k tal que $\nabla f(x^k)^T d^k < 0$, veamos que el paso 3 de un método de búsqueda lineal está bien definido, o sea, siempre es posible escoger $\alpha_k > 0$ tal que $f(x^k + \alpha_k d^k) < f(x^k)$.

Proposición 8.14 Sea $f : \mathbb{R}^n \mapsto \mathbb{R}$ diferenciable en x y $d \in \mathbb{R}^n$ tal que $\nabla f(x)^T d < 0$. Entonces, dado $\tau \in (0, 1)$ existe $\delta > 0$ tal que

$$f(x + \alpha d) \leq f(x) + \tau \alpha \nabla f(x)^T d,$$

para todo $\alpha \in (0, \delta]$.


Demostración. Defina $\phi(\alpha) = f(x + \alpha d)$. Entonces

$$\begin{aligned}\phi(\alpha) &= \phi(0) + \phi'(0)\alpha + o(\alpha) \\ &= \phi(0) + \tau\phi'(0)\alpha + (1 - \tau)\phi'(0)\alpha + o(\alpha) \\ &= \phi(0) + \tau\phi'(0)\alpha + \alpha \left((1 - \tau)\phi'(0) + \frac{o(\alpha)}{\alpha} \right).\end{aligned}$$

Como $\phi'(0) = \nabla f(x)^T d < 0$ y $1 - \tau > 0$, entonces para todo $\alpha > 0$ suficientemente pequeño se tiene que $\alpha \left((1 - \tau)\phi'(0) + \frac{o(\alpha)}{\alpha} \right) < 0$. Usando que $\phi(0) = f(x)$ se obtiene lo deseado. ■

Claramente, el resultado anterior nos garantiza la existencia de α_k tal que $f(x^k + \alpha_k d^k) < f(x^k)$. Veamos ahora cómo obtener α_k computacionalmente. Para ello usaremos la función auxiliar $\phi(\alpha) = f(x^k + \alpha d^k)$ y los escalares $\phi_0 = f(x^k)$ y $\phi'_0 = \nabla f(x^k)^T d^k$.

Regla de Armijo. Comenzar con $\alpha_k = 1$ e ir reduciendo su valor por un factor $\beta \in (0, 1)$ hasta que se cumpla que $\phi(\alpha_k) \leq \phi_0 + \tau\alpha_k\phi'_0$.



Algoritmo 38 (regla de Armijo)

Entradas: $f : \mathbb{R}^n \mapsto \mathbb{R}$, $x, d \in \mathbb{R}^n$, $\phi_0, \phi'_0 \in \mathbb{R}$ y $\tau, \beta \in (0, 1)$. **Salida:** $x^+ = x + \alpha d$.

Paso 0: Definir $\alpha = 1$, $x^+ = x + \alpha d$ y obtener $\phi = f(x^+)$.

Paso 1: Si $\phi \leq \phi_0 + \tau\alpha\phi'_0$, retornar x^+ .

Sino, definir


$$\begin{aligned}\alpha &\leftarrow \beta\alpha, \\ x^+ &= x + \alpha d.\end{aligned}$$

Paso 2: Obtener $\phi = f(x^+)$ e ir al paso 1.

La Proposición 8.14 nos garantiza que este procedimiento sólo puede iterar un número finito de veces. Para su implementación computacional se sugiere limitar el número de iteraciones permitidas. En la práctica, los valores más utilizados son $\beta = 0.5$ y $\tau = 10^{-4}$. Como el intervalo de pasos aceptables contiene al origen, puede ocurrir que el paso obtenido sea muy pequeño, repercutiendo de manera negativa en el avance del método. Esto puede remediarse con las siguientes reglas.

Regla de Goldstein. Dado $\tau \in (0, \frac{1}{2})$, obtener $\alpha_k \in [\alpha_l, \alpha_u]$ comenzando con $\alpha_l = 0$ y $\alpha_u = +\infty$, e ir reduciendo α_u con un factor $\beta \in (0, 1)$ o aumentando α_l con un factor $\rho > 1$ hasta que se cumpla que

$$\begin{aligned}\phi(\alpha_k) &\leq \phi_0 + \tau \alpha_k \phi'_0, \\ \phi(\alpha_k) &\geq \phi_0 + (1 - \tau) \alpha_k \phi'_0.\end{aligned}$$



Algoritmo 39 (regla de Goldstein)

Entradas: $f : \mathbb{R}^n \mapsto \mathbb{R}$, $x, d \in \mathbb{R}^n$, $\phi_0, \phi'_0 \in \mathbb{R}$, $\tau \in (0, 1/2)$, $\beta \in (0, 1)$ y $\rho > 1$. *Salida:* $x^+ = x + \alpha d$.

Paso 0: Definir $\alpha = 1$, $\alpha_l = 0$, $\alpha_u = +\infty$, $x^+ = x + \alpha d$ y obtener $\phi = f(x^+)$.

Paso 1: Si $\phi > \phi_0 + \tau \alpha \phi'_0$, hacer $\alpha_u = \alpha$ e ir al paso 3.

Paso 2: Si $\phi \geq \phi_0 + (1 - \tau) \alpha \phi'_0$, retornar x^+ .
Sino, hacer $\alpha_l = \alpha$.

Paso 3: Definir

$$\alpha = \begin{cases} \beta \alpha_l + (1 - \beta) \alpha_u, & \text{si } \alpha_u < +\infty, \\ \rho \alpha_l, & \text{si } \alpha_u = +\infty, \end{cases}$$

$$x^+ = x + \alpha d.$$

Paso 4: Obtener $\phi = f(x^+)$ e ir al paso 1.

Al igual que en la regla anterior, para su implementación computacional se sugiere limitar el número de iteraciones permitidas. En la práctica, los valores más utilizados son $\beta = 0.5$, $\rho = 2$ y $\tau = 10^{-4}$. Para su implementación se suele almacenar 0 en vez de $+\infty$ en α_u . Note que la cantidad de evaluaciones funcionales será en general mayor a la de la regla de Armijo.

Paso exacto. Tomar α_k que sea minimizador global de

$$\underset{\alpha \geq 0}{\text{minimizar}} \phi(\alpha).$$

Esta opción fue la usada para los métodos de proyección unidimensional de la Sección 7.2. Suele utilizarse si α_k puede determinarse mediante una fórmula cerrada.

Paso menguante. Se predefine una sucesión $\{\alpha_k\}$ que cumpla

$$\alpha_k \rightarrow 0^+ \quad \text{y} \quad \sum_{k=0}^{\infty} \alpha_k = +\infty.$$

Esta opción suele utilizarse cuando cada evaluación funcional es muy costosa computacionalmente, haciendo impracticables las reglas de Armijo y Goldstein.

Paso constante. Tomar en todas las iteraciones el mismo valor para α_k . Esta opción es la menos aconsejable, pues en general no podemos garantizar el descenso de la función objetivo. En algunos casos particulares, como cuando la función objetivo es cuadrática, se puede obtener un valor de paso constante que garantice la convergencia de un método de búsqueda lineal.

Elección de la dirección de la búsqueda lineal

Veamos que el paso 2 de un método de búsqueda lineal está bien definido, o sea, siempre es posible escoger una dirección d^k tal que $\nabla f(x^k)^T d^k < 0$.

Dirección de Cauchy. Conocido como el método del máximo descenso, define

$$d^k = -\nabla f(x^k).$$

En concordancia con lo visto en la Sección 7.2, esta dirección normalizada corresponde a la obtenida utilizando norma 2. El lector puede verificar que las variantes con norma 1 o norma infinito también son válidas.

Note para esta dirección vale que

$$\nabla f(x^k)^T d^k = -\|\nabla f(x^k)\|_2^2.$$

Un pseudocódigo utilizando la regla de Armijo sería el siguiente.

Algoritmo 40 (método de Cauchy para minimización)

Entradas: $f : \mathbb{R}^n \mapsto \mathbb{R}$, $x \in \mathbb{R}^n$, $\epsilon > 0$ y $k_{\text{máx}} \in \mathbb{N}$. *Salida:* x^+ aproximación de x^* .

Paso 0: Obtener $\phi = f(x)$, $r = \nabla f(x)$, definir $\sigma = \|r\|_2$ y $k = 0$.

Paso 1: Si $k > k_{\text{máx}}$ o $\sigma \leq \epsilon$, retornar $x^+ = x$.

Sino, definir

$$\begin{aligned} x & \text{ aplicando Algoritmo 38 con } \phi_0 = \phi, \phi'_0 = -\sigma^2, \\ \phi & = f(x), \\ r & = \nabla f(x), \\ \sigma & = \|r\|_2. \end{aligned}$$

Paso 2: Hacer $k \leftarrow k + 1$ e ir al paso 1.

Dirección de Newton. Proviene de definir d^k como la dirección generada por el método de Newton para la ecuación no lineal $\nabla f(x) = 0$. O sea,

$$d^k = - \left(\nabla^2 f(x^k) \right)^{-1} \nabla f(x^k).$$

Si la matriz $\nabla^2 f(x^k)$ es definida positiva, entonces $\nabla f(x^k)^T d^k < 0$. Más aún, si además existen $\mu_0 > 0$ y $\mu_1 > 0$ tales que para todo k , $\|\nabla^2 f(x^k)\|_2 \leq \mu_0$ y $\|\nabla^2 f(x^k)^{-1}\|_2 \leq \mu_1$, entonces

$$\nabla f(x^k)^T d^k \leq -\frac{1}{\mu_0^2 \mu_1} \|\nabla f(x^k)\|_2^2.$$

Un pseudocódigo utilizando descomposición de Cholesky y regla de Armijo es el siguiente.

Algoritmo 41 (método de Newton para minimización)

Entradas: $f : \mathbb{R}^n \mapsto \mathbb{R}$, $x \in \mathbb{R}^n$, $\epsilon > 0$ y $k_{\max} \in \mathbb{N}$. *Salida:* x^+ aproximación de x^* .

Paso 0: Obtener $\phi = f(x)$, $r = \nabla f(x)$, $H = \nabla^2 f(x)$ y definir $k = 0$.

Paso 1: Si $k > k_{\max}$ o $\|r\|_2 \leq \epsilon$, retornar $x^+ = x$. Sino, definir

$$\begin{aligned} d & \text{ t.q. } r + Hd = 0 \text{ aplicando el Algoritmo 7 a } (H, -r), \\ x & \text{ aplicando Algoritmo 39 con } \phi_0 = \phi, \phi'_0 = r^T d, \\ \phi & = f(x), \\ r & = \nabla f(x), \\ H & = \nabla^2 f(x). \end{aligned}$$

Paso 2: Hacer $k \leftarrow k + 1$ e ir al paso 1.

En este caso el modelo de caja negra para evaluar la función f debería permitirnos obtener $f(x)$, $\nabla f(x)$ y $\nabla^2 f(x)$.

El principal inconveniente con este método es que para funciones no convexas $\nabla^2 f(x^k)$ puede no ser definida positiva para algún x^k . Esto puede subsanarse modificando la descomposición de Cholesky (Algoritmo 6) de manera que siempre se pueda obtener el factor G . Dados $\epsilon_1 > \epsilon_0 \geq 0$, antes de dividir por $\sqrt{G_{ii}}$, la descomposición de Cholesky modificada realiza la siguiente verificación: si $G_{ii} \leq \epsilon_0$ tomar $G_{ii} = \epsilon_1$. Con esta descomposición se obtiene que $G^T G = \nabla^2 f(x^k) + E_k$ siempre es definida positiva. Como no se trabaja con la derivada exacta, éste es un método cuasi-Newton. Se suele utilizar $\epsilon_1 = 10^{-2}$ y, para no alterar matrices que son definidas positivas, $\epsilon_0 = 0$. Algunos autores utilizan $\epsilon_0 = 10^{-8}$ para evitar matrices mal condicionadas.

Dirección de Gauss-Newton. En el caso particular donde la función objetivo es

$$f(x) = \frac{1}{2} \|F(x)\|_2^2,$$

con $F : \mathbb{R}^n \mapsto \mathbb{R}^m$, se puede escoger una aproximación de $\nabla^2 f(x)$ aprovechando la estructura del problema. Como $\nabla f(x) = F'(x)^T F(x)$ y $\nabla F_i(x)$ son las filas de $F'(x)$, se

tiene que

$$\begin{aligned}
 \nabla f(x+h) &= F'(x+h)^T F(x+h) \\
 &= F'(x+h)^T (F(x) + F'(x)h + o(\|h\|)) \\
 &= F'(x)^T (F(x) + F'(x)h) + (F'(x+h) - F'(x))^T F(x) + o(\|h\|) \\
 &= \nabla f(x) + F'(x)^T F'(x)h + \sum_{i=1}^m F_i(x) (\nabla F_i(x+h) - \nabla F_i(x)) + o(\|h\|) \\
 &= \nabla f(x) + F'(x)^T F'(x)h + \sum_{i=1}^m F_i(x) \nabla^2 F_i(x)h + o(\|h\|).
 \end{aligned}$$

Demostrando que $\nabla^2 f(x) = F'(x)^T F'(x) + \sum_{i=1}^m F_i(x) \nabla^2 F_i(x)$. En este método se aproxima en cada iteración $\nabla^2 f(x^k)$ por

$$H_k = F'(x^k)^T F'(x^k).$$

Note que esta matriz es simétrica y semidefinida positiva. Cuando H_k no es definida positiva se la redefine como la matriz definida positiva $F'(x^k)^T F'(x^k) + E_k$ generada por el método de Cholesky modificado, o con $E_k = \gamma_k I$ con $\gamma_k > 0$. Este último se conoce como método de Levenberg-Marquardt.

Para su implementación numérica, se puede utilizar el método de Newton con una función f que evalúe F para obtener $F(x)$ y $F'(x)$, y retorne como valor funcional $\frac{1}{2}\|F(x)\|$, como gradiente $F'(x)^T F(x)$ y como Hessiana $F'(x)^T F'(x)$.

Dirección BFGS. Proviene de definir d^k como la dirección generada por el método cuasi-Newton secante con actualización BFGS para la ecuación no lineal $\nabla f(x) = 0$. O sea,

$$d^k = -H_k^{-1} \nabla f(x^k),$$

con H_0 simétrica definida positiva y donde, para $y^k = \nabla f(x^{k+1}) - \nabla f(x^k)$ y $v^k = x^{k+1} - x^k$,

$$H_{k+1} = H_k - \frac{H_k v^k (v^k)^T H_k}{(v^k)^T H_k v^k} + \frac{y^k (y^k)^T}{(y^k)^T v^k}.$$

En esta caso siempre obtendremos que $\nabla f(x^k)^T d^k < 0$. Como en el caso del método de Newton, si existen $\mu_0 > 0$ y $\mu_1 > 0$ tales que $\|M_k\|_2 \leq \mu_0$ y $\|M_k^{-1}\|_2 \leq \mu_1$ para todo k , entonces

$$\nabla f(x^k)^T d^k \leq -\frac{1}{\mu_0^2 \mu_1} \|\nabla f(x^k)\|_2^2.$$

Para su implementación, tomando $W_k = H_k^{-1}$ y la fórmula de inversión de Sherman-Morrison-Woodbury, se obtiene

$$W_{k+1} = W_k + \frac{v^k (v^k)^T}{(y^k)^T v^k} - \frac{W_k y^k (y^k)^T W_k}{\tau_k} + \tau_k p^k (p^k)^T,$$

donde $p^k = \frac{v^k}{(y^k)^T v^k} - \frac{W_k y^k}{\tau_k}$ y $\tau_k = (y^k)^T W_k y^k$. Con esto se obtiene el siguiente pseudo-código.

Algoritmo 42 (método BFGS para minimización)

Entradas: $f : \mathbb{R}^n \mapsto \mathbb{R}$, $x \in \mathbb{R}^n$, $\epsilon > 0$ y $k_{\max} \in \mathbb{N}$. *Salida:* x^+ aproximación de x^* .

Paso 0: Obtener $\phi = f(x)$, $r = \nabla f(x)$ y definir $W = I$, $x^+ = x$ y $k = 0$.

Paso 1: Si $k > k_{\max}$ o $\|r\|_2 \leq \epsilon$, retornar x^+ . Sino, definir

$$\begin{aligned}
 d &= -Wr, \\
 x^+ &\text{ aplicando Algoritmo 38 con } \phi_0 = \phi, \phi'_0 = r^T d, \\
 \phi &= f(x^+), \\
 r^+ &= \nabla f(x^+), \\
 y &= r^+ - r, \\
 v &= x^+ - x, \\
 w &= Wy, \\
 \gamma &= y^T v, \\
 \tau &= y^T w, \\
 p &= v/\gamma - w/\tau, \\
 W &= W + vv^T/\gamma - ww^T/\tau + \tau pp^T, \\
 x &= x^+, \\
 r &= r^+.
 \end{aligned}$$

Paso 2: Hacer $k \leftarrow k + 1$ e ir al paso 1.

Convergencia del método de búsqueda lineal

Cuando se desea minimizar una función en $\mathbb{R}^n$, realizar búsquedas a lo largo de direcciones puede no ser suficiente para garantizar que se ha encontrado un minimizador. Veamos un caso donde esto ocurre.

Ejemplo 8.15 Considere la función $f : \mathbb{R}^2 \mapsto \mathbb{R}$ tal que

$$f(x_1, x_2) = (x_2 - px_1^2)(x_2 - qx_1^2),$$

donde $0 < p < q$.

Veamos que $x^* = (0, 0)$ es un mínimo local de f a lo largo de toda recta que pasa por x^* , o sea, $g(\alpha) = f(x^* + \alpha d)$ tiene en $\alpha = 0$ un mínimo local para toda $d \in \mathbb{R}^2$. Tome $\alpha \neq 0$ y $d \neq (0, 0)$, como

$$g(\alpha) = \alpha^2(d_2 - \alpha p d_1^2)(d_2 - \alpha q d_1^2),$$

si $d_2 \neq 0$ entonces $g(\alpha)/\alpha^2 \rightarrow d_2^2 > 0$ cuando $\alpha \rightarrow 0$. Por lo tanto $g(\alpha) \geq \alpha^2 d_2^2/2 > 0$ para $\alpha \neq 0$ próximo a cero. Si $d_2 = 0$ entonces $g(\alpha) = \alpha^4 p q d_1^4 > 0$ para $\alpha \neq 0$. Por lo tanto, para α no nulo suficientemente pequeño, vale

$$f(x^*) = g(0) = 0 < g(\alpha) = f(x^* + \alpha d).$$

Note que esto no garantiza que x^* es un mínimo local de f en $\mathbb{R}^2$. Tomando $\gamma(\alpha) = (\alpha, m\alpha^2)$ con $p < m < q$ vale que $\gamma(\alpha) \rightarrow x^*$ si $\alpha \rightarrow 0$, pero para $\alpha \neq 0$

$$f(\gamma(\alpha)) = \alpha^4(m - p)(m - q) < 0 = f(x^*).$$

Por otro lado, en pocos casos se podrá garantizar que la sucesión generada $\{x^k\}$ es convergente, pero veremos que al menos una subsucesión lo hace.

Teorema 8.16 Sea f continuamente diferenciable y suponga que $\{x^k\}$ es generada por un método de búsqueda lineal donde $x^{k+1} = x^k + \alpha_k d^k$ con

$$\nabla f(x^k)^T d^k \leq -\gamma \|\nabla f(x^k)\|^q,$$

para $\gamma, q > 0$, y α_k obtenido por la regla de Armijo. Entonces todo punto límite de $\{x^k\}$ es un punto estacionario del problema de minimizar f en $\mathbb{R}$.

Demostración. Si $\nabla f(x^k) = 0$ entonces x^k es un punto estacionario. Suponga que $\nabla f(x^k) \neq 0$ para todo k . Sea x^* un punto límite de $\{x^k\}$, o sea, existe una subsucesión $\{x^{k_j}\}$ tal que $x^{k_j} \rightarrow x^*$.

Como $f(x^{k+1}) < f(x^k)$ para todo k , entonces la sucesión $\{f(x^k)\}$ es monótona decreciente y vale que $\lim_{j \rightarrow \infty} f(x^{k_j}) = f(x^*)$. Por lo tanto $\lim_{k \rightarrow \infty} f(x^k) = f(x^*)$.

Por la regla de Armijo, se tiene que

$$f(x^k) - f(x^{k+1}) \geq -\tau \alpha_k \nabla f(x^k)^T d^k \geq \tau \gamma \alpha_k \|\nabla f(x^k)\|^q.$$

Luego,

$$\tau \gamma \sum_{k=0}^{\infty} \alpha_k \|\nabla f(x^k)\|^q \leq \sum_{k=0}^{\infty} f(x^k) - f(x^{k+1}) = f(x^0) - f(x^*) < +\infty.$$

Como la serie es convergente, se obtiene que $\alpha_k \|\nabla f(x^k)\|^q \rightarrow 0$.

Si $\alpha_{k_j} \geq \bar{\alpha} > 0$ para todo j , entonces

$$\bar{\alpha} \|\nabla f(x^*)\|^q \leq \lim_{j \rightarrow \infty} \alpha_{k_j} \|\nabla f(x^{k_j})\|^q = 0.$$

Obteniendo que x^* es un punto estacionario.

Sino, tomando una subsucesión si fuera necesario, se tiene que $\alpha_{k_j} \rightarrow 0$. Sea $\tilde{\alpha}_{k_j} = \alpha_{k_j} / \beta$ el paso antes de la última reducción en la regla de Armijo. Entonces

$$f(x^{k_j} + \tilde{\alpha}_{k_j} d^{k_j}) > f(x^{k_j}) + \tau \tilde{\alpha}_{k_j} \nabla f(x^{k_j})^T d^{k_j}.$$

Como

$$f(x^{k_j} + \tilde{\alpha}_{k_j} d^{k_j}) = f(x^{k_j}) + \tilde{\alpha}_{k_j} \nabla f(x^{k_j})^T d^{k_j} + o(\tilde{\alpha}_{k_j}),$$

se tiene que

$$0 < (1 - \tau) \nabla f(x^{k_j})^T d^{k_j} + \frac{o(\tilde{\alpha}_{k_j})}{\tilde{\alpha}_{k_j}} \leq -(1 - \tau) \gamma \|\nabla f(x^{k_j})\|^q + \frac{o(\tilde{\alpha}_{k_j})}{\tilde{\alpha}_{k_j}}.$$

Como $\tilde{\alpha}_{k_j} \rightarrow 0$, tomando límite se obtiene que $0 \leq -(1 - \tau) \gamma \|\nabla f(x^*)\|^q$. Concluyendo que x^* es un punto estacionario. ■

8.3. Ejercicios

1. Sea $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ diferenciable en $\bar{x}$ con $F(\bar{x}) = 0$ y derivada $F'(\bar{x})$ invertible. Demuestre que existen $\varepsilon > 0$ y $c > 0$ tales que

$$\|x - \bar{x}\|_2 \leq c\|F(x)\|_2, \quad \forall x \in B(\bar{x}, \varepsilon).$$

2. Determine si puede o no existir una función $f : \mathbb{R} \rightarrow \mathbb{R}$ diferenciable que tenga un único punto estacionario que sea minimizador local pero no minimizador global de f en $\mathbb{R}$.
3. Sean $n \geq 2$ y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ definida por

$$f(x) = (1 - x_n)^3 \sum_{i=1}^{n-1} x_i^2 + x_n^2.$$

Demuestre que $\bar{x} = 0$ es el único punto estacionario de f en $\mathbb{R}^n$, que es un minimizador local estricto de f y que no es un minimizador global de f en $\mathbb{R}^n$.

4. Sea $W \in \mathbb{R}^{n \times n}$ simétrica definida positiva, $\xi \in [0, 1]$ y para $p, q \in \mathbb{R}^n$ defina

$$W_+ = W + \frac{pp^T}{p^T q} - \frac{Wq q^T W}{\tau} + \xi \tau v v^T \quad \text{donde } v = \frac{p}{p^T q} - \frac{Wq}{\tau}, \quad \tau = q^T W q.$$

Demuestre que W_+ es simétrica y que W_+ es definida positiva si y solo si $p^T q > 0$.

5. Un productor cosecha x_i toneladas de maní, almacena $(1 - u_i)x_i$ toneladas de su producción e invierte $u_i x_i$. Con esto la producción de la próxima cosecha será $x_{i+1} = x_i + \omega u_i x_i$ con $\omega > 0$. Encuentre una estrategia óptima $u_0, \dots, u_{N-1}$ que maximice lo almacenado a lo largo de N cosechas penalizando el no cumplimiento de $u_i \in [0, 1]$ mediante la función $\psi(t) = \rho(\min\{t, \max\{0, t - 1\}\})^4$. O sea, se debe maximizar

$$x_N + \sum_{i=0}^{N-1} (1 - u_i)x_i - \sum_{i=0}^{N-1} \psi(u_i).$$

Escriba la anterior como función de $u_0, \dots, u_{N-1}$ y calcule su gradiente y Hessiana

Bibliografía

- [1] Joseph-Frédéric Bonnans, Jean Charles Gilbert, Claude Lemaréchal, and Claudia A Sagastizábal. *Numerical optimization: theoretical and practical aspects*. Springer Science & Business Media, 2006. 8.1.4, 8.2
- [2] Gene H. Golub and Charles F. Van Loan. *Matrix computations*. Johns Hopkins Studies in the Mathematical Sciences. Johns Hopkins University Press, Baltimore, MD, third edition, 1996. 4.1.1, 4.1.2, 4.1.5, 5.3, 6.3, 6.3
- [3] Yousef Saad. *Iterative methods for sparse linear systems*. Society for Industrial and Applied Mathematics, Philadelphia, PA, second edition, 2003. 7.2.2
- [4] J. Stoer and R. Bulirsch. *Introduction to numerical analysis*, volume 12 of *Texts in Applied Mathematics*. Springer-Verlag, New York, second edition, 1993. 4.2, 7.1
- [5] David S. Watkins. *Fundamentals of matrix computations*. Pure and Applied Mathematics (New York). Wiley-Interscience [John Wiley & Sons], New York, second edition, 2002. 6.3